

Dobývání znalostí

Učební text k okruhu státní závěrečné zkoušky

SZZ Umělá inteligence, MFF UK

srpen 2026

Text pokrývá okruh *Dobývání znalostí* magisterské SZZ oboru Umělá inteligence. Kapitoly odpovídají **jedna ku jedné** větám oficiálního znění okruhu (viz mapovací tabulka níže). Vychází ze slidů přednášek **NDBI023 Dobývání znalostí** a **NAIL116 Sociální sítě a jejich analýza** (I. Mrázová, MFF UK) a je doplněn o standardní látku z učebnic Han, Kamber, Pei: *Data Mining — Concepts and Techniques*, Tan, Steinbach, Kumar: *Introduction to Data Mining*, Aggarwal: *Data Mining — The Textbook* a pro sítě Easley, Kleinberg: *Networks, Crowds and Markets*, Newman: *Networks* a Zafarani, Abbasi, Liu: *Social Media Mining*. Obsahuje definice, pseudokódy, odvození, číselné příklady a srovnávací tabulky; každá kapitola končí shrnutím pro ústní zkoušku.

Rozsah textu a značení

Rozsah kapitol odpovídá váze látky: nejvíce prostoru dostávají metody dobývání znalostí (kap. 3) a analýza sociálních sítí (kap. 6) — tedy to, čemu se obě přednášky věnují nejpodrobněji a co okruh jmenuje nejkonkrétněji.

Značkou [♦ nad rámec slidů] je označena látka, která **není ve slidech** ani jednoho z obou kurzů (slidy jsou k dispozici kompletní), ale je v textu ponechána — buď proto, že ji *jmenuje oficiální znění okruhu*, nebo proto, že bez ní nedává okolní výklad smysl. Slouží jako nabídka ke škrtnutí: co označeno není, je ve slidech doloženo. Následuje-li za značkou dvojtečka, upřesňuje, čeho přesně se výhrada týká — typicky že souhrnná tabulka nebo rámec jsou moje, ale jednotlivé položky v nich ze slidů pocházejí.

Slidy pokrývají: analýzu dat a shlukování, asociační pravidla, rozhodovací stromy a ensembly, SVM s vyhodnocováním klasifikátorů, bayesovské modely a ELM (NDBI023); základní pojmy, modelování vlivu, homofilii a afiliaci, analýzu vazeb a komplexní sítě s detekcí komunit a predikcí vazeb (NAIL116). Nejnápadnější mezera je **proces KDD a metodologie** (kap. 1). Kapitola o **charakteristických a diskriminačních pravidlech** (kap. 4) je postavena především na slidech kurzu *Internet a klasifikační metody* (Holeňa, přednášky i_{km}1–i_{km}6, zejména i_{km}5); podle Han–Kamber v ní zůstává jen vymezení obou druhů pravidel s mírami t-weight/d-weight. Slidy n_{mr}1–n_{mr}5 z téže složky patří jinému kurzu a látku kapitoly nepokrývají (viz poznámka na jejím začátku).

Mapování okruhu na kapitoly

Věta oficiálního znění okruhu	Kapitola v tomto textu
Základní paradigmaty dobývání znalostí.	1 Základní paradigmaty dobývání znalostí
Příprava dat; výběr atributů a metody pro analýzu jejich relevance.	2 Příprava dat, výběr atributů a analýza jejich relevance
Metody pro dobývání znalostí; asociační pravidla, přístupy založené na principu učení s učitelem a klastrová analýza.	3 Metody pro dobývání znalostí (3.1 asociační pravidla, 3.2–3.3 učení s učitelem, 3.4 klastrová analýza)
Metody pro extrakci charakteristických diskriminačních pravidel a měření jejich zajímavosti.	4 Charakteristická a diskriminační pravidla a jejich zajímavost
Reprezentace, vyhodnocování a vizualizace získaných znalostí.	5 Reprezentace, vyhodnocování a vizualizace znalostí
Modely pro analýzu sociálních sítí; míry centrality, detekce komunit.	6 Modely pro analýzu sociálních sítí, centralita a detekce komunit
Praktické využití technik pro dobývání znalostí a analýzu sociálních sítí.	7 Praktické využití technik

Poznámka k terminologii. Text používá české termíny; anglický ekvivalent je uveden kurzívou v závorce při prvním výskytu, protože obě přednášky i celá literatura jsou anglicky.

Obsah

Mapování okruhu na kapitoly	2
1 Základní paradigmaty dobývání znalostí	5
1.1 Motivace a vymezení oboru	5
1.2 Proces KDD	5
1.3 Typy úloh dobývání znalostí	6
1.4 Typy dat	7
1.5 Metodologie dobývání znalostí	7
1.6 Shrnutí ke zkoušce	8
2 Příprava dat, výběr atributů a analýza jejich relevance	9
2.1 Proč je příprava dat klíčová	9
2.2 Čištění dat: chybějící hodnoty	9
2.3 Čištění dat: šum a odlehlé hodnoty	9
2.4 Integrace dat	10
2.5 Transformace a standardizace atributů	10
2.6 Diskretizace numerických atributů	11
2.6.1 Fuzzy diskretizace	11
2.6.2 Seskupování hodnot kategoriálních atributů (KEX)	11
2.7 Redukce dat	12
2.7.1 Příliš mnoho objektů	12
2.7.2 Příliš mnoho atributů	12
2.8 Analýza relevance atributů: filtry a wrappery	12
2.8.1 Kritéria na kontingenčních tabulkách	13
2.8.2 Kritéria založená na entropii	14
2.9 Vztahy mezi atributy: regrese a korelace	14
2.10 Shrnutí ke zkoušce	15
3 Metody pro dobývání znalostí	17
3.1 Asociační pravidla a frekventované vzory	17
3.1.1 Analýza nákupního košíku	17

3.1.2	Support, confidence a lift	17
3.1.3	Volba položek, taxonomie a virtuální položky	18
3.1.4	Algoritmus Apriori	18
3.1.5	Vícenásobný minimální support: MS-Apriori	19
3.1.6	Třídní asociační pravidla (CAR)	21
3.1.7	Dolování sekvenčních vzorů	21
3.1.8	FP-Growth a FP-strom	22
3.2	Přístupy založené na principu učení s učitelem	23
3.2.1	Formulace úlohy	23
3.2.2	Rozhodovací stromy	23
3.2.3	Bayesovská klasifikace	28
3.2.4	Support Vector Machines	28
3.2.5	Logistická regrese	30
3.2.6	Diskriminační analýza	31
3.2.7	Neuronové sítě a extrémní učicí stroje (ELM)	31
3.2.8	Ensemble metody	32
3.2.9	Srovnání klasifikačních metod	34
3.3	Klastrová analýza	34
3.3.1	Formulace úlohy a míry vzdálenosti	34
3.3.2	Metoda k -means	35
3.3.3	Metoda k -medoids, CLARA a CLARANS	36
3.3.4	Hierarchické shlukování	36
3.3.5	Vektorová kvantizace: algoritmus LVQ	37
3.3.6	Mřížkové a hustotní metody	37
3.4	Shrnutí ke zkoušce	38
4	Charakteristická a diskriminační pravidla a jejich zajímavost	41
4.1	Pravidla jako srozumitelná forma klasifikace	41
4.2	Charakteristická a diskriminační pravidla: t-weight a d-weight	41
4.3	Extrakce pravidel z klasifikačních stromů	42
4.4	Evoluční konstrukce pravidel	43
4.5	Observační pravidla: confidence, podpora a testy hypotéz	43
4.6	Statistický pohled: regresní a diskriminační analýza	44
4.7	Měření zajímavosti pravidel	44
4.8	Aplikace: spam, malware a síťové hrozby, doporučování	45
4.9	Shrnutí ke zkoušce	45
5	Reprezentace, vyhodnocování a vizualizace znalostí	47
5.1	Formy reprezentace znalostí	47
5.2	Vyhodnocování modelů	47
5.2.1	Kritéria hodnocení klasifikačních metod	47
5.2.2	Metody odhadu chyby	48
5.2.3	Matice záměn a odvozené míry	48
5.2.4	Skórování, řazení a lift analýza	49
5.2.5	ROC křivka a AUC	49
5.3	Vizualizační techniky	50
5.4	Vyhodnocení znalostí z pohledu uživatele	51
5.5	Shrnutí ke zkoušce	51
6	Modely pro analýzu sociálních sítí, centralita a detekce komunit	52
6.1	Vymezení oboru a motivace	52
6.2	Reprezentace sítí	52
6.3	Síla vazeb	53

6.4	Klíčoví hráči: míry centrality	54
6.5	Koheze: míry na úrovni sítě	55
6.6	Model reálných komplexních sítí a jejich vlastnosti	56
6.7	Modelování vlivu	57
6.8	Vliv versus korelace	58
6.9	Homofilie, výběr a sociální vliv	58
6.10	Afiliční sítě a uzávěrové procesy	59
6.11	Schellingův model segregace	60
6.12	Pozitivní a negativní vztahy: strukturní balance	61
6.13	Analýza vazeb: huby, autority a algoritmus HITS	62
6.14	PageRank	64
6.15	Tematické komunity a jejich objevování	66
6.16	Detekce komunit	67
6.16.1	Taxonomie metod detekce komunit	69
6.17	Predikce vazeb	71
6.18	Shrnutí ke zkoušce	72
7	Praktické využití technik	75
7.1	Dobývání znalostí	75
7.2	Analýza sociálních sítí	76
7.3	Provozní a etické aspekty nasazení	76
7.4	Shrnutí ke zkoušce	77

1 Základní paradigmatata dobývání znalostí

Kapitola vymezuje obor, jeho proces a základní dělení úloh a dat — rámec, do něhož se zasazují všechny ostatní kapitoly.

1.1 Motivace a vymezení oboru

Organizace shromažďují data v objemech, které daleko přesahují kapacitu člověka je prohlédnout. Klasické dotazování (SQL, OLAP) umí odpovědět na otázku, kterou už umíme položit; *dobývání znalostí* odpovídá na otázky, které jsme položili neuměli — hledá v datech struktury, o jejichž existenci jsme předem nevěděli.

Ilustrativní příklad: systém prošel 20 milionů výkonů účtovaných zdravotní pojišťovně, 214 tisíc z nich označil za podivné a 14 tisíc nejpodězřelejších předal k ruční kontrole. Revizní lékaři, kteří jsou schopni prohlédnout řádově stovky případů, z předložených případů okamžitě označili 8 tisíc za podvodné. Stroj tu nenahradil experta — *zaostřil* jeho pozornost.

Dobývání znalostí z databází

Dobývání znalostí z databází (*Knowledge Discovery in Databases*, KDD) je netriviální proces získávání implicitních, dosud neznámých a potenciálně užitečných informací z dat.

Klíčová jsou všechna čtyři slova:

- **netriviální** — nejde o prostý dotaz ani agregaci;
- **implicitní** — znalost v datech není explicitně zapsána;
- **dosud neznámá** — výsledek, který každý zná, je bezcenný;
- **potenciálně užitečná** — musí vést k akci nebo rozhodnutí.

Termín *dobývání dat* (*data mining*, DM) se v úzkém pojetí vztahuje pouze k jednomu kroku procesu KDD (vlastní aplikaci analytických algoritmů), v běžné praxi se však oba pojmy používají zaměnitelně. Obor se konstituoval v 90. letech 20. století na průsečíku tří disciplín:

- **umělá inteligence** — zejména metody strojového učení (indukce pravidel, stromy, neuronové sítě);
- **databázové systémy** — ukládání a efektivní přístup k velkým datovým souborům, datové sklady, vyhledávání informací;
- **statistika** — modelování a analýza závislostí nalezených v datech, testování hypotéz.

Čtvrtou — a v praxi rozhodující — složkou je nutnost využít zpracovaná data k podpoře (strategického) rozhodování v podniku. Bez ní se dobývání znalostí redukuje na akademické cvičení.

Vztah k datovým skladům a OLAP. [♦ nad rámec slidů] Typickým zdrojem dat pro KDD je *datový sklad* (*data warehouse*) — integrovaná, subjektivě orientovaná, časově variantní a stálá databáze konsolidovaná z provozních systémů. Data se v něm organizují do *datové kostky*: *dimenze* (čas, produkt, region, ...) $\times$ *míry* (tržby, počty kusů); v relační implementaci jde o *hvězdicové schéma* (tabulka faktů obklopená tabulkami dimenzí), fyzicky MOLAP (multidimenzionální uložení) nebo ROLAP (relační). **OLAP** (*On-Line Analytical Processing*) nad kostkou umožňuje agregační operace *roll-up* / *drill-down* a řezy *slice* & *dice* — odpovídá ale jen na otázky, které si analytik umí *předem položit*. Dobývání znalostí jde o krok dál: hledá vzory, o nichž předem nevíme, že v datech jsou. Souvislost generalizace v OLAP s indukci orientovanou na atributy viz kap. 4.

1.2 Proces KDD

[♦ nad rámec slidů: pětifázový rámec jako celek; náplň jednotlivých fází ve slidech je] Dobývání znalostí je **interaktivní a iterativní** proces: výsledky jednoho kroku běžně vedou k návratu ke krokům předchozím. Klasické schéma (Fayyad et al.) má pět fází:

Fáze	Vstup → výstup	Náplň
Výběr (<i>selection</i>)	původní data → vybraná data	výběr relevantních záznamů a atributů z datového skladu
Předzpracování (<i>pre-processing</i>)	vybraná data → předzpracovaná data	čištění, chybějící hodnoty, šum, odlehlé hodnoty, integrace zdrojů
Transformace (<i>transformation</i>)	předzpracovaná data → transformovaná data	normalizace, diskretizace, odvozené atributy, redukce dimenze
Vlastní dobývání (<i>data mining</i>)	transformovaná data → vzory	aplikace algoritmů (stromy, asociace, klastry, ...)
Interpretace (<i>interpretation</i>)	vzory → znalost	vyhodnocení z pohledu koncového uživatele, vizualizace, nasazení

Cílem prvních tří fází (souhrnně *příprava dat*, kap. 2) je z dat uložených ve složité struktuře vybudovat **jednu tabulku** obsahující relevantní údaje o zkoumaných objektech (klientech banky, zákaznících, ...). Tento krok typicky spotřebuje 60–80 % celkového času projektu.

Sedm kroků očima manažera. [♦ nad rámec slidů] Organizační pohled na tentýž proces (impuls = problém, výstup = znalost k jeho řešení): (1) *tým* — experti na oblast, na data a na metody KDD, žádná role není zastupitelná; (2) *specifikace problému* — převod obchodního zadání („zvýšit zisk“ → „predikovat odchod zákazníka“); (3) *sběr dat* včetně externích o prostředí (sezóna, kampaně, počasí) — může vést k přeformulování problému; (4) *volba metod* včetně vizualizačních; (5) *předzpracování*; (6) *dolování* — opakovaně, výsledky ovlivňují parametry dalších běhů; (7) *interpretace* — analytická zpráva, případně akce.

1.3 Typy úloh dobývání znalostí

[♦ nad rámec slidů] Podle vztahu nalezené znalosti k cílovému konceptu:

Typ úlohy	Cíl	Charakter výsledku
Klasifikace / predikce	zařadit nové případy, resp. odhadnout budoucí vývoj entity	preferujeme <i>přesnost pokrytí</i> před jednoduchostí; hodně znalosti, obtížně interpretovatelné
Popis (charakterizace, profil)	najít dominantní strukturu či vztahy v datech	požadujeme <i>srozumitelnost</i> při plném pokrytí konceptu; méně znalosti a méně přesné
Hledání „nugetů“	najít zajímavou (novou, překvapivou) znalost	znalost <i>nemusí</i> pokrývat celý koncept; hodnotí se překvapivost

Predikce: počasí, cena akcií, spotřeba elektřiny. *Popis*: profil bonitního klienta. *Nuget*: neobvyklá kombinace zboží v košíku, podezřelý vzorec transakcí.

Deskriptivní vs. prediktivní úlohy

Deskriptivní (*descriptive*) úlohy charakterizují obecné vlastnosti dat: charakterizace a diskriminace, asociační a korelační analýza, shlukování, detekce odlehlých hodnot, analýza vývoje.

Prediktivní (*predictive*) úlohy provádějí inferenci nad daty za účelem predikce: klasifikace (diskrétní cílový atribut), regrese (spojitý cílový atribut), predikce časových řad.

Ortogonální dělení podle dostupnosti cílové proměnné: *učení s učitelem* (*supervised*) — klasifikace, regrese; *učení bez učitele* (*unsupervised*) — shlukování, asociační pravidla, detekce odlehlých hodnot; *poloučené* (*semi-supervised*) — malá označovaná a velká neoznačovaná část.

Toto dělení je klíčem ke kap. 3: okruh v ní jmenuje po jednom reprezentantu učení bez učitele nad transakčními daty (asociační pravidla), učení s učitelem a učení bez učitele nad metrickými daty (klastrová analýza).

1.4 Typy dat

Podle typu atributu — určuje, jaké operace jsou smysluplné a jaké metody lze použít:

Škála	Operace	Příklad	Statistika
Nominální (<i>nominal</i>)	$=, \neq$	barva, druh ovoce	modus, četnosti
Ordinální (<i>ordinal</i>)	$=, <$	známka, {nízký, střední, vysoký}	medián, kvantily
Intervalová (<i>interval-scaled</i>)	$+, -$	teplota ve °C, datum	průměr, směr. odchylka
Poměrová (<i>ratio-scaled</i>)	$\times, /$	příjem, hmotnost, četnost	geometrický průměr

U intervalové škály mají intervaly v celém rozsahu stejnou důležitost (rozdíl věku 10 a 20 let je týž jako mezi 40 a 50). Poměrová má navíc absolutní nulu, takže má smysl poměr; poměrové atributy s exponenciálním chováním (počet mikroorganismů Ae^{Bt}) se logaritmují a dále se s nimi zachází jako s intervalovými. Nominální atribut o v hodnotách se pro numerické metody převede na v binárních; ordinální se zpracovává jako intervalový.

Podle struktury datového souboru:

- **Tabulková / relační data** — objekty $\times$ atributy; standardní vstup většiny metod.
- **Transakční data** — proměnná délka záznamu (nákupní košík); vstup asociačních pravidel.
- **Temporální data** (*temporal*) — např. časové řady kurzů akcií. Typickou úlohou je predikce budoucích hodnot; řada se transformuje do tabulky posuvným oknem: vstupy $y(t_0), y(t_1), y(t_2), y(t_3) \rightarrow$ výstup $y(t_4); y(t_1), \dots, y(t_4) \rightarrow y(t_5)$ atd.
- **Prostorová data** (*spatial*) — geografické informační systémy; implicitní relace sousedství (hodnoty atributů sousedních objektů se od sebe příliš neliší), užitečné zejména pro interpretaci.
- **Strukturní data** (*structural*) — např. chemické sloučeniny zapsané řetězcí SMILES nebo soubory faktů v Prologu; úlohou je třeba klasifikace látek podle struktury.
- **Textová a webová data, multimédia, grafy a sítě** — vyžadují specifickou reprezentaci (vektorový model, grafové modely, viz kap. 6).

1.5 Metodologie dobývání znalostí

[♦ nad rámec slidů] Metodologie poskytuje jednotný rámec nezávislý na oboru podnikání a umožňuje přenos zkušeností z úspěšných projektů. Vznikají u výrobců BI nástrojů (SEMMA od SAS, 5A od SPSS), nebo jako softwarově neutrální standardy (CRISP-DM).

SEMMA (SAS Enterprise Miner), pět fází: *Sample* — výběr dat (vzorkování, imputace, rozdělení na trénovací/testovací/validační množinu); *Explore* — vizuální průzkum a redukce (odlehle hodnoty, vícerozměrné histogramy, shlukování, Kohonenovy mapy); *Modify* — příprava objektů, hodnot a proměnných; *Model* — aplikace metod (stromy, regrese, neuronové sítě); *Assess* — vyhodnocení spolehlivosti a užitečnosti.

CRISP-DM (*C*Ross-*I*ndustry *S*tandard *P*rocess for *D*ata *M*ining) — otevřený, oborově, nástrojově i aplikačně neutrální model; financovala iniciativa ESPRIT, konsorcium ISL (později SPSS, dnes IBM), Teradata, NCR, Daimler AG a OHRA. Šest fází, jejichž **pořadí není striktní** — výsledky jedné fáze určují další kroky a některé je nutné opakovat (proces se kreslí jako cyklus s vnějším cyklem nasazení a monitoringu):

1. **Porozumění problému** (*Business Understanding*) — obchodní cíle a kritéria úspěchu; inventura zdrojů (lidé, informace, software, kapacita), předpoklady a omezení, rizika, náklady a přínosy; cíle dobývání znalostí; plán projektu.
2. **Porozumění datům** (*Data Understanding*) — sběr, popis (množství, vlastnosti, formát), průzkum a vizualizace (rozdělení atributů, vztahy dvojic, subpopulace, statistiky), ověření kvality.
3. **Příprava dat** (*Data Preparation*) — výběr, čištění, odvozené atributy, integrace, agregace, formátování; iterativně a v různém pořadí.

4. **Modelování** (*Modeling*) — volba techniky (její předpoklady mohou vynutit další úpravy dat), návrh testu, sestavení modelu s různými parametry, posouzení.
5. **Vyhodnocení** (*Evaluation*) — výsledky vůči *obchodním* kritériím úspěchu, schválení modelů, revize procesu, další kroky.
6. **Nasazení** (*Deployment*) — prezentace ve formě nasaditelné uživatelem; plán nasazení, monitoring a údržba; závěrečná zpráva a revize projektu (včetně slepých uliček).

ASUM-DM (IBM, 2015) reaguje na hlavní výtoku vůči CRISP-DM — malou podporu projektového řízení. Fáze *Analyze, Design, Configure & Build, Deploy, Operate & Optimize*, průřezově *Project Management*.

	SEMMA	CRISP-DM	ASUM-DM
Původ	SAS Institute	ESPRIT / konsorcium	IBM (2015)
Neutralita	vázáno na SAS EM	nástrojově neutrální	vázáno na IBM
Byznys fáze	chybí	ano (fáze 1 a 5)	ano
Projektové řízení	ne	slabé	explicitní, průřezové
Počet fází	5	6	5 + PM

1.6 Shrnutí ke zkoušce

- **KDD** = netriviální proces získávání implicitních, dosud neznámých a potenciálně užitečných informací z dat; interaktivní a iterativní.
- **Pět fází KDD**: výběr → předzpracování → transformace → dobývání → interpretace. Příprava dat spotřebuje 60–80 % času.
- **Kořeny oboru**: umělá inteligence (strojové učení), databáze, statistika + potřeba podpory rozhodování. **OLAP** odpovídá na předem položené otázky, KDD hledá vzory, o nichž nevíme.
- **Tři typy úloh**: klasifikace/predikce (přesnost > jednoduchost), popis (srozumitelnost, plné pokrytí), hledání nugetů (překvapivost, nemusí pokrývat).
- **Deskriptivní vs. prediktivní úlohy; s učitelem vs. bez učitele vs. poloučené.**
- **Škály atributů**: nominální, ordinální, intervalová, poměrová — určují přípustné operace i metody. Nominální → v binárních atributů; poměrový s exponenciálním chováním → logaritmovat.
- **Metodologie**: SEMMA (Sample, Explore, Modify, Model, Assess), CRISP-DM (6 fází, pořadí není striktní, cyklické), ASUM-DM (CRISP-DM + projektové řízení).
- Nejčastější doplňující otázka: *proč pořadí fází CRISP-DM není striktní?* — protože výsledky fáze určují další kroky; např. zjištěná kvalita dat vede zpět k přeformulování cíle.

2 Příprava dat, výběr atributů a analýza jejich relevance

Okruh spojuje *přípravu dat* (aby byla data vůbec zpracovatelná) a *výběr atributů s analýzou relevance* (vybrat ty, které nesou informaci). Druhé je speciálním případem prvního (redukce dimenze), okruh je ale jmenuje zvlášť — čeká se znalost konkrétních kritérií a umění je spočítat.

2.1 Proč je příprava dat klíčová

Předzpracování je pro úspěch aplikace *klíčové*, je obtížné a časově náročné a těžší ze spolupráce s doménovým expertem. Cíl: vybrat (nebo vytvořit) z dostupných dat ta relevantní pro danou úlohu a reprezentovat je ve formě vhodné pro zvolený algoritmus; výsledkem je *jedna* datová tabulka objekty $\times$ atributy.

♦ **nad rámec slidů** Rozměry kvality dat: *přesnost* (*accuracy*), *úplnost* (*completeness*), *konzistence*, *aktuálnost* (*timeliness*), *důvěryhodnost*, *interpretovatelnost* — „garbage in, garbage out“.

2.2 Čištění dat: chybějící hodnoty

Základní strategie (v pořadí od nejjednodušší k nejpřesnější):

1. **Ignorovat objekty** s chybějící hodnotou — jednoduché, ale při mnoha attributech ztratíme většinu dat a zavádí zkreslení, není-li chybění náhodné.
2. **Nová hodnota „nevím“** (*I don't know*) — absence se stane plnohodnotnou kategorií; vhodné, nese-li sama informaci (nevyplněný příjem u žádosti o úvěr).
3. **Existující hodnotou atributu**: nejčastější (modus, u numerických průměr či medián), úměrně poměru všech hodnot (náhodně podle empirického rozdělení), nebo libovolnou.
4. **Modelem** (regrese, rozhodovací strom, *k*-NN) z ostatních atributů — nejpřesnější, výpočetně nejdražší, riskuje umělou závislost mezi atributy.

♦ **nad rámec slidů** Terminologicky se rozlišuje MCAR (*missing completely at random*), MAR (*missing at random* — chybění závisí na pozorovaných attributech) a MNAR (*missing not at random* — závisí na nepozorované hodnotě samotné). Jen u MCAR je prosté vypuštění nezkrácené.

Některé metody umí chybějící hodnoty zpracovat samy: C4.5 je při konstrukci stromu ignoruje (kritérium dělení počítá jen ze známých hodnot) a při klasifikaci je odhaduje z ostatních vzorů; CART chybějící hodnoty do rozhodovacího kritéria nezapočítává; naivní Bayes umí klasifikovat i nekompletně popsane vzory (kap. 3).

2.3 Čištění dat: šum a odlehlé hodnoty

Šum (*noise*) je náhodná chyba nebo rozptyl v měřené veličině. Techniky vyhlazování: **binning** (hodnoty se rozdělí do košů a nahradí průměrem, mediánem nebo hranicí koše), **regrese** (hodnoty se nahradí predikcí regresní funkce), **shlukování** (hodnoty mimo shluky se označí za odlehlé) a **kombinace stroje a člověka** (podezřelé hodnoty se předloží ke kontrole).

Rozpětí, kvartily, mezikvartilové rozpětí, odlehlá hodnota

Rozpětí (*range*) množiny dat je rozdíl nejvyšší a nejnižší hodnoty.

Kvartily Q_1, Q_2, Q_3 dělí data na čtyři části: 25 % pozorování má hodnotu menší než dolní kvartil Q_1 , 50 % pod mediánem Q_2 a 75 % pod horním kvantilem Q_3 .

Mezikvartilové rozpětí (*interquartile range*): $IQR = Q_3 - Q_1$.

Odlehlá hodnota (*outlier*) je extrémní hodnota ležící mimo celkový vzorec dat. Běžné pravidlo: odlehlá je každá hodnota

$$x > Q_3 + 1,5 \cdot IQR \quad \text{nebo} \quad x < Q_1 - 1,5 \cdot IQR.$$

Výpočet kvartilů pro n vzestupně seřazených hodnot (diskrétní data): pro Q_1 dělíme n čtyřmi — je-li $n/4$ celé číslo, bereme střed mezi odpovídajícím a následujícím členem; není-li celé, zaokrouhlíme nahoru a vezmeme odpovídající člen. Pro Q_3 analogicky s $3n/4$. U spojitých dat se místo zaokrouhlení interpoluje.

Příklad — krabicový graf a odlehlé hodnoty

Hladina glukózy v krvi u 30 žen (mmol/l), stonkový diagram (klíč: 2 | 1 znamená 2,1):

2 | 2 2 3 3 5 7 (6)

3 | 1 2 6 7 7 7 8 8 8 8 9 9 9 (13)

4 | 0 0 0 0 4 5 6 7 8 (9)

5 | 1 5 (2)

$n = 30$, $30/4 = 7,5 \rightarrow$ zaokrouhlíme na 8, osmé číslo je 3,2, tedy $Q_1 = 3,2$. Medián $Q_2 = 3,8$.

Pro Q_3 : $3 \cdot 30/4 = 22,5 \rightarrow 23$, 23. číslo je 4,0, tedy $Q_3 = 4,0$.

$IQR = 4,0 - 3,2 = 0,8$; dolní mez = $3,2 - 1,5 \cdot 0,8 = 2,0$; horní mez = $4,0 + 1,5 \cdot 0,8 = 5,2$.

Odehlá hodnota je 5,5. Nejvyšší hodnota, která odehlá není, je 5,1 — v krabicovém grafu (*box plot*) k ní vede vous, odehlá hodnota se vyznačí křížkem.

Násobek 1,5 je konvence (s násobkem 1 je kritérium přísnější). *Příklad:* želví samci $Q_1 = 400$, $Q_3 = 580$ g $\Rightarrow IQR = 180$, meze 220 a 760 — z hodnot 400, 260, 550, 640 g není odehlá žádná. Samice $Q_1 = 260$, $Q_3 = 340$ $\Rightarrow$ meze 180 a 420 — odehlé jsou 170 g a 440 g.

2.4 Integrace dat

♦ **nad rámec slidů** Při *integraci* (*data integration*) spojujeme více zdrojů do jedné tabulky. Hlavní problémy: **problém identity entity** (atribut `cust_id` v jedné databázi odpovídá `customer_number` v druhé; nutná metadata a párování záznamů); **redundance** (atribut odvoditelný z jiných — roční příjem = 12×měsíční; detekuje se korelační analýzou u numerických a χ^2 testem u kategoriálních atributů, viz odd. 2.8); **konflikty hodnot** (různé jednotky, škály, kódování); **duplicita** (tentýž objekt vícekrát s drobně odlišnými hodnotami).

2.5 Transformace a standardizace atributů

Standardizace dává všem atributům *stejný vliv* na výpočet vzdáleností (nutí je do společného rozsahu). Pro $x_i = (0,1; 20)$ a $x_j = (0,9; 720)$ je

$$\text{dist}(x_i, x_j) = \sqrt{(0,9 - 0,1)^2 + (720 - 20)^2} = 700,000457,$$

tedy vzdálenost je zcela ovládnuta druhým atributem; první nemá prakticky žádný vliv.

Základní standardizační transformace

Nechť f je atribut a x_{if} jeho hodnota u i -tého objektu.

Desítkové škálování (*decimal scaling*) do $[-1, 1]$: dělíme hodnoty nejmenší mocninou 10, která udrží všechny transformované hodnoty v $[-1, 1]$.

Min-max normalizace (*range standardization*) do $[0, 1]$:

$$\text{range}(x_{if}) = \frac{x_{if} - \min(f)}{\max(f) - \min(f)},$$

do $[-1, 1]$ pak $\text{range}_{[-1,1]}(x_{if}) = 2 \cdot \text{range}(x_{if}) - 1$.

Standardizace podle průměrné absolutní odchylky — nulový průměr a jednotková střední absolutní odchylka:

$$m_f = \frac{1}{n}(x_{1f} + \dots + x_{nf}), \quad s_f = \frac{1}{n}(|x_{1f} - m_f| + \dots + |x_{nf} - m_f|), \quad z(x_{if}) = \frac{x_{if} - m_f}{s_f}.$$

Standardizace podle směrodatné odchylky (*std-score*) — nulový průměr a jednotková korigovaná výběrová směrodatná odchylka:

$$\text{cors}_f = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_{if} - m_f)^2}, \quad \text{std}(x_{if}) = \frac{x_{if} - m_f}{\text{cors}_f}.$$

Volba mezi z-skóry: střední absolutní odchylka je *robustnější* k odlehlým hodnotám než směrodatná (odchylky se neumocňují), takže outliersy stlačí ostatní data méně.

2.6 Diskretizace numerických atributů

Řada metod (asociační pravidla, ID3, CHAID, bayesovská klasifikace s diskrétními atributy) vyžaduje kategoriální vstup. *Diskretizace* rozdělí rozsah numerického atributu na intervaly. Metody se liší ve čtyřech ohledech: *strategií* (dělení intervalů shora, nebo slučování zdola), *počtem* intervalů, *typem* intervalů a *kritériem* kvality (minimální klasifikační chyba, entropie, χ^2 test).

- **Ekvidistantní** (*equi-width*) — rozsah se rozdělí na intervaly stejné délky. Nejjednodušší, ale citlivé na odlehlé hodnoty a nerovnoměrné rozdělení.
- **Ekvifrekvenční** (*equi-depth*) [♦ *nad rámec slidů*] — intervaly se stejným počtem objektů.
- **S využitím informace o třídě** — hranice se volí tak, aby intervaly byly co nejčistší; kritériem je entropie (rekurzivní dělení, jako v C4.5) nebo χ^2 (slučování zdola, jako v CHAID).

2.6.1 Fuzzy diskretizace

Ostré hranice pošlou dva blízké objekty do různých kategorií. *Fuzzy diskretizace* je „rozostří“: jedné numerické hodnotě mohou odpovídat *dvě* diskretizované hodnoty se součtem charakteristických funkcí 1. Vznikají „fuzzy“-objekty s vahou < 1 danou *součinem* charakteristických funkcí všech atributů:

$$w = \prod_j \mu_j.$$

Rizika: ztráta informace a *kontradikce* — objekty se stejnými diskretizovanými hodnotami, ale různými třídami.

Procedura *Interval* (fuzzy diskretizace)

1. Má-li posloupnost hodnot stejnou třídu, vytvoř z ní interval s charakteristickou funkcí rovnou 1 na celém intervalu.
2. Pro každý interval Int_i patřící do třídy „?“:
 - patří-li sousední intervaly Int_{i-1} a Int_{i+1} do *téže* třídy, spoj je do jednoho intervalu $Int_{i-1} \cup Int_i \cup Int_{i+1}$ (charakteristická funkce = 1 na celém intervalu);
 - jinak vytvoř *dva fuzzy-intervaly*: spojením $Int_{i-1} \cup Int_i$ s charakteristickou funkcí rovnou 1 na $[L_{i-1}, U_{i-1}]$ a lineárně klesající $\frac{U_{i+1}-x}{U_{i+1}-L_{i-1}}$ na přechodové oblasti, a analogicky spojením $Int_i \cup Int_{i+1}$ s funkcí lineárně rostoucí $\frac{x-L_{i-1}}{U_{i+1}-L_{i-1}}$.
3. Zajisti spojitě pokrytí celého rozsahu (mezery mezi intervaly se chápou jako intervaly třídy „?“).

2.6.2 Seskupování hodnot kategoriálních atributů (KEX)

Má-li kategoriální atribut příliš mnoho hodnot, je užitečné je seskupit. **Cíl**: vytvořit takové grupy $A(Grp)$, aby $P(\text{Class} \mid A(Grp))$ *významně* lišilo od apriorního $P(\text{Class})$ — a vytvořit jich tolik, kolik je tříd, plus jednu navíc („?“).

Algoritmus seskupování hodnot (KEX)

Hlavní cyklus:

1. vytvoř uspořádaný seznam hodnot uvažovaného atributu;
2. pro každou hodnotu: (a) spočítej četnosti výskytu objektů s touto hodnotou v jednotlivých třídách; (b) přiřaď hodnotě kód třídy procedurou *Assign*;
3. vytvoř grupy hodnot procedurou *Group*.

Procedura *Assign*: patří-li pro danou hodnotu všechny objekty do téže třídy, přiřaď hodnotě kód této třídy; jinak — liší-li se rozdělení tříd pro danou hodnotu *významně* (podle χ^2 testu) od apriorního rozdělení tříd — přiřaď kód nejčastější třídy, a pokud ne, přiřaď kód „?“.

Procedura *Group*: vytvoř grupu z hodnot, kterým byl přiřazen stejný kód třídy.

2.7 Redukce dat

2.7.1 Příliš mnoho objektů

Dávkové zpracování se stává problematickým. Řešení: (a) **vzorek** objektů; (b) uložení dovolující přístup bez nutnosti mít data celá v paměti; (c) **více modelů nad podmnožinami** a jejich kombinace (ensemble, kap. 3). Klíčová je **reprezentativnost** vzorku — rozdělení hodnot atributů na vzorku má souhlasit s rozdělením na celých datech.

Nevyvážené třídy vedou k preferenci majoritní třídy. Řešení: různé *váhy* typů chyb (cenově citlivé učení) nebo výběr z tříd s *různou pravděpodobností* (převzorkování minority, podvzorkování majority).

2.7.2 Příliš mnoho atributů

Dvě principiálně odlišné cesty:

- **Redukce transformací** — z existujících atributů vytvoříme *méně nových*, typicky jako lineární kombinace původních (analýza hlavních komponent, PCA). Nevýhody: je nutné znát hodnoty *všech* původních atributů a nové atributy nemusí mít jasnou interpretaci.
- **Redukce selekcí** (*feature selection*) — z existujících atributů vybereme jen ty nejdůležitější. Interpretace se zachovává a nepotřebné atributy se vůbec nemusí měřit.

[♦ nad rámec slidů] PCA hledá ortogonální směry maximálního rozptylu (vlastní vektory kovarianční matice s největšími vlastními čísly); je to *nesupervizovaná* transformace, takže může zahodit směr, který je pro predikci klíčový, ale má malý rozptyl.

2.8 Analýza relevance atributů: filtry a wrappery

Hledáme atributy, které nejlépe přispívají ke správné klasifikaci objektů.

Filtry vs. wrappery

Filtrační metody (*filter*) — pro každý atribut spočítáme charakteristiku odrážející jeho přínos ke klasifikaci, atributy podle ní seřadíme a vybereme určitý počet nejlepších. Charakteristika je *nezávislá* na následně použitém modelu; metoda je rychlá.

Obalové metody (*wrapper*) — pomocí algoritmu strojového učení se postaví model nad *podmnožinou* atributů a model se vyhodnotí; použije se nejlepší z postavených modelů (s odpovídající podmnožinou atributů). Metoda je výpočetně drahá, ale zohledňuje interakci atributů s *konkrétním* modelem.

Prohledávání prostoru podmnožin:

- „zdola nahoru“ (*bottom-up, dopředná selekce*) — začneme od modelů nad jednotlivými atributy a postupně přidáváme další;

- „shora dolů“ (*top-down, zpětná eliminace*) — začneme od modelu nad úplnou množinou atributů a postupně odstraňujeme nepotřebné.

Zásadní omezení filtrů: každý atribut se hodnotí *samostatně*, takže vzájemný vliv atributů se zachycuje obtížně. Kritérium lze počítat pro *množinu* atributů, ale kombinatorická explozivnost to omezuje na hladové dopředné či zpětné prohledávání. [♦ nad rámec slidů] Důsledek: filtr propustí dvojici silně korelovaných atributů (oba mají vysoké skóre, druhý ale nepřináší nic nového) a zahodí atribut užitečný jen *v kombinaci* s jiným (XOR-vztah).

2.8.1 Kritéria na kontingenčních tabulkách

Vztah vstupního atributu A (hodnoty $v_1, \dots, v_R$) a cílového atributu C (třídy $v_1, \dots, v_S$) se popisuje kontingenční tabulkou o četnostech a_{kl} kombinace $A(v_k) \wedge C(v_l)$, s marginály

$$r_k = \sum_{l=1}^S a_{kl}, \quad s_l = \sum_{k=1}^R a_{kl}, \quad n = \sum_{k=1}^R \sum_{l=1}^S a_{kl}.$$

Odhady pravděpodobností: $P(A(v_k) \wedge C(v_l)) = a_{kl}/n$, $P(A(v_k)) = r_k/n$, $P(C(v_l)) = s_l/n$. Očekávaná četnost při nezávislosti je $e_{kl} = r_k s_l / n$.

χ^2 jako kritérium relevance

$$\chi^2 = \sum_{k=1}^R \sum_{l=1}^S \frac{(a_{kl} - e_{kl})^2}{e_{kl}} = n \sum_{k=1}^R \sum_{l=1}^S \frac{(a_{kl} - \frac{r_k s_l}{n})^2}{r_k s_l} \quad (\text{čím větší, tím lepší}).$$

Alternativní tvar pro ruční výpočet: $\chi^2 = \sum_k \sum_l \frac{a_{kl}^2}{e_{kl}} - n$.

Jako statistický test: při platnosti nulové hypotézy o nezávislosti

$$H_0 : P(A = v_k \wedge C = v_l) = P(A = v_k) P(C = v_l) \quad \forall k, l$$

má statistika χ^2 rozdělení s $(R-1)(S-1)$ stupni volnosti. Je-li $\chi^2 \geq \chi_{(R-1)(S-1)}^2(\alpha)$, nulovou hypotézu na hladině významnosti α zamítáme a přijímáme alternativní hypotézu o *závislosti*.

Příklad — χ^2 test na čtyřpolní tabulce

		Poskytnutí úvěru		
		ANO	NE	r_k
Výše příjmu	vysoký	50	0	50
	nízký	30	40	70
s_l		80	40	120

Očekávané četnosti: $e_{11} = 50 \cdot 80 / 120 = 33,3$; $e_{12} = 50 \cdot 40 / 120 = 16,7$; $e_{21} = 70 \cdot 80 / 120 = 46,7$; $e_{22} = 70 \cdot 40 / 120 = 23,3$. Rozdíly jsou tedy $+16,7$, $-16,7$, $-16,7$, $+16,7$ a hodnota statistiky $\chi^2 = 42,857$.

Na hladině významnosti $\alpha = 0,05$ je kritická hodnota $\chi_{(1)}^2(0,05) = 3,84$. Protože $42,857 > 3,84$, **mezi výší příjmu a poskytnutím úvěru je závislost**.

Fisherův exaktní test

χ^2 test lze použít jen pro dostatečně velké četnosti — musí platit $(r_k s_l) / n \geq 5$ pro všechna k, l . Pro čtyřpolní tabulky s malými četnostmi se používá *Fisherův test*. Pravděpodobnost, že čtyřpolní tabulka má při daných marginálech r_1, r_2, s_1, s_2 právě četnosti a_{kl} :

$$p = \frac{r_1! r_2! s_1! s_2!}{n! a_{11}! a_{12}! a_{21}! a_{22}!} = \frac{\binom{s_1}{a_{11}} \binom{s_2}{a_{12}}}{\binom{n}{r_1}}.$$

Pravděpodobnosti se sečtou přes všechny uvažované hodnoty skutečných četností při daných marginálech (nechť $m = \min(r_1, s_1)$):

$$P = \sum_{i=0}^m \frac{r_1! r_2! s_1! s_2!}{n! (a_{11} - i)! (a_{12} + i)! (a_{21} + i)! (a_{22} - i)!}.$$

Je-li $P \leq \alpha$, nulová hypotéza se na hladině α zamítá.

Příklad. Pro tabulku s marginály $r = (12, 18)$, $s = (6, 24)$, $n = 30$ vychází $P_0 = 0,031$ a $P_1 = 0,173$, tedy $P = P_0 + P_1 = 0,204 > 0,05$ — **nulovou hypotézu o nezávislosti přijímáme**. (Kontrola: součet $P_0, \dots, P_6 = 0,031 + 0,173 + 0,340 + 0,302 + 0,128 + 0,024 + 0,002 = 1,000$.)

2.8.2 Kritéria založená na entropii

Entropie, vzájemná informace, informační míra závislosti

Entropie atributu A jako vážený průměr entropií jeho hodnot (čím *menší*, tím lepší):

$$H(A) = \sum_{k=1}^R \frac{r_k}{n} H(A(v_k)), \quad H(A(v_k)) = - \sum_{l=1}^S \frac{a_{kl}}{r_k} \log_2 \frac{a_{kl}}{r_k}.$$

Vzájemná informace (*mutual information*):

$$\text{MI}(A, C) = \sum_{k=1}^R \sum_{l=1}^S \frac{a_{kl}}{n} \log_2 \frac{n a_{kl}}{r_k s_l}.$$

Informační míra závislosti (*information measure of dependence*) — normalizovaná vzájemná informace (čím *větší*, tím lepší):

$$\text{ID}(A, C) = \frac{\text{MI}(A, C)}{H(C)} = \frac{\text{MI}(A, C)}{- \sum_{l=1}^S \frac{s_l}{n} \log_2 \frac{s_l}{n}}.$$

Normalizace v ID je podstatná: samotná MI systematicky zvýhodňuje atributy s mnoha hodnotami (v limitě je identifikátor objektu „nejinformativnější“ atribut). Totéž zvýhodnění řeší poměrný informační zisk v C4.5 (kap. 3).

2.9 Vztahy mezi atributy: regrese a korelace

Zatímco kontingenční tabulky popisují vztah *kategoriálních* atributů, u numerických se používá regresní a korelační analýza. *Korelační analýza* odpovídá na otázku, zda mezi dvěma numerickými veličinami *existuje* lineární vztah; *lineární regrese* určuje jeho *parametry*.

Důvody pro regresní analýzu: nákladné měření výstupu (predikovat jej z dostupných vstupů); vstupy známé dříve než výstup (odhad); řízené vstupy pomohou najít chování výstupu; hledaný kauzální vztah mezi vstupem a výstupem.

Lineární regrese jedné proměnné metodou nejmenších kvadrátů

Vzory $[x_1, y_1], \dots, [x_p, y_p]$, regresní rovnice $y = \beta x + \alpha$, kvadratická chyba

$$E = \sum_{i=1}^p \varepsilon_i^2 = \sum_{i=1}^p (y_i - \hat{y}_i)^2 = \sum_{i=1}^p (y_i - \beta x_i - \alpha)^2.$$

Položíme parciální derivace nule:

$$\frac{\partial E}{\partial \alpha} = -2 \sum_i (y_i - \beta x_i - \alpha) = 0, \quad \frac{\partial E}{\partial \beta} = -2 \sum_i (y_i - \beta x_i - \alpha) x_i = 0,$$

odkud po úpravě $\alpha = \bar{y} - \beta \bar{x}$ a

$$\beta = \frac{\sum_{i=1}^p (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^p (x_i - \bar{x})^2} \quad (\text{tj. výběrová kovariance dělená výběrovým rozptylem } x).$$

Predikce: $\hat{y} = \beta x + \alpha$.

Korelační koeficient

Posouzení „množství“ lineární závislosti:

$$\rho(x, y) = \frac{\sigma_{xy}}{\sqrt{\sigma_x^2 \sigma_y^2}} = \frac{\sigma_{xy}}{\sigma_x \sigma_y}, \quad \sigma_{xy} = \frac{1}{n-1} \sum_i (x_i - \bar{x})(y_i - \bar{y}),$$

$$\sigma_x^2 = \frac{1}{n-1} \sum_i (x_i - \bar{x})^2, \quad \sigma_y^2 = \frac{1}{n-1} \sum_i (y_i - \bar{y})^2.$$

Platí $\rho \in [-1, 1]$; $|\rho| = 1$ znamená přesný lineární vztah, $\rho = 0$ žádný *lineární* vztah (nikoli žádnou závislost — ρ nezachytí nelineární vztahy).

Vícerozměrná lineární regrese. Předpokládáme lineární závislost vysvětlované veličiny Y na několika vysvětlujících veličinách $X_1, \dots, X_m$: $\hat{y} = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m$, maticově $\hat{Y} = X\beta$, kde X je rozšířená matice vstupních vzorů (první sloupec jedničky) a $\beta = (\beta_0, \dots, \beta_m)$. Kvadratická odchylka $E = (Y - X\beta)^\top (Y - X\beta)$; z $\partial E / \partial \beta = 0$ dostáváme normální rovnice $X^\top X \beta = X^\top Y$, tedy

$$\beta = (X^\top X)^{-1} X^\top Y.$$

Pro složité praktické úlohy je tento výpočet nákladný $\Rightarrow$ používají se aproximativní (iterativní) řešení.

Nelineární regrese předpokládá složitější funkční závislost (kvadratickou, exponenciální, ...). Nej důležitějším případem je *logistická regrese*, která modeluje kategoriální (dvouhodnotový) výstup — protože jde současně o klasifikátor, je zpracována v kap. 3, odd. 3.2.5.

2.10 Shrnutí ke zkoušce

- **Cíl přípravy dat:** vybrat relevantní data, reprezentovat je pro zvolený algoritmus, výsledkem *jedna* tabulka objekty $\times$ atributy.
- **Chybějící hodnoty:** ignorovat objekt / nová hodnota „nevím“ / existující hodnota (modus, poměrně, libovolně) / doplnit modelem. Umět říct, kdy je která volba vhodná (absence jako informace $\rightarrow$ „nevím“).
- **Odlehle hodnoty:** $IQR = Q_3 - Q_1$, outlier mimo $[Q_1 - 1,5 IQR, Q_3 + 1,5 IQR]$. Umět spočítat kvantily z vzestupně seřazených dat (pravidlo $n/4$ a $3n/4$, zaokrouhlení nahoru) a nakreslit box plot.
- **Standardizace:** desítkové škálování, min-max do $[0, 1]$ a $[-1, 1]$, z-skóre podle střední absolutní odchylky (robustnější), std-skóre podle směrodatné odchylky. Motivace: bez ní vzdálenost ovládne atribut s největším rozsahem.
- **Diskretizace:** ekvidistantní, ekvifrekvenční, s využitím třídy (entropie, χ^2); **fuzzy diskretizace** — rozostřené hranice, jedné hodnotě odpovídají dvě kategorie se součtem charakteristických funkcí 1, váha fuzzy-objektu je součin $\prod_j \mu_j$; rizika: ztráta informace a kontradikce. **KEX** seskupuje hodnoty kategoriálního atributu podle χ^2 testu proti apriornímu rozdělení tříd (procedury *Assign* a *Group*).

- **Redukce dat:** příliš mnoho objektů $\rightarrow$ vzorkování (reprezentativnost!), efektivní uložení, více modelů nad podmnožinami; nevyvážené třídy $\rightarrow$ váhy chyb nebo různé pravděpodobnosti výběru. Příliš mnoho atributů $\rightarrow$ *transformace* (PCA: méně nových atributů jako lineární kombinace, ale nutné znát všechny původní a chybí interpretace) vs. *selekce* (podmnožina původních, interpretace zůstává).
- **Filtry vs. wrappery:** filtr počítá charakteristiku pro každý atribut samostatně a je nezávislý na modelu (rychlý, ale nezachytí interakce); wrapper staví model nad podmnožinou a vyhodnocuje jej (drahý, zohledňuje interakce). Prohledávání *bottom-up* (přidávání) nebo *top-down* (odebírání).
- **Filtrovací kritéria:** χ^2 (větší = lepší), entropie $H(A)$ (menší = lepší), $MI(A, C)$, $ID(A, C) = MI/H(C)$ (větší = lepší). Umět zdůvodnit normalizaci ID: bez ní jsou zvýhodněny atributy s mnoha hodnotami.
- χ^2 **test:** $(R - 1)(S - 1)$ stupňů volnosti, podmínka $r_{kSI}/n \geq 5$; pro malé četnosti **Fisherův exaktní test**. Umět projít výpočet na čtyřpolní tabulce (příklad s úvěrem: $\chi^2 = 42,857 > 3,84 \Rightarrow$ závislost).
- **Regrese a korelace:** metoda nejmenších kvadrátů, β jako kovariance dělená rozptylem, $\alpha = \bar{y} - \beta\bar{x}$; vícerozměrně $\beta = (X^T X)^{-1} X^T Y$; korelační koeficient $\rho = \sigma_{xy}/(\sigma_x \sigma_y)$ měří jen *lineární* závislost.

3 Metody pro dobývání znalostí

Nejobsáhlejší věta okruhu jmenuje tři skupiny metod pro tři situace: *asociační pravidla* (transakční data bez cílového atributu), *učení s učitelem* (data s cílovým atributem) a *klastrová analýza* (metrická data bez cílového atributu). Podle nich je kapitola rozdělena.

3.1 Asociační pravidla a frekventované vzory

3.1.1 Analýza nákupního košíku

Analýza nákupního košíku (*market basket analysis*, MBA) je archetypální úloha: „které položky se v košíku vyskytují společně?“ Výsledky se vyjadřují ve formě pravidel a lze je okamžitě použít — při plánování a rozvržení prodejny, nabídce kuponů a časově omezených slev, nebo „balíčkování“ produktů.

Položka (*item*) je nabízený produkt nebo služba, **transakce** obsahuje jednu nebo více položek. **Frekvenční tabulka** udává počet společných výskytů každých dvou položek v transakcích; na její diagonále je počet transakcí obsahujících danou položku.

Příklad — frekvenční tabulka

Transakce v obchodě s potravinami:

Zák.	Položky		chléb	máslo	mléko	káva
1	chléb, máslo	chléb	4	3	1	2
2	mléko, chléb, máslo	máslo	3	4	1	2
3	chléb, káva	mléko	1	1	1	0
4	chléb, máslo, káva	káva	2	2	0	3
5	káva, máslo					

Z tabulky je povaha prodeje vidět okamžitě: *chléb a máslo se kupují spolu, mléko se nikdy nekupuje s kávou*.

Pravidla mají formu **IF podmínka THEN závěr**. Mají být **snadno pochopitelná** (vztah lze ověřit) a **použitelná** (vedou k zásahu), naopak nemají být **triviální** (každý to zná) ani **nevysvětlitelná** (nemají vysvětlení a nevedou k akci).

3.1.2 Support, confidence a lift

Support, confidence, lift

Support (podpora) — jak často lze pravidlo použít:

$$\text{sup}(R) = \frac{\text{počet transakcí obsahujících } i \text{ a } j}{\text{počet všech transakcí}} \cdot 100\%.$$

Confidence (spolehlivost) — jak spolehlivé jsou výsledky pravidla:

$$\text{conf}(R) = \frac{\text{počet transakcí obsahujících } i \text{ a } j}{\text{počet transakcí obsahujících } i} \cdot 100\%.$$

Lift (zdvih) — kolikrát je lepší použít pravidlo pro predikci než jen předpokládat jeho výsledek:

$$\text{lift}(R) = \frac{p(i \wedge j)}{p(i)p(j)}.$$

Je-li $\text{lift} < 1$, je pravidlo pro predikci *horší než náhodná volba* a **negace závěru** může dát lepší pravidlo (**IF podmínka THEN NOT závěr**).

Příklad — support, confidence, lift

Nad daty z předchozího příkladu (5 transakcí):

Pravidlo 1: „kdo kupuje chléb, kupuje i máslo.“ $\text{sup} = 3/5 = 60\%$, $\text{conf} = 3/4 = 75\%$.

Pravidlo 2: „kdo kupuje kávu, kupuje i máslo.“ $\text{sup} = 2/5 = 40\%$, $\text{conf} = 2/3 = 66\%$.

Pravidlo 3: „kdo kupuje mléko, kupuje i máslo.“ $\text{sup} = 1/5 = 20\%$, $\text{conf} = 1/1 = 100\%$,
 $\text{lift} = \frac{1/5}{(1/5) \cdot (4/5)} = \frac{5}{4} = 1,25$.

Pravidlo 3 má *stoprocentní* spolehlivost, ale support jen 20 % — opírá se o jedinou transakci.

Lift 1,25 říká, že zdvih proti náhodě je jen malý (máslo kupuje 80 % zákazníků tak jako tak).

To je základní past: *vysoká confidence sama o sobě nestačí*.

3.1.3 Volba položek, taxonomie a virtuální položky

Transakční data bývají hůř kvalitní a vyžadují rozsáhlejší předzpracování; relevance položek se mění v čase. Volba úrovně je kompromis mezi rostoucím počtem kombinací a přímou použitelností výsledků (konkrétní položky), při zachování dostatečného supportu.

Taxonomie je hierarchie kategorií: zpočátku obecnější položky, později pravidla pro konkrétní položky, a to jen z transakcí, které je obsahují. Uvažované položky mají mít přibližně stejnou frekvenci — *vzácné posunout výše* v taxonomii, *častější nechat níže* (aby nejfrekventovanější nedominovaly pravidlům).

Virtuální položky přesahují taxonomii: rozostřují hranici mezi typy produktů (značky — Calvin Klein) a nesou informaci o transakci samotné — anonymní (den, čas) nebo podepsanou (zákazník a jeho chování). Riziko *redundance* v pravidlech: virtuální položka odpovídá právě jedné položce z taxonomie („IF produkt_Škoda THEN Škoda“), nebo se v pravidle sejde virtuální i obecná položka („IF produkt_Škoda AND malé auto THEN stan“ místo „IF Fabia THEN stan“). *Srovnání prodejen:* virtuální položka označí typ prodejny (neodpovídá žádnému produktu) — vezmi data z nových prodejen a přibližně stejně velká data ze stávajících, aplikuj MBA na oba soubory a zaměř se na pravidla s virtuálními položkami.

Prořezávání podle minimálního supportu eliminuje málo frekventované položky (akce se musí týkat dost transakcí): buď eliminovat vzácné položky a jejich pravidla, nebo taxonomií vytvořit obecné položky splňující prah. Proměnný minimální support vede ke *kaskádovému efektu*.

3.1.4 Algoritmus Apriori

Frekventovaná množina položek a Apriori princip

Frekventovaná množina položek (*frequent itemset*) je kombinace (konjunkce) kategorií, která na datech dosáhne předem stanovené frekvence — supportu *minsup*.

Vlastnost uzavřenosti dolů (*downward closure property*) — klíčová idea Apriori: *každá podmnožina frekventované množiny je také frekventovaná*. Ekvivalentně: je-li množina nefrekventovaná, jsou nefrekventované i všechny její nadmnožiny.

Při hledání kombinací délky k se proto využijí známé kombinace délky $k - 1$ — *prohledávání do šířky*. Aby byla kombinace délky k vygenerována, požaduje se, aby *všechny* její podkombinace délky $k - 1$ splňovaly požadavek na frekvenci.

Algoritmus APRIORI (R. Agrawal)

- 1: $L_1 \leftarrow$ všechny kategorie, které dosahují alespoň požadované frekvence
- 2: $k \leftarrow 2$
- 3: **while** $L_{k-1} \neq \emptyset$ **do**
- 4: $C_k \leftarrow \text{APRIORI-GEN}(L_{k-1})$ ▷ generování kandidátů
- 5: $L_k \leftarrow$ ty kombinace z C_k , které dosáhly alespoň požadované frekvence
- 6: $k \leftarrow k + 1$

```

7: end while
Funkce APRIORI-GEN( $L_{k-1}$ ):
1: for každou dvojici kombinací  $Comb_p, Comb_q \in L_{k-1}$  do
2:   if  $Comb_p$  a  $Comb_q$  se shodují v  $k - 2$  kategoriích then
3:     přidej  $Comb_p \cup Comb_q$  do  $C_k$  ▷ krok spojení
4:   end if
5: end for
6: for každou kombinaci  $Comb \in C_k$  do ▷ krok prořezání
7:   if některá její podkombinace délky  $k - 1$  není v  $L_{k-1}$  then
8:     odstraň  $Comb$  z  $C_k$ 
9:   end if
10: end for

```

Generování pravidel. Po nalezení kombinací s vyhovující frekvencí se vytvoří asociační pravidla (platí *frekvence nadkombinace* $\leq$ *frekvence kombinace*). Každá kombinace $Comb$ se rozdělí na všechny možné dvojice podkombinací Ant a Suc tak, že

$$Suc = Comb \setminus Ant, \quad Ant \cap Suc = \emptyset, \quad Ant \cup Suc = Comb.$$

Pro pravidlo $Ant \Rightarrow Suc$ pak *support* odpovídá frekvenci kombinace $Comb$ a *confidence* poměru frekvencí kombinací $Comb$ a Ant .

Výhody MBA	Nevýhody MBA
jasné a pochopitelné výsledky — IF-THEN pravidla okamžitě použitelná	výpočetní náklady: prostor asociačních pravidel je exponenciální, $O(2^m)$ pro m položek
dobývání bez cílových výstupních hodnot (bez apriorní znalosti)	nutnost taxonomií a virtuálních položek
umí zpracovat data proměnné délky	obtížné určení vhodného počtu položek; položky by měly mít přibližně stejnou frekvenci
jednoduchý a snadno pochopitelný výpočet	produkuje nadměrné množství pravidel — tisíce, desetitisíce, miliony

3.1.5 Vícenásobný minimální support: MS-Apriori

Problém vzácných položek. Jediný *minsup* předpokládá, že všechny položky mají podobnou povahu a frekvenci. V praxi se ale některé položky vyskytují velmi často a jiné vzácně (kuchyňský robot vs. chléb a mléko). Důsledek:

- je-li *minsup* příliš **vysoký**, pravidla se vzácnými položkami se nenajdou;
- je-li příliš **nízký** (aby se našla pravidla s vzácnými i častými položkami), hrozí *kombinatorická explozivnost* — časté položky se pospojují všemi možnými způsoby.

Model vícenásobných minimálních supportů (MIS)

Minimální support pravidla se vyjádří pomocí *minimálních supportů položek* (*minimum item support*, MIS) těch položek, které v pravidle vystupují. Každá položka může mít vlastní $MIS(i)$; zadáním různých hodnot vyjádří uživatel různé požadavky na support pro různá pravidla.

Minsup pravidla $R : a_1, \dots, a_k \Rightarrow a_{k+1}, \dots, a_r$ je *nejnižší* hodnota MIS mezi jeho položkami: pravidlo splňuje minimální support, je-li jeho skutečný support $\geq \min(MIS(a_1), \dots, MIS(a_r))$.

Omezení rozdílu supportů: aby se v téže množině neobjevily velmi časté a velmi vzácné položky, požaduje se

$$\max_{i \in s} \{sup(i)\} - \min_{i \in s} \{sup(i)\} \leq \varphi,$$

kde $0 \leq \varphi \leq 1$ je uživatelem zadaný maximální rozdíl supportů (stejný pro všechny množiny).

Příklad — minsup pravidla podle MIS

Položky *chléb*, *obuv*, *oděvy* s $MIS(chléb) = 2\%$, $MIS(obuv) = 0,1\%$, $MIS(oděvy) = 0,2\%$.

R_1 : *oděvy* $\Rightarrow$ *chléb* [sup = 0,15 %] minsup **nesplňuje**, protože $0,15\% < MIS(oděvy) = 0,2\%$.

R_2 : *oděvy* $\Rightarrow$ *obuv* [sup = 0,15 %] minsup **splňuje**, protože $0,15\% \geq MIS(obuv) = 0,1\%$.

Uzavřenost dolů v novém modelu neplatí! MIS totiž dovoluje vyšší minimální supporty pro pravidla s jen frekventovanými položkami a nižší pro pravidla s méně frekventovanými. Příklad: $MIS(1) = 10\%$, $MIS(2) = 20\%$, $MIS(3) = 5\%$, $MIS(4) = 6\%$. Množina $\{1, 2\}$ se supportem 9 % je nefrekventovaná, ale $\{1, 2, 3\}$ a $\{1, 2, 4\}$ frekventované být mohou — $\{1, 2\}$ tedy *nesmíme* zahodit.

Řešení: položky se seřadí *vzestupně podle hodnot MIS* a toto pořadí se pak používá ve všech dalších operacích algoritmu. Každá množina w má formu $\{w[1], \dots, w[k]\}$, kde $MIS(w[1]) \leq \dots \leq MIS(w[k])$.

Algoritmus MS-Apriori

```
1:  $M \leftarrow \text{SORT}(I, MS)$  ▷ setřídění položek podle MIS(i)
2:  $L \leftarrow \text{INIT-PASS}(M, T)$  ▷ první průchod daty;  $L$  je množina semen
3:  $F_1 \leftarrow \{\{i\} \mid i \in L, i.\text{count}/n \geq MIS(i)\}$ 
4: for  $k = 2$ ;  $F_{k-1} \neq \emptyset$ ;  $k++$  do
5:   if  $k = 2$  then
6:      $C_k \leftarrow \text{LEVEL2-CANDIDATE-GEN}(L, \varphi)$ 
7:   else
8:      $C_k \leftarrow \text{MSCANDIDATE-GEN}(F_{k-1}, \varphi)$ 
9:   end if
10:  for každou transakci  $t \in T$  do
11:    for každého kandidáta  $c \in C_k$  do
12:      if  $c \subseteq t$  then
13:         $c.\text{count}++$ 
14:      end if
15:      if  $c \setminus \{c[1]\} \subseteq t$  then
16:         $c.\text{tailCount}++$  ▷ pro generování pravidel
17:      end if
18:    end for
19:  end for
20:   $F_k \leftarrow \{c \in C_k \mid c.\text{count}/n \geq MIS(c[1])\}$ 
21: end for
22: return  $F = \bigcup_k F_k$ 
```

První průchod daty (INIT-PASS): algoritmus zjistí support každé položky, pak v setříděném pořadí najde *první* položku i , která splní $MIS(i)$, a vloží ji do množiny semen L . Pro každou další položku j za i platí: je-li $j.\text{count}/n \geq MIS(i)$, patří j také do L .

Příklad: $MIS(1) = 10\%$, $MIS(2) = 20\%$, $MIS(3) = 5\%$, $MIS(4) = 6\%$; 100 transakcí, četnosti $\{3\} = 6$, $\{4\} = 3$, $\{1\} = 9$, $\{2\} = 25$. Pak $L = \{3, 1, 2\}$ a $F_1 = \{\{3\}, \{2\}\}$. Položka 4 není v L , protože $4.\text{count}/n < MIS(3) = 5\%$; $\{1\}$ není v F_1 , protože $1.\text{count}/n < MIS(1) = 10\%$.

Generování kandidátů úrovně 2 (LEVEL2-CANDIDATE-GEN): pro každou položku $l \in L$ v daném pořadí, splňuje-li $l.\text{count}/n \geq MIS(l)$, se pro každou položku h za l přidá kandidát $\{l, h\}$, pokud $h.\text{count}/n \geq MIS(l)$ a $|\text{sup}(h) - \text{sup}(l)| \leq \varphi$. Podstatné je, že se používá L , ne F_1 — F_1 totiž neobsahuje položky, které splňují MIS nějaké dřívější položky, ale ne své vlastní (v příkladu položka 1).

Generování kandidátů vyšších úrovní (MSCANDIDATE-GEN) má dvě části. *Krok spojení* je jako v Apriori: spojí se $f_1 = \{i_1, \dots, i_{k-2}, i_{k-1}\}$ a $f_2 = \{i_1, \dots, i_{k-2}, i'_{k-1}\}$, které se liší jen v poslední

položce, pokud $i_{k-1} < i'_{k-1}$ a $|\sup(i_{k-1}) - \sup(i'_{k-1})| \leq \varphi$. *Krok prořezání:* pro každou $(k-1)$ -podmnožinu s kandidáta c — není-li $s \in F_{k-1}$, lze c smazat, **s jedinou výjimkou:** neobsahuje-li s položku $c[1]$ (taková s je právě jedna), tedy položku s nejnižší hodnotou MIS, nesmíme c smazat — nevíme totiž, zda s nesplňuje $\text{MIS}(c[1])$, víme jen, že nesplňuje $\text{MIS}(c[2])$; to platí, jen pokud $\text{MIS}(c[2]) = \text{MIS}(c[1])$.

Proč tailCount. U Apriori platí: je-li f frekventovaná a $f_{\text{sub}} \subseteq f$, je i f_{sub} frekventovaná — k určení confidence pravidel tedy stačí supporty frekventovaných množin. U MS-Apriori to nestačí; problém vzniká, když by v závěru pravidla byla položka s *nejnižší* hodnotou MIS. Proto se zvlášť počítá $c.\text{tailCount}$ — support množiny c bez první položky.

Jak zadat hodnoty MIS: (a) $\lambda \cdot \sup(i)$ podle skutečného supportu položky ($0 \leq \lambda \leq 1$ stejné pro všechny); (b) seskupit položky do bloků s podobnými frekvencemi a dát bloku jednu hodnotu MIS. Trik: MIS = 100 % generování pravidel s těmito položkami zakáže. Model vícenásobných minsupů zahrnuje model jediného supportu jako speciální případ.

3.1.6 Třídní asociační pravidla (CAR)

Běžné dolování necílí na žádný atribut — najde všechna pravidla a libovolná položka může být podmínkou i závěrem. Někdy ale uživatele zajímají právě *cílové* atributy či třídy (které slovo je asociováno s kterým tématem dokumentu).

Třídní asociační pravidlo

Nechť T je množina n transakcí, každá navíc označovaná třídou y ; I je množina všech položek, Y množina všech tříd a $I \cap Y = \emptyset$.

Třídní asociační pravidlo (class association rule, CAR) je implikace $X \rightarrow y$, kde $X \subseteq I$ a $y \in Y$. Support a confidence jsou definovány stejně jako u běžných asociačních pravidel.

Příklad — CAR na textové kolekci

Dokument	Třída
1: Student, Učitel, Škola	Vzdělávání
2: Student, Škola	Vzdělávání
3: Učitel, Škola, Město, Hra	Vzdělávání
4: Baseball, Basketbal	Sport
5: Basketbal, Hráč, Divák	Sport
6: Baseball, Trenér, Hra, Tým	Sport
7: Basketbal, Tým, Město, Hra	Sport

Pro $\text{minsup} = 20\%$ a $\text{minconf} = 60\%$ jsou příklady CAR:

Student, Škola $\rightarrow$ Vzdelávání [$\text{sup} = 2/7$, $\text{conf} = 2/2$], Hra $\rightarrow$ Sport [$\text{sup} = 2/7$, $\text{conf} = 2/3$].

CAR lze dolovat **přímo v jednom kroku** (na rozdíl od běžných asociačních pravidel). Klíčovou operací je nalezení všech *pravidlových položek* (rule-items) tvaru $(\text{condset}, y)$, kde $\text{condset} \subseteq I$ a $y \in Y$, se supportem nad minsup ; každá pravidlová položka reprezentuje pravidlo $\text{condset} \rightarrow y$. Apriori lze na generování CAR snadno upravit.

Také zde lze použít ideu vícenásobných minimálních supportů: uživatel zadá *různé minimální supporty různým třídám* (tím efektivně různý minsup pravidlům každé třídy) — např. pravidla třídy *Ano* s minsup 5 % a třídy *Ne* s minsup 10 %. Nastavením minimálního třídního supportu na 101 % se generování pravidel pro danou třídu zakáže.

3.1.7 Dolování sekvenčních vzorů

Asociační pravidla neuvažují *pořadí* transakcí. V mnoha aplikacích je ale pořadí podstatné: v MBA je zajímavé vědět, zda lidé kupují položky v posloupnosti (nejprve postel, o nějakou dobu později povle-

čení); v dolování z webových logů (*web usage mining*) se hledají navigační vzory podle posloupností návštěv stránek.

Sekvence, velikost, délka, podsekvence

Nechť $I = \{i_1, \dots, i_m\}$ je množina položek. *Sekvence* je uspořádaný seznam množin položek. *Množina položek* (prvek sekvence) je neprázdná $X \subseteq I$; sekvenci s značíme $\langle a_1 a_2 \dots a_r \rangle$, kde a_i je prvek. Bez újmy na obecnosti předpokládáme položky v prvku v lexikografickém pořadí.

Velikost sekvence je počet jejích prvků, *délka* počet položek; sekvence délky k se nazývá k -sekvence.

$s_1 = \langle a_1 \dots a_r \rangle$ je *podsekvencí* $s_2 = \langle b_1 \dots b_v \rangle$ (a s_2 *nadsekvencí* s_1 , též s_2 *obsahuje* s_1), existují-li celá čísla $1 \leq j_1 < j_2 < \dots < j_r \leq v$ taková, že $a_1 \subseteq b_{j_1}, \dots, a_r \subseteq b_{j_r}$.

Příklad. Pro $I = \{1, \dots, 9\}$ je $\langle \{3\}\{4, 5\}\{8\} \rangle$ podsekvencí $\langle \{6\}\{3, 7\}\{9\}\{4, 5, 8\}\{3, 8\} \rangle$, protože $\{3\} \subseteq \{3, 7\}$, $\{4, 5\} \subseteq \{4, 5, 8\}$ a $\{8\} \subseteq \{3, 8\}$. Naopak $\langle \{3\}\{8\} \rangle$ *není* obsažena v $\langle \{3, 8\} \rangle$ ani naopak. Velikost $\langle \{3\}\{4, 5\}\{8\} \rangle$ je 3, délka 4.

Úloha: pro danou množinu S vstupních datových sekvencí (sekvenční databázi) najít všechny sekvence, které mají uživatelem zadaný minimální support; taková sekvence se nazývá *frekventovaná sekvence* nebo *sekvenční vzor*. Support sekvence je podíl datových sekvencí v S , které ji obsahují.

Algoritmus **GSP** (*Generalized Sequential Pattern*) generuje sekvenční vzory způsobem obdobným Apriori — prohledávání do šířky s generováním a testováním kandidátů, kde kandidáti délky k vznikají spojováním frekventovaných sekvencí délky $k - 1$.

Analýza časových řad pomocí MBA — „příčina–následek“: zavedou se nové položky pro transakce *před* uvažovanou událostí (příčiny) a *po* ní (následky), duplicity se odstraní. *Okno* je snímek dat za období (transakce z posledního měsíce) — zachycuje trendy u vzácných položek. Může být nutná identifikace zákazníka.

Disociační pravidla „IF A AND NOT B THEN C “: zavedou se položky komplementární k původním. Nevýhody: dvojnásobný počet položek, větší transakce a negované položky jsou častější než původní (pravidla s všemi negovanými se obtížně využívají).

3.1.8 FP-Growth a FP-strom

Apriori používá přístup *generuj a testuj*: generování kandidátů je nákladné (prostorově i časově) a nákladné je i počítání supportu — kontrola podmnožin je výpočetně drahá a databáze se prochází *opakovaně* (I/O). **FP-Growth** umožňuje hledat frekventované množiny *bez generování kandidátů* ve dvou krocích: (1) postavit kompaktní datovou strukturu *FP-strom* (dvěma průchody daty); (2) extrahovat frekventované množiny přímo z *FP-stromu* jeho procházením.

FP-strom

Uzly *FP-stromu* odpovídají položkám a mají počítadlo. *FP-Growth* čte transakce po jedné a mapuje každou na *cestu* ve stromu. Používá se *fixní pořadí* položek, takže cesty se mohou překrývat, mají-li transakce stejný *prefix*; v takovém případě se počítadla inkrementují. Mezi uzly obsahujícími tutéž položku se udržují ukazatele, které tvoří jednosměrné spojové seznamy. Čím více cest se překrývá, tím vyšší je komprese a tím spíše se *FP-strom* vejde do paměti.

Konstrukce (2 průchody). *Průchod 1:* zjistí support každé položky, zahodí nefrekventované, seřadí frekventované *klesajícím* supportem (např. a, b, c, d, e) — toto pořadí maximalizuje sdílení prefixů. *Průchod 2:* postav strom. Např. $\{a, b\}$ dá cestu $\text{null} \rightarrow a \rightarrow b$ s počítadly 1; $\{b, c, d\}$ dá *disjunktní* cestu $\text{null} \rightarrow b \rightarrow c \rightarrow d$ (bez společného prefixu) a ukazatel mezi oba uzly b ; $\{a, c, d, e\}$ má společný prefix a , takže se cesty překryjí a počítadlo a se inkrementuje.

Velikost FP-stromu. Obvykle menší než původní data (transakce sdílejí prefixy). *Nejlepší případ:* všechny transakce stejné $\Rightarrow$ jediná cesta. *Nejhorší:* každá transakce unikátní $\Rightarrow$ strom je alespoň

tak velký jako data a nároky jsou *vyšší* (ukazatele a počítadla). Velikost závisí na pořadí položek — klesající support je jen *heuristika*, nemusí dát nejmenší strom.

Extrakce frekventovaných množin z FP-stromu

Postup *zdola nahoru*, od listů ke kořeni, metodou *rozděl a panuj*: nejprve množiny končící na e , pak na de , ..., pak na d , cd atd. Pro každou položku:

1. získej **prefixový podstrom** (*prefix path sub-tree*) pomocí spojových seznamů;
2. ověř frekventovanost sečtením počítadel po spojovém seznamu (v příkladu pro $\text{minSup} = 2$ je $\text{count}(e) = 3$, takže $\{e\}$ je frekventovaná);
3. je-li frekventovaná, hledej rekurzivně množiny končící na de , ce , be , ae pomocí *podmíněného FP-stromu*.

Podmíněný FP-strom (*conditional FP-tree*) pro e je strom, který by vznikl, kdyby se uvažovaly *jen transakce obsahující e* a e se z nich odstranilo. Z prefixového podstromu se získá ve třech krocích: aktualizuj počítadla tak, aby odrážela počet transakcí s e ; odstraň uzly e ; odstraň nefrekventované položky (má-li b support 1, má jej i be , takže b lze odstranit). Pak se z něj hledají množiny končící na de , ce , ae (be ne — b ve stromu není) a pro každou se rekurzivně opakuje týž postup (např. $e \rightarrow de \rightarrow ade$).

Výhody FP-Growth

jen 2 průchody daty
„komprimuje“ data

žádné generování kandidátů, výrazně rychlejší než Apriori

Nevýhody FP-Growth

FP-strom se nemusí vejít do paměti
stavba FP-stromu je nákladná (ale poté se množiny čtou snadno)
prořezávat lze jen na úrovni jednotlivých položek; support lze spočítat teprve po vložení *všech* dat do stromu

♦ **nad rámec slidů** Doplnkově: *uzavřená* frekventovaná množina (*closed*) je taková, jejíž žádná vlastní nadmnožina nemá stejný support; *maximální* (*maximal*) je taková, jejíž žádná vlastní nadmnožina není frekventovaná. Maximální množiny jsou nejkompaktnější reprezentace (ztrácejí ale informaci o supportech podmnožin), uzavřené jsou kompromis — bezeztrátová reprezentace všech supportů.

3.2 Přístupy založené na principu učení s učitelem

3.2.1 Formulace úlohy

Klasifikace a predikce

Je dána trénovací množina $\{(x_1, y_1), \dots, (x_p, y_p)\}$, kde x_i je vektor hodnot vstupních atributů a y_i hodnota *cílového* atributu. Úkolem je najít model $\hat{y} = f(x)$, který dobře předpovídá cílový atribut i pro dosud neviděné vstupy.

Je-li cílový atribut *diskrétní*, jde o **klasifikaci**, je-li *spojitý*, o **regresi** (predikci). Řešení má vždy dvě fáze: (1) **indukce** (učení, trénování) modelu z trénovacích dat; (2) **aplikace** modelu na nová data.

Zásadní je, že model se hodnotí na *nových* datech — schopnost model naučit trénovací data nazpaměť je bezcenná (*přeučení*, *overfitting*). Metody odhadu chyby a míry kvality jsou v kap. 5, odd. 5.2.

3.2.2 Rozhodovací stromy

Rozhodovací strom

Nechť D je databáze $\{d_1, \dots, d_p\}$, $\{A_1, \dots, A_n\}$ množina atributů a $C = \{C_1, \dots, C_m\}$ množina tříd. *Rozhodovací strom* pro D je strom, kde:

- každý vnitřní uzel je označen atributem A_a ;
- každá hrana je označena predikátem (aplikovatelným na atribut rodičovského uzlu);

- každý list má označení třídy C_j .

Strom dělí prostor příznaků na *obdélníkové oblasti*; vzory se klasifikují podle oblasti, do níž patří.

Výhody	Nevýhody
snadná implementace a interpretace	obtížné zpracování spojitých dat (nutná kategorizace → obdélníkové oblasti)
efektivnost	nelze vždy použít — hranice tříd může být diagonální a strom s osově zarovnanými řezy ji umí jen schodovitě aproximovat (v příkladu bankovního úvěru vede hranice napříč rovinou <i>zůstatek na kontě</i> × <i>příjem</i>)
extrakce jednoduchých pravidel	obtížné zpracování chybějících dat
použitelnost i na velké datové soubory	přeučení ⇒ nutné <i>prořezávání</i>
	neuvažují vzájemné korelace mezi atributy

Terminologie: *rozhodovací atributy* pro dělení datové množiny označují rozhodovací uzly stromu; *rozhodovací predikáty* označují hrany; *zastavovací kritérium* je např. „všechny vzory z redukované množiny patří do téže třídy“.

Algoritmus TDIDT (*Top Down Induction of Decision Trees*)

Indukce stromu shora dolů metodou *rozděl a panuj*:

1. Vyber jeden atribut jako *kořen* částečného (pod)stromu.
2. Rozděl data přicházející do tohoto uzlu na podmnožiny podle hodnot vybraného atributu a přidej uzel pro každou podmnožinu.
3. Existuje-li uzel takový, že vzory do něj přicházející nepatří všechny do téže třídy, zopakuj proces pro něj od kroku 1; jinak skonči.

Entropie a volba dělicího atributu

Cílem je vybrat takový atribut, který nejlépe rozdělí vzory z různých tříd. *Entropie* jako míra neuspořádanosti („překvapení“) v systému:

$$H = - \sum_{j=1}^m p_j \log_2 p_j,$$

kde p_j je pravděpodobnost výskytu třídy j (relativní frekvence na uvažované množině vzorů) a m počet tříd. Konvence: $0 \log_2 0 = 0$; přepočet $\log_2 x = \log_{10} x / 0,301$.

Pro atribut A : pro každou jeho možnou hodnotu v se spočítá entropie $H(A(v))$ na množině příkladů pokrytých kategorií $A(v)$,

$$H(A(v)) = - \sum_{j=1}^m p_j^{A(v)} \log_2 p_j^{A(v)},$$

a *vážená průměrná entropie* atributu jako vážený součet

$$H(A) = \sum_v \frac{|A(v)|}{|D|} H(A(v)).$$

Vybírá se atribut s *minimální* $H(A)$.

Příklad — žádost o úvěr

Klient	Příjem	Konto	Pohlaví	Nezaměstnaný	Úvěr
C1	vysoký	vysoké	žena	ne	ano
C2	vysoký	vysoké	muž	ne	ano
C3	nízký	nízké	muž	ne	ne
C4	nízký	vysoké	žena	ano	ano
C5	nízký	vysoké	muž	ano	ano
C6	nízký	nízké	žena	ano	ne
C7	vysoký	nízké	muž	ne	ano
C8	vysoký	nízké	žena	ano	ano
C9	nízký	střední	muž	ano	ne
C10	vysoký	střední	žena	ne	ano
C11	nízký	střední	žena	ano	ne
C12	nízký	střední	muž	ne	ano

Krok 1 — výběr atributu podle minimální entropie. Čtyřpolní tabulka pro *příjem* a *úvěr*: vysoký příjem 5 ano / 0 ne, nízký příjem 3 ano / 4 ne.

$$H(\text{příjem}(\text{vysoký})) = -\frac{5}{5} \log_2 \frac{5}{5} - \frac{0}{5} \log_2 \frac{0}{5} = 0,$$

$$H(\text{příjem}(\text{nízký})) = -\frac{3}{7} \log_2 \frac{3}{7} - \frac{4}{7} \log_2 \frac{4}{7} = 0,9852,$$

$$H(\text{příjem}) = \frac{5}{12} \cdot 0 + \frac{7}{12} \cdot 0,9852 = 0,5747.$$

Obdobně $H(\text{konto}) = \frac{1}{3} \cdot 0 + \frac{1}{3} \cdot 1 + \frac{1}{3} \cdot 1 = 0,6667$, $H(\text{pohlaví}) = \frac{1}{2} \cdot 0,9183 + \frac{1}{2} \cdot 0,9183 = 0,9183$ a $H(\text{nezaměstnaný}) = \frac{1}{2} \cdot 1 + \frac{1}{2} \cdot 0,65 = 0,825$. Minimum má **příjem** $\Rightarrow$ první větvení.

Krok 2. Příjem(vysoký) $\rightarrow$ list úvěr(ano). Příjem(nízký), 7 klientů: $H(\text{konto}) = 0,3935$, $H(\text{pohlaví}) = 0,965$, $H(\text{nezam.}) = 0,9792 \Rightarrow$ **konto**. **Krok 3.** Konto(vysoké) $\rightarrow$ ano, konto(nízké) $\rightarrow$ ne; konto(střední), 3 klienti: $H(\text{pohlaví}) = 0,6667$, $H(\text{nezam.}) = 0 \Rightarrow$ **nezaměstnanost**.

Pravidla ze stromu (cesta kořen–list = pravidlo): příjem(vysoký) $\rightarrow$ ano; příjem(nízký) $\wedge$ konto(vysoké) $\rightarrow$ ano; příjem(nízký) $\wedge$ konto(nízké) $\rightarrow$ ne; příjem(nízký) $\wedge$ konto(střední) $\wedge$ nezam.(ano) $\rightarrow$ ne; příjem(nízký) $\wedge$ konto(střední) $\wedge$ nezam.(ne) $\rightarrow$ ano.

Převod stromu na pravidla obecně: každá cesta od kořene k listu odpovídá jednomu pravidlu; vnitřní uzly (s hodnotou pro odpovídající hranu) tvoří levou stranu (tělo), list (cílová třída) pravou stranu (hlavu).

Faktory důležité pro indukci stromu:

- *volba* rozhodovacích atributů — ovlivňuje efektivitu; užitečný je informovaný vstup doménového experta;
- *pořadí* atributů — eliminuje redundantní porovnání;
- *větvení* — počet nutných dělení; náročnější pro spojité atributy či mnoho hodnot;
- *forma stromu* — vhodnější vyvážené s málo úrovněmi (za cenu složitějších porovnání); některé algoritmy tvoří jen binární stromy (často hluboké);
- *zastavovací kritéria* — správná klasifikace trénovacích dat; *předčasné zastavení* zabrání velkým stromům a přeučení (přesnost vs. efektivita); *Occamova břitva* (1320) — preferuj nejjednodušší hypotézu pro D ;
- *množství trénovacích dat* — málo $\Rightarrow$ nespolehlivý strom, mnoho $\Rightarrow$ přeučení;
- *prořezávání (pruning)* — vyšší přesnost i efektivita na testovacích datech; odstraní redundantní porovnání, podstromy a irelevantní atributy; lze už během indukce, nebo až na hotovém stromu;
- *složitost* — závisí na p (data), n (atributy) a formě stromu: indukce $O(np \log p)$, klasifikace q vzorů stromem hloubky $O(\log p)$ je $O(q \log p)$.

Algoritmus ID3 (*Iterative Dichotomiser*, Ross Quinlan, 1986): učení funkcí s booleovskými hodnotami, *hladová* metoda, staví strom shora dolů; v každém uzlu volí atribut, který nejlépe klasifikuje

lokální trénovací data — nejlepší atribut má *největší informační zisk*. Proces pokračuje, dokud nejsou všechna trénovací data správně klasifikována, nebo dokud nejsou využity všechny atributy.

Algoritmus ID3 a informační zisk

ID3(*EXAMPLES*, *TARGET_ATTRIBUTE*, *ATTRIBUTES*):

```

1: vytvoř kořen ROOT
2: if všechny EXAMPLES jsou pozitivní then return ROOT s jediným uzlem označeným „+“
3: end if
4: if všechny EXAMPLES jsou negativní then return ROOT s jediným uzlem označeným „-“
5: end if
6: if ATTRIBUTES =  $\emptyset$  then return ROOT s uzlem označeným nejčastější hodnotou TARGET_ATTRIBUTE v EXAMPLES
7: end if
8: A ← atribut z ATTRIBUTES, který nejlépe klasifikuje EXAMPLES
9: rozhodovací atribut pro ROOT ← A
10: for každou možnou hodnotu vi atributu A do
11:   připoj k ROOT novou hranu odpovídající predikátu A = vi
12:   EXAMPLESvi ← podmnožina EXAMPLES s hodnotou vi pro A
13:   if EXAMPLESvi =  $\emptyset$  then
14:     připoj k hraně list označený nejčastější hodnotou TARGET_ATTRIBUTE
15:   else
16:     připoj podstrom ID3(EXAMPLESvi, TARGET_ATTRIBUTE, ATTRIBUTES \ {A})
17:   end if
18: end for
19: return ROOT

```

Informační zisk (*information gain*) — očekávané snížení entropie po rozdělení dat podle uvažovaného atributu:

$$\text{GAIN}(D, A) = H(D) - \sum_{v \in \text{VALUES}(A)} \frac{|D_v|}{|D|} H(D_v).$$

Protože $H(D)$ je pro všechny atributy stejná, je maximalizace informačního zisku ekvivalentní minimalizaci vážené entropie $H(A)$.

Algoritmus C4.5 (Quinlan, 1993) — modifikace ID3:

- **Chybějící data** — při konstrukci ignorována (kritérium dělení se počítá jen ze známých hodnot), při klasifikaci odhadována z hodnot známých u jiných vzorů.
- **Spojitá data** — kategorizují se podle hodnot atributu na trénovacích vzorech.
- **Prořezávání validací** (trénovací $\frac{2}{3}$ / validační $\frac{1}{3}$). *Reduced-error pruning*: podstrom se nahradí listem s nejčastější třídou, ale jen když nový strom není na validační množině horší. *Subtree raising*: podstrom se nahradí svým nejčastěji používaným podstromem zvednutým výš; testuje se přesnost.
- **Prořezávání pravidel** (*rule post-pruning*) — strom (přeučení dovoleno) → pravidla (jedno na cestu kořen-list) → vypouštěj předpoklady, dokud to nezhorší odhadovanou přesnost → seřaď podle očekávané přesnosti a v tom pořadí klasifikuj. Snazší a radikálnější než prořezávání stromů, výsledek je průhledný.
- **Odhad přesnosti pravidel** — standardně validační množinou; C4.5 hodnotí na *trénovacích datech* $\text{acc} = k/n$ (správně klasifikované ku pokrytým). Charakteristikou pravidla je *dolní mez*

z binomického rozdělení, na 95% hladině

$$acc - 1,96 \sqrt{\frac{acc(1 - acc)}{n}}.$$

- **Poměrný informační zisk** (*information gain ratio*) jako kritérium dělení (bere se *největší*):

$$\text{GAIN_RATIO}(D, A) = \frac{\text{GAIN}(D, A)}{-\sum_v \frac{|D_v|}{|D|} \log_2 \frac{|D_v|}{|D|}},$$

jmenovatel penalizuje *nadměrné větvení* (atributy s mnoha hodnotami).

Algoritmus C5.0 — komerční C4.5 pro velké databáze: efektivnější generování pravidel a vyšší přesnost díky *boostingu* (vzorům se přiřadí váhy podle vlivu při klasifikaci, pro každou kombinaci vah vznikne samostatný klasifikátor, hlasuje se většinově).

CART — Classification And Regression Trees

Generuje *binární* stromy — při každém dělení dat se tvoří právě dvě hrany. Volba nejlepšího rozhodovacího atributu podle entropie nebo **Gini indexu**: pro atribut o r hodnotách $v_1, \dots, v_r$, n vzorů a m tříd

$$G = \sum_{i=1}^r \frac{n_i}{n} G(v_i), \quad G(v_i) = 1 - \sum_{j=1}^m p_j^2, \quad \sum_{i=1}^r n_i = n,$$

kde n_i je počet vzorů s hodnotou v_i a p_j pravděpodobnost třídy j v těchto n_i vzorech. *Nižší* hodnoty G znamenají lepší diskriminaci.

Dělení se provádí podle „nejlepšího“ nalezeného bodu pro daný uzel t ; procházejí se všechny možné hodnoty v rozhodovacího atributu A (při rovnosti se použije pravý podstrom). Označme P_L, P_R pravděpodobnosti zpracování levým, resp. pravým podstromem a $P(C_j | t_L), P(C_j | t_R)$ pravděpodobnosti, že vzor patří do třídy C_j a je v levém, resp. pravém podstromu uzlu t . Kritérium dělení:

$$\Phi = 2P_L P_R \sum_{j=1}^m |P(C_j | t_L) - P(C_j | t_R)|,$$

které nabývá maxima, jsou-li všechny vzory dané třídy seskupeny v témže podstromu.

Charakteristické vlastnosti CART: pořadí atributů odpovídá jejich vlivu při klasifikaci; chybějící data jsou ignorována a nezapočítávají se do vyhodnocení rozhodovacích kritérií; zastavovací kritérium — žádné další dělení už nezlepší klasifikační přesnost; vysoká přesnost na trénovací množině nemusí odrážet přesnost na testovacích datech.

CHAID — Chi-square Automatic Interaction Detection

Kritériem větvení je χ^2 . Algoritmus automaticky *seskupuje hodnoty* kategoriálních atributů — hodnoty se postupně slučují od původního počtu, dokud nezůstanou jen dvě grupy; následně se vybere atribut a jeho kategorizace, které jsou pro dělení dat v daném kroku nejlepší. Při větvení tedy nevzniká tolik větví, kolik má atribut hodnot.

Seskupování hodnot atributu:

1. Opakuj, dokud nezůstanou jen dvě grupy hodnot: (a) vyber pár kategorií atributu, které jsou si z hlediska χ^2 nejvíce podobné a lze je sloučit; (b) novou kategorii uvažuj jako možné seskupení v daném kroku.
2. Pro každou možnou grupu hodnot testuj χ^2 testem její relevanci k predikované proměnné.
3. Vyber seskupení, které dává „nejlepší“ rozdělení s nejvýznamnějším rozštěpením.
4. Urči, zda toto seskupení statisticky významně přispívá k rozlišení vzorů z různých tříd.

3.2.3 Bayesovská klasifikace

Bayesova formule a hypotéza MAP

Pravděpodobnost, že hypotéza H platí, pozorujeme-li E :

$$P(H | E) = \frac{P(E | H) P(H)}{P(E)},$$

kde $P(H)$ je *apriorní* pravděpodobnost hypotézy, $P(H | E)$ *aposteriorní* (podmíněná) pravděpodobnost a $P(E)$ pravděpodobnost jevu E .

Nejpravděpodobnější hypotéza H_{MAP} (*maximum a posteriori*) má největší aposteriorní pravděpodobnost. Protože jmenovatel $P(E)$ je pro všechny hypotézy stejný, lze jej zanedbat:

$$H_{MAP} = \arg \max_{H \in \mathcal{H}} P(H | E) = \arg \max_{H \in \mathcal{H}} P(E | H) P(H).$$

Naivní bayesovský klasifikátor

Předpoklad: jevy $E_1, \dots, E_k$ jsou *podmíněně nezávislé* při platnosti hypotézy H . V reálných úlohách je tento předpoklad splněn jen zřídka — odtud označení „naivní“. Pak

$$P(H | E_1, \dots, E_k) = \frac{P(E_1, \dots, E_k | H) P(H)}{P(E_1, \dots, E_k)} = \frac{P(H)}{P(E_1, \dots, E_k)} \prod_{i=1}^k P(E_i | H),$$

a klasifikujeme hypotézou s největší aposteriorní pravděpodobností

$$H_{MAP} = \arg \max_{H_t} P(H_t) \prod_{i=1}^k P(E_i | H_t).$$

Odhady z dat: $P(H_t) = P(\text{třída } t) = \frac{\text{počet vzorů z } t}{\text{počet všech vzorů}}$ a $P(E_k | H_t) = \frac{\text{počet vzorů z } t \text{ splňujících } E_k}{\text{počet vzorů z } t}$.

Výhoda: možnost klasifikovat i *nekompletně popsané* vzory. **Nevýhoda:** nulová aposteriorní pravděpodobnost $P(E_k | H_t)$, není-li v trénovací množině žádný odpovídající vzor, resp. podhodnocené členy při nízkém společném výskytu E_k a H_t .

Příklad — bayesovská klasifikace úvěru

Jednoduchý případ: $P(\text{půjčit}) = 0,667$, $P(\text{zamítnout}) = 0,333$, $P(\text{vysoký příjem} | \text{půjčit}) = 0,91$, $P(\text{vysoký příjem} | \text{zamítnout}) = 0,12$. Pak $0,91 \cdot 0,667 = 0,607$ vs. $0,12 \cdot 0,333 = 0,040$, tedy $H_{MAP} = \text{půjčit}$.

Naivní klasifikátor nad daty z příkladu o úvěru (12 klientů): $P(\text{úvěr(ano)}) = 8/12 = 0,667$, $P(\text{úvěr(ne)}) = 4/12 = 0,333$; $P(\text{konto(střední)} | \text{ano}) = 2/8 = 0,25$, $P(\text{konto(střední)} | \text{ne}) = 2/4 = 0,5$; $P(\text{nezam.(ne)} | \text{ano}) = 5/8 = 0,625$, $P(\text{nezam.(ne)} | \text{ne}) = 1/4 = 0,25$.

Pro klienta se středním kontem, který není nezaměstnaný:

$$0,667 \cdot 0,25 \cdot 0,625 = 0,1042 \quad \text{vs.} \quad 0,333 \cdot 0,5 \cdot 0,25 = 0,0416,$$

klient se tedy zařadí do třídy **úvěr(ano)**.

3.2.4 Support Vector Machines

SVM (V. Vapnik, 70. léta v Rusku; na Západě známé od roku 1992) jsou *lineární* klasifikátory hledající hyperrovinu, která oddělí pozitivní a negativní třídu; pro nelineární separaci se používají *kernelové* funkce. Mají důkladný teoretický základ i vyšší přesnost než většina metod, zejména pro vysokorozměrná data — patří k nejlepším klasifikátorům textu.

Lineární SVM, separabilní případ

Trénovací množina $D = \{(x_1, y_1), \dots, (x_r, y_r)\}$, $x_i \in X \subseteq \mathbb{R}^n$, $y_i \in \{1, -1\}$. SVM hledá lineární funkci $f(x) = \langle w \cdot x \rangle + b$ tak, že

$$y_i = \begin{cases} 1 & \text{pro } \langle w \cdot x_i \rangle + b \geq 0, \\ -1 & \text{pro } \langle w \cdot x_i \rangle + b < 0. \end{cases}$$

Hyperrovina $\langle w \cdot x \rangle + b = 0$ se nazývá *rozhodovací hranice* (*decision boundary*). Takových hyperrovin je mnoho — SVM hledá tu s *největším okrajem* (*margin*); teorie strojového učení říká, že tato hyperrovina minimalizuje mez chyby.

Vzdálenost bodu x_i od hyperroviny je $\frac{|\langle w \cdot x_i \rangle + b|}{\|w\|}$, kde $\|w\| = \sqrt{\langle w \cdot w \rangle}$. Pro okrajové hyperroviny H_+ a H_- platí

$$d_+ = d_- = \frac{1}{\|w\|}, \quad \text{margin} = d_+ + d_- = \frac{2}{\|w\|}.$$

Optimalizační úloha:

$$\text{minimalizuj } \frac{\langle w \cdot w \rangle}{2} \quad \text{za podmínek } y_i(\langle w \cdot x_i \rangle + b) \geq 1, \quad i = 1, \dots, r,$$

což je souhrnný zápis podmínek $\langle w \cdot x_i \rangle + b \geq 1$ pro $y_i = 1$ a $\langle w \cdot x_i \rangle + b \leq -1$ pro $y_i = -1$.

Duální formulace a podpůrné vektory

Úloha se řeší standardní *Lagrangeovou* metodou:

$$L_P = \frac{\langle w \cdot w \rangle}{2} - \sum_{i=1}^r \alpha_i [y_i(\langle w \cdot x_i \rangle + b) - 1], \quad \alpha_i \geq 0.$$

Optimální řešení musí splňovat *Kuhn–Tuckerovy podmínky*, které jsou pro *konvertní* účelovou funkci s *lineárními* omezeními nejen nutné, ale i postačující. Podmínka komplementarity ukazuje, že $\alpha_i > 0$ mohou mít jen body *na* okrajových hyperrovinách (pro ně $y_i(\langle w \cdot x_i \rangle + b) - 1 = 0$) — to jsou **podpůrné vektory** (*support vectors*); pro všechny ostatní je $\alpha_i = 0$.

Vynulováním parciálních derivací L_P podle w a b a substitucí zpět dostaneme *Wolfeho duální* úlohu

$$L_D = \sum_{i=1}^r \alpha_i - \frac{1}{2} \sum_{i,j} y_i y_j \alpha_i \alpha_j \langle x_i \cdot x_j \rangle \rightarrow \max,$$

jejíž maximum se nabývá pro tytéž hodnoty w, b, α_i jako minimum L_P . Duální úloha se řeší snáz než primární (numerické techniky).

Rozhodovací hranice a testování vzoru z :

$$\langle w \cdot x \rangle + b = \sum_{i \in sv} y_i \alpha_i \langle x_i \cdot x \rangle + b = 0, \quad \text{sign} \left(\sum_{i \in sv} \alpha_i y_i \langle x_i \cdot z \rangle + b \right).$$

Vrátí-li výraz 1, je z klasifikován jako pozitivní, jinak jako negativní.

Kernelový trik

Reálná data mohou vyžadovat nelineární separaci, proto se *transformují* do jiného (obvykle mnohem vícerozměrného) *prostoru příznaků* (*feature space*) F , v němž třídy oddělí *lineární* hranice: $\phi : X \rightarrow F$.

Problém explicitní transformace: dimenze F může být pro užitečné transformace enormní i při rozumném počtu vstupních atributů — *prokletí dimenzionality* činí explicitní výpočet ne-

zvládnutelným.

Klíčové pozorování: duál potřebuje ke konstrukci optimální hyperroviny i k vyhodnocení rozhodovací funkce *pouze skalární součiny* $\langle \phi(x) \cdot \phi(z) \rangle$, nikdy $\phi(x)$ samotné. Umíme-li tedy počítat skalární součin přímo ze vstupních vektorů, ϕ znát nemusíme — *kernelová funkce*

$$K(x, z) = \langle \phi(x) \cdot \phi(z) \rangle$$

nahradí skalární součin ve všech výrazech (**kernelový trik**).

Příklad (polynomiální kernel $d = 2$, 2-D vstup):

$$\begin{aligned} \langle x \cdot z \rangle^2 &= (x_1 z_1 + x_2 z_2)^2 = x_1^2 z_1^2 + 2x_1 z_1 x_2 z_2 + x_2^2 z_2^2 \\ &= \langle (x_1^2, x_2^2, \sqrt{2}x_1 x_2) \cdot (z_1^2, z_2^2, \sqrt{2}z_1 z_2) \rangle = \langle \phi(x) \cdot \phi(z) \rangle. \end{aligned}$$

Kernel $\langle x \cdot z \rangle^d$ je tedy skalární součin v transformovaném prostoru, aniž bychom ϕ kdy vyčíslili. Zda je daná funkce kernelem, říká *Mercerova věta*. Běžné kernely: lineární (identita), polynomiální, gaussovský (RBF), sigmoidální.

Další vlastnosti SVM. Pracuje jen v reálném prostoru (kategoriální atributy je nutné převést na numerické) a jen *dvoutřídně* — pro více tříd *jeden proti ostatním* (*one-against-rest*) nebo kódy opravující chyby. Hyperrovina je pro člověka obtížně pochopitelná a kernely to zhoršují, takže se SVM používá tam, kde se srozumitelnost nevyžaduje. ♦ nad rámec slidů Pro nelineárně separabilní data se zavedou *proměnné vůle* (*slack variables*) $\xi_i \geq 0$ a minimalizuje se $\frac{\langle w \cdot w \rangle}{2} + C \sum_i \xi_i$; C řídí kompromis mezi šířkou okraje a počtem chyb.

3.2.5 Logistická regrese

Logistická regrese je nejdůležitější případ nelineární regrese (odd. 2) a zároveň klasifikátor: závislá proměnná y je kategoriální, typicky dvouhodnotová, a modeluje se *pravděpodobnost*, že y nabude určité hodnoty, v závislosti na kombinaci hodnot nezávislých veličin.

Logistická regrese

Pro binární $y \in \{0, 1\}$ se modeluje logaritmus „podmíněné šance“ (*conditional odds*):

$$\ln \frac{P(y = 1 \mid x_1, \dots, x_m)}{1 - P(y = 1 \mid x_1, \dots, x_m)} = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m = z,$$

odkud

$$P(y = 1 \mid x) = \frac{e^z}{1 + e^z} = \frac{1}{1 + e^{-z}} = \sigma(z) \quad (\text{sigmoida}).$$

Učení maximalizací věrohodnosti (*maximum likelihood*):

$$L = \prod_{i=1}^p P(y_i \mid x_{i,1}, \dots, x_{i,m}) = \prod_{i=1}^p \left(\frac{1}{1 + e^{-z_i}} \right)^{y_i} \left(\frac{1}{1 + e^{z_i}} \right)^{1-y_i}.$$

Místo maximalizace L se minimalizuje *křížová entropie* $E = -\log L$:

$$E = - \sum_i \left[y_i \log \sigma(z_i) + (1 - y_i) \log (1 - \sigma(z_i)) \right].$$

Protože derivace sigmoidy je $\sigma' = \sigma(1 - \sigma)$, dostaneme po zjednodušení velmi jednoduchá adaptační pravidla

$$\Delta \beta_j = -\eta \frac{\partial E}{\partial \beta_j} = \eta \sum_i (y_i - \sigma(z_i)) x_{i,j}, \quad \Delta \beta_0 = \eta \sum_i (y_i - \sigma(z_i)),$$

kde η je rychlost učení. Chyba tedy vstupuje do úpravy vah přímo jako rozdíl *pozorované* a *predikované* hodnoty.

Je běžnou volbou základního klasifikátoru tam, kde se požaduje pravděpodobnostní výstup a interpreovatelné koeficienty — např. predikce vazeb v sítích (kap. 6).

3.2.6 Diskriminační analýza

Diskriminační analýza

Klasifikace vzorů do známých tříd: hledá se závislost nominální veličiny (určující příslušnost ke třídě) na ostatních numerických veličinách. Předpokládáme, že ke každé třídě C_j , $j = 1, \dots, m$ existuje *diskriminační funkce* g_j ; vzor $x = (x_1, \dots, x_m)$ patří do třídy C_j , právě když

$$g_j(x) = \max_k g_k(x).$$

Lineární diskriminační analýza: $g_j(x) = \beta_{j0} + \beta_{j1}x_1 + \dots + \beta_{jm}x_m$. Pro dvě třídy lze místo g_1, g_2 hledat jedinou funkci $g = g_1 - g_2$ a klasifikovat podle *znaménka*: „+“ znamená třídu 1, „−“ třídu 2.

Optimální klasifikace ve smyslu minimální chyby nastane, jsou-li diskriminační funkce $\propto$ aposteriorní (podmíněné) pravděpodobnosti zařazení pozorování x do třídy C_j : $g_j(x) = P(C_j | x) = \frac{p(x | C_j)P(C_j)}{p(x)}$; pro dvě třídy $g(x) = p(x | C_1)P(C_1) - p(x | C_2)P(C_2)$.

Pro *normální rozdělení* s různými středními hodnotami μ_1, μ_2 a obecnými kovariančními maticemi S_1, S_2 vychází *kvadratická* diskriminační funkce. Jsou-li kovarianční matice *shodné* ($S_1 = S_2 = S$), redukuje se na *lineární*

$$g(x) = (\mu_1 - \mu_2)^\top S^{-1}x - \frac{1}{2}(\mu_1 - \mu_2)^\top S^{-1}(\mu_1 + \mu_2) - \ln \frac{P(C_2)}{P(C_1)},$$

a jsou-li navíc obě třídy stejně pravděpodobné a $S = I$, jde o jednoduché srovnávání vzdáleností od středních hodnot. Pro normální rozdělení se tedy hledání diskriminačních funkcí redukuje na **odhad středních hodnot** (výběrovými průměry) a **kovariančních matic** (korigovanými výběrovými rozptyly).

3.2.7 Neuronové sítě a extrémní učící stroje (ELM)

Síť ELM (*Extreme Learning Machine*, G.-B. Huang)

Dopředná síť s *jednou* skrytou vrstvou: n vstupních neuronů, L skrytých, 1 výstupní. Výstup skrytých neuronů $h(x) = [G(a_1, b_1, x), \dots, G(a_L, b_L, x)]$, kde a_i je váhový vektor a b_i bias i -tého neuronu; např. $G(a_i, b_i, x) = g(\langle a_i \cdot x \rangle + b_i)$ (sigmoida) nebo $G(a_i, b_i, x) = g(b_i \|x - a_i\|)$ (RBF). Výstup sítě $f_L(x) = \sum_{i=1}^L \beta_i G(a_i, b_i, x)$.

Klíčová myšlenka: parametry skrytých neuronů *není nutné adaptovat* — mohou být vygenerovány *náhodně*, dokonce bez znalosti trénovacích dat. Pro každou spojitou f a náhodnou posloupnost $\{(a_i, b_i)\}$ platí s pravděpodobností 1

$$\lim_{L \rightarrow \infty} \left\| f - \sum_{i=1}^L \beta_i G(a_i, b_i, \cdot) \right\| = 0$$

při β_i minimalizujících $\|f - f_L\|$.

Maticový model: soustava $\sum_{i=1}^L \beta_i G(a_i, b_i, x_j) = t_j$, $j = 1, \dots, N$ je ekvivalentní $H\beta = T$, kde H je *výstupní matice skryté vrstvy* (j -tý řádek = výstupy skrytých neuronů pro vzor x_j).

Algoritmus učení (tři neiterativní kroky):

- 1: zvol *náhodně* parametry skrytých neuronů (a_i, b_i) , $i = 1, \dots, L$
- 2: spočítej výstupní matici skryté vrstvy H
- 3: spočítej výstupní váhy $\beta = H^+ T$

kde H^+ je Mooreova–Penroseova pseudoinverze H . Stablnější řešení s lepší generalizací dá regularizace — přičtení I/C na diagonálu $H^T H$: $f(x) = h(x)(I/C + H^T H)^{-1} H^T T$.

Výhody ELM: neiterativní procedura ze tří kroků; velmi rychlé trénování — neřeší se lokální minima, inicializace ani přeučení; parametry a_i, b_i jsou nezávislé na datech i na sobě, takže je lze vygenerovat *už před* předložením dat (konvenční techniky musí data „vidět“); funguje s *libovolnou* omezenou po částech spojitou nekonstantní přenosovou funkcí (gradientní algoritmy vyžadují hladké).

3.2.8 Ensemble metody

Bagging (*bootstrapped aggregating*)

Snaží se snížit *rozptyl* klasifikátoru: je-li rozptyl klasifikátoru σ^2 , pak rozptyl průměru k nezávislých a stejně rozdělených (i.i.d.) klasifikátorů klesne na σ^2/k .

Bootstrapping aproximuje i.i.d. klasifikátory: body se vybírají s *opakováním* uniformně z původních dat; vzorek má přibližně stejnou velikost jako původní data, může obsahovat duplikáty a obsahuje podíl

$$1 - \left(1 - \frac{1}{n}\right)^n \approx 1 - \frac{1}{e} = 63,2\%$$

různých bodů z původních dat (pravděpodobnost, že bod ve vzorku *není*, je $(1 - 1/n)^n$). Nakreslí se k nezávislých bootstrapových vzorků velikosti n , na každém se natrénuje klasifikátor a pro testovací vzor se predikce určí *většinovým hlasem*.

Vhodnost: rozhodovací stromy jsou pro bagging ideální — mají *nízké zkreslení* a *vysoký rozptyl* (jsou-li dostatečně hluboké). **Omezení:** bagging *nesnižuje zkreslení* modelu; je-li zkreslení hlavním zdrojem chyby, může přesnost i mírně zhoršit kvůli korelacím mezi komponentami (a tedy porušenému i.i.d. předpokladu).

Náhodné lesy (*random forests*)

Mají-li k klasifikátorů s rozptylem σ^2 vzájemnou *pozitivní korelaci* ρ , je rozptyl zprůměrované predikce

$$\rho\sigma^2 + \frac{(1 - \rho)\sigma^2}{k}.$$

Člen $\rho\sigma^2$ je *nezávislý* na počtu komponent k — právě on omezuje přínos baggingu. Bootstrapo-

vané stromy přitom bývají pozitivně korelované.

Náhodný les je ensemble stromů, do jejichž *konstrukce* je vložena náhodnost, aby byly komponenty méně korelované. Dvě cesty: (1) **bagging** — stromy se trénují na bootstrapových vzorcích; (2) **omezený počet příznaků** — v každém uzlu se předloží *náhodná podmnožina* m příznaků a informační zisk se počítá jen na ní. Druhá cesta navíc zrychluje trénování a stromy není nutné prořezávat; snížený rozptyl nezhoršuje zkreslení. Výstup lesa je většinový hlas.

Algoritmus: pro každý z N stromů vytvoř bootstrapový vzorek a nad ním trénuj strom tak, že v každém uzlu vybereš náhodně m příznaků, spočítáš informační zisk jen na nich a vybereš optimální.

Parametry: $m \approx \sqrt{\text{počet příznaků}}$ (lesy na něm nejsou příliš citlivé); počet stromů — lze pokračovat, dokud chyba klesá.

Boosting a AdaBoost (Freund & Schapire, 1996)

Princip: každý trénovací vzor má *váhu*, klasifikátory se trénují s těmito vahami a váhy se iterativně upravují podle výkonu — budoucí modely tedy *závisí na předchozích* (tentýž algoritmus, jinak vážený trénovací soubor). **Idea:** zvýšit relativní váhu *nesprávně klasifikovaných* vzorů, a tak se v dalších iteracích soustředit na ně; vážená kombinace takové posloupnosti má nižší *zkreslení* (bagging naopak snižuje rozptyl).

ADABOOST(data D , bazový klasifikátor A , max. počet kol T):

- 1: $t \leftarrow 0$; pro každý vzor i inicializuj $W_1(i) = 1/n$
- 2: **repeat**
- 3: $t \leftarrow t + 1$
- 4: urči váženou chybu ϵ_t na D , aplikuje-li se A na data s vahami $W_t(\cdot)$
- 5: $\alpha_t \leftarrow \frac{1}{2} \ln((1 - \epsilon_t)/\epsilon_t)$
- 6: **for** každý *nesprávně* klasifikovaný $X_i \in D$ **do**
- 7: $W_{t+1}(i) \leftarrow W_t(i)e^{\alpha_t}$
- 8: **end for**
- 9: **for** každý *správně* klasifikovaný $X_i \in D$ **do**
- 10: $W_{t+1}(i) \leftarrow W_t(i)e^{-\alpha_t}$
- 11: **end for**
- 12: normalizuj $W_{t+1}(i) \leftarrow W_{t+1}(i) / \sum_j W_{t+1}(j)$
- 13: **until** $t \geq T$ **nebo** $\epsilon_t = 0$ **nebo** $\epsilon_t \geq 0,5$
- 14: klasifikuj testovací vzory ensemblem s vahami komponent α_t

ϵ_t je podíl nesprávně predikovaných trénovacích vzorů (po vážení W_t) modelem v t -té iteraci.

Vlastnosti: *posloupnost* klasifikátorů téhož bazového algoritmu, každý závisí na předchozím a soustředí se na jeho chyby; při testování se výsledky kombinují. **Citlivost na šum:** při mnoha odlehklých hodnotách může důraz na „obtížné“ příklady výkon zhoršit.

Náhodné lesy	Boosting
rychlé — mohou běžet <i>paralelně</i> a v každém uzlu prohledávají malou množinu příznaků	vyčerpávající — v každé fázi prohledává <i>celou</i> množinu příznaků a každá fáze závisí na předchozí
stromy jsou levné na trénování, lze jich ve stejném čase vypěstovat více i na velkých a složitých datech	musí běžet <i>sekvenčně</i> , což může být nákladné
překvapivě dobré výsledky vzhledem k malé části prostoru problému, kterou každý strom vidí	při <i>stejném</i> počtu stromů boosting náhodné lesy překonává (lesy v každé fázi prohledávají jen podmnožinu)

3.2.9 Srovnání klasifikačních metod

Metoda	Srozumitel- nost	Přesnost	Rychlost	Poznámka
Rozhodovací strom	vysoká	střední	vysoká	obdélníkové oblasti, nutné prořezávání, ignoruje korelace atributů
Pravidla z C4.5	nejvyšší	střední	vysoká	prořezávání pravidel je radikálnější než stromů
Naivní Bayes	střední	překvapivě dobrá	velmi vysoká	zvládne nekompletní vzory; problém s nulovými pravděpodobnostmi
SVM	velmi nízká	vysoká	nízká (trénink)	nejlepší pro vysokorozměrná data (text); jen 2 třídy, jen reálný prostor
Logistická regrese	vysoká	střední	vysoká	pravděpodobnostní výstup, interpretovatelné koeficienty stačí odhadnout μ_j a S_j
Diskriminační analýza	střední	dobrá při normalitě	vysoká	
Neuronová síť / ELM	velmi nízká	vysoká	ELM velmi vysoká	ELM negeneruje lokální minima, netrénuje skrytou vrstvu
Náhodný les	nízká	velmi vysoká	vysoká (paralelně)	snižuje rozptyl, nezhoršuje zkreslení
Boosting / AdaBoost	nízká	velmi vysoká	nízká (sekvencně)	snižuje zkreslení; citlivý na šum a odlehlé hodnoty

3.3 Klastrová analýza

3.3.1 Formulace úlohy a míry vzdálenosti

Klastrová analýza (shlukování, *cluster analysis*) rozděljuje pozorované vzory do skupin (klastřů, shluků) vzájemně podobných vzorů. **Předpoklad:** umíme měřit *vzdálenost* mezi vzory. Každý vzor je charakterizován m numerickými veličinami.

Míry vzdálenosti

Pro vzory $x_1 = (x_{11}, \dots, x_{1m})$ a $x_2 = (x_{21}, \dots, x_{2m})$:

1. **Hammingova** (*Manhattan*, L_1): $d_H(x_1, x_2) = \sum_{i=1}^m |x_{1i} - x_{2i}|$
2. **Euklidovská** (L_2): $d_E(x_1, x_2) = \sqrt{\sum_{i=1}^m (x_{1i} - x_{2i})^2}$
3. **Čebyševova** (L_∞): $d_C(x_1, x_2) = \max_i |x_{1i} - x_{2i}|$
4. **Minkowského metrika** (L_q) — předchozí tři jsou jejími speciálními případy: $d_q(x_1, x_2) = \left(\sum_{i=1}^m |x_{1i} - x_{2i}|^q \right)^{1/q}$

Platí $d_H = d_1$, $d_E = d_2$, $d_C = \lim_{q \rightarrow \infty} d_q$; pro vzor $(0, \dots, 0)$ a vzor jednotkové vzdálenosti dávají všechny tři metriky hodnotu 1.

Volba metriky závisí na zúčastněných veličinách a jejich rozsahu $\Rightarrow$ veličiny je třeba **normalizovat** (dělením průměrem, směrodatnou odchylkou, rozsahem max – min, ...; viz kap. 2). Uvedené metriky předpokládají *stejný rozptyl* všech veličin. Mají-li veličiny *různý* rozptyl, používá se

Mahalanobisova vzdálenost

$$d_M^2(x_1, x_2) = (x_1 - x_2)^\top S^{-1} (x_1 - x_2),$$

kde S je kovarianční matice. Zohledňuje jak různé rozptyly, tak korelace mezi veličinami (pro $S = I$ se redukuje na kvadrát euklidovské vzdálenosti).

Vzdálenost mezi dvěma klastry C_k a C_l

Metoda nejbližšího souseda (*single linkage*) — minimum ze vzdáleností jejich prvků: $D(C_k, C_l) = \min_{x_i, x_j} d(x_i, x_j)$, $x_i \in C_k$, $x_j \in C_l$.

Metoda nejvzdálenějšího souseda (*complete linkage*) — maximum: $D(C_k, C_l) = \max_{x_i, x_j} d(x_i, x_j)$.

Metoda průměrné vzdálenosti (*average linkage*) — průměr vzdáleností mezi vzory (n_k , n_l jsou počty vzorů v klastrech):

$$D(C_k, C_l) = \frac{1}{n_k n_l} \sum_{i=1}^{n_k} \sum_{j=1}^{n_l} d(x_i, x_j).$$

Centroidní metoda — vzdálenost středů klastrů: $D(C_k, C_l) = d(c_k, c_l)$, kde c_k , c_l jsou středy (centroidy) klastrů.

Centroid je střed klastru — „prototyp“, který jej reprezentuje. Podle tvaru klastru a metriky může mít tentýž klaster i více centroidů současně.

3.3.2 Metoda k -means

Algoritmus k -means (Lloyd, 1982)

```
1: rozděl vzory náhodně do  $k$  klastrů  $C_1, \dots, C_k$  (disjunktních, v sjednocení všechny vzory)
2: urči centroidy všech klastrů v aktuálním rozdělení, např.  $c_k = \frac{1}{|C_k|} \sum_{x \in C_k} x$ 
3: for každý vzor  $x$  do
4:   urči vzdálenosti  $d(x, c_k)$  pro  $1 \leq k \leq K$ 
5:   nechť  $d(x, c_l) = \min_k d(x, c_k)$ 
6:   if  $x$  nepatří do klastru  $l$  then
7:     přesuň  $x$  do klastru  $l$ 
8:   end if
9: end for
10: if došlo k přesunu then
11:   goto krok 2
12: else
13:   konec
14: end if
```

Po skončení jsou klastry reprezentovány svými centroidy.

Varianty: při počátečním rozdělení prohlásit za centroidy *prvních k vzorů* (eliminuje krok 2 v první iteraci); upravovat centroidy *po každém* přesunu (v cyklu, nikoli po jeho skončení).

Rozšíření Lloydova algoritmu. Střídavé minimalizační kroky neposkytují záruku aproximace, přesto Lloydův algoritmus *nikdy nezvýší* cenu počátečního shlukování $\Rightarrow$ vyplatí se dodat algoritmu *prokazatelně dobrou inicializaci*:

- **k -means++** (Arthur, Vassilvitskii, 2007) — vyber k z P vzorů s pravděpodobností proporcionální kvadrátu vzdálenosti k nejbližšímu už existujícímu centroidu: $\frac{d^2(x_i, c)}{\sum_{j=1}^P d^2(x_j, c)}$.
- **LocalSearch++** (Lattanzi, Sohler, 2019) — nejprve k -means++ pro volbu k počátečních centroidů; poté se vzorkují nové vzory s analogickou pravděpodobností a nahrazují existující centroidy, pokud tím sníží celkovou kvadratickou vzdálenost vzorů k jejich nejbližším centroidům.

Metoda k -medians používá jako účelovou funkci Manhattanovu vzdálenost, $d(x_i, c) = \|x_i - c\|_1$. Lze ukázat, že optimálním reprezentantem c je pak *medián* datových bodů v klastru *podél každé dimenze*. Protože se medián volí v každé dimenzi nezávisle, výsledný m -rozměrný reprezentant obvykle *nepatří* do původní datové množiny. k -medians volí reprezentanty *robustněji* než k -means —

medián není tak citlivý na odlehlé hodnoty jako průměr.

3.3.3 Metoda k -medoids, CLARA a CLARANS

Algoritmus k -medoids

Pro datovou množinu D o n d -rozměrných bodech $x_1, \dots, x_n$ se hledá k reprezentantů $y_1, \dots, y_k$ z původní databáze D (počet k zadává uživatel), které minimalizují účelovou funkci danou součtem vzdáleností bodů k jejich nejbližším reprezentantům:

$$O = \sum_{i=1}^n \min_j d(x_i, y_j).$$

Časová složitost jedné iterace je $O(knd)$; obvykle stačí malý konstantní počet iterací.

Proč reprezentanty z D ? (1) Centroidy k -means mohou být zkresleny odlehlými hodnotami a ocitnout se v prázdných oblastech nereprezentativních pro klastr, což může vést k částečnému splynutí klastrů. (2) Pro složitá data (množina časových řad různé délky) může být optimální centrální reprezentant obtížně spočitatelný. k -medoids stačí vhodná funkce podobnosti, lze je tedy definovat pro libovolný typ dat.

Postup: *hill-climbing* — množina reprezentantů S se inicializuje body z D a iterativně se zlepšuje výměnou bodu z S za datový bod z D . Strategie výměny:

1. vyzkoušet všech $|S| \cdot |D|$ možností a vybrat nejlepší — *extrémně drahé*;
2. použít náhodně vybranou množinu r párů (x, y) ($x \in D, y \in S$) a vyměnit nejlepší z nich. Vyžaduje čas proporcionální $r \cdot |D|$; algoritmus konverguje, když se účelová funkce nezlepší, nebo je-li průměrné zlepšení pod uživatelem zadaným prahem.

k -medoids je *pomalejší* než k -means, ale použitelný na různé typy dat.

Škálovatelné varianty: CLARA a CLARANS

Škálovatelné implementace k -medoids pro data, která se nevejdou do hlavní paměti. Dědí výhody i nevýhody bazového algoritmu (generalizovatelnost na různé typy dat, ale vysokou výpočetní složitost).

CLARA (*Clustering LARge Applications*) vychází z varianty PAM (*Partitioning Around Medoids*), která testuje na výměnu všech $k(n-k)$ párů medoid–nemedoid a vymění nejlepší z nich, až do konvergence k lokálnímu optimu — $O(kn^2)$ výpočtů vzdálenosti, tj. $O(kn^2d)$ času na iteraci, *značně drahé*. CLARA proto PAM aplikuje na vzorek velikosti $f \cdot n$ ($f \ll 1$) a zbylé body přiřadí k nalezeným medoidům; postup se opakuje nad nezávisle volenými vzorky a vybere se nejlepší shlukování. Iterace pak stojí $O(kf^2n^2d + k(n-k))$ — pro malá f o řády rychleji. **Hlavní problém:** vzorek nemusí obsahovat dobrou volbu medoidů.

CLARANS (*... based on RANdomized Search*) pracuje s *plnými* daty, čímž se problému špatných vzorků vyhýbá. Testuje výměny náhodných medoidů za náhodné nemedoidy; zlepši-li se kvalita, výměna se provede definitivně, jinak roste počítadlo neúspěchů — lokální optimum je nalezeno po *MaxAttempt* neúspěšných pokusech. Celé se opakuje *MaxLocal*-krát. CLARANS prozkoumá *větší rozmanitost* prostoru řešení než CLARA.

3.3.4 Hierarchické shlukování

Aglomerativní hierarchické shlukování

Přístup „zdola nahoru“ (*bottom-up*).

Inicializace: (1) určí vzájemné vzdálenosti mezi všemi vzory; (2) přiřadí každý vzor do samostatného klastru.

Hlavní cyklus: dokud je klastrů více než jeden: (1) najdi dva vzájemně nejbližší klustry a slouč je; (2) pro nový klastr spočítej jeho vzdálenost od ostatních klastrů.

Výsledek se zobrazuje jako **dendrogram** — ukazuje (zleva doprava) postupné slučování klastrů; výška spojení odpovídá vzdálenosti, při níž ke sloučení došlo. *Optimální počet klastrů není znám předem* — volí se řezem dendrogramu ve vhodné výšce.

Divizivní hierarchické shlukování („shora dolů“) postupuje obráceně: začíná jedním klastrem obsahujícím všechny vzory a ten postupně dělí. Nejznámějším příkladem v kontextu sítí je Girvanové-Newmanův algoritmus (kap. 6).

CURE (*Clustering Using REpresentatives*)

Aglomerativní hierarchický algoritmus, *velmi rychlý* a schopný odhalit klastry *libovolného tvaru* (na rozdíl např. od CLARANS). Postup:

1. Vyber vzorek s bodů z databáze D o n bodech.
2. Rozděl s bodů na p částí velikosti s/p .
3. Každou část shlukuj *nezávisle* hierarchickým slučováním do k' klastrů; celkový počet $k' \cdot p$ klastrů přes všechny části je stále větší než uživatelem požadované k .
4. Nad $k' \cdot p$ klastry proveď hierarchické shlukování až na požadovaných k .
5. Každý z $(n - s)$ nevzorkovaných bodů přiřaď ke klastru s nejbližším reprezentantem.

3.3.5 Vektorová kvantizace: algoritmus LVQ

LVQ — *Learning Vector Quantization*

Slouží pro **shlukování s učitelem** (třídy jsou označeny C):

- 1: inicializuj všechny váhové vektory $w_j(0)$, rychlosti učení $\mu(0)$, $k \leftarrow 0$
- 2: **while** není splněna zastavovací podmínka **do**
- 3: **for** každý trénovací vzor x **do**
- 4: urči index $j = q$ váhového vektoru s *minimální* euklidovskou vzdáleností, tj. $\min_j \|x - w_j\|_2^2$
- 5: **if** třída x souhlasí s třídou w_q **then**
- 6: $w_q(k+1) \leftarrow w_q(k) + \mu(k)(x - w_q(k))$ ▷ přitáhni
- 7: **else**
- 8: $w_q(k+1) \leftarrow w_q(k) - \mu(k)(x - w_q(k))$ ▷ odtlač
- 9: **end if**
- 10: **end for**
- 11: $k \leftarrow k + 1$; sniž rychlost učení, např. $\mu(k) = \mu(k-1)/(k+1)$ pro $k > 0$
- 12: **end while**

Váhové vektory se obvykle inicializují *prvními m vektory* trénovací množiny (musí zahrnovat vzory ze všech tříd) — tím se neurony automaticky „kalibrují“ s třídami.

3.3.6 Mřížkové a hustotní metody

Mřížkové metody (např. MAFA)

- Data se diskretizují do p (ekvidistantních) intervalů, což pro d -rozměrná data dá p^d hyperkrychlí.
- Výsledné hyperkrychle jsou stavebními bloky pro shlukování.
- Pomocí prahu hustoty τ se identifikují *husté* hyperkrychle (alespoň τ bodů).
- Klastř libovolného tvaru se skládá z více hustých oblastí, které jsou *propojeny*; dvě mřížkové oblasti jsou propojené, sdílejí-li stěnu.

Cíl: určit klastry jako husté vzájemně propojené oblasti. Hustým mřížkovým buňkám odpovídají uzly grafu, hrany reprezentují sousedskou propojenost; data pokrytá buňkami z komponent souvislosti tohoto grafu tvoří výsledné klastry.

DBSCAN — *Density-Based Spatial Clustering of Applications with Noise*

Stavebními bloky jsou místo mřížkových buněk *jednotlivé datové body*, resp. kruhové oblasti okolo nich; hustota je dána počtem bodů ležících v jejich radiu ε (včetně bodu samotného):

1. **Jádrový bod** (*core point*) — kulová oblast o radiu ε okolo něj obsahuje alespoň τ datových bodů.
2. **Hraniční bod** (*border point*) — oblast obsahuje méně než τ bodů, ale zároveň alespoň jeden jádrový bod ve vzdálenosti ε .
3. **Šumový bod** (*noise point*) — není ani jádrový, ani hraniční.

Algoritmus:

1. Urči jádrové, hraniční a šumové body.
2. Zkonstruuji graf propojenosti, kde každý uzel odpovídá jádrovému bodu; hrana mezi dvěma jádrovými body existuje *právě když* leží od sebe ve vzdálenosti nejvýše ε .
3. Najdi všechny komponenty souvislosti tohoto grafu — odpovídají klastrům (postaveným na jádrových bodech). Hraniční body se přiřadí ke klastru, s nímž mají nejvyšší úroveň propojenosti; šumové body se ohlásí jako *odlehle hodnoty*.

Metoda	Tvar klastrů	Počet klastrů	Odlehle hodnoty	Poznámka
k -means	kulovité	zadán	citlivá	rychlá; závislá na inicializaci $\rightarrow k$ -means++
k -medians	kulovité	zadán	robustnější	medián po dimenzích; reprezentant není z dat
k -medoids	kulovité	zadán	robustní	reprezentanti z dat; libovolný typ dat; pomalejší
CLARA / CLARANS	kulovité	zadán	robustní	škálovatelné k -medoids (vzorkování / náhodné prohledávání)
Hierarchické	podle metriky spojování	určí se z dendrogramu	citlivé	bez nutnosti zadat k předem; $O(n^2)$ – $O(n^3)$
CURE	libovolný	zadán	robustní	vzorkování + hierarchické slučování po částech
LVQ	kulovité	dán počtem neuronů	—	shlukování s učitelem
Mřížkové (MAFIA)	libovolný	vyplyne	šum vypadne	citlivé na granularitu mřížky
DBSCAN	libovolný	vyplyne	detekuje je	parametry ε, τ ; problém s různou hustotou klastrů

3.4 Shrnutí ke zkoušce

Asociační pravidla.

- **Support** = podíl transakcí s i i j ; **confidence** = podíl transakcí s i i j mezi transakcemi s i ; **lift** = $p(i \wedge j) / (p(i)p(j))$. $\text{Lift} < 1 \Rightarrow$ pravidlo horší než náhoda, negace závěru může být lepší. Umět spočítat všechny tři z malé tabulky transakcí.
- **Apriori** využívá *uzavřenost dolů* (každá podmnožina frekventované množiny je frekventovaná), prohledává *do šířky*; APRIORI-GEN = krok spojení (kombinace shodné v $k - 2$ kategoriích) + krok prořezání (chybí-li podkombinace délky $k - 1$). Prostor pravidel je $O(2^m)$, MBA produkuje *nadměrné množství pravidel*.
- **Taxonomie a virtuální položky** řeší volbu úrovně položek; vzácné položky výše v taxonomii, časté níže; virtuální položky nesou informaci o transakci (den, čas, zákazník) — pozor na redundanci pravidel.
- **MS-Apriori**: problém vzácných položek $\rightarrow$ každá položka má vlastní MIS, minsup pravidla je *minimum* MIS jeho položek, plus omezení rozdílu supportů φ . *Uzavřenost dolů přestává platit* $\Rightarrow$ položky se seřadí vzestupně podle MIS, používá se množina semen L (ne F_1) a **tailCount** pro generování pravidel. Umět uvést protipříklad k uzavřenosti dolů.

- **CAR**: transakce označované třídou, pravidlo $X \rightarrow y$; dolují se přímo v jednom kroku přes pravidlové položky (*condset*, y); lze zadat různé minsupy různým třídám (101 % = zakázat třídu).
- **Sekvenční vzory**: sekvence = uspořádaný seznam množin položek; *velikost* = počet prvků, *délka* = počet položek; podsekvence přes vnořené inkluze. Algoritmus **GSP** pracuje obdobně jako Apriori. Pozor: $\langle \{3\}\{8\} \rangle$ a $\langle \{3, 8\} \rangle$ se navzájem *neobsahují*.
- **FP-Growth**: 2 průchody daty, žádné generování kandidátů; FP-strom sdílí *prefixy* (pořadí položek podle klesajícího supportu — heuristika), spojové seznamy položek; extrakce zdola nahoru *rozděl a panuj* přes *prefixové podstromy* a *podmíněné FP-stromy* (aktualizovat počítadla $\rightarrow$ odstranit uzly položky $\rightarrow$ odstranit nefrekventované položky). Nejhorší případ: unikátní transakce $\Rightarrow$ strom větší než data.

Učení s učitelem.

- **Rozhodovací stromy**: TDIDT (rozděl a panuj), volba atributu podle *minimální vážené entropie* $H(A) = \sum_v \frac{|A(v)|}{|D|} H(A(v))$, ekvivalentně maximálního *informačního zisku*. Umět projít příklad s úvěrem (příjem 0,5747; konto 0,6667; pohlaví 0,9183; nezaměstnaný 0,825) a převést strom na pravidla. Složitost indukce $O(np \log p)$, klasifikace $O(q \log p)$.
- **ID3** (Quinlan 1986) — hladový, informační zisk. **C4.5** (1993) — chybějící a spojitá data, prořezávání validací (*reduced-error pruning*, *subtree raising*), *rule post-pruning*, odhad přesnosti dolní mezí $acc - 1,96 \sqrt{acc(1 - acc)/n}$, *poměrný* informační zisk (penalizuje nadměrné větvení). **C5.0** — komerční, boosting. **CART** — *binární* stromy, Gini index $G(v_i) = 1 - \sum_j p_j^2$ (nižší = lepší), kritérium $\Phi = 2P_L P_R \sum_j |P(C_j|t_L) - P(C_j|t_R)|$. **CHAID** — χ^2 , automatické seskupování hodnot kategoriálních atributů.
- **Bayes**: $H_{MAP} = \arg \max_H P(E | H)P(H)$ (jmenovatel lze zanedbat); *naivní* předpoklad podmíněné nezávislosti $\Rightarrow \arg \max_{H_t} P(H_t) \prod_i P(E_i | H_t)$. Umí nekompletní vzory; problém nulových pravděpodobností. Umět spočítat příklad (0,1042 vs. 0,0416).
- **SVM**: maximální okraj $2/\|w\|$, primární úloha $\min \frac{\langle w, w \rangle}{2}$ za podmínek $y_i(\langle w, x_i \rangle + b) \geq 1$; Kuhn–Tuckerovy podmínky jsou pro konvexní úlohu s lineárními omezeními nutné i *postačující*; $\alpha_i > 0$ jen pro *podpůrné vektory*; Wolfeho duál. **Kernelový trik**: duál potřebuje jen skalární součiny $\Rightarrow K(x, z) = \langle \phi(x), \phi(z) \rangle$, ϕ nikdy nevyčíslíme (Mercerova věta). Jen 2 třídy, jen reálný prostor, neinterpretovatelné.
- **Logistická regrese**: $\ln \frac{p}{1-p} = \beta^\top x$, tedy $p = \sigma(z) = 1/(1 + e^{-z})$; učení maximální věrohodností / minimalizací křížové entropie; $\sigma' = \sigma(1 - \sigma) \Rightarrow$ adaptační pravidlo $\Delta \beta_j = \eta \sum_i (y_i - \sigma(z_i)) x_{ij}$.
- **Diskriminační analýza**: $g_j(x)$ pro každou třídu, klasifikuje se maximem; pro dvě třídy stačí znaménko $g = g_1 - g_2$; optimální je $g_j \propto P(C_j | x)$; normální rozdělení $\rightarrow$ kvadratická funkce, při shodných kovariančních maticích *lineární* $\Rightarrow$ stačí odhadnout μ_j a S .
- **ELM**: náhodné parametry skrytých neuronů (i bez znalosti dat), výstupní váhy *jednou* pseudoinverzí $\beta = H^+ T$; regularizace I/C na diagonále. Rychlé, bez lokálních minim, funguje s libovolnou omezenou po částech spojitou přenosovou funkcí.
- **Ensemble**: *bagging* snižuje *rozptyl* ($\sigma^2 \rightarrow \sigma^2/k$ pro i.i.d.), bootstrap obsahuje $\approx 63,2\%$ různých bodů ($1 - 1/e$), stromy jsou ideální komponenty (nízké zkreslení, vysoký rozptyl); zkreslení nesnižuje. *Náhodné lesy* řeší korelaci komponent — rozptyl je $\rho \sigma^2 + (1 - \rho) \sigma^2/k$, první člen na k nezávisí; náhodnost přes bootstrap a náhodnou podmnožinu $m \approx \sqrt{\# \text{příznaků}} \text{ příznaků}$ v každém uzlu. *Boosting/AdaBoost* snižuje *zkreslení*, váhy chybně klasifikovaných vzorů rostou, $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$, běží *sekvenčně*, je citlivý na šum. Umět srovnat lesy vs. boosting (paralelní a levné vs. vyčerpávající a přesnější při stejném počtu stromů).

Klastrová analýza.

- **Metriky**: Hammingova/Manhattan (L_1), euklidovská (L_2), Čebyševova (L_∞), Minkowského (L_q , ostatní jsou její speciální případy); **Mahalanobisova** $d_M^2 = (x_1 - x_2)^\top S^{-1}(x_1 - x_2)$ pro veličiny s různým rozptylem. Před shlukováním *normalizovat*.
- **Vzdálenost klastrů**: nejbližší soused (min), nejvzdálenější soused (max), průměrná vzdálenost, centroidní metoda.

- ***k*-means** (Lloyd 1982): náhodné rozdělení → centroidy → přesuny → opakuj, dokud dochází k přesunům. Nikdy nezvýší cenu, ale bez záruky aproximace ⇒ ***k*-means++** (pravděpodobnost $\propto$ kvadrát vzdálenosti k nejbližšímu centroidu), **LocalSearch++**.
- ***k*-medians** (Manhattan, medián po dimenzích, robustnější) vs. ***k*-medoids** (reprezentanti z *dat*, hill-climbing s výměnami, $O(knd)$ na iteraci, libovolný typ dat). **PAM** testuje všech $k(n-k)$ výměn ($O(kn^2d)$); **CLARA** vzorkuje ($O(kf^2n^2d + k(n-k))$, riziko špatného vzorku), **CLARANS** prohledává náhodně nad plnými daty (*MaxAttempt*, *MaxLocal*).
- **Hierarchické shlukování** zdola nahoru: každý vzor svůj klastř → slučuj dva nejbližší; výstupem **dendrogram**, počet klastřů se volí až řezem. **CURE**: vzorek → p částí → nezávisle hierarchicky na k' klastřů → hierarchicky na k → přiřaď zbytek; rychlé, libovolný tvar klastřů.
- **LVQ**: shlukování s učitelem — vítězný váhový vektor se ke vzoru přitáhne při souhlasu tříd a odtlačí při nesouhlasu; μ klesá jako $\mu(k-1)/(k+1)$.
- **Mřížkové metody** (MAFIA): p^d hyperkrychlí, prah hustoty τ , klastř jako propojené husté oblasti (komponenty souvislosti grafu buněk). **DBSCAN**: *jádrový* bod ($\geq \tau$ bodů v radiu ε), *hraniční* ($< \tau$, ale jádrový bod do ε), *šumový*; klastř = komponenty souvislosti grafu jádrových bodů, šumové body se hlásí jako odlehlé. Umí klastř *libovolného tvaru* a sama detekuje odlehlé hodnoty.

4 Charakteristická a diskriminační pravidla a jejich zajímavost

Věta okruhu žádá *metody pro extrakci charakteristických diskriminačních pravidel a měření jejich zajímavosti*. Kapitola je postavena především na slidech kurzu *Internet a klasifikační metody* (Holeňa), hlavně 5. přednášky *Kdy je klasifikace srozumitelná uživateli?*: proč pravidla (odd. 4.1), extrakce pravidel z klasifikačních stromů (odd. 4.3) a evolucí (odd. 4.4), observační pravidla (odd. 4.5), statistický pohled (odd. 4.6), měření zajímavosti (odd. 4.7) a aplikace (odd. 4.8). Pojmy *charakteristické* a *diskriminační* pravidlo s mírami t-weight a d-weight (odd. 4.2) jsou doplněny podle Han–Kamber, protože je okruh jmenuje výslovně.

Zdroje kapitoly

Ze šesti přednášek kurzu *Internet a klasifikační metody* (ikm1–ikm6) je pro tuto kapitolu klíčová ikm5 (srozumitelnost klasifikace: pravidla, jejich extrakce a observační kalkul); dále se zde využívá ikm1 (aplikace: spam, doporučování, hrozby v síti), ikm2 (míry kvality binární klasifikace) a ikm3 (diskriminační analýza). Látka ikm4 (SVM: maximalizace pásu, opěrné vektory, kernel trick) a ikm6 (týmy klasifikátorů: bagging, boosting, náhodné lesy) se kryje s kap. 3, matice záměn a ROC/AUC z ikm2 s kap. 5 — zpracovány jsou tam. Slidy nmr1–nmr5 z téže složky patří jinému (volitelnému) Holeňovu kurzu a látku kapitoly nepokrývají. Podle Han–Kamber je jen odd. 4.2; regresní a diskriminační analýzu dokládají i slidy NDBI023 (*Data Analysis*).

4.1 Pravidla jako srozumitelná forma klasifikace

Klasifikátor je matematicky zobrazení $f: X \rightarrow \{C_1, \dots, C_m\}$ z prostoru příznaků do konečné množiny tříd; přesněji $f: X \times \Theta \rightarrow \{C_1, \dots, C_m\}$, kde učení znamená volbu parametrů $\theta \in \Theta$ podle zkušenosti s kvalitou klasifikace při předchozích volbách (odd. 3.2). Konkrétní naučený předpis — třeba znaménko $\langle w, x \rangle + b$ u SVM nebo složená nelineární funkce u neuronové sítě — je ale pro běžného uživatele málo srozumitelný. Popisuje-li binární klasifikátor $f: X \rightarrow \{1, 0\}$ pravdivost nějaké implikace $\varphi \Rightarrow \psi$ či ekvivalence $\varphi \Leftrightarrow \psi$ mezi vlastnostmi objektu, stačí místo celého f znát toto *pravidlo*: pravidlo logiky je srozumitelnější než matematická formule.

Booleovská a fuzzy pravidla

Booleovská pravidla pracují s pravdivostními hodnotami $t(\varphi) \in \{0, 1\}$: *ekvivalence* $\varphi \Leftrightarrow \psi$ je pravdivá, právě když $t(\varphi) = t(\psi)$; *implikace* $\varphi \Rightarrow \psi$ je pravdivá, právě když $t(\varphi) = 0$, nebo $t(\varphi) = t(\psi) = 1$. Pravidla se typicky uplatňují na objektech, kde antecedent platí ($t(\varphi) = 1$) — tam implikace splývá s ekvivalencí.

Fuzzy pravidla připouštějí stupně pravdivosti $t(\varphi) \in [0, 1]$. Fuzzy implikace je *reziduum* t-normy T :

$$t(\varphi \Rightarrow \psi) = \sup\{c \in [0, 1] : T(t(\varphi), c) \leq t(\psi)\},$$

fuzzy ekvivalence $t(\varphi \Leftrightarrow \psi) = T(t(\varphi \Rightarrow \psi), t(\psi \Rightarrow \varphi))$. Důležité speciální případy: je-li $t(\varphi) \leq t(\psi)$, je $t(\varphi \Rightarrow \psi) = 1$; je-li $t(\varphi) = t(\psi)$, je $t(\varphi \Leftrightarrow \psi) = 1$.

Srozumitelnost je důvod, proč se pravidla používají tam, kde výsledek klasifikace posuzuje člověk: analytik malwaru chce vědět, *proč* je program podezřelý, a doporučovací systémy vysvětlením zvyšují důvěru uživatele v doporučení (odd. 4.8).

4.2 Charakteristická a diskriminační pravidla: t-weight a d-weight

♦ *nad rámec slidů* Oddíl je zpracován podle Han–Kamber — okruh oba druhy pravidel jmenuje výslovně.

Charakterizace vs. diskriminace

Charakterizace dat (*data characterization*) — shrnutí obecných vlastností *cílové třídy* („jak vypadá typický klient s hypotékou?“); výsledkem jsou *charakteristická pravidla*. **Diskriminace**

dat (*data discrimination*) — porovnání cílové třídy s jednou či více *kontrastními třídami* („čím se liší od klienta bez hypotéky?“); výsledkem jsou *diskriminační pravidla*. Vlastnost může být pro cílovou třídu *typická*, a přesto nemít žádnou *rozlišovací sílu* — je-li stejně typická i pro třídu kontrastní.

Pravidla tohoto druhu se získávají *generalizací dat: indukce orientovaná na atributy* (*attribute-oriented induction*, AOI) nahrazuje hodnoty atributů obecnějšími podle koncepčních hierarchií (město → kraj, datum narození → věková kategorie), atributy s mnoha hodnotami bez hierarchie odstraňuje (jméno, telefon) a shodné zobecněné záznamy slučuje s čítačem **count**; totéž provádí operace *roll-up* / *drill-down* nad OLAP kostkou (kap. 1). Nad zobecněnými záznamy se pak definují dvě váhy:

t-weight, d-weight a kvantitativní pravidla

Nechť $q_1, \dots, q_N$ jsou zobecněné záznamy cílové třídy.

Typičnost (t-weight) záznamu q_a :

$$t\text{-weight}(q_a) = \frac{\text{count}(q_a)}{\sum_{i=1}^N \text{count}(q_i)} \in [0, 1],$$

tj. podíl objektů cílové třídy, které q_a pokrývá (součet přes všechny záznamy je 100 %). Vystupuje v **kvantitativním charakteristickém pravidle** (nutná podmínka — implikace z třídy):

$$\forall X \quad \text{target}(X) \Rightarrow \text{cond}_1(X) [t: w_1] \vee \dots \vee \text{cond}_N(X) [t: w_N].$$

Rozlišovací váha (d-weight) záznamu q_a vůči cílové třídě C_t a kontrastním třídám $C_1, \dots, C_m$:

$$d\text{-weight}(q_a) = \frac{\text{count}(q_a \in C_t)}{\text{count}(q_a \in C_t) + \sum_{j=1}^m \text{count}(q_a \in C_j)} \in [0, 1],$$

tj. podíl objektů pokrytých záznamem q_a , které patří do cílové třídy. Vystupuje v **kvantitativním diskriminačním pravidle** (postačující podmínka — implikace do třídy):

$$\forall X \quad \text{target}(X) \Leftarrow \text{cond}(X) [d: w].$$

Kvantitativní popisné pravidlo kombinuje obojí ($\Leftrightarrow, [t: w, d: w']$).

Příklad — klienti s hypotékou (200) vs. bez hypotéky (800)

Primární relace po generalizaci:

Věk	Příjem	Region	počet cíl	počet kontrast	t-weight (cíl)	d-weight
30–40	vysoký	Praha	90	10	45 %	90 %
30–40	střední	Praha	50	150	25 %	25 %
40–50	vysoký	mimo Prahu	40	160	20 %	20 %
20–30	nízký	mimo Prahu	20	480	10 %	4 %

Výpočet pro první záznam: $t = 90/200 = 45\%$, $d = 90/(90 + 10) = 90\%$.

Klasická past: 3. řádek má $t = 20\%$, ale $d = 40/200 = 20\%$ je *přesně* apriorní podíl cílové třídy ($200/1000 = 20\%$) — rozlišovací síla je nulová; 4. řádek s $d = 4\%$ hluboko pod apriorním podílem hypotéku spíše *vyklučuje*. Vysoká typičnost tedy sama o sobě neznamena rozlišovací sílu: d-weight je vždy třeba srovnávat s apriorním podílem třídy.

4.3 Extrakce pravidel z klasifikačních stromů

Nejpřímější metoda extrakce pravidel vychází z klasifikačního stromu: uzly binárního stromu testují booleovské podmínky (typicky $x_i \leq c$, tedy řezy kolmé na souřadnicové osy), vstup podle výsledku testu propadá doleva či doprava a každý list odpovídá jedině třídě.

Pravidla ze stromu

- Každé cestě kořen $\rightarrow$ list odpovídá *konjunkce* podmínek testovaných na cestě; třída listu dává konsekvant: $(\text{cond}_1 \wedge \dots \wedge \text{cond}_k) \Rightarrow C_j$.
- Cesty do listů *téže* třídy se spojí *disjunkcí* — třída je sjednocením obdélníkových oblastí, které jednotlivé cesty vymezují.

Učení stromu je optimalizace dělení v uzlu vůči volbě proměnné a dělicího bodu (podprostory spojitých vstupů, podmnožiny diskretních); dvě nejčastěji optimalizovaná kritéria jsou *informační zisk* $IG(\text{rodič}; L, P) = H_{\text{rodič}} - \left(\frac{n_L}{n} H_L + \frac{n_P}{n} H_P\right)$ a *Giniho index nečistoty* $1 - \sum_j p_j^2$; podrobně (TDIDT, ID3, C4.5, CART) odd. 3.2. Nové vstupy se klasifikují průchodem uzlových testů; v listech se předpokládá, že rozdělení nových vstupů odpovídá rozdělení učicích dat.

Prořezávání (*pruning*) snižuje přeučení a současně extrahovaná pravidla *zkracuje* (srov. prořezávání pravidel v C4.5, odd. 3.2). **Zobecněná dělení** — obecná nadrovina či kvadratická plocha místo řezu kolmého na osu — zlepšují aproximaci hranice tříd, ale snižují srozumitelnost pravidel získaných konjunkcí podmínek.

4.4 Evoluční konstrukce pravidel

Pravidla lze konstruovat i genetickým algoritmem — informatickou aplikací biologického vývoje druhů: křížením a mutací řetězce (genomu) kódujícího pravidlo se výrazněji posilují žádoucí vlastnosti, zde míry kvality klasifikace (přesnost AC, precision PR, TPr, TNr či AUC — odd. 4.7). Postup je vhodný, jsou-li antecedent i konsekvant konjunkcemi malého počtu atomů. Všechny evoluční algoritmy jsou *populační*; podle toho, co je jedincem populace, se rozlišují dva přístupy:

Přístup	Jedinec	Vlastnosti
michiganský	jedno pravidlo; hledá se celá populace	jednoduchý, ale populace zbytečně konverguje k podobným pravidlům
pittsburghský	celý hledaný soubor pravidel	výsledkem rovnou konzistentní sada; evoluce populace souborů je složitější a výpočetně náročnější

4.5 Observační pravidla: konfidence, podpora a testy hypotéz

Booleovská logika umí o datech vypovědět jen dvojím způsobem: „*všechny* objekty splňují $\varphi \Rightarrow \psi$ “ (nastává zřídka), nebo „*existuje* objekt splňující $\varphi \wedge \psi$ “ (slabá informace). Pro užitečnější popis dat byl navržen *observační kalkul* (Hájek–Havránek 1978, základ české metody GUHA).

Observační pravidla a zobecněné kvantifikátory

Observační pravidlo má tvar $\varphi \sim \psi$, kde $\sim$ je *zobecněný kvantifikátor*: pravdivost pravidla zachycuje výsledek statistické analýzy dat odpovídajících φ a ψ , shrnutých čtyřpolní tabulkou — a objektů splňuje $\varphi \wedge \psi$, b objektů $\varphi \wedge \neg\psi$, c objektů $\neg\varphi \wedge \psi$, d objektů $\neg\varphi \wedge \neg\psi$, celkem $n = a + b + c + d$.

Dva běžné typy observačních pravidel:

- **založená na odhadech pravděpodobností** (případně podmíněných) — nejběžnější jsou asociační pravidla (odd. 3.1) s konfidencí $c_0 \in (0, 1)$ a podporou $s_0 \in (0, 1)$:

$$(\varphi \sim \psi) = 1 \quad \text{právě když} \quad \frac{a}{a+b} \geq c_0 \wedge \frac{a}{n} \geq s_0,$$

kde $\frac{a}{a+b}$ je nestranný odhad $P(\psi | \varphi)$;

- **založená na testech hypotéz** (H_0 nulová, H_1 alternativní) — např. $(\varphi \sim \psi) = 1$, právě když jednostranný Fisherův test (odd. 2.8.1) na hladině $\alpha \in (0; 0,5)$ zamítá H_0 : nezávislost φ a ψ ve prospěch H_1 : pozitivní závislost φ a ψ .

4.6 Statistický pohled: regresní a diskriminační analýza

Charakteristický a diskriminační popis tříd nemusí mít podobu logických pravidel — klasická statistika řeší tytéž dvě úlohy *regresní* a *diskriminační analýzou*. Kontext: klasifikační metody se dělí podle toho, zda hranici mezi třídami primárně *hledají* (neuronové sítě, rozhodovací stromy, SVM — moderní, výpočetně náročné), nebo ji *nehledají* a vycházejí ze zkušenosti podobných případů či z pravděpodobností tříd (*k*-NN, bayesovská klasifikace, diskriminační analýza — tradiční, výpočetně nenáročné).

Regresní analýza určuje vztah veličiny Y k jedné či více veličinám $X_1, \dots, X_n$: lineární regrese jedné proměnné metodou nejmenších čtverců, vícerozměrná lineární regrese a logistická regrese pro kategoriální výstup — podrobně odd. 2.9 a 3.2.5. Regresní model je kvantitativní obdobou *charakteristického* popisu: říká, jaké hodnoty výstupu jsou pro dané vstupy typické.

Diskriminační analýza (DA) klasifikuje vzory do *známých* tříd, ale hranici nehledá: každé třídě C_j *prokládá* pravděpodobnostní rozdělení z předem zvolené rodiny hustot $F = \{f(\cdot | \theta) : \theta \in \Theta\}$ — v původní Fisherově DA vícerozměrné normální rozdělení. Učení je maximálně věrohodný odhad parametrů θ_j z učicích dat třídy C_j ; nový vzor x se klasifikuje podle $\arg \max_j p_j f(x | \theta_j)$, kde p_j je apriorní pravděpodobnost třídy.

Lineární vs. kvadratická diskriminační analýza

LDA: kovarianční matice Σ je dána předem a společná všem třídám; diskriminační funkce

$$g_j(x) = \ln p_j - \frac{1}{2} (x - \mu_j)^\top \Sigma^{-1} (x - \mu_j),$$

odhaduje se jen μ_j (q parametrů na třídu pro $x \in \mathbb{R}^q$); množina $\{x : g_j(x) = g_k(x)\}$ mezi dvěma třídami je *nadrovina*.

QDA: navíc vlastní kovarianční matice Σ_j každé třídy (dalších $\frac{q(q+1)}{2}$ parametrů na třídu); hranice mezi třídami je *kvadratická plocha*.

Pro dvě třídy lze místo g_1, g_2 hledat jedinou funkci $g = g_1 - g_2$ a klasifikovat podle *znaménka* — podmínka $g(x) > 0$ je kvantitativní obdobou *diskriminačního pravidla* (postačující podmínka příslušnosti k první třídě). Odvození lineární a kvadratické diskriminační funkce z normálních rozdělení viz odd. 3.2.6.

Úloha	Pravidlová podoba	Statistická podoba
charakterizace	charakteristické pravidlo ($\Rightarrow$, t-weight)	regresní analýza
diskriminace	diskriminační pravidlo ($\Leftarrow$, d-weight)	diskriminační analýza

4.7 Měření zajímavosti pravidel

Extrakce typicky vydá víc pravidel, než kolik jich uživatel unese — pravidla je třeba měřit, třídit a filtrovat. Pravidlo $\varphi \Rightarrow \psi$ je přitom samo binární klasifikátor, takže se na ně vztahují míry kvality binární klasifikace (odd. 5.2): přesnost (*accuracy*) AC, správnost predikce (*precision*) PR, citlivost (*recall*) TPr, specifita TNr = $1 - \text{FPr}$, F-míra $FM = \frac{2PR \cdot TPr}{PR + TPr}$ a AUC. U observačních pravidel jim odpovídají *konfidence* $\frac{a}{a+b}$ (precision pravidla) a *podpora* $\frac{a}{n}$; u charakteristických a diskriminačních pravidel je d-weight precision pravidla a t-weight jeho recall vůči cílové třídě.

Role měř při práci s pravidly:

- *fitness* při evoluční konstrukci pravidel (odd. 4.4);
- *třídění*: pravidla pro rodiny malware se řadí podle precision (odd. 4.8);
- *filtrace*: odstraňování redundantních a nepřesných pravidel;
- *prahování*: observační pravidlo je „zajímavé“, překročí-li konfidence a podpora zvolené prahu, nebo zamítne-li test nezávislost (odd. 4.5) — každá volba míry a prahu je jiný zobecněný kvantifikátor, a tedy jiná množina pravidel nalezených v datech.

Různá cena různých chyb. Tradiční přesnost a chybovost předpokládají, že každá chyba vadí stejně — nerealisticky: nedoručený ham vadí víc než nerozpoznaný spam, nerozpoznané napadení sítě víc než falešný poplach. Zobecněním chybovosti je *střední hodnota ceny* $\frac{1}{n} \sum_{i,j} c(i,j) n_{ij}$, kde $c(i,j)$ je cena klasifikace třídy i jako j (tradiční chybovost: $c(i,i) = 0$, jinak 1); zajímavost pravidla se pak měří cenou chyb, kterých se dopouští.

[♦ nad rámec slidů: subjektivní míry podle Han–Kamber] Vedle objektivních měr rozhodují *subjektivní*: srozumitelnost (celý smysl extrakce pravidel), jednoduchost (délka konjunkce, počet pravidel), neočekávanost (rozpor s očekáváním uživatele) a akceschopnost (lze na základě pravidla jednat). Prakticky: pravidlo je zajímavé, je-li současně srozumitelné, platné na nových datech, potenciálně užitečné a nové.

4.8 Aplikace: spam, malware a síťové hrozby, doporučování

Tři internetové aplikace klasifikačních metod z 1. přednášky kurzu ilustrují roli pravidel:

Filtrace spamu je klasifikace {kombinace hodnot příznaků} $\rightarrow$ {spam, ham}: příznaky z obsahu zprávy (slova, kombinace slov, obrázky) a z metainformací (doména, kódování, podvržená adresa odesílatele; anomálie průběhu SMTP; stejná zpráva mnoha adresátům). Není-li dosažitelná současně nízká FP i FN, pomáhá třetí třída mezi spamem a hamem — karanténa/nejistota (např. SpamBayes). Pravidlové filtry pracují hlavně s metainformacemi; prostá booleovská disjunkce pravidel vede k vysoké falešné pozitivitě („grafické tělo zprávy $\Rightarrow$ automaticky spam“), lepší je Łukasiewiczova fuzzy disjunkce pravidel se stejným konsekvem. FP (nedoručený ham) přitom vadí víc než FN.

Detekce malwaru a síťových hrozeb. Podezřelé programy nakonec vyhodnocuje analytik — chce rozumět, *proč* jsou podezřelé, proto pravidla. Vzniká jich mnoho, takže se odstraňují redundantní a nepřesné; typická je hierarchická klasifikace se dvěma vrstvami pravidel (první přesná pro normální software a citlivá pro malware, druhá třídí rodiny malwaru, setříděná podle precision). U síťových hrozeb (útoky R2L, U2R, DoS, probe) jsou obdobou pravidel *signatury* známých útoků — vzory se stoprocentně jistým závěrem.

Doporučovací systémy. Při kolaborativním filtrování podle chování uživatele se používají pravidla „uživatel prošel stránky $S_1, \dots, S_n \Rightarrow$ doporuč objekt O (obecněji: nabídní další stránku S_d)“. Získávají se statistickou analýzou clickstreamových dat — odhady pravděpodobností a testováním platnosti modelů (hypotéz), z jejichž výsledků se pravidla konstruují heuristicky; jde tedy o observační pravidla obou typů z odd. 4.5. Doporučovací systémy často vysvětlují, *proč* objekt doporučují — vysvětlení zvyšuje srozumitelnost doporučení pro uživatele.

4.9 Shrnutí ke zkoušce

- **Proč pravidla:** klasifikátor $f: X \rightarrow \{C_1, \dots, C_m\}$ je matematický předpis, málo srozumitelný; pravidlo logiky ($\varphi \Rightarrow \psi$, $\varphi \Leftrightarrow \psi$) je srozumitelnější. Booleovská implikace pravdivá při $t(\varphi) = 0$ nebo $t(\varphi) = t(\psi) = 1$; fuzzy implikace = residuum t-normy, $t(\varphi) \leq t(\psi) \Rightarrow$ implikace pravdivá se stupněm 1.
- **Charakteristické vs. diskriminační pravidlo** (Han–Kamber): charakterizace popisuje cílovou třídu ($\Rightarrow$, nutná podmínka, **t-weight** = $\frac{\text{count}(q_a)}{\sum_i \text{count}(q_i)}$); diskriminace ji odlišuje od kontrastních ($\Leftarrow$, postačující podmínka, **d-weight** = podíl pokrytých objektů patřících do cílové třídy). Umět spočítat z tabulky; d-weight vždy srovnat s *apriorním* podílem třídy.
- **Extrakce ze stromu:** cesta kořen $\rightarrow$ list = konjunkce podmínek, cesty do listů téže třídy = disjunkce; učení dělením podle informačního zisku či Giniho indexu; prořezávání pravidla zkracuje; zobecněná (šikmá) dělení snižují srozumitelnost.
- **Evoluce pravidel:** genetický algoritmus, fitness = AC/PR/TPR/TNR/AUC; michiganský přístup (jedinec = pravidlo) vs. pittsburghský (jedinec = soubor pravidel).
- **Observační pravidla** (Hájek–Havránek 1978, GUHA): $\varphi \sim \psi$ se zobecněným kvantifikátorem nad čtyřpolní tabulkou (a, b, c, d) ; (1) odhady pravděpodobností — asociační pravidla, $\frac{a}{a+b} \geq$

c_0 (confidence) $\wedge \frac{a}{n} \geq s_0$ (podpora); (2) testy hypotéz — jednostranný Fisherův test zamítá nezávislost ve prospěch pozitivní závislosti.

- **Statisticky:** regresní analýza = charakteristický popis vztahu Y na $X_1, \dots, X_n$ (nejmenší čtverce, vícerozměrná, logistická); diskriminační analýza = klasifikace do známých tříd prokládáním rozdělení: ML odhad θ_j , predikce $\arg \max_j p_j f(x \mid \theta_j)$; **LDA** (společná Σ , hranice nadrovina, q parametrů) vs. **QDA** (vlastní Σ_j , hranice kvadratická plocha, $+\frac{q(q+1)}{2}$ parametrů); dvě třídy $\rightarrow$ znaménko $g = g_1 - g_2$.
- **Zajímavost:** pravidlo = binární klasifikátor $\rightarrow$ AC, PR (= confidence), TPr (recall), TNr, F-míra, AUC; role: fitness, třídění (malware podle precision), filtrace redundantních, prahování (confidence a podpora = zobecněný kvantifikátor); různé ceny chyb (střední hodnota ceny). Subjektivně: srozumitelnost, jednoduchost, neočekávanost, akceschopnost.
- **Aplikace:** spam (metainformace, 3. třída karanténa, Łukasiewiczova disjunkce proti FP), malware (dvouvrstvá hierarchie pravidel), síťové hrozby (signatury), doporučování (pravidla z clickstreamu).

5 Reprezentace, vyhodnocování a vizualizace znalostí

Tři části podle tří slov ve větě okruhu: *v jaké formě* znalost vyjádříme, *jak ověříme*, že je dobrá, a *jak ji zobrazíme*. Prostřední část — vyhodnocování klasifikátorů — je ve slidech pokrytá celá a ptá se na ni u zkoušky nejčastěji.

5.1 Formy reprezentace znalostí

♦ nad rámec slidů: tabulka jako přehled; jednotlivé metody v ní jsou ve slidech doloženy]

Forma	Typický zdroj	Vlastnosti
IF-THEN pravidla	asociační pravidla, C4.5	nejrozumitelnější; lokální (každé pravidlo se čte samostatně); riziko konfliktů a nadprodukce
Rozhodovací strom	ID3/C4.5/CART	globální model, snadno čitelný do hloubky 4–5; nad ni nepřehledný
Rozhodovací tabulka	diskretizovaná data	úplný výčet kombinací; přehledná jen pro málo atributů
Matematická funkce	regrese, SVM, NN	kompaktní a přesná; obtížně interpretovatelná (kromě lineárního modelu s normalizovanými vahami)
Prototypy / centroidy	k -means, k -medoids, LVQ	„typický zástupce“ skupiny; velmi intuitivní pro byznys
Pravděpodobnostní model	naivní Bayes, bayesovská síť	explicitní nejistota; graf sítě je čitelný
Grafy a sítě	analýza sociálních sítí	vztahy mezi entitami; vizuálně silné
Instance (paměť případů)	k -NN, CBR	„model“ je samotná data; vysvětlení odkazem na podobné případy

Interpreovatelnost a vysvětlitelnost

♦ nad rámec slidů: vysvětlitelnost a post-hoc metody; interpreovatelnost jako kritérium hodnocení modelu je ve slidech — viz odd. 5.2] *Interpreovatelnost* (*interpretability*) — schopnost člověka porozumět tomu, jak model dospěl k výstupu. *Vysvětlitelnost* (*explainability*) — schopnost podat srozumitelné odůvodnění konkrétního rozhodnutí.

Rozlišujeme *modely inherentně interpreovatelné* (lineární modely, rozhodovací stromy, sady pravidel, prototypy) a *post-hoc vysvětlení černých skříněk* — důležitost atributů (permutační, SHAP), lokální surogátní modely (LIME), grafy částečné závislosti (PDP), extrakce pravidel z neuronové sítě, analýza citlivosti, kontrafaktuální vysvětlení („kdyby byl váš příjem o 5000 vyšší, úvěr by byl schválen“).

Interpreovatelnost není jen pohodlí: v regulovaných doménách (úvěry, pojištění, medicína) je právním požadavkem (GDPR čl. 22 — právo na vysvětlení automatizovaného rozhodnutí; AI Act pro vysoce rizikové systémy).

5.2 Vyhodnocování modelů

5.2.1 Kritéria hodnocení klasifikačních metod

- **Prediktivní přesnost** (*accuracy*) — podíl správně klasifikovaných vzorů:

$$Accuracy = \frac{\text{počet správných klasifikací}}{\text{počet všech testovaných případů}}.$$

- **Efektivita** — čas potřebný pro konstrukci modelu a čas pro jeho použití.
- **Robustnost** — zacházení se šumem a chybějícími hodnotami.
- **Škálovatelnost** — efektivita pro databáze uložené na disku.
- **Interpreovatelnost** — jasnost a vzhled, který model poskytuje.
- **Kompaktnost modelu** — velikost stromu, počet pravidel, ...

5.2.2 Metody odhadu chyby

Holdout, křížová validace, leave-one-out, validační množina

Holdout: D se rozdělí na disjunktí *trénovací* D_{train} a *testovací* D_{test} . **Zásadní pravidlo:** trénovací množina se nesmí použít při testování a testovací při učení — jen neviděná testovací množina dá *nezkreslený* odhad. Vhodné pro *velká* D .

k -násobná křížová validace (*k-fold cross-validation*): data se uniformně rozdělí na k stejně velkých disjunktích podmnožin, každá se jednou použije jako testovací a zbylých $k - 1$ jako trénovací. Z k přesností $Accuracy_i$ je výsledkem průměr

$$Accuracy_{CV} = \frac{1}{k} \sum_{i=1}^k Accuracy_i.$$

Běžné je 5 a 10; metoda se používá spíše pro *menší* data.

Leave-one-out: křížová validace, kde každý fold má jediný testovací vzor — pro m vzorů m -násobná CV. Pro *velmi malá* data.

Validační množina: data se rozdělí na *tři* části — trénovací, validační a testovací. Validační slouží k odhadu *parametrů* učicích algoritmů (vezmou se hodnoty s nejlepší přesností na ní); místo ní lze použít i křížovou validaci.

Interval spolehlivosti pro křížovou validaci

Přibližný $N\%$ interval spolehlivosti:

$$Accuracy_{CV} \pm t_{N,k-1} \cdot s_{Accuracy}, \quad s_{Accuracy} = \sqrt{\frac{1}{k(k-1)} \sum_{i=1}^k (Accuracy_i - Accuracy_{CV})^2}.$$

Hodnoty $t_{N,k-1}$ pro dvoustranné intervaly:

k	hladina spolehlivosti N		
	90 %	95 %	99 %
2	2,92	4,30	9,92
10	1,81	2,23	3,17
30	1,70	2,04	2,75
∞	1,64	1,96	2,58

Často se používá $t = 1,96$ (pro $k \rightarrow \infty$ a $N = 95\%$).

5.2.3 Matice záměn a odvozené míry

Přesnost je jen *jedna* míra ($error = 1 - accuracy$) a v některých aplikacích není vhodná. Při dolování z textu nás mohou zajímat jen dokumenty určitého tématu, což je malá část velké kolekce. Při klasifikaci silně *nevyvážených* dat (detekce průniků do sítě, finanční podvody) nás zajímá jen minoritní třída: při 1 % průniků dosáhneme 99% přesnosti tím, že *neuděláme nic* — a neodhalíme žádný průnik. Zajímavá třída se nazývá *pozitivní*, ostatní *negativní*.

Matice záměn, precision, recall, F_1

		klasifikováno jako	
		pozitivní	negativní
skutečnost	pozitivní	TP	FN
	negativní	FP	TN

TP — správné klasifikace pozitivních vzorů (*true positive*); FN — nesprávné klasifikace pozitivních vzorů (*false negative*); FP — nesprávné klasifikace negativních vzorů (*false positive*); TN

— správné klasifikace negativních vzorů.

$$p = \text{precision} = \frac{TP}{TP + FP}, \quad r = \text{recall} = \frac{TP}{TP + FN}.$$

Precision je podíl správných mezi vzory *označenými* za pozitivní, *recall* podíl nalezených mezi *skutečně* pozitivními. **Obě míry hodnotí klasifikaci pouze na pozitivní třídě.**

F_1 -**míra** kombinuje obě do jedné — je jejich *harmonickým průměrem*:

$$F_1 = \frac{2pr}{p+r} = \frac{2}{\frac{1}{p} + \frac{1}{r}}.$$

Harmonický průměr dvou čísel je blíž tomu *menšímu* z nich, takže F_1 je velká jen tehdy, jsou-li *obě* míry velké.

Ilustrace pastí: klasifikátor, který správně označí jediný pozitivní vzor a žádný negativní neoznačí chybně, má $p = 100\%$ a $r = 1\%$. Vysoká precision sama o sobě tedy neříká nic o užitečnosti.

5.2.4 Skórování, řazení a lift analýza

Skórování (*scoring*) je příbuzné klasifikaci, zajímá nás ale jediná (pozitivní) třída — např. kupující v marketingové databázi. Místo definitivního zařazení dostane každý vzor *odhad pravděpodobnosti* (*probability estimate*, PE), že do pozitivní třídy patří; klasifikátor jej musí umět dodat (u rozhodovacího stromu lze použít confidence v listu). Vzory se pak podle PE *seřadí* a rozdělí do n (např. 10) příhrádek (*bins*); podle počtu pozitivních vzorů v příhrádkách se nakreslí **lift křivka** — *lift analýza*.

Příklad — lift analýza pro cílenou kampaň

Chceme rozeslat propagační materiály potenciálním zákazníkům (hodinky). Každá zásilka stojí \$0,50, prodej jedné hodinky přinese \$5 zisku. Kolik zásilek poslat a komu?

Testovací množina má 10 000 vzorů, z nichž 500 je pozitivních. Po oskórování a seřazení do 10 příhrádek (po 1000 vzorech):

Příhrádka	1	2	3	4	5	6	7	8	9	10
Pozitivních	210	120	60	40	22	18	12	7	6	5
% z celku	42	24	12	8	4,4	3,6	2,4	1,4	1,2	1,0
Kumulativně	42	66	78	86	90,4	94	96,4	97,8	99	100

První příhrádka obsahuje 42 % všech pozitivních případů, první tři 78 %. Náhodné rozeslání by v každé příhradce dalo 10 % — rozdíl mezi lift křivkou a touto diagonálou je přínos modelu. Rozhodnutí „kolik zásilek“ pak vychází z ekonomiky: zásilkou do první příhrádky získáme $210 \cdot \$5 - 1000 \cdot \$0,50 = \$550$, do desáté $5 \cdot \$5 - 1000 \cdot \$0,50 = -\$475$.

5.2.5 ROC křivka a AUC

ROC křivka (*Receiver Operating Characteristic*)

Graf *míry správně pozitivních* (TPR) proti *míře falešně pozitivních* (FPR):

$$TPR = \frac{TP}{TP + FN}, \quad FPR = \frac{FP}{FP + TN}, \quad TNR = \frac{TN}{FP + TN}.$$

TPR je *recall* pozitivní třídy, nazývaný též *senzitivita*; FPR je podíl skutečně negativních případů klasifikovaných jako pozitivní; TNR (recall negativní třídy) je *specifita* a platí $FPR = 1 - \text{specifita}$.

Každá ROC křivka vede z (0,0) (vše negativní) do (1,1) (vše pozitivní). **Hlavní diagonála** odpovídá náhodnému hádání — predikci pozitivní třídy s fixní pravděpodobností, kdy $TPR = FPR$.

Konstrukce ROC křivky z klasifikace ve formě žebříčku testovacích případů:

1. Získej žebříček setříděním testovacích případů *klesajícím* výstupem klasifikátoru (např. aposteriorní pravděpodobností).
2. Rozděl žebříček *na každém* testovacím případě na dvě části a považuj každý případ v horní části za pozitivní a každý v dolní za negativní.
3. Pro každé takové rozdělení spočítej dvojici (FPR , TPR). Je-li horní část prázdná, dostaneme bod $(0, 0)$; je-li prázdná dolní část, bod $(1, 1)$.
4. Spoj sousední body.

AUC — plocha pod ROC křivkou

Dva klasifikátory se mohou v ROC prostoru *křížit*: v příkladu ze slidů je pro $FPR < 0,43$ lepší C_1 a pro $FPR > 0,43$ lepší C_2 — jednoznačná odpověď „který je lepší“ tedy neexistuje. Celkově lze použít *plochu pod ROC křivkou* (*area under the curve*, AUC): je-li $AUC(C_i) > AUC(C_j)$, říkáme, že C_i je lepší než C_j . Perfektní klasifikátor má $AUC = 1$, náhodné hádání $AUC = 0,5$.

5.3 Vizualizační techniky

♦ nad rámec slidů: tabulka jako přehled; krabicový graf, dendrogram a ROC/lift křivka samy ve slidech jsou]

Technika	K čemu	Omezení / poznámka
Histogram	rozdělení jedné numerické veličiny	citlivý na volbu šířky košů
Krabicový graf (<i>box plot</i>)	medián, kvartily, odlehlé hodnoty; srovnání skupin	neukáže bimodalitu (řeší <i>violin plot</i>)
Bodový graf (<i>scatter plot</i>)	vztah dvou numerických veličin	při mnoha bodech překryv → průhlednost, hexbin
Matice bodových grafů (SPLOM)	všechny dvojice atributů najednou	použitelné do zhruba 10 atributů
Paralelní souřadnice	vysokorozměrná data — objekt je lomená čára přes svislé osy atributů	silně závisí na pořadí os; nutné škálování; křížení čar = negativní korelace
Teplotní mapa (<i>heatmap</i>)	korelační matice, matice záměn	volba barevné škály (divergentní pro korelace)
Dendrogram	výsledek hierarchického shlukování	pořadí listů není jednoznačné
Projekce (PCA, MDS, t-SNE, UMAP)	2-D pohled na vysokorozměrná data	t-SNE/UMAP zkreslují globální vzdálenosti — <i>velikosti</i> shluků a mezery mezi nimi nelze interpretovat
ROC / lift křivka	kvalita klasifikátoru	viz odd. 5.2
Mozaikový graf	kontingenční tabulka kategoriálních atributů	vizuální alternativa k χ^2
Vizualizace sítě	sociální sítě, grafy vztahů	„chlupatá koule“ u velkých grafů → agregace komunit

Tři role vizualizace v KDD: *explorativní analýza* (fáze porozumění datům) — odhalí rozdělení, odlehlé a chybějící hodnoty, nečekané vztahy; Anscombeho kvartet jsou čtyři datové sady s identickými průměry, rozptyly i korelacemi, ale zcela odlišnou strukturou, kterou odhalí jedině graf; *vizualizace modelu* — strom, dendrogram, síť, hranice rozhodování; *prezentace výsledků* — agregace, jednoduchost, jeden graf = jedno sdělení.

Zásady: vysoký poměr datové a inkoustové složky (Tufte); nezkreslovat (nulová osa u sloupcových grafů, lineární nebo zřetelně označené logaritmické osy); barva podle typu dat (kategorie → kvalitativní paleta, pořadí → sekvenční, odchylka od středu → divergentní) a s ohledem na barvosleposti; vždy popisky a jednotky; žádné 3-D efekty ani koláčové grafy s mnoha výsečemi.

5.4 Vyhodnocení znalostí z pohledu uživatele

Pojem „vyhodnocování získaných znalostí“ má tři různé roviny, které je třeba rozlišovat:

- *statistické vyhodnocení modelu* — přesnost, matice záměn, ROC/AUC, odhad chyby křížovou validací (odd. 5.2);
- *vyhodnocení zajímavosti jednotlivých vzorů* — support, confidence, lift, χ^2 , t-weight a d-weight (odd. 3.1 a kap. 4);
- *vyhodnocení z pohledu uživatele* — zda je nalezená znalost srozumitelná, platná, užitečná a nová.

První dvě roviny jsou objektivní a měřitelné, třetí je nutně subjektivní — tentýž vzor může být pro jednoho objevem a pro druhého notorií. Část výsledků bude zřejmá, část použitelná přímo a část je nutné prezentovat srozumitelněji; obvykle se shrnou do *analytické zprávy*, výstupem může být i provedení akce.

5.5 Shrnutí ke zkoušce

- **Formy reprezentace znalostí:** IF-THEN pravidla (nejsrozumitelnější, lokální), rozhodovací strom (globální, čitelný do hloubky 4–5), rozhodovací tabulka, matematická funkce (kompaktní, neinterpretovatelná), prototypy/centroidy, pravděpodobnostní model, grafy a sítě, instance (k -NN, CBR). Umět ke každé formě říct, z jaké metody vzniká a čím se platí za její srozumitelnost.
- **Kritéria hodnocení metod:** prediktivní přesnost, efektivita (čas konstrukce i použití), robustnost, škálovatelnost, interpretovatelnost, kompaktnost modelu.
- **Odhad chyby:** *holdout* (velká data; trénovací a testovací množina se nesmí míchat), *k-násobná křížová validace* (menší data; 5 a 10 je běžné; přesnost jako průměr k přesností + interval spolehlivosti s $t_{N,k-1}$), *leave-one-out* (velmi malá data, m -násobná CV), *validační množina* (třetí část dat, na ní se ladí *parametry* algoritmu).
- **Matice záměn:** TP , FN , FP , TN ; $p = \frac{TP}{TP+FP}$, $r = \frac{TP}{TP+FN}$, $F_1 = \frac{2pr}{p+r}$ (harmonický průměr — blíží menšímu z čísel). Umět vysvětlit, proč accuracy nestačí u nevyvážených dat (1 % průniků $\Rightarrow$ 99 % přesnosti „nedělat nic“).
- **ROC:** $TPR = \frac{TP}{TP+FN}$ (senzitivita = recall pozitivní třídy) proti $FPR = \frac{FP}{FP+TN}$; $TNR = \text{specificita} = 1 - FPR$. Křivka vede z (0,0) do (1,1), diagonála = náhodné hádání. Umět popsat konstrukci ze žebříčku (dělení na každém případě). **AUC:** 1 pro perfektní, 0,5 pro náhodný klasifikátor; potřebná proto, že se ROC křivky dvou klasifikátorů mohou *křížit*.
- **Skórování a lift:** místo třídy se přiřadí odhad pravděpodobnosti (u stromu confidence v listu), vzory se seřadí a rozdělí do příhrádek; lift křivka proti diagonále náhodného výběru. Umět provést ekonomickou úvahu (kolik zásilek se vyplatí).
- **Tři roviny „vyhodnocování“:** statistická kvalita modelu, zajímavost vzorů, vyhodnocení uživatelem. První dvě objektivní, třetí subjektivní. **Čtyři kritéria zajímavosti znalosti:** srozumitelnost, platnost, užitečnost, novost.
- **Vizualizace:** technika podle úlohy (histogram, box plot, scatter, SPLOM, paralelní souřadnice, heatmapa, dendrogram, projekce, ROC/lift); tři role v KDD (explorace — Anscombeho kvartet, vizualizace modelu, prezentace); zásady (Tufte, nekreslovat osami, barva podle typu dat). Znat omezení: t-SNE a UMAP zkreslují globální vzdálenosti.

6 Modely pro analýzu sociálních sítí, centralita a detekce komunit

Okruh jmenuje *modely*, *míry centrality* a *detekci komunit*; podle toho je kapitola členěna: reprezentace sítí a míry na úrovni aktéra (centralita) a sítě (koheze), pak modely (vlastnosti reálných sítí, šíření vlivu, homofilie, segregace, strukturní balance, analýza vazeb — HITS a PageRank) a nakonec detekce komunit a predikce vazeb.

6.1 Vymezení oboru a motivace

Analýza sociálních sítí

Analýza sociálních sítí (*social network analysis*, SNA) je interdisciplinární obor s původem ve třech oblastech:

- *sociální vědy* — otázky a problémy vysvětlující sociální chování analýzou společností;
- *analýza sítí* — formulace a řešení problémů, které mají síťovou strukturu;
- *teorie grafů* — matematický aparát pro reprezentaci a analýzu grafů.

Zásadní posun perspektivy: SNA se soustředí na **vztahy** mezi sociálními entitami (jednotlivci, skupinami, institucemi) *spíše než na entity samotné* a jejich atributy. Studium společnosti ze síťové perspektivy chápe jednotlivce jako *zasazené* do sítě vztahů a hledá vysvětlení sociálního chování ve struktuře těchto sítí, nikoli v jednotlivcích samotných.

Analýza vazeb (*link analysis*) jako motivace: najít a vizualizovat vztahy mezi daty. Aplikace: telekomunikace; kriminalistika a právo (propojené skupiny zločinců); marketing (vztahy mezi zákazníky).

Šest stupňů odloučení (Milgram, 1967): náhodně vybraní lidé z Nebrasky měli poslat dopis burzovnímu makléři v Bostonu, a to jen přes osobně známé prostředníky. Mezi dopisy, které cíl našly, byl průměrný počet vazeb *šest* (mnoho dopisů ale nedorazilo). Experiment předznamenal pozdější objevy — huby, tendenci postupovat podle geografie či profese. Totéž dokládají *Erdősova čísla*: Erdős napsal přes 1500 článků s 507 spoluautory, průměrné Erdősovo číslo mezi matematiky je 4,65, maximum 13.

Bezškálové sítě (*scale-free*, SF) jako druhá motivace: několik uzlů má extrémně mnoho spojení (*huby*), většina jen několik. Důsledkem je *odolnost proti náhodné poruše* a zároveň *zranitelnost koordinovaným útokem*: může selhat až 80 % náhodných uzlů bez fragmentace, ale eliminace 5–15 % *hubů* rozpadne celý systém. Aplikace: ochrana proti šíření virů internetem (vymýcení je v SF architektuře v podstatě nemožné), medicína (vakcinace cílená na huby, léky mířící na klíčové molekuly), business (kaskádové finanční krachy, influencer marketing). Příklady SF sítí: *sociální* (spoluautorství, Hollywood), *biologické* (metabolismus buňky, proteinové regulační sítě), *sociotechnické* (internet — routery a spoje; WWW — stránky a URL).

6.2 Reprezentace sítí

Základní reprezentace

Sít' je graf $G = (V, E)$: *vrcholy* (uzly) jsou aktéři, *hrany* (vazby) vztahy mezi nimi. Tři ekvivalentní zápisy:

- **obrázek grafu**;
- **seznam hran** (*edge list*) — dvojice vrcholů, u ohodnocených grafů plus sloupec vah;
- **matice sousednosti** (*adjacency matrix*) $A = (a_{ij})$, $a_{ij} = 1$, je-li vrchol i spojen s vrcholem j , jinak 0; u vážených grafů obsahuje váhy.

U **orientovaných** grafů (kdo koho kontaktuje) matice sousednosti *nemusí* být symetrická; u **neorientovaných** (kdo koho zná) symetrická je. Tentýž seznam hran má v obou případech jinou interpretaci.

Váhy hran mohou vyjadřovat frekvenci interakce v období pozorování, počet vyměněných předmětů, individuální percepci silné vazby, náklady komunikace či výměny (vzdálenost), nebo jejich kombinaci. Hrany samy reprezentují interakce, toky informací či zboží, podobnosti a afiliace, nebo sociální vztahy.

Ego sítě a „celé“ sítě. *Ego síť* je osobní síť jednoho aktéra (*ego*) a jeho sousedů (*alterů*); pro další analýzu ego *není* potřebné, protože všichni alteri jsou s ním spojeni z definice. „Celá“ síť obsahuje i izolované uzly (*isolates*), ale **žádná studovaná síť není v praxi „celá“** — je to jen částečný obraz (*problém specifikace hranic, boundary specification problem*).

6.3 Síla vazeb

Uživatel může mít online tisíce „přátel“, ale vazby nejsou stejně silné a hrají různou roli při formování komunit a difuzi informací. *Silné vazby* jsou blízcí přátelé, *slabé* známí. **Síla slabých vazeb** (Granovetter, 1973): občasné setkání se vzdálenými známými mohou poskytnout důležitou informaci o nových příležitostech (hledání práce).

Homofilie, tranzitivita, přemostění

Homofilie (*homophily*) — tendence vztahovat se k lidem s podobnými charakteristikami (status, přesvědčení, ...). Vede k tvorbě homogenních skupin (klastřů), kde je snazší vytvářet vztahy; *extrémní* homogenizace ale může působit proti inovaci a generování idejí, takže *heterofilie* je v některých kontextech žádoucí. Homofilní vazby mohou být silné i slabé.

Tranzitivita (*transitivity*) — „existuje-li vazba mezi *A* a *B* a mezi *B* a *C*, budou v tranzitivní síti spojeni i *A* a *C*.“ Silné vazby jsou tranzitivní častěji než slabé, takže tranzitivita *indukuje* existenci silných vazeb (není to ale nutná ani postačující podmínka). Tranzitivita a homofilie společně vedou ke vzniku *klik* (plně propojených klastřů).

Přemostění (*bridging*) — *most* (*bridge*) je uzel či hrana spojující různé skupiny; obvykle jde o slabé vazby, ale ne každá slabá vazba je most. Mosty usnadňují mezigrupovou komunikaci, zvyšují sociální kohezi a podporují inovaci.

Určování síly vazby z topologie sítě. Mosty spojující dvě různé komunity jsou slabé vazby; hrana je *most*, jestliže její odstranění rozpojí její koncové uzly. Mosty jsou v reálných sítích poměrně vzácné $\Rightarrow$ definice se *uvolní* na **zkratkový most** (*shortcut bridge*): kontroluje se, zda se po odstranění hrany *zvětší* vzdálenost jejích koncových uzlů (na více než 2). Čím větší vzdálenost, tím *slabší* vazba. Např. $d(2, 5) = 4$ po odstranění hrany $(2, 5)$, ale $d(5, 6) = 2$ po odstranění $(5, 6) \Rightarrow (5, 6)$ je silnější vazba než $(2, 5)$.

Překryv sousedství (*neighborhood overlap*)

Pro dva uzly i, j spojené vazbou — čím větší překryv, tím *silnější* vazba:

$$O(i, j) = \frac{\text{počet společných přátel } i \text{ a } j}{\text{počet přátel, kteří jsou sousedy alespoň } i \text{ nebo } j} = \frac{|N_i \cap N_j|}{|N_i \cup N_j| - 2},$$

kde -2 ve jmenovateli vylučuje i a j samotné.

Příklady: $O(2, 5) = 0$; $O(5, 6) = \frac{|\{4\}|}{|\{2, 4, 5, 6, 7, 10\}| - 2} = \frac{1}{4}$; pro graf $G = (\{1, 2\}, \{(1, 2)\})$ je $O(1, 2) = 0$.

Určování síly vazby z profilů a interakcí. Na Twitteru je skutečná síť přátelství určena *frekvencí*, s jakou spolu dva uživatelé mluví, nikoli sítí follower–followee — a právě tato skutečná síť ovlivňuje používání Twitteru silněji. Na Facebooku lze sílu vazeb predikovat z příspěvků iniciovaných přítelem, zpráv na zdi a počtu společných přátel. Numerickou sílu lze učit maximální věrohodností: podobnost profilů určuje sílu vazby a ta určuje interakci, takže se maximalizuje věrohodnost pozorovaných profilů a interakcí.

6.4 Klíčoví hráči: míry centrality

Stupňová centralita (*degree centrality*)

Vstupní a výstupní stupeň uzlu = počet vazeb do uzlu / z uzlu (v neorientovaných grafech shodné). Měří *propojenost*, *vliv* či *popularitu* — které uzly jsou centrální pro šíření informace a ovlivňování ostatních ve svém „sousedství“.

Cesty a nejkratší cesty

Cesta mezi dvěma uzly je libovolná posloupnost neopakujících se uzlů, která je spojuje. *Nejkratší cesta* spojuje dva uzly nejmenším počtem hran (*vzdálenost* uzlů). Kratší cesty jsou preferované pro rychlou komunikaci či výměnu — ale ne vždy, například při šíření nemoci.

Algoritmy nejkratších cest. *Jeden zdroj:* obecné grafy (orientované, záporné váhy dovoleny) — Bellmanův–Fordův algoritmus, $O(|V||E|)$; grafy bez záporných vah — Dijkstrův algoritmus, $O(|V|^2)$; hledá-li se cesta jen mezi dvěma vrcholy, lze algoritmus zastavit po jejím nalezení. *Všechny páry:* záporné váhy dovoleny — Floydův–Warshallův, $O(|V|^3)$; řidší grafy se zápornými vahami — Johnsonův, $O(|E||V| + |V|^2 \log_2 |V|)$; bez záporných vah — Dijkstra, $O(|V|^3)$.

Mezilehlá centralita (*betweenness centrality*)

Pro uzel v : pro každou dvojici s, t se počet nejkratších cest mezi s a t procházejících v vydělí všemi nejkratšími cestami mezi s a t a hodnoty se sečtou přes všechny dvojice (někdy se normalizuje tak, aby maximum bylo 1). Indikuje uzly na *komunikačních cestách* mezi jinými uzly — tedy místa, kde by se síť mohla *rozpadnout*.

Blízkostní centralita (*closeness centrality*)

Míra *dosahu* — rychlost, s jakou se informace z daného uzlu dostane k ostatním: spočítá se *průměrná* délka všech nejkratších cest z uzlu ke všem ostatním uzlům sítě (kolik „skoků“ je v průměru potřeba), a vezme se *převrácená hodnota*. Vyšší hodnoty znamenají vyšší blízkost (jsou „lepší“). Užitečná, jde-li především o rychlost šíření.

Vlastní centralita (*eigenvector centrality*)

Je proporcionální součtu vlastních centralit přímých sousedů: moc a status aktéra jsou *rekurzivně* definovány mocí a statusem jeho sousedů. Měří tedy, jak dobře je aktér spojen s jinými *dobře propojenými* aktéry.

Formálně: pro $G = (V, E)$ s maticí sousednosti $A = (a_{i,j})$

$$x_i = \frac{1}{\lambda} \sum_{j \in M(i)} x_j = \frac{1}{\lambda} \sum_{j \in V} a_{i,j} x_j \iff Ax = \lambda x,$$

kde $M(i)$ je množina sousedů i . Existuje mnoho vlastních čísel λ , pro něž nenulové řešení existuje; *požadavek nezápornosti* všech složek vlastního vektoru však znamená, že žádanou míru centrality dává *jen největší* vlastní číslo. Vlastní vektor je určen až na společný násobek, takže je nutná normalizace (např. součet přes všechny vrcholy = 1 nebo = $|V|$).

Blíže souvisí s Google PageRank (odkazy ze silně odkazovaných stránek váží více, odd. 6.14).

Míra	Interpretace v sociálních sítích
Stupňová	Kolik lidí může tato osoba dosáhnout <i>přímo</i> ? — <i>Síť hudebních spoluprací</i> : s kolika lidmi spolupracoval?
Mezilehlá	Jak pravděpodobně leží tato osoba na nejpřímější cestě v síti? — <i>Síť špiónů</i> : přes koho nejspíš protéká většina informací?
Blízkostní	Jak rychle může tato osoba dosáhnout všech v síti? — <i>Síť sexuálních vztahů</i> : jak rychle se do zbytku sítě rozšíří přenosná nemoc?
Vlastní	Jak dobře je tato osoba spojena s jinými dobře propojenými lidmi? — <i>Citační síť</i> : který autor je nejvíce citován jinými dobře citovanými autory?

Množiny klíčových hráčů. Jednotlivé míry nestačí. V příkladu ze slidů je uzel 10 nejcentrálnější podle stupňové centrality, ale uzly 3 a 5 *společně* dosáhnou více uzlů a vazba mezi nimi je *kritická* — při jejím přerušení se síť rozpadne na dvě izolované podsítě. Uzly 3 a 5 společně jsou tedy pro síť důležitější než uzel 10 sám.

Strukturní ekvivalence

Vyjadřuje *podobnost* mezi aktéry v sociální síti; je založena na sousedech, které sdílejí (ekvivalentně na počtu identických vazeb). Dva aktéři jsou *strukturně ekvivalentní*, lze-li jejich pozice vzájemně vyměnit *bez změny celkové struktury* sítě. Přibližnou strukturní ekvivalenci lze použít pro hierarchické shlukování sociálních sítí.

6.5 Koheze: míry na úrovni sítě

Reciprocita, hustota, klastrovací koeficient

Reciprocita (*reciprocity*) — míra vzájemnosti a reciproční výměny v síti, související se sociální kohezí: podíl počtu *reciprokých* vztahů (hrana v obou směrech) na celkovém počtu vztahů v síti, kde dva vrcholy jsou „ve vztahu“, existuje-li mezi nimi alespoň jedna hrana. **Má smysl jen v orientovaných grafech.**

Hustota (*density*) — podíl počtu hran v síti na celkovém počtu *možných* hran:

$$\text{density} = \frac{|E|}{|V|(|V| - 1)/2} \quad (\text{neorientovaný graf}), \quad \frac{|E|}{|V|(|V| - 1)} \quad (\text{orientovaný}).$$

Běžná míra toho, jak dobře je síť propojená (jak „těsně upletená“ je). Perfektně propojená síť se nazývá *klika* a má hustotu 1. Orientované grafy mají poloviční hustotu než jejich neorientované protějšky, protože možných hran je dvakrát více.

Klastrovací koeficient (*clustering coefficient*) uzlu i měří hustotu jeho *sousedství* — sítě tvořené pouze uzly přímo spojenými s i . Pro $G = (V, E)$ je sousedství $N_i = \{v_j : e_{ij} \in E \vee e_{ji} \in E\}$, $k_i = |N_i|$, a

$$C_i = \frac{2|\{e_{jk} : v_j, v_k \in N_i, e_{jk} \in E\}|}{k_i(k_i - 1)} \quad (\text{neorientovaný}), \quad C_i = \frac{|\{e_{jk}\}|}{k_i(k_i - 1)} \quad (\text{orientovaný}).$$

Klastrovací koeficient sítě C je průměr koeficientů všech uzlů, $C = \frac{1}{|V|} \sum_{i=1}^{|V|} C_i$. Indikuje přítomnost (sub)komunit; shlukovací algoritmy se snaží maximalizovat počet hran padnoucích do téhož klastru.

Průměr, průměrná vzdálenost, excentricita, malé světy

Průměr sítě (*diameter*) — nejdelší nejkratší cesta (vzdálenost) mezi libovolnými dvěma uzly. Užitečná míra *dosahu* sítě: udává, jak dlouho nejdéle trvá dosáhnout libovolného uzlu. Řidší sítě mají obecně větší průměr.

Průměrná vzdálenost — průměr všech nejkratších cest v síti; udává, jak daleko od sebe budou dva uzly v průměru.

Excentricita vrcholu — největší geodetická vzdálenost mezi daným vrcholem a libovolným jiným vrcholem grafu.

Malý svět (*small world*) — síť, která vypadá téměř náhodně, ale má *významně vysoký klastrovací koeficient a relativně krátkou průměrnou délku cesty*: uzly se lokálně klastrují a zároveň jsou dosažitelné v několika krocích. V sociálních sítích je to velmi častý jev, a to kvůli *tranzitivitě* silných vazeb a *schopnosti slabých vazeb dosáhnout přes klastry*. Sítě malého světa mají mnoho klastrů, ale i mnoho mostů mezi nimi, které zkracují průměrnou vzdálenost.

6.6 Model reálných komplexních sítí a jejich vlastnosti

Šest charakteristických vlastností reálných komplexních sítí

Reálné komplexní sítě (sociální, informační a znalostní, technologické, biologické) jsou *nenáhodné a neregulární* grafy s unikátními rysy:

1. **Efekt malého světa** — první na něj poukázal Milgram (experiment z 60. let, cca 300 účastníků, mediánová délka úspěšných cest 6). Vychází z „šesti stupňů odloučení“: každý je od každého v průměru šest kroků. Důsledky pro rychlost šíření informací i nemocí.
2. **Tranzitivita / klastrování** — vysoká pravděpodobnost *úplných podsítí* uvnitř větších sítí (každý zná každého), zejména v sociálních sítích.
3. **Mocninné rozdělení stupňů** — *rozdělení stupňů* je histogram podílu uzlů se stupněm k ; u reálných sítí je zcela odlišné od náhodných grafů.
4. **Odolnost sítě** (*resilience*) — vliv odstranění uzlů na propojenost. Většina sítí je *robustní* proti náhodnému odstranění, ale podstatně méně proti *cílenému* odstranění uzlů s nejvyšším stupněm: odstraněním „vrátných“ (*gatekeepers*) se výrazně změní komunikační schopnost sítě, protože se některé uzly odpojí. Jediný uzel strukturu obvykle neohrozí — testuje se odstraněním *procenta* uzlů.
5. **Vzorce míchání** (*mixing patterns*) — při koexistenci různých typů uzlů je běžná *selektivita* ve tvorbě spojení, tzv. *asortativní míchání* (*assortative mixing*) čili homofilie (klasicky míchání podle rasy). Reálné sítě k němu mají vyšší tendenci.
6. **Komunitní struktura** — vzniká z *globální i lokální heterogeneity* rozložení hran: v některých oblastech grafu je vysoká koncentrace hran (*komunity*), mezi nimi nízká.

Bezškálové sítě a preferenční připojování

Bezškálové sítě (Barabási, Albert, 1999) mají rozdělení stupňů podle *mocninného zákona* (WWW, citační a biologické sítě, některé sociální). Mocninná rozdělení vznikají tehdy, *závisí-li množství, které něčeho dostanete, na množství, které už máte*; topologicky to dá síť s několika silně propojenými uzly (*huby*) a velkým počtem uzlů s nízkým stupněm.

Mechanismus se nazývá *rich-get-richer / poor-get-poorer*, ekvivalentně *Matoušův efekt*; Price jej nazval *kumulativní výhoda*, Barabási a Albert **preferenční připojování** (*preferential attachment*). Nové uzly se připojují k dobře propojeným uzlům, které bývají spojené s centrálními a prestižními pozicemi (více statusu, popularity, znalostí, peněz).

Dva mechanismy vzniku SF sítě jsou tedy **růst** a **preferenční připojování**. Výsledná síť má *dlouhý chvost* rozdělení stupňů a *strukturu malého světa*; tranzitivita a vlastnosti silných/slabých vazeb ke struktuře malého světa vést mohou, nejsou k jejímu vysvětlení ale *nutné*.

Důvody preferenčního připojování: *popularita* („bohatí bohatnou“) — chceme být spojeni s populárními lidmi a věcmi, což jejich popularitu dále zvyšuje, bez ohledu na objektivní charakteristiky; *kvalita* („dobří se zlepšují“) — hodnotíme podle objektivních kritérií, takže kvalitnější uzly přitáhnou pozornost rychleji; *smíšený model* — kdo se stane hvězdou, nelze předpovědět, i když kvalita hraje roli: mezi uzly s podobnými atributy se „hvězdami“ stanou ty, které první dosáhnou kritického množství (*halo efekt*).

Struktura jádro–periferie a centralizace

Centralizace měří, jak je síť centralizovaná; vychází z *rozdílů ve stupních* mezi uzly a normalizuje se do $[0, 1]$. Síť závislá na 1–2 vysoce propojených uzlech (důsledek preferenčního připojování) má větší rozdíly ve stupňové centralitě. Centralizované struktury mohou být lepší v úlohách vyžadujících koordinaci (týmové řešení problémů), ale jsou *náchylnější k selhání*, odpojili-li se klíčoví hráči.

Mnoho velkých komunit má *jádro* hustě propojených uživatelů, kritické pro propojení mnohem větší *periferie*. Jádra lze identifikovat vizuálně, zkoumáním polohy uzlů s vysokým stupněm a jejich společných rozdělení stupňů, nebo *bow-tie analýzou* (použitou pro analýzu struktury webu).

6.7 Modelování vlivu

Společné vlastnosti metod modelování vlivu

- sociální síť je reprezentována *orientovaným* grafem, každý aktér je jeden uzel;
- každý uzel začíná jako *aktivní* nebo *neaktivní*;
- aktivovaný uzel aktivuje své sousedy;
- **jednou aktivovaný uzel už nelze deaktivovat.**

Model lineárního prahu (LTM)

Aktér (uzel) podnikne akci, pokud počet jeho přátel, kteří akci podnikli, překročí určitý *prah*.

- Každý uzel v si zvolí prah θ_v *náhodně* z uniformního rozdělení na $[0, 1]$.
- V každém diskrétním kroku zůstávají všechny uzly aktivní z předchozího kroku aktivní.
- Aktivují se uzly splňující

$$\sum_{u \in N_v^{\text{aktivní}}} w_{u,v} \geq \theta_v \sum_{u \in N_v} w_{u,v}.$$

LTM se soustředí na *příjemce* vlivu.

Model nezávislých kaskád (ICM)

Soustředí se na *vysílající* uzly.

- Uzel v aktivovaný v kroku t má *jedinou* příležitost aktivovat každého ze svých sousedů, a to náhodně.
- Pro sousední uzel u úspěje aktivace s pravděpodobností $p_{v,u}$ (např. $p = 0,5$).
- Úspěje-li, u se stane aktivním v kroku $t + 1$.
- V dalších kolech se už v o aktivaci u *nepokouší*.
- Difuze začíná počáteční aktivovanou množinou uzlů a pokračuje, dokud není možná žádná další aktivace.

Maximalizace vlivu

Úloha: pro danou síť a parametr k vybrat k uzlů do aktivační množiny B tak, aby se maximalizoval vliv ve smyslu počtu aktivních uzlů na konci. Označme $\sigma(B)$ očekávaný počet uzlů ovlivněných množinou B :

$$\max_{|B| \leq k} \sigma(B).$$

Úloha je **NP-těžká**, ale lze dokázat, že *hladový* přístup dává řešení na úrovni **63 %** optima.

Hladový přístup: začni s $B = \emptyset$; vyhodnoť $\sigma(\{v\})$ pro každý uzel a vyber uzel s maximálním σ jako první prvek B ; poté opakovaně vybírej uzel, který $\sigma(B)$ zvýší nejvíce, tj. $\arg \max_{v \in V \setminus B} \sigma(B \cup \{v\})$.

6.8 Vliv versus korelace

Atributy a chování uživatelů často korelují se sítí. Pro binární atribut u každého uzlu (zda je kuřák): koreluje-li se sítí, budou aktéři sdílet stejné hodnoty pozitivně korelované se sociálními spoji (kuřáci interagují spíše s kuřáky).

Test korelace

Jestliže podíl hran spojujících uzly s *různými* hodnotami atributu je významně *nižší* než očekávaná pravděpodobnost, jde o důkaz korelace.

Příklad: jsou-li spoje nezávislé na kuřáctví, je podíl kuřáků $p = 4/9$ a nekuřáků $1 - p = 5/9$. Jedna hrana spojuje dva kuřáky s pravděpodobností $p \cdot p$, dva nekuřáky $(1 - p)(1 - p)$ a kuřáka s nekuřákem $2p(1 - p) = 2 \cdot \frac{4}{9} \cdot \frac{5}{9} = 49\%$. Ve skutečném grafu je tento podíl $2/14 = 14\% < 49\%$, takže síť **vykazuje určitý stupeň korelace** vzhledem ke kuřáctví.

Tři sociální procesy vysvětlující korelaci

- **Homofilie** — tendence propojovat se s těmi, kdo s námi sdílejí určitou podobnost („vrána k vráně sedá“).
- **Zmatení** (*confounding*) — korelace může být vytvořena i *vnějšími* vlivy prostředí („jednotlivci žijící ve stejném městě se spíše stanou přáteli než náhodní jednotlivci“).
- **Vliv** (*influence*) — proces způsobující korelaci chování mezi sousedními aktéry („přejde-li většina mých přátel k jinému mobilnímu operátorovi, mohu být jimi ovlivněn a přejít také“).

Proč vliv rozlišovat od homofilie a zmatení? *Analýza:* predikce dynamiky systému — zda se nová norma chování, technologie nebo idea může šířit jako epidemie. *Návrh:* konstrukce systému vyvolávajícího konkrétní chování, např. vakcinační strategie (náhodné, cílené na demografickou skupinu, náhodní známí) nebo virální marketingové kampaně.

Logistický model vlivu a shuffle test

Vliv se určuje *časovými značkami*: v diskrétních krocích $t = 0, 1, 2, \dots$ se každý neaktivní uzel stane aktivním s pravděpodobností $p(a)$, kde a je počet aktivních kontaktů. p se modeluje *logistickou* funkcí počtu aktivních přátel:

$$p(a) = \frac{e^{\alpha \ln(a+1) + \beta}}{1 + e^{\alpha \ln(a+1) + \beta}}, \quad \text{ekvivalentně} \quad \ln \frac{p(a)}{1 - p(a)} = \alpha \ln(a + 1) + \beta,$$

kde α je *koefficient sociální korelace*, β vrozená tendence k aktivaci a $\ln(a + 1)$ vysvětlující proměnná.

Věrohodnost aktivace. Stane-li se v čase t aktivními $y_{a,t}$ uživatelů s a aktivními přáteli a $n_{a,t}$ jich zůstane neaktivních, je věrohodnost celé posloupnosti $\prod_t \prod_a p(a)^{y_{a,t}} (1 - p(a))^{n_{a,t}}$. Z logu aktivit se spočítají α, β , které ji maximalizují; α **měří korelaci mezi uzly**.

Shuffle test (test na vliv). Myšlenka: *nehraje-li vliv roli, je časování aktivace nezávislé na časování ostatních* — po náhodném zpřeházení časových značek bychom měli dostat podobnou sociální korelaci. Postup: spočítej $y_{a,t}, n_{a,t}$ a z nich α, β ; vyber náhodnou permutaci π časů aktivace ($t'_i = t_{\pi(i)}$), z nových časů spočítej $y'_{a,t}, n'_{a,t}$ a z nich α', β' . Jsou-li α a α' blízko sebe, model *nevykazuje* sociální vliv; **významný rozdíl** je důkazem **vlivu**.

6.9 Homofilie, výběr a sociální vliv

Test homofilie

Motivace: „vrána k vráně sedá“ — vaši přátelé jsou vám podobnější věkem, rasou, zájmy a názory než náhodně vybraná skupina jednotlivců. *Homofilie* je princip, že máme tendenci být podobní svým přátelům.

Test: kdyby byl každému uzlu *náhodně* přiřazen atribut podle poměru v reálné síti, počet „různorodých“ hran by se od reálné sítě významně nelišil. Je-li podíl p mužů a q žen, je pravděpodobnost hrany muž–muž p^2 , žena–žena q^2 a *různopohlavní* hrany $2pq$.

Je-li podíl heterogenních (různopohlavních) hran významně nižší než $2pq$, jde o důkaz homofilie.

Příklad: různopohlavních hran je 5 z 18; $p = 6/9 = 2/3$, $q = 3/9 = 1/3$; bez homofilie by jich mělo být $2pq = 4/9$, tj. 8 z 18 $\Rightarrow$ *důkaz homofilie*.

Poznámky k testu homofilie. „Významně nižší“ — vhodné je posuzovat odchylku pod střední hodnotou. Co když má síť *významně více* než $2pq$ různorodých hran? Pak jde o *inverzní homofilii* (příklad: partnerské vztahy muž–žena). Test lze použít na libovolnou charakteristiku (rasa, věk, rodný jazyk, preference); pro charakteristiky s více než dvěma hodnotami se počítá analogicky — počet heterogenních hran se porovná s tím, jak by vypadal náhodně generovaný graf s reálnými daty jako pravděpodobnostmi.

Výběr vs. sociální vliv

Tranzitivní uzávěr (*triadic closure*): mají-li dva jednotlivci společného přítele, je přátelství mezi nimi pravděpodobnější. Homofilie naznačuje, že dva jednotlivci jsou si podobnější *kvůli* společnému příteli, takže vazba může vzniknout, i když ani jeden o společném příteli neví. Obvykle je obtížné přisoudit vznik vazby jedinému faktoru.

Výběr (*selection*) — lidé mají tendenci vybírat si přátele, kteří jsou jim podobní. Působí na různých úrovních intencionality: aktivně si vybíráte podobné přátele v malé skupině; *nebo* je populace vaší školy relativně homogenní vůči celkové populaci, takže vás prostředí *nutí* vybírat si podobné přátele.

Mutabilní vs. imutabilní charakteristiky: *imutabilní* se nemění (pohlaví, rasa) nebo se mění konzistentně s populací (věk, generace); *mutabilní* se mění v čase (chování, přesvědčení, zájmy, názory).

Sociální vliv je *opakem* výběru: *výběr* — individuální charakteristiky řídí tvorbu vazeb; *sociální vliv* — existující vazby formují mutabilní charakteristiky lidí.

Longitudinální studie jsou nutné proto, že z jediného snímku sítě nelze rozhodnout, zda působí výběr, nebo vliv: sledují spoje i chování v čase a odpovídají na otázku *mění se chování po změnách v síti, nebo síť po změnách v chování?* Na tom závisí návrh intervencí — vykazuje-li užívání drog homofilii *vlivem*, funguje program, v němž přátelé přesvědčí ostatní přestat; vznikla-li homofilie *výběrem*, vyberou si bývalí uživatelé nové přátele a chování ostatních to neovlivní.

Christakis a Fowler sledovali obezitu a sociální síť 12 000 lidí po 32 let a našli homofilii podle obezity. Testovali tři vysvětlení — *výběr* (vybírají si lidé přátele s podobným stavem?), *zmatení* (korelují se stavem i jiné faktory?) a *sociální vliv* (ovlivnila změna stavu přátel budoucí stav osoby?) — a **našli významný důkaz pro třetí:** obezita je typ „nákazy“, který se může šířit sociálním vlivem.

6.10 Afilační síť a uzávěrové procesy

Afilační a sociálně-afilační síť

Afilační síť vkládá do sítě kontext tím, že zobrazuje spojení k aktivitám, společnostem, organizacím, čtvrtím atd. Je to *bipartitní graf*: každá hrana spojuje dva uzly patřící do *různých* množin (osoby vs. *afiliace* čili *fokusy*).

Sociálně-afilační síť má *dva typy hran*: *osoba–osoba* (přátelství nebo jiný sociální vztah) a *osoba–fokus* (účast v daném fokusu).

Tři uzávěrové procesy

- **Tranzitivní uzávěr** (*triadic closure*) — dva lidé se spojí, protože mají společného přítele.
- **Fokální uzávěr** (*focal closure*) — dva lidé se spojí, protože mají společný fokus; uzávěr výběrem.
- **Členský uzávěr** (*membership closure*) — osoba se zapojí do fokusu, protože je v něm zapojen její přítel; uzávěr *sociálním vlivem*.

Otázky o uzávěru. Jaká je pravděpodobnost, že dva lidé vytvoří vazbu, jako funkce počtu společných přátel? Analogicky pro fokální uzávěr (funkce počtu společných fokusů) a členský uzávěr (funkce počtu přátel už v daném fokusu zapojených).

Metodika měření tranzitivního uzávěru

1. Pořiď dva snímky sítě v časech t_1 a t_2 .
2. Pro každé k identifikuj všechny *páry* uzlů, které mají v t_1 přesně k společných přátel, ale *nejsou* přímo spojeny hranou.
3. Definuj $T(k)$ jako *podíl* těchto párů, které do t_2 vytvořily hranu. To je pravděpodobnost, že mezi dvěma lidmi s k společnými přáteli vznikne vazba.
4. Vynes $T(k)$ jako funkci k .

Bázový (nulový) model: je-li pravděpodobnost vytvoření vazby s jedním společným přítelem p a jednotlivé společné přátele považujeme za *nezávislé* příležitosti, pak

$$T_{\text{base}}(k) = 1 - (1 - p)^k \quad (\text{resp. } 1 - (1 - p)^{k-1} \text{ podle konvence}).$$

Empirické výsledky. *Tranzitivní uzávěr* — *e-mailová síť* (Kossinets, Watts, 2006): komunikace 22 000 studentů po jeden rok, vazba = e-mail za posledních 60 dní, snímky den po dni, $T(k)$ zprůměrováno přes páry snímků. Při *žádném* společném příteli se e-maily téměř nevyměňují; *významný nárůst* z 1 na 2 společné přátele; další nárůst je významný, ale na menší subpopulaci — tedy *klesající výnosy*. *Fokální uzávěr* tamtéž (fokusy = vyučované předměty z rozvrhů): *sdílení předmětu má téměř stejný efekt jako sdílení přítele*, opět s klesajícími výnosy. *Členský uzávěr*: Backstrom et al. (2006) na LiveJournalu (fokusy = členství v komunitách) a Crandall et al. (2008) na Wikipedii (vazba = komunikace přes diskusní stránku, fokusy = editované články) — tentýž vzorec, nárůst od 1 ke 2 a pak klesající výnosy.

Výběr a sociální vliv na datech Wikipedie. Podobnost dvou editorů se měřila jako

$$\frac{\text{počet článků editovaných oběma editory}}{\text{počet článků editovaných alespoň jedním editorem}}$$

(obdoba překryvu sousedství). Zjištění: *páry editorů, které komunikovaly, jsou si v chování významně podobnější než ty, které nekomunikovaly*. Vzniká homofilie tím, že editoři mluví s editory téhož článku (*výběr*), nebo tím, že je k článkům dovedou ti, s nimiž mluví (*vliv*)? Průměrováním historií interakcí ($0 =$ vznik vazby, jen editoři s ≥ 100 akcemi před i po první interakci, baseline = náhodný pár) vyšlo, že podobnost roste *už před* vznikem vazby (*výběr*) a roste *dál i po* něm (*vliv*).

6.11 Schellingův model segregace

Schellingův model (T. Schelling, 70. léta)

Jednoduchý model, který ukazuje, jak mohou *globální* vzorce dobrovolné segregace vznikat z *lokální* homofilie.

- Populaci tvoří dva typy jednotlivců — agenti X a O ; oba typy reprezentují *imutabilní* charakteristiku (rasa, etnicita, země původu, rodný jazyk).
- Agenti jsou náhodně rozmístěni v mřížce.
- Agent je se svou polohou *spokojen*, je-li alespoň t jeho sousedů agentem téhož typu (t je předem nastavený prah).

- V každém kole se nejprve identifikují všichni *nespokojení* agenti; poté se všichni nespokojení přesunou na místo, kde budou spokojeni.

Někdy agent nové uspokojující místo nenajde — pak zůstane, nebo se přesune na náhodné místo. Přesuny mohou způsobit, že *dříve spokojený agent přestane být spokojen* — proto proces pokračuje.

Výsledek: mřížka je segregovanější než na začátku.

Varianty modelu: pořadí přesunů (náhodné vs. „zametací“), cíl přesunu (nejbližší uspokojující vs. náhodné místo), prah (procentní, různý mezi skupinami i v nich), „obtočený“ svět. Variant je mnoho, ale *výsledek zůstává stejný: samovolně vzniklá segregace*.

Závěr: Schellingův model je příkladem, jak se *imutabilní* charakteristiky mohou stát silně korelovanými s *mutabilními*: volba místa k životu (mutabilní) se v čase přizpůsobí typu agenta (imutabilní), čímž vzniká segregace (homofilie).

6.12 Pozitivní a negativní vztahy: strukturní balance

Dosud měl vztah pozitivní konotaci; existují ale sítě s *negativními* (nepřátelskými) vztahy. Otázka: **kdy je síť v balancovaném stavu?** Opět uvidíme, jak lokální vlastnosti vynucují globální (srov. Schellingův model). Zjednodušení (později uvolníme): *všechny* páry uzlů jsou spojeny pozitivním či negativním vztahem, tj. úplný graf — vhodné pro malé skupiny lidí nebo pro státy.

Vlastnost strukturní balance

Pro tři uzly existují (až na symetrii) čtyři konfigurace znamének:

Znaménka	Interpretace	Stav
+, +, +	A, B, C jsou vzájemní přátelé	balancovaný
+, -, -	A a B jsou přátelé se společným nepřítelem C	balancovaný
+, +, -	B a C jsou přátelé A , ale spolu ne vycházejí	nebalancovaný
-, -, -	A, B, C jsou vzájemní nepřátelé	nebalancovaný

Vlastnost strukturní balance: pro každý trojúhelník jsou všechny tři hrany pozitivní, nebo je pozitivní právě jedna.

Věta o balanci

Věta. Je-li označovaný *úplný* graf balancovaný, pak buď

- jsou všechny páry uzlů přátelé, *nebo*
- lze uzly rozdělit do dvou skupin X a Y tak, že každý pár uzlů v X se má rád, každý pár v Y se má rád, a každý v X je nepřítelem každého v Y .

Důkaz. Nechť G je balancovaná síť. Jsou-li všechny hrany pozitivní, jsme hotovi. Existuje-li alespoň jedna negativní hrana, vyber uzel A a polož X = všichni přátelé A (včetně A), Y = všichni nepřátelé A . Pak platí: (1) každé dva uzly v X jsou přátelé — kdyby ne, měli bychom trojúhelník A + dva jeho přátelé s jedinou negativní hranou, tedy dvě kladné a jednu zápornou, což je nebalancované; (2) každé dva uzly v Y jsou přátelé — kdyby ne, měli bychom trojúhelník A + dva jeho nepřátelé se třemi negativními hranami, což je nebalancované; (3) každý uzel v X je nepřítelem každého uzlu v Y — jinak by trojúhelník A , přítel z X , nepřítel z Y měl dvě kladné a jednu zápornou hranu. $\square$

Aplikace strukturní balance. *Vývoj aliancí v Evropě 1872–1907:* Liga tří císařů 1872–81, Trojspolek 1882, přerušení německo-ruské smlouvy 1890, francouzsko-ruská aliance 1891–94, Entente Cordiale 1904, britsko-ruská aliance 1907 — síť postupně *sklouzává k balancovanému označování*, a tím do první světové války. *Bangladéš 1972:* podpora Pákistánu ze strany USA je méně překvapivá, uvědomíme-li si, že SSSR byl nepřítelem Číny, Čína nepřítelem Indie a Indie měla špatné vztahy s Pákistánem — USA tehdy zlepšovaly vztahy s Čínou, a tak podpořily nepřátele jejích nepřátel.

Slabá strukturní balance a generalizace

Vlastnost slabé strukturní balance: neexistuje trojice uzlů, jejíž hrany tvoří *právě dvě pozitivní a jednu negativní*. (Konfigurace „tři negativní“ je tedy dovolena — ta odpovídá situaci, kdy pár vytvoří alianci proti třetímu; „dvě pozitivní a jedna negativní“ je silnější nebalancovanost, protože B a C se snaží svou animozitu vyřešit.)

Věta. Je-li označovaný úplný graf slabě balancovaný, lze jeho uzly rozdělit do skupin vzájemných přátel tak, že každé dva uzly patřící do různých skupin jsou nepřátelé.

Důkaz. (1) Nechť A je uzel a X množina přátel A včetně A . (2) Všichni přátelé A jsou přátelé mezi sebou. (3) A a všichni jeho přátelé jsou nepřáteli všech ostatních. (4) Odstraň X ze sítě a pokračuj krokem 1. $\square$

Generalizace na neúplné grafy. (a) Ne všechny páry v síti jsou spojeny — (neúplný) graf je balancovaný, lze-li jej „doplnit“ přidáním hran na označovaný úplný graf, který je balancovaný. (b) Ne všechny trojúhelníky musí být balancované — je-li *většina* trojúhelníků balancovaná, lze síť *přibližně* rozdělit na dvě frakce.

6.13 Analýza vazeb: huby, autority a algoritmus HITS

Oba algoritmy analýzy vazeb, PageRank i HITS, byly publikovány v roce 1998. PageRank se stal dominantním díky *nezávislosti na dotazu*, odolnosti proti spamu a obchodnímu úspěchu Googlu.

Autority a huby

Autorita (*authority*) — stránka s mnoha *vstupními* odkazy: má autoritativní obsah k tématu, a proto na ni mnoho lidí odkazuje. **Hub** — stránka s mnoha *výstupními* odkazy: organizátor informací k tématu odkazující na mnoho dobrých autorit.

Klíčová myšlenka HITS: *dobrý hub odkazuje na mnoho dobrých autorit a dobrá autorita je odkazována mnoha dobrými huby* — jsou tedy ve vztahu *vzájemného zesilování* (bipartitní podgraf hustě propojených hubů a autorit).

Proč huby oddělovat od autorit? Konkurenční firmy na sebe neodkazují, takže se nelze chápat jako přímá vzájemná podpora. V PageRanku naopak podpora přechází přímo z jedné prominentní stránky na druhou — to je dominantní způsob podpory u akademických a vládních stránek, mezi blogery a ve vědecké literatuře.

Algoritmus HITS (*Hypertext Induced Topic Search*)

Na rozdíl od PageRanku, který je *statický*, je HITS *závislý na dotazu*. Po zadání dotazu HITS nejprve rozšíří seznam relevantních stránek vrácených vyhledávačem a pak vytvoří *dvě* pořadí rozšířené množiny: pořadí autorit a pořadí hubů.

Sběr stránek. Pro obecný dotaz q : pošli q vyhledávači; posbírej t nejvýše hodnocených stránek (v původním článku $t = 200$) — tato množina se nazývá *kořenová množina* S ; rozšiř S o každou stránku, na kterou odkazuje nějaká stránka z S , a o každou stránku, která odkazuje na stránku z S — vznikne větší *bázová množina* B .

Skóre. Nechť $G = (V, E)$ je hypertextový graf B o n stránkách s maticí sousednosti L ($L_{ij} = 1$, existuje-li hrana (i, j) , jinak 0). Označme $a(i)$ skóre autority a $h(i)$ skóre hubu stránky i . Vzájemné zesilování:

$$a(i) = \sum_{(j,i) \in E} h(j), \quad h(i) = \sum_{(i,j) \in E} a(j),$$

maticově, s $a = (a(1), \dots, a(n))^T$ a $h = (h(1), \dots, h(n))^T$:

$$a = L^T h, \quad h = La.$$

Výpočet mocninou iterací:

1: $a_0 \leftarrow h_0 \leftarrow (1, 1, \dots, 1)^T$; $k \leftarrow 1$

2: **repeat**

3: $a_k \leftarrow L^\top h_{k-1}; \quad h_k \leftarrow La_k$

4: $a_k \leftarrow a_k / \|a_k\|_1; \quad h_k \leftarrow h_k / \|h_k\|_1$

▷ normalizace

5: $k \leftarrow k + 1$

6: **until** $\|a_k - a_{k-1}\|_1 < \varepsilon$ a $\|h_k - h_{k-1}\|_1 < \varepsilon$

7: **return** a a h

Normalizace je nezbytná, protože velikost hodnot autorit a hubů s každou aktualizací roste; konvergence nastane jen s normalizací (dělí se součtem všech skóre).

Spektrální analýza HITS

Po k krocích platí (spektrum matice = množina jejích vlastních čísel)

$$a_k = (L^\top L)^{k-1} a_0, \quad h_k = (LL^\top)^k h_0.$$

Vektor a_k tedy musí konvergovat k *vlastnímu vektoru* matice $L^\top L$: existují normalizační konstanty c_k takové, že a_k/c_k konverguje k limitě, a směr se při násobení maticí nezmění právě tehdy, je-li vektor vlastním vektorem.

Matice $L^\top L$ je *symetrická*, má tedy n vlastních vektorů $z_1, \dots, z_n$ s vlastními čísly $c_1, \dots, c_n$, $|c_1| \geq |c_2| \geq \dots \geq |c_n|$. Rozvineme-li $a_0 = x_1 z_1 + \dots + x_n z_n$, pak

$$a_k = c_1^k x_1 z_1 + \dots + c_n^k x_n z_n, \quad \frac{a_k}{c_1^k} = x_1 z_1 + x_2 \left(\frac{c_2}{c_1}\right)^k z_2 + \dots$$

Za předpokladu $c_1 > c_2 \geq \dots$ jde pro $k \rightarrow \infty$ každý člen kromě prvního k nule, takže a_k/c_1^k konverguje k $x_1 z_1$ — k *hlavnímu* vlastnímu vektoru. (Konvergenci nezávisle na počátečním vektoru a uvolnění předpokladu $c_1 > c_2$ zde nedokazujeme.)

Vztah ke ko-citaci a bibliografickému párování

Ko-citace stránek i a j (např. počet článků, které citují *oba* články i a j):

$$C_{ij} = \sum_{k=1}^n L_{ki} L_{kj} = (L^\top L)_{ij}.$$

Matice autorit $L^\top L$ algoritmu HITS je tedy *ko-citační matice*.

Bibliografické párování stránek i a j (počet článků, které jsou citovány *oběma* články i a j):

$$B_{ij} = \sum_{k=1}^n L_{ik} L_{jk} = (LL^\top)_{ij}.$$

Matice hubů $LL^\top$ je tedy matice bibliografického párování.

Silné a slabé stránky HITS. *Silná*: řadí stránky *podle tématu dotazu*, což dá relevantnější autority a huby. *Slabé*: snadné spamování (přidat výstupní odkazy na vlastní stránku je triviální); *drift tématu* (mnoho stránek v rozšířené množině nemusí být k tématu); neefektivnost v době dotazu (sběr kořenové množiny, rozšíření i výpočet vlastních vektorů jsou drahé).

6.14 PageRank

Prestiž pořadí (*rank prestige*)

Míry prestiže uvažují *prominenci aktérů, kteří „hlasují“*: osoba vybraná důležitou osobou je prestižnější než osoba vybraná méně důležitou (hlas ředitele váží více než hlas zaměstnance). Je-li váš okruh vlivu plný prestižních aktérů, je vysoká i vaše prestiž.

Prestiž pořadí $P(i)$ je definována jako lineární kombinace pořadí těch, kteří odkazují na i :

$$P(i) = A_{1i}P(1) + A_{2i}P(2) + \cdots + A_{ni}P(n), \quad \text{maticově} \quad P = A^T P,$$

kde $A_{ji} = 1$, odkazuje-li j na i , jinak 0. To je *charakteristická rovnice* vlastního systému matice A^T ; P je vlastní vektor A^T .

Základní PageRank

PageRank interpretuje hyperodkaz ze stránky u na stránku v jako *hlas* stránky u pro stránku v . Nezajímá jej ale pouhý počet hlasů — analyzuje i stránku, která hlas dává: *hlasy důležitých stránek váží více a pomáhají činit ostatní stránky důležitějšími*. Protože stránka může odkazovat na mnoho jiných, musí své skóre *rozdělit*.

Web jako orientovaný graf $G = (V, E)$, $n = |V|$. PageRank stránky i :

$$P(i) = \sum_{(j,i) \in E} \frac{P(j)}{O_j},$$

kde O_j je počet výstupních odkazů j . Maticově: nechť $A_{ij} = 1/O_i$ pro $(i, j) \in E$ a 0 jinak; pak $P = A^T P$.

Intuice: PageRank je jako „kapalina“, která cirkuluje sítí, přechází od uzlu k uzlu po hranách a shromažďuje se v nejdůležitějších uzlech. *Celkový PageRank v síti zůstává konstantní* — každá stránka svůj PageRank rozdělí a pošle po odkazech dál; PageRank se nikdy nevytváří ani nezaniká, jen se přemísťuje. Proto *není nutná normalizace* — na rozdíl od HITS.

Problém základní definice. V mnoha sítích skončí veškerý PageRank ve „špatných“ uzlech. Odkazují-li si F a G navzájem místo na A , PageRank, který k nim přiteče z C , se už nikdy nemůže vrátit — pro velká k dostaneme $\frac{1}{2}$ pro každý z F , G a 0 pro všechny ostatní. Jde o „pomalý únik“ (*slow leak*): malé množiny uzlů dosažitelné z ostatního grafu, ale bez cest zpět. **Řešení:** posílat malý zlomek PageRanku *všem* uzlům.

Škálovaný PageRank a tlumicí faktor

Zvol *škálovací faktor* d mezi 0 a 1 a nahraď základní pravidlo aktualizace:

1. nejprve aplikuj základní pravidlo;
2. všechny hodnoty PageRanku sniž faktorem d (celkový PageRank v síti se tím zmenší z 1 na d);
3. zbývajících $1 - d$ jednotek rozděl *rovnoměrně* mezi všechny uzly, tj. $(1 - d)/n$ každému.

Proč to funguje: je to „vodní cyklus“, který v každém kroku $1 - d$ jednotek PageRanku „odpaří“ a rovnoměrně je „sprchne“ na všechny uzly.

Opakovaná aplikace škálovaného pravidla *konverguje* k limitním hodnotám PageRanku a ekvilibrium je *jednoznačné* — hodnoty ale závisejí na volbě d . V praxi se používá d mezi 0,8 a 0,9 ($d = 0,85$ v původním článku); d se nazývá *tlumicí faktor* (*damping factor*).

PageRank jako markovský řetězec

Web jako *stochastický proces*: stránka = *stav*, hyperodkaz = *přechod*. *Náhodné surfování*: přechodová pravděpodobnost je $1/O_i$, klikáči surfař na odkazy uniformně náhodně (bez tlačítka „zpět“ a bez zadávání URL).

Nechť A je matice přechodových pravděpodobností a p_0 počáteční rozdělení; pak $p_k = A^\top p_{k-1}$. **Věta o markovských řetězcích:** konečný řetězec se stochastickou maticí A má **jednoznačné stacionární rozdělení**, je-li A *ireducibilní* a *aperiodická* — p_k pak konverguje k π nezávisle na volbě p_0 a v ustáleném stavu $\pi = A^\top \pi$, tedy π je hlavní vlastní vektor $A^\top$ s vlastním číslem 1. Právě π je vektor PageRanku: odráží *dlouhodobou pravděpodobnost*, že náhodný surfař stránku navštíví.

Pro webový graf neplatí ani jedna podmínka:

- A *není stochastická* — stránky bez výstupních odkazů dají v matici nulové řádky (*visící stránky, dangling pages*). Řešení: odstranit je během výpočtu (pořadí jiných stránek přímo neovlivňují), nebo z nich přidat odkazy na všechny stránky ($A_{ij} = 1/n$).
- A *není ireducibilní* — to by znamenalo *silně souvislý* graf (cesta z i do j pro každý pár), což web není.
- A *není aperiodická* — stav i je *periodický* s periodou $k > 1$, mají-li všechny cesty z i zpět do i délku dělitelnou k ; řetězec je aperiodický, jsou-li aperiodické všechny stavy. Příklad $k = 3$: z 1 vede zpět jen cesta $1 \rightarrow 2 \rightarrow 3 \rightarrow 1$.

Poslední dvě se řeší jedinou strategií: přidat odkaz z každé stránky na každou s malou přechodovou pravděpodobností řízenou parametrem d — rozšířená matice je pak ireducibilní i aperiodická.

Finální PageRank

Po augmentaci má náhodný surfař na stránce dvě možnosti: s pravděpodobností d zvolí náhodně odkaz, který bude následovat, a s pravděpodobností $1 - d$ skočí na náhodnou stránku:

$$P = \left(\frac{1-d}{n}\right) \mathbf{E} + d A^\top P,$$

kde $\mathbf{E} = \mathbf{e}\mathbf{e}^\top$ ($\mathbf{e}$ je sloupcový vektor jedniček), tj. $\mathbf{E}$ je matice $n \times n$ samých jedniček. Matice $\left(\frac{1-d}{n}\right)\mathbf{E} + dA^\top$ je stochastická (transponovaná), ireducibilní i aperiodická. Po přeskálování tak, aby $\mathbf{e}^\top P = n$:

$$P = (1-d)\mathbf{e} + d A^\top P, \quad \text{tj. pro každou stránku } i: \quad P(i) = (1-d) + d \sum_{j=1}^n A_{ji} P(j),$$

což je ekvivalentní formuli z původního článku o PageRanku

$$P(i) = (1-d) + d \sum_{(j,i) \in E} \frac{P(j)}{O_j}.$$

Výpočet mocninou iterací:

- 1: $P_0 \leftarrow \mathbf{e}/n$; $k \leftarrow 1$
- 2: **repeat**
- 3: $P_k \leftarrow (1-d)\mathbf{e} + dA^\top P_{k-1}$
- 4: $k \leftarrow k + 1$
- 5: **until** $\|P_k - P_{k-1}\|_1 < \varepsilon$
- 6: **return** P_k

Výhody PageRanku. *Boj se spamem:* stránka je důležitá, jsou-li důležité stránky, které na ni odkazují — a protože pro majitele stránky není snadné přidat *vstupní* odkazy z jiných důležitých stránek, není snadné PageRank ovlivnit. *Globální a dotazově nezávislá míra:* hodnoty PageRanku všech stránek se počítají a ukládají *offline*, nikoli v době dotazu. **Kritika:** právě dotazová nezávislost — PageRank neumí rozlišit stránky autoritativní *obecně* od stránek autoritativních *k tématu dotazu*.

Důležité: hyperodkazové řazení není jediný algoritmus ve vyhledávacích — kombinuje se s mnoha

faktory založenými na obsahu, aby vzniklo finální pořadí. (Yahoo! a MSN mají vlastní nepublikované odkazové algoritmy.)

6.15 Tematické komunity a jejich objevování

Odkazy lze použít i k nalezení *tematických komunit* — skupin tvůrců obsahu či lidí se společnými zájmy (webové, e-mailové, komunity pojmenovaných entit). Souvisí *cílené procházení* (*focused crawling*): následují se odkazy a klasifikátor rozhoduje, zda je stránka k tématu.

Tematická komunita

Pro danou konečnou množinu entit $E = \{e_1, \dots, e_n\}$ téhož typu je *tematická komunita* pár $K = (T, M)$, kde T je *téma* komunity a $M \subseteq E$ množina všech entit z E , které téma T sdílí. Je-li $e \in M$, říkáme, že e je *členem* komunity K .

- *Téma definuje komunitu* — pro dané T je množina členů jednoznačná, takže dvě komunity se stejným tématem jsou si rovny.
- *Téma lze definovat libovolně* — událost (skandál) nebo koncept (dolování z webu).
- *Entita může být v libovolném počtu komunit* $\Rightarrow$ komunity se mohou *překrývat* a sdílet členy.
- *Entity v E jsou téhož typu* — lidé a organizace nemohou být v téže komunitě.

Komunity mohou tvořit *hierarchii*: (T, M) může obsahovat *subkomunity* $\{(T_1, M_1), \dots, (T_k, M_k)\}$, kde T_i je podtéma T a $M_i \subseteq M$; (T, M) je pak *superkomunita* a každou subkomunitu lze dále dekomponovat.

Cíl objevování: v datové sadě najít skryté komunity — pro každou její *téma* (obvykle množina klíčových slov) a *členy*.

Manifestace komunity v datech: členové jsou nějak propojeni a přidružené texty obsahují slova indikativní pro téma. *Webové stránky* — propojení *hyperodkazy*, téma ze slov na stránkách; *e-maily* — členové komunikují mezi sebou, téma ze slov v e-mailech; *textové dokumenty* — členové se objevují *spolu* v téže větě (či dokumentu), téma ze slov ve větě.

Bipartitní jádra komunit

(i, j) -*bipartitní jádro* je úplný bipartitní podgraf s alespoň i *vějířovými* uzly (*fans*) a alespoň j *středovými* uzly (*centers*), tj. obsahuje všechny možné hrany mezi i vějířovými a j středovými vrcholy. Vějíře reprezentují *specializované huby*, středy odpovídají *autoritám*.

Postup hledání bipartitních jader:

- *Krok 1 — prořezání.* Odstraň velmi silně odkazované stránky (vstupní stupeň $> k$, např. $k = 50$). Pak iterativně: odstraň vějíře s výstupním stupněm $< j$, středy se vstupním stupněm $< i$ a hrany spojené s odstraněnými uzly.
- *Krok 2 — generování (i, j) -jader.* Najdi všechna $(1, j)$ -jádra (vrcholy s výstupním stupněm $\geq j$); $(2, j)$ -jádra zkonstruuuj kontrolou každého vějíře, který odkazuje také na některý střed z $(1, j)$ -jader; pokračuj až do i .

Omezení: algoritmus najde jen *jádrové* stránky komunit, ne všechny členské stránky, a nenajde ani *témata* komunit, ani jejich hierarchickou strukturu.

Překrývající se komunity pojmenovaných entit

Cíl: najít komunity entit z textového korpusu. **Hlavní idea:** dvě entity jsou propojeny, *vykytnou-li se v téže větě* (jsou-li dva lidé zmíněni v téže větě, obvykle mezi nimi existuje vztah); entita může být ve více komunitách a téma reprezentují nejvýznamnější klíčová slova. Slibné výsledky u komunit politiků a celebrit z webových dokumentů.

Algoritmus:

1. *Postav graf vazeb* — v každé větě identifikuj pojmenované entity a má-li věta více než jednu, propoj je *po párech*; klíčová slova z věty připoj k párům jako textový obsah, ostatní věty zahod.

2. *Najdi všechny trojúhelníky* — trojúhelník tří svázaných entit je základní stavební blok; komunita se rozšiřuje trojúhelníky sdílejícími hranu.
3. *Najdi jádra komunit* — jádro je skupina těsně svázaných trojúhelníků, tj. *uvolněná klika*: množina těsně propojených členů.
4. *Klasteruj okolo jader* — trojúhelníky a páry mimo jádra přiřaď k jádrům podle *podobnosti textového obsahu*.

6.16 Detekce komunit

Komunita a detekce komunit

Komunity jsou tvořeny jednotlivci tak, že ti *uvnitř* skupiny interagují mezi sebou *častěji* než s těmi vně skupiny. V různých kontextech se jim říká také *skupina*, *klastr*, *kohezí podgrupa*, *modul*.

Detekce komunit je objevování skupin v síti, kde příslušnost jednotlivců ke skupinám *není explicitně dána*.

Definice komunity je subjektivní: hustě propojený podgraf může být komunitou, ale i každá komponenta souvislosti může být komunitou.

Dva typy skupin v sociálních médiích: *explicitní* (vzniklé přihlášením uživatelů) a *implicitní* (sociální interakce). Proč extrahovat skupiny z topologie, i když lze do skupin vstoupit? Ne všechny weby platformu pro komunity mají; ne všichni jsou ochotni do skupiny vstoupit; skupiny se *dynamicky mění*. Interakce navíc doplňují ostatní druhy informací, pomáhají vizualizaci i navigaci a jsou základem pro další úlohy.

Metody minimálního řezu

Minimální řez (Ahuja et al., 1993). *Řez* je rozdělení vrcholů do dvou disjunktních množin; *úloha minimálního řezu* minimalizuje počet hran (u vážených sítí součet vah) mezi nimi — *velikost řezu*. Motivace: většina interakcí je *uvnitř* skupiny, mezi skupinami jsou vzácné $\Rightarrow$ detekce komunit $\approx$ minimální řez. Pro $k > 2$ se použije *iterativní bisekce* (skupiny se postupně dělí na dvě).

Nevýhoda: produkuje nevyvážené skupiny (jedna množina často jednoprvková).

Složitost: s - t řez přes maximální tok $O(n^5)$; Kargerův algoritmus $O(n^4)$, ale bez záruky nalezení minima. Pro jednotkové váhy a bez balančních omezení je 2-cestný řez polynomiální, $O(n^2 \log n)$ (Kargerův randomizovaný minimální řez). Obecné váhy a balanční omezení činí úlohu **NP-těžkou**.

Poměrový a normalizovaný řez

Minimální řez často vrací nevyvážené rozdělení (jedna množina je singleton) $\Rightarrow$ změníme účelovou funkci tak, aby brala v úvahu *velikost komunity*. Pro rozdělení $\pi = \{C_1, \dots, C_k\}$:

$$\text{RatioCut}(\pi) = \frac{1}{k} \sum_{i=1}^k \frac{\text{cut}(C_i, \bar{C}_i)}{|C_i|}, \quad \text{NCut}(\pi) = \frac{1}{k} \sum_{i=1}^k \frac{\text{cut}(C_i, \bar{C}_i)}{\text{vol}(C_i)},$$

kde $|C_i|$ je počet uzlů v C_i , $\text{vol}(C_i)$ součet stupňů v C_i a $\text{cut}(A, B) = \sum_{i \in A, j \in B} a_{ij}$. **Obě míry preferují vyvážené rozdělení.**

Girvanové–Newmanův algoritmus (2002)

Divizivní hierarchický algoritmus (přístup shora dolů): dekomponuje celý výchozí graf na postupně menší souvislé části, dokud nezůstanou žádné hrany k odstranění a každý uzel nereprezentuje sám komunitu.

Idea: identifikovat hrany spojující vrcholy z *různých* komunit (tzv. mosty) a iterativně je z grafu odstraňovat. **Kritérium:** *mezilehlost hrany* (*edge betweenness*) — podíl nejkratších cest procházejících danou hranou; hrany s vysokou mezilehlostí leží na velkém počtu nejkratších cest mezi

vrcholy, a jsou tedy mosty.

- 1: spočítej mezilehlost všech hran v síti
- 2: odstraň hranu s *nejvyšší* mezilehlostí
- 3: opakuji předchozí kroky, dokud v grafu zbývají hrany k odstranění

Vstup: celý graf. **Výstup:** hierarchická struktura, reprezentovaná např. dendrogramem.

Volba počtu komunit: algoritmus vrátí *množinu* řešení, ale neurčí nejlepší — pro každé dělení se spočítá *modularita* a vybere se rozdělení s nejvyšší.

Nevýhoda: vhodný pouze pro sítě *střední velikosti* kvůli vysokým výpočetním nákladům — $O(m^2n)$ pro graf o m hranách a n vrcholech, resp. $O(n^3)$ pro řídké sítě.

Příklad výpočtu mezilehlosti hrany: mezilehlost hrany $e(1, 2)$ je 4, protože všechny nejkratší cesty z 2 do $\{4, 5, 6, 7, 8, 9\}$ musí procházet buď $e(1, 2)$, nebo $e(2, 3)$, a $e(1, 2)$ je nejkratší cesta mezi 1 a 2. Po odstranění $e(4, 5)$ se mezilehlost $e(4, 6)$ zvýší na 20 (nejvyšší); po odstranění $e(4, 6)$ má nejvyšší mezilehlost 4 hrana $e(7, 9)$.

Modularita Q

Kvantifikuje kvalitu daného rozdělení grafu na komunity. **Základní idea:** síť má smysluplnou komunitní strukturu, je-li počet hran *mezi* komunitami menší, než by se očekávalo při náhodné volbě. Očekávaný počet hran mezi uzly i a j se stupni k_i, k_j je $k_i k_j / 2m$.

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j),$$

kde A_{ij} je prvek matice sousednosti (počet hran mezi i a j), m počet hran, k_i stupeň vrcholu i , c_i skupina, do níž i patří, a δ Kroneckerovo delta.

Hodnoty: $Q \in [-1, 1]$. Pozitivní Q znamená, že v síti lze komunitní strukturu najít; velké pozitivní hodnoty naznačují, že rozdělení odráží skutečnou strukturu. Pro smysluplné komunity by mělo být $Q \geq 0,3$ (Clauset et al., 2004).

Louvainova metoda (Blondel et al., 2008)

Hladová optimalizační metoda pro *aglomerativní hierarchickou* maximalizaci modularity, ve dvou fázích.

Fáze 1 — každý uzel je zprvu samostatná komunita; pak se opakovaně přesouvá izolovaný uzel do sousední komunity, počítá se zisk/ztráta modularity Q a při zisku se uzel v nové komunitě ponechá. Opakuje se, dokud lze modularitu zlepšit. **Výstup:** rozdělení k -té úrovně (k je číslo iterace).

Fáze 2 — z původní sítě se vytvoří *supergraf*: každý *supervrchol* je agregací uzlů jedné komunity z fáze 1 a dva supervrcholy spojuje hrana, existuje-li alespoň jedna hrana mezi odpovídajícími komunitami. Obě fáze se opakují až do maximální modularity.

Výhody: dobrý výkon i na velkých grafech při nízkých nákladech — $O(n \log n)$. **Nevýhoda:** výsledky jsou *citlivé na pořadí* zpracování.

Další nevýhody: *nesouvislé komunity* — přesun uzlu může původní komunitu učinit *vnitřně nesouvislou*, a přesto v ní ostatní uzly zůstanou (jsou lokálně optimálně přiřazeny); *uváznutí v lokálních optimech*; *selhání v upřesnění* komunit po počátečním slučování.

Leidenův algoritmus (Traag, Waltman, van Eck, 2019)

Upřesnění Louvainovy metody pro *aglomerativní hierarchickou* maximalizaci modularity. Tři fáze: (1) lokální přesuny uzlů (obdobně jako Louvain); (2) **upřesnění rozdělení**; (3) agregace sítě (obdobně jako Louvain).

Výhody: efektivnější než Louvainova metoda, ale pro obrovské grafy může vést k delším dobám zpracování; paralelní vícejádrové implementace mohou rychlost zvýšit. **Nevýhoda:** *tvrdé*

rozdělení — uzly mohou patřit jen do jedné komunity.

Výzvy detekce komunit. Přes množství algoritmů zůstává úloha náročná ze dvou důvodů: počet komunit obvykle není znám a je třeba jej určit; komunity jsou *heterogenní* co do velikosti a hustoty.

6.16.1 Taxonomie metod detekce komunit

Metody lze rozdělit do čtyř kategorií (kritéria se mohou podle úlohy lišit): *uzlově orientované* (každý uzel ve skupině splňuje určité vlastnosti), *skupinově orientované* (spojení uvnitř skupiny jako celku splňují určité vlastnosti, bez zoomu na úroveň uzlů), *síťově orientované* (rozdělení celé sítě do několika disjunktních množin) a *hierarchicky orientované* (konstrukce hierarchické struktury komunit).

Uzlově orientovaná detekce komunit

Uzly mohou být požadovány, aby splňovaly různé vlastnosti používané v tradiční SNA:

Úplná vzájemnost — kliky. *Klika* je maximální úplný podgraf tří a více navzájem sousedních uzlů. Nalezení maximální kliky je **NP-těžké**. *Rekurzivní prořezávání*: v klice velikosti k má každý uzel stupeň $\geq k - 1$, takže uzly se stupněm $< k - 1$ v maximální klice nebudou — opakovaně vzorkuj podsítě, najdi v ní kliku (hladově), a je-li velikosti k , odstraň všechny uzly se stupněm $\leq k - 1$; opakuj, dokud není síť dost malá. V sociálních médiích se prořeže mnoho uzlů, protože stupně následují mocninné rozdělení. Kliky se obvykle používají jako *jádro* či *semeno* pro větší komunity.

Metoda perkolace klik (*clique percolation method*, CPM) — klika je striktní a v praxi nestabilní definice; CPM hledá *překrývající se* komunity. *Vstup*: k a síť. *Postup*: najdi všechny kliky velikosti k ; zkonstruuj *graf klik* (dvě kliky jsou sousední, sdílejí-li $k - 1$ uzlů); komponenty souvislosti grafu klik jsou komunity. *Příklad*: kliky velikosti 3 jsou $\{1, 2, 3\}$, $\{1, 3, 4\}$, $\{4, 5, 6\}$, $\{5, 6, 7\}$, $\{5, 6, 8\}$, $\{5, 7, 8\}$, $\{6, 7, 8\} \Rightarrow$ komunity $\{1, 2, 3, 4\}$ a $\{4, 5, 6, 7, 8\}$ (uzel 4 je v obou).

Dosažitelnost — k -klika, k -klub, k -klan. Každý uzel ve skupině má být dosažitelný v k skocích. k -klika je maximální podgraf s největší geodetickou vzdáleností dvou uzlů $\leq k$ (pozor: *uvnitř podgrafu* může mít průměr $\geq k - 2$; klika $\{12, 4, 10, 1, 6\}$ má $d(1, 6) = 3$). k -klub má průměr $\leq k$; k -klan je k -klika s průměrem $\leq k$. *Příklad*: kliky $\{1, 2, 3\}$; 2-kliky $\{1, 2, 3, 4, 5\}$, $\{2, 3, 4, 5, 6\}$; 2-kluby $\{1, 2, 3, 4\}$, $\{1, 2, 3, 5\}$, $\{2, 3, 4, 5, 6\}$.

Stupně uzlů — k -jádro, k -plex. Každý uzel má mít daný počet spojení *uvnitř* skupiny. k -jádro (k -core): každý uzel je spojen s alespoň k dalšími členy. k -plex: ve skupině o n_s uzlech je každý uzel sousední s ne méně než $n_s - k$ uzly. Definice jsou komplementární (k -jádro je $(n_s - k)$ -plex), ale množina všech k -jader pro dané k není identická s množinou všech $(n_s - k)$ -plexů — velikost n_s se mezi k -jádry může lišit.

Vazby uvnitř vs. vně — LS množiny. *LS množina* (Luccio–Sami): každá vlastní podmnožina má více vazeb *ve* skupině než *mimo* ni. Vznikla pro návrh obvodů na čipech, pro síťovou analýzu je *příliš striktní*. Uvolněním je k -komponenta — maximální podgraf, který zůstává souvislý i po odstranění méně než k vrcholů či hran (vyžaduje výpočet hranové souvislosti algoritmem minimálního řezu / maximálního toku).

Omezení uzlově orientovaných definic: příliš striktní (použitelné jako jádro komunity); neškálovatelné, jen pro malé sítě; někdy nekonzistentní s vlastnostmi rozsáhlých sítí (stupně uzlů v bezškálových sítích).

Skupinově orientovaná detekce: kvazikliky

Skupinově orientovaná kritéria vyžadují, aby *celá skupina* splňovala určitou podmínku — např. aby hustota skupiny byla dostatečně velká ($\geq$ daný prah). Podgraf $G_S = (V_S, E_S)$ je γ -hustá kvaziklika, je-li

$$|E_S| \geq \gamma \cdot \frac{|V_S|(|V_S| - 1)}{2}.$$

Lze použít strategii podobnou klikám: *lokální prohledávání* — vzorkuj podgraf a najdi maximální γ -hustou kvazikliku (velikosti k); *heuristické prořezávání* — odstraň uzly se stupněm menším než průměrný stupeň ($< \gamma(k-1)$).

Síťově orientovaná detekce komunit

Kritéria uvažují spojení v síti *globálně*; cílem je rozdělit uzly sítě do *disjunktních* množin. Přístupy: shlukování podle podobnosti vrcholů; modely latentního prostoru; aproximace blokovým modelem; spektrální shlukování; maximalizace modularity.

Shlukování podle podobnosti vrcholů. Na uzly se aplikuje k -means, kde podobnost vrcholů je dána podobností jejich *sousedství* (spojení se chápou jako příznaky). *Strukturní ekvivalence* (spojení s *touž* množinou aktérů) je pro praxi příliš restriktivní, používají se míry

$$\text{Jaccard}(v_i, v_j) = \frac{|N_i \cap N_j|}{|N_i \cup N_j|}, \quad \cos(v_i, v_j) = \frac{|N_i \cap N_j|}{\sqrt{|N_i| |N_j|}}.$$

Modely latentního prostoru. Zobrazí uzly do *nízkorozměrného* prostoru se zachováním jejich blízkosti a pak aplikují k -means. *Vícerozměrné škálování* (MDS): z párových (např. geodetických) vzdáleností se sestaví matice blízkosti; souřadnice $S \in \mathbb{R}^{n \times l}$ vyjdou jako $S = V\Lambda^{1/2}$, kde V je l hlavních vlastních vektorů a Λ diagonální matice jejich vlastních čísel (z dvojité centrované matice blízkosti).

Blokové modely. $A \approx S\Sigma S^T$, kde Σ je *míchací matice* a S *indikátorová matice komunit*; při uvolnění S na reálné hodnoty jsou optimem hlavní vlastní vektory A .

Spektrální shlukování. Poměrový i normalizovaný řez lze přeformulovat jako minimalizaci $\text{tr}(S^T L S)$ s *grafovým laplaciánem* $L = D - A$ (poměrový řez), resp. *normalizovaným* $L = D^{-1/2}(D - A)D^{-1/2}$; D je diagonální matice stupňů. Po *spektrální relaxaci* je optimem matice vlastních vektorů s *nejmenšími* vlastními čísly (první je nepoužitelný — říká, že všechny uzly patří do téhož klastru).

Maximalizace modularity. *Síla komunity* je $\sum_{i,j \in C} (A_{ij} - \frac{d_i d_j}{2m})$, modularita $Q = \frac{1}{2m} \sum_C \sum_{i,j \in C} (A_{ij} - \frac{d_i d_j}{2m})$. Analogicky ke spektrálnímu shlukování se použije *matice modularity* $B = A - \frac{dd^T}{2m}$; optimem jsou její *hlavní* vlastní vektory, na něž se postprocessingem pustí k -means.

Jednotný pohled: maticová faktorizace. Modely latentního prostoru, blokové modely, spektrální shlukování a maximalizace modularity lze všechny zapsat jako faktorizaci $X \approx S\Sigma S^T$, kde

$$X = \begin{cases} \text{(dvojitě centrovaná) matice blízkosti} & \text{modely latentního prostoru,} \\ \text{sociomatrice } A & \text{aproximace blokovým modelem,} \\ \text{grafový laplacián} & \text{minimalizace řezu,} \\ \text{matice modularity} & \text{maximalizace modularity.} \end{cases}$$

Omezení: všechny vyžadují, aby uživatel zadal *počet komunit* předem.

Hierarchicky orientovaná detekce komunit

Cíl: vybudovat hierarchickou strukturu komunit na základě topologie sítě; umožňuje analýzu sítě v různých *rozlišeních*. Dva reprezentativní přístupy:

Divizivní hierarchické shlukování — např. Girvanové-Newman ($O(m^2 n)$, resp. $O(n^3)$ pro řídké sítě): rozděl uzly do několika množin a každou dále dělej na menší (na rozdělení lze aplikovat síťově orientované metody). Konkrétně: rekurzivně odstraňuj „nejslabší“ vazbu — najdi hranu s nejmenší silou, odstraň ji, aktualizuj síly hran a opakuj, dokud se síť nerozpadne na požadovaný počet komponent souvislosti; každá komponenta je komunita. Sílu vazby lze měřit *mezilehlostí hrany* — vyšší mezilehlost značí most.

Aglomerativní hierarchické shlukování — např. Louvain, $O(n \log n)$: inicializuj každý uzel jako komunitu; postupně slučuj komunity do větších podle konkrétního kritéria (např. na základě *přírůstku modularity*). Dalším příkladem je *Walktrap* — spouští krátké náhodné procházky a podle jejich výsledků slučuje komunity zdola nahoru.

6.17 Predikce vazeb

Úloha predikce vazeb

Cíl: predikovat *budoucí* vazby mezi páry uzlů v síti. V komerčních sociálních sítích (Facebook, LinkedIn) se uživatelům doporučují potenciální přátelé. Použít lze podobnost obsahu i strukturu:

- **Míry založené na obsahu** využívají princip *homofilie* — uzly s podobným obsahem se spíše propojí. Zlepšují predikci vazeb, ale jsou citlivé na konkrétní síť (např. krátké a šumivé tweety s nestandardními akronymy na Twitteru). *Obsahová homofilie nutně neimplikuje strukturní propojenost!*
- **Strukturní míry** využívají princip *tranzitivního uzávěru* — dva uzly, které sdílejí sousedství, se spíše propojí. Tranzitivní uzávěr je velmi častý napříč doménami, míry jsou účinné v různých typech sítí a přímo aplikovatelné. Patří k nim *sousedské míry*, *Katzova míra*, míry založené na *náhodných procházkách*. *Strukturní propojenost obvykle implikuje i obsahovou homofilii.*

Sousedské míry predikce vazeb

Využívají počet *společných sousedů* mezi párem uzlů i a j ke kvantifikaci pravděpodobnosti budoucí vazby. Nechť S_i je množina sousedů uzlu i .

Míra společných sousedů: $CN(i, j) = |S_i \cap S_j|$. *Slabina:* nezohledňuje *relativní* počet společných sousedů — dvě velmi populární osobnosti spojené s mnoha aktéry mohou mít mnoho společných sousedů *jen náhodou*.

Jaccardova míra: $Jaccard(i, j) = \frac{|S_i \cap S_j|}{|S_i \cup S_j|}$ — podobnost sousedství *normalizovaná* vůči stupňům uzlů, které se kvůli mocninnému rozdělení silně liší; vyšší stupně obou uzlů koeficient sníží. *Slabina:* nepřizpůsobuje se *prostředním* sousedům — je-li společný soused velmi populární, vyskytuje se jako společný soused i u mnoha jiných párů, a je tedy pro predikci *méně důležitý*.

Adamicova–Adarova míra — vážená verze míry společných sousedů zohledňující jejich různou důležitost: váha souseda je *klesající* funkcí jeho stupně, např. $1/\log |S_k|$:

$$AA(i, j) = \sum_{k \in S_i \cap S_j} \frac{1}{\log |S_k|}.$$

Příklad: pro čtyři společné sousedy se stupni 4, 2, 2, 4 je $\frac{1}{\log 4} + \frac{1}{\log 2} + \frac{1}{\log 2} + \frac{1}{\log 4} = \frac{3}{\log 2}$.

Katzova míra

Sousedské míry *nejdou účinné* při malém počtu společných sousedů: sdílejí-li Alice a Bob jediného společného souseda a Alice a Jim také, sousedské míry mezi těmito případy nerozliší — existuje ale *nepřímá* propojenost přes delší cesty. Pak jsou vhodnější míry založené na *procházkách*, jako Katzova.

Nechť $W_{ij}^{(t)}$ je počet procházek délky t mezi uzly i a j . Pro předem zvolený parametr $\beta < 1$:

$$Katz(i, j) = \sum_{t=1}^{\infty} \beta^t W_{ij}^{(t)},$$

kde β je *diskontní faktor*, který potlačuje význam delších procházek; pro malá β nekonečná suma konverguje. Je-li A symetrická matice sousednosti neorientované sítě, lze matici Katzových

koeficientů K rozměru $n \times n$ spočítat jako

$$K = \sum_{t=1}^{\infty} \beta^t A^t = (I - \beta A)^{-1} - I$$

(vlastní čísla A^t jsou t -té mocniny vlastních čísel A). Silně centrální uzly mají tendenci tvořit vazby s mnoha uzly $\Rightarrow$ součet Katzových koeficientů uzlu i vůči ostatním uzlům se nazývá jeho **Katzova centralita**.

Predikce vazeb jako klasifikační úloha

Přítomnost či absence vazby mezi párem uzlů se chápe jako *binární* indikátor třídy; pro každý pár uzlů se zkonstruuje vícerozměrný datový záznam:

- *příznaky* zahrnují všechny různé podobnosti mezi uzly — sousedské, Katzovy, založené na procházkách — plus řadu příznaků preferenčního připojování, např. stupně obou uzlů v páru;
- výsledkem je *pozitivně-neoznačovaná* klasifikační úloha: páry uzlů s hranou jsou pozitivní příklady a zbývající páry jsou neoznačované;
- neoznačované příklady lze při trénování přibližně považovat za negativní;
- protože je negativních párů v rozsáhlých a řídkých sítích příliš mnoho, použije se jen *vzorek* negativních příkladů.

Algoritmus. *Trénovací fáze:* vygeneruj data s jedním záznamem pro každý pár uzlů s hranou a vzorek záznamů z párů bez hrany; příznaky odpovídají extrahovaným podobnostním a strukturním rysům; označení třídy je přítomnost či absence hrany; postav a natrénuj model klasifikátoru. *Testovací fáze:* převed' každý testovaný pár uzlů na vícerozměrný záznam a použij natrénovaný klasifikátor k predikci označení. Běžnou volbou bazového klasifikátoru je *logistická regrese*; kvůli nevyváženosti dat se často používají *cenově citlivé* verze klasifikátorů.

Výhody supervizovaného přístupu: obsahové příznaky lze snadno přidat; klasifikátor se sám naučí relevanci příznaků; pro orientované sítě lze příznaky extrahovat *asymetricky* (vstupní a výstupní stupně, personalizovaný PageRank); vyšší flexibilita díky schopnosti učit se vztahy mezi vazbami a příznaky různých typů.

Souhrn predikce vazeb. Účinnost se liší podle datové sady: *sousedské* míry se efektivně spočítají i pro rozsáhlá data a fungují téměř tak dobře jako ostatní nesupervizované; *Katzova* míra a míry na *náhodných procházkách* jsou pro *velmi řídké* sítě, kde nelze počet společných sousedů robustně změřit; *supervize* dá lepší přesnost a adaptabilitu napříč doménami, ale je drahá; obsah predikci vylepšuje, strukturní míry jsou však *výrazně silnější* (kvůli tranzitivitě reálných sítí). Obsahové míry stavějí na „obrácené homofilii“ — podobný či s vazbami korelovaný obsah se využívá k predikci vazeb.

6.18 Shrnutí ke zkoušce

- **SNA** = sociální vědy + analýza sítí + teorie grafů; soustředí se na *vztahy*, ne na entity a jejich atributy. Reprezentace: obrázek, seznam hran, matice sousednosti (u orientovaných grafů nesymetrická). *Ego síť* vs. „celá“ síť — *problém specifikace hranic*: žádná studovaná síť není celá.
- **Síla vazeb**: silné vs. slabé; *síla slabých vazeb* (Granovetter 1973). Homofilie, tranzitivita a přemostění; homofilie + tranzitivita $\rightarrow$ *kliky*. Most = hrana, jejíž odstranění rozpojí koncové uzly; *zkratkový most* = vzdálenost po odstranění vzroste nad 2. **Překryv sousedství** $O(i, j) = \frac{|N_i \cap N_j|}{|N_i \cup N_j| - 2}$ — čím větší, tím silnější vazba.
- **Čtyři míry centrality**: *stupňová* (kolik lidí přímo dosáhne), *mezilehlá* (na kolika nejkratších cestách leží; kde se síť rozpadne), *blízkostní* (převrácená průměrná délka nejkratších cest; rychlost šíření), *vlastní* ($Ax = \lambda x$, jen *největší* vlastní číslo dává nezáporný vektor; jak dobře je spojen s dobře propojenými). Umět interpretační tabulku a vysvětlit, proč nestačí jedna míra (uzly 3 a 5 *společně* > uzel 10). **Strukturní ekvivalence**: pozice lze vyměnit bez změny struktury.
- **Koheze**: reciprocita (jen orientované grafy), hustota ($|E|/\binom{|V|}{2}$); klika = 1; orientované mají

poloviční), **klastrovací koeficient** $C_i = \frac{2|e_{jk}|}{k_i(k_i-1)}$ a síť jako průměr, průměr sítě (*diameter*) = nejdelší nejkratší cesta, průměrná vzdálenost, excentricita. **Malý svět** = vysoký C + krátká průměrná cesta.

- **Šest vlastností reálných komplexních sítí:** efekt malého světa (Milgram, medián 6), tranzitivita/klastrování, mocinné rozdělení stupňů, odolnost (robustní k náhodnému, zranitelná cíleným odstraněním hubů), vzorce míchání (asortativní míchání = homofilie), komunitní struktura. **Bezškálové sítě:** růst + *preferenční připojování* (rich-get-richer, Matoušův efekt, kumulativní výhoda); důvody — popularita, kvalita, smíšený model (halo efekt). **Centralizace** a struktura *jádro-periferie* (bow-tie analýza).
- **Modelování vlivu:** společné rysy (orientovaný graf, aktivní/neaktivní, *aktivovaný uzel nelze deaktivovat*). **LTM** — prah θ_v uniformně z $[0, 1]$, aktivace při $\sum_{\text{aktivní}} w_{u,v} \geq \theta_v \sum w_{u,v}$; soustředí se na *příjemce*. **ICM** — *jediná* příležitost aktivovat každého souseda s pravděpodobností $p_{v,u}$; soustředí se na *vysílající*. **Maximalizace vlivu** je NP-těžká, hladový přístup dává **63 %** optima.
- **Vliv vs. korelace:** *test korelace* (podíl hran mezi různými hodnotami atributu vs. $2p(1-p)$; příklad kuřáků $14\% < 49\%$); tři procesy — homofilie, *zmatení*, vliv; logistický model $\ln \frac{p(a)}{1-p(a)} = \alpha \ln(a+1) + \beta$, α = koeficient sociální korelace; **shuffle test** — zpřeházej časové značky; liší-li se α' významně od α , jde o důkaz *vlivu*.
- **Test homofilie:** heterogenních hran je významně méně než $2pq \Rightarrow$ homofilie; významně *více* $\Rightarrow$ *inverzní* homofilie (partnerské vztahy). Umět příklad: 5 z 18 vs. $2pq = 8$ z 18.
- **Výběr vs. sociální vliv:** výběr = charakteristiky řídí tvorbu vazeb; vliv = vazby formují *mutabilní* charakteristiky. *Imutabilní* (pohlaví, rasa, věk) vs. *mutabilní* (chování, názory). Rozlišit lze jen *longitudinálními* studiemi (obezita: Christakis & Fowler, 12 000 lidí / 32 let $\rightarrow$ důkaz pro *sociální vliv*).
- **Afiliční síť:** bipartitní (osoby $\times$ fokusy), sociálně-afiliční má dva typy hran. **Tři uzávěry:** tranzitivní (společný přítel), *fokální* (společný fokus; *výběr*), *členský* (přítel už ve fokusu; *sociální vliv*). Metodika měření $T(k)$ ze dvou snímků; bazový model $T_{\text{base}}(k) = 1 - (1-p)^k$; empiricky velký nárůst z 1 na 2 a poté *klesající výnosy*.
- **Schellingův model:** agenti dvou typů v mřížce, spokojeni při $\geq t$ sousedech téhož typu, nespokojení se přesouvají $\Rightarrow$ *samovolná segregace*. Ukazuje, jak se *imutabilní* charakteristika stane silně korelovanou s *mutabilní* (volbou místa) a jak lokální homofilie vytvoří globální vzorec.
- **Strukturní balance:** balancované trojúhelníky jsou +++ a +-- (tj. všechny tři pozitivní, nebo právě jedna pozitivní). **Věta o balanci:** úplný balancovaný graf $\Rightarrow$ všichni přátelé, nebo rozdělení na dvě skupiny vnitřních přátel a vzájemných nepřátel — umět důkaz (X = přátelé A , Y = nepřátelé A , tři kroky). **Slabá balance:** zakázána jen konfigurace *dvě pozitivní a jedna negativní* $\Rightarrow$ rozdělení na *libovolný počet* skupin. Aplikace: evropské aliance 1872–1907, Bangladéš 1972.
- **HITS:** dotazově *závislý*; kořenová množina S ($t = 200$) $\rightarrow$ bazová množina B ; $a = L^\top h$, $h = La$, mocinná iterace s **nutnou normalizací**; $a_k = (L^\top L)^{k-1} a_0$ konverguje k hlavnímu vlastnímu vektoru $L^\top L =$ *ko-citační* matice ($LL^\top$ = bibliografické párování). Slabiny: snadné spamování, drift tématu, neefektivnost v době dotazu.
- **PageRank:** dotazově *nezávislý*, $P(i) = \sum_{(j,i) \in E} P(j)/O_j$, *nepotřebuje normalizaci* (celkový PageRank je konstantní — „kapalina“). Problém „pomaleho úniku“ $\Rightarrow$ *škálované* pravidlo s tlumícím faktorem d (0,8–0,9; 0,85 v článku), „vodní cyklus“. Markovský řetězec potřebuje *stochastickou, ireducibilní a aperiodickou* matici — webový graf nesplňuje ani jednu (visící stránky, není silně souvislý, periodicitu); vše se řeší *jedinou* strategií (odkaz z každé stránky na každou s malou pravděpodobností). Finální tvar $P(i) = (1-d) + d \sum_{(j,i) \in E} P(j)/O_j$, výpočet mocninou iterací. Výhody: odolnost proti spamu (vstupní odkazy nelze snadno získat), globální offline míra; kritika: dotazová nezávislost.
- **Tematické komunity:** $K = (T, M)$, téma určuje komunitu, komunity se mohou *překrývat*, hierarchie subkomunit. *Bipartitní jádra* — (i, j) -jádro, vějíře = huby, středy = autority; prořezání + generování jader; najde jen jádra, ne témata ani hierarchii. *Komunity pojmenovaných entit:* graf ze společných výskytů ve větě $\rightarrow$ trojúhelníky $\rightarrow$ jádra $\rightarrow$ klastrování podle textové podobnosti.

- **Detekce komunit** — **definice je subjektivní**; explicitní vs. implicitní skupiny. *Minimální řez*: nevyvážené skupiny, $O(n^5)$ / Karger $O(n^4)$, s obecnými vahami a balančními omezeními **NP-těžké** $\Rightarrow$ *poměrový* a *normalizovaný řez* (dělení $|C_i|$, resp. $\text{vol}(C_i)$).
- **Girvanové–Newman**: divizivní, odstraňuje hrany s nejvyšší *mezilehlostí*, $O(m^2n)$ / $O(n^3)$; počet komunit se vybere podle nejvyšší **modularity** $Q = \frac{1}{2m} \sum_{i,j} (A_{ij} - \frac{k_i k_j}{2m}) \delta(c_i, c_j)$, $Q \in [-1, 1]$, smysluplné komunity $Q \geq 0,3$.
- **Louvain**: hladová aglomerativní maximalizace modularity ve dvou fázích (lokální přesuny $\rightarrow$ supergraf), $O(n \log n)$; nevýhody: citlivost na pořadí, *nesouvislé komunity*, lokální optima. **Leiden** přidává fázi *upřesnění rozdělení*; jen tvrdé rozdělení. Výzvy: neznámý počet komunit, heterogenní velikosti a hustoty.
- **Čtyři kategorie metod**: *uzlově orientované* (kliky — NP-těžké, rekurzivní prořezávání uzlů se stupněm $< k-1$, **CPM** pro *překrývající se* komunity přes graf klik sdílejících $k-1$ uzlů; k -klicka / k -klub / k -klan; k -jádro a k -plex jsou komplementární; LS množiny a k -komponenty), *skupinově orientované* (γ -husté kvazikliky), *síťově orientované* (podobnost vrcholů — Jaccard, kosinus + k -means; MDS; blokové modely; spektrální shlukování přes grafový laplacián s *nejmenšími* vlastními čísly; maximalizace modularity přes matici modularity s *největšími* — vše sjednoceno jako maticová faktorizace $X \approx S \Sigma S^T$, vyžaduje zadat počet komunit), *hierarchicky orientované* (divizivní = Girvanové–Newman, aglomerativní = Louvain, Walktrap).
- **Predikce vazeb**: obsahové míry (homofilie) vs. strukturní (tranzitivní uzávěr; silnější). Sousedské míry: *společní sousedé* $|S_i \cap S_j|$ (nezohledňuje stupně), *Jaccard* $\frac{|S_i \cap S_j|}{|S_i \cup S_j|}$ (normalizuje stupně obou uzlů, ne prostředních sousedů), *Adamic–Adar* $\sum_k \frac{1}{\log |S_k|}$ (váha klesá se stupněm společného souseda). **Katzova míra** $\sum_t \beta^t W_{ij}^{(t)} = (I - \beta A)^{-1} - I$ pro *řídke* sítě s málo společnými sousedy; součet přes ostatní uzly = *Katzova centralita*. **Klasifikační pojetí**: pozitivně-neoznačkováná úloha, vzorek negativ, logistická regrese jako bazový klasifikátor, cenově citlivé varianty; výhoda — klasifikátor se sám naučí relevanci příznaků a lze použít *asymetrické* příznaky u orientovaných sítí.

7 Praktické využití technik

Poslední věta okruhu žádá spojení obou polovin dohromady: k čemu se probrané techniky *skutečně* používají. U zkoušky se hodí umět ke každé aplikaci říct *jakou úlohu* řeší (kap. 1), *jakou metodou* (kap. 3) a *jak se vyhodnocuje* (kap. 5).

7.1 Dobývání znalostí

Aplikace	Typ úlohy / metoda	Poznámka
Analýza nákupního košíku	asociační pravidla, Apriori / FP-Growth	plánování a rozvržení prodejny, kupony a časově omezené slevy, „balíčkování“ produktů; srovnání nových a existujících prodejen pomocí <i>virtuálních položek</i>
Detekce podvodů	klasifikace, detekce odlehlých hodnot	20 mil. výkonů zdravotní pojišťovny → 214 tis. podivných → 14 tis. předaných k ruční kontrole → 8 tis. potvrzených podvodů; stroj <i>zaostřuje</i> pozornost experta
Kreditní skórování	rozhodovací stromy, naivní Bayes, logistická regrese	průběžný příklad v celém textu; požaduje se <i>srozumitelnost</i> (regulace) a zacházení s chybějícími hodnotami
Segmentace zákazníků	klastrová analýza (<i>k</i> -means, hierarchické)	reprezentace segmentu <i>centroidem</i> („typický zákazník“) je pro byznys velmi intuitivní
Predikce odchodu (churn)	klasifikace na nevyvážených datech	accuracy nestačí ⇒ precision/recall, F_1 , ROC/AUC; <i>lift analýza</i> pro rozhodnutí, kolik zákazníků kontaktovat
Cílené marketingové kampaně	skórování a řazení, lift	ekonomická úvaha nad lift křivkou (příklad s hodinkami: 1. příhrádka +\$550, 10. příhrádka −\$475)
Klasifikace textu	SVM s kernely	patří k nejlepším klasifikátorům pro text (vysokorozměrná data); srozumitelnost se neočekává
Predikce časových řad	regrese, neuronové sítě	řada se transformuje posuvným oknem na tabulku vstupů a výstupů
Klasifikace chemických látek	klasifikace strukturních dat	reprezentace řetězci SMILES nebo fakty v Prologu
Web usage mining	sekvenční vzory (GSP)	navigační vzory uživatelů podle posloupností návštěv stránek
Doporučovací systémy [♦ nad rámec slidů]	klastrová analýza, klasifikace, predikce vazeb	kolaborativní filtrování (podobnost uživatelů či položek) vs. obsahové filtrování; studený start řeší obsah

Poznámka k motivaci rozhodovacích stromů. Banka Barclays zavedla telefonní systém rozdělující volající podle úvěrového hodnocení: klienti s vysokými úsporami nebo dostatečným limitem šli na britského operátora, ostatní do indického call centra — cílem bylo „odfiltrovat“ zákazníky bez peněz na produkty banky. Kritika: systém preferuje bohatší klienty a nemá za cíl dát nejlepší radu. Ilustruje, že *technicky správný* model může mít problematické důsledky a že fáze *vyhodnocení* v CRISP-DM musí zahrnovat i pohled mimo přesnost.

7.2 Analýza sociálních sítí

Oblast	Využití
Podniky	analýza a zlepšení komunikačních toků v organizaci, s partnery či zákazníky; marketingové kampaně založené na sociálních sítích (vizualizace komunikačních toků před a po zavedení systému pro správu obsahu)
Bezpečnostní složky a armáda	identifikace kriminálních a teroristických sítí ze zachycené komunikace; identifikace <i>klíčových hráčů</i> v nich (míry centrality, odd. 6)
Sociální sítě (Facebook)	identifikace a doporučení potenciálních přátel na základě „přátel přátel“ — přímo úloha <i>predikce vazeb</i>
Občanská společnost	odhalování konfliktů zájmů ve skrytých vazbách mezi státními orgány, lobbisty a podniky
Síťoví operátoři	optimalizace struktury a kapacity komunikačních sítí
Medicína	nakažlivé nemoci a jejich prevence; sexuálně přenosné nemoci — epidemie syfilis v Rockdale County (Atlanta, 1996): skupina bílých dívek okolo 16 let, skupina bílých chlapců 17–21 let a skupina afroamerických chlapců 17–21 let; syfilis diagnostikována u 6 bílých žen, 2 bílých mužů a 2 afroamerických mužů
Bezškálové sítě	<i>výpočetní technika</i> : SF sítě (WWW) jsou odolné proti náhodným poruchám, ale zranitelné koordinovaným útokem — vymýcení internetových virů je v podstatě nemožné; <i>medicína</i> : vakcinace cílená na huby (lidé s mnoha kontakty, obtížně identifikovatelní), léky mířící na klíčové molekuly nemoci podle vazebných sítí v buňkách; <i>business</i> : vazby mezi firmami a odvětvími pro eliminaci kaskádových krachů, šíření „nákaz“ v marketingu
Detekce komunit	<i>Belgický mobilní operátor</i> (Louvainova metoda): cca 2 miliony zákazníků; velikost uzlu odpovídá počtu jednotlivců v komunitě, barva hlavnímu jazyku komunity (červená francouzština, zelená nizozemština); zobrazeny jen komunity nad 100 zákazníků. Zoom ve vyšším rozlišení odhalí <i>přechodovou</i> komunitu tvořenou subkomunitami s méně zřetelným jazykovým oddělením

Kdy a proč SNA použít. Studovat sociální síť nebo zvýšit její efektivitu; vizualizovat vzorce ve vztazích a interakcích; sledovat cesty, kterými proudí informace; identifikovat typy aktérů (klíčové hráče); najít příčiny dysfunkčních komunit a podpořit kohezi a růst online komunity. Klíčová myšlenka: rozsah akcí a příležitostí dostupných jednotlivci je často funkcí jeho *pozice* v síti, takže odhalení pozic (otec, učitel, pracovník) přináší i překvapivé výsledky.

Úvahy o návrhu (*thoughts on design*)

Teorie SNA inspirovala některé z prvních sociálních sítí (např. SixDegrees), stále se však při návrhových rozhodnutích nepoužívá tak často. Otevřené otázky:

- Jak může online platforma (nebo její správci) využít metody a poznatky SNA?
- Jak může platforma povzbudit uživatele, aby jednali (*lokálně*) tak, že tím rozšíří komunitu?
- Jaká opatření může online komunita přijmout k optimalizaci své struktury? Příklad: *kliky* mohou být nežádoucí, protože odhánějí nově příchozí.
- Jaké struktury jsou žádoucí pro různé typy online platform?
- Jak mohou online komunity identifikovat a využít klíčové hráče ke svému prospěchu?

7.3 Provozní a etické aspekty nasazení

[♦ nad rámeček slidů] Nasazení modelu (fáze *Deployment* v CRISP-DM, odd. 1.5) není konec projektu:

- **Monitoring a drift.** Rozdělení dat se v čase mění (*data drift*), stejně jako vztah mezi vstupy a cílem (*concept drift*) — model je nutné pravidelně přeučovat a sledovat pokles kvality na produkčních datech.
- **Zpětná vazba modelu do dat.** Nasazený model ovlivňuje realitu, kterou měří: skórovací model pro schvalování úvěrů vidí jen ty žadatele, kterým úvěr schválil, takže další trénovací data jsou

jím samým zkreslená.

- **Soukromí.** Analýza sociálních sítí pracuje s daty *o vztazích*, které uživatel často nemohl ovlivnit; i anonymizovaný graf lze deanonymizovat podle struktury. Predikce vazeb a modelování vlivu jsou v podstatě nástroje pro předpovídání a ovlivňování chování konkrétních lidí.
- **Spravedlnost a diskriminace.** Model naučený na historických datech reprodukuje historickou nerovnost (viz případ Barclays výše); chráněný atribut lze často *rekonstruovat* z ostatních atributů, takže jeho vypuštění samo nestačí.
- **Právní rámec.** GDPR čl. 22 (právo na vysvětlení automatizovaného rozhodnutí) a AI Act pro vysoce rizikové systémy — v regulovaných doménách je interpretovatelnost právním požadavkem, nikoli pohodlím.

7.4 Shrnutí ke zkoušce

- Ke každé aplikaci umět říct **trojici**: typ úlohy (deskriptivní / prediktivní, s učitelem / bez učitele), použitá metoda, způsob vyhodnocení.
- **Vlajkové aplikace dobývání znalostí**: analýza nákupního košíku (asociační pravidla), detekce podvodů (příklad zdravotní pojišťovny — stroj *zaostřuje* pozornost experta, nenahrazuje jej), kreditní skórování (stromy a Bayes; požadavek srozumitelnosti), segmentace zákazníků (klastrování, centroid = typický zákazník), churn a cílený marketing (nevyvážená data → ROC/AUC a *lift*), klasifikace textu (SVM), predikce časových řad (posuvné okno), web usage mining (sekvenční vzory).
- **Vlajkové aplikace SNA**: identifikace klíčových hráčů v kriminálních a teroristických sítích (centralita), doporučování přátel (predikce vazeb), optimalizace komunikačních sítí, epidemiologie (Rockdale County 1996), vakcinace cílená na *huby*, marketing a kaskádové finanční krachy v bezškálových sítích, segmentace zákazníků operátora podle jazykových komunit (Louvain, 2 mil. zákazníků).
- **Klíčová vlastnost SF sítí pro praxi**: odolnost proti náhodným poruchám (až 80 % uzlů) vs. zranitelnost cíleným útokem (5–15 % hubů) — z toho plyne jak strategie vakcinace, tak nemožnost vymýtit internetové viry.
- **Nasazení není konec**: monitoring driftu, zpětná vazba modelu do dat, soukromí (i anonymizovaný graf lze deanonymizovat), spravedlnost (chráněný atribut lze rekonstruovat z ostatních), GDPR čl. 22 a AI Act.