

Vzorce a rovnice ke SZZ

Multiagentní systémy • Přírodou inspirované počítání • Dobývání znalostí

SZZ Umělá inteligence, MFF UK

srpen 2026

Výcuc ze tří učebních textů (01-multiagentni-systemy, 02-prirodou-inspirovane-pocitani, 03-dobyvani-znalosti): **jen vzorce a rovnice, které je potřeba umět**, každý s krátkým popisem toho, co znamená a kde se používá. Slouží k poslednímu opakování a k ověření, že člověk formulí umí napsat bez nahlédnutí do textu — *proč* to tak je a kdy se to používá je v příslušné kapitole zdrojového textu.

Jak text používat

Názvy i čísla kapitol a podkapitol jsou převzaty ze zdrojových textů 01, 02 a 03, takže se dá listovat oběma směry: kapitola 3.2.4 *Support Vector Machines* je zde i tam pod stejným číslem. *Mezery v číslování* znamenají, že daná kapitola zdroje žádný vzorec neobsahuje. Vzorec, který pokrývá dvě sousední podkapitoly zdroje, je zařazen pod tu první a pojmenován podle obou. U každého vzorce je uveden význam všech symbolů; kde je vzorců k jednomu tématu více, jsou v pořadí, v jakém se odvozují nebo používají.

Značení sdílené napříč celým textem: f fitness / hustota, tříd/atributů, P populace nebo pravděpodobnost, γ diskontní faktor, α rychlost učení nebo hladina významnosti, η rychlost učení. Význam se vždy upřesňuje na místě.

Obsah

01	Multiagentní systémy	4
1	Architektura autonomního agenta a mechanismus výběru akcí	4
1.5	Abstraktní architektura agenta	4
1.6	Čistě reaktivní agent a agent s vnitřním stavem	4
1.7	Utilita: jak agentovi říct, co má dělat	4
2	Metody pro řízení agentů: symbolické a konekcionistické reaktivní plánování, hybridní přístupy	5
2.1	Klasický přístup UI a deduktivní agent	5
2.3	Plánování: STRIPS	5
3	Problém hledání cesty	5
3.2	A^*	5
3.3	Dynamické prostředí: D^* Lite	6
4	Komunikace a znalosti v MAS: ontologie, řečové akty, FIPA-ACL, protokoly	6
4.7	KQML a FIPA-ACL	6
5	Distribuované řešení problémů, kooperace, teorie her a aukce	6
5.8	Hra v normální formě	6
5.9	Klasické hry	7
5.15	Návrh mechanismů, VCG a vyjednávání	7
6	Metody pro učení agentů a zpětnovazební učení	7

6.2	Markovský rozhodovací proces	7
6.3	Q-learning a SARSA	8
6.4	Metody založené na politice	8
02	Přírodou inspirované počítání	9
1	Genetické algoritmy, genetické a evoluční programování	9
1.1	Obecné schéma evolučního algoritmu	9
1.2	Genetické algoritmy	10
1.3	Reprezentace jedince a genetické operátory	10
1.4	Genetické a evoluční programování	11
2	Teorie schémat a pravděpodobnostní modely SGA	11
2.1	Teorie schémat	11
2.2	Pravděpodobnostní modely jednoduchého GA	12
3	Evoluční strategie, diferenciální evoluce, koevoluce, otevřená evoluce	13
3.1	Evoluční strategie	13
3.2	Diferenciální evoluce	14
3.3	Koevoluce	14
3.4	Otevřená evoluce	15
4	Rojové optimalizační algoritmy	15
4.1	Optimalizace rojem částic (PSO)	15
4.2	Optimalizace mravenčí kolonií (ACO)	15
5	Lokální prohledávání a memetické algoritmy	16
5.2	Simulované žihání	16
6	Aplikace evolučních algoritmů	16
6.1	Evoluce pravidlových a expertních systémů	16
6.2	Neuroevoluce	17
6.3	Kombinatorické úlohy a práce s omezeními	17
6.4	Vícekritériální optimalizace	17
03	Dobývání znalostí	19
2	Příprava dat, výběr atributů a analýza jejich relevance	19
2.3	Čištění dat: šum a odlehlé hodnoty	19
2.5	Transformace a standardizace atributů	19
2.6	Diskretizace numerických atributů	19
2.8	Analýza relevance atributů: filtry a wrappery	19
2.9	Vztahy mezi atributy: regrese	21
3	Metody pro dobývání znalostí	21
3.1	Asociační pravidla a frekventované vzory	21
3.2	Přístupy založené na principu učení s učitelem	22
3.3	Klastrová analýza	26
4	Charakteristická a diskriminační pravidla a jejich zajímavost	27
4.1	Pravidla jako srozumitelná forma klasifikace	27
4.3	Charakteristická a diskriminační pravidla: t-weight a d-weight	27
4.6	Observační pravidla: konfidence, podpora a testy hypotéz	27

4.8	Měření zajímavosti pravidel	28
5	Reprezentace, vyhodnocování a vizualizace znalostí	28
5.2	Vyhodnocování modelů	28
6	Modely pro analýzu sociálních sítí, centralita a detekce komunit	29
6.3	Síla vazeb	29
6.4	Klíčové hráči: míry centrality	29
6.5	Koheze: míry na úrovni sítě	29
6.7	Modelování vlivu	29
6.8	Vliv versus korelace	30
6.9	Homofilie, výběr a sociální vliv	30
6.13	Analýza vazeb: huby, autority a algoritmus HITS	30
6.14	PageRank	31
6.16	Detekce komunit	31
6.17	Predikce vazeb	31

01 Multiagentní systémy

Abstraktní architektury, plánování, hledání cesty, teorie her a aukce, zpětnovazební učení.

1 Architektura autonomního agenta a mechanismus výběru akcí

1.5 Abstraktní architektura agenta

► Běh agenta v prostředí

$$r = e_0 \xrightarrow{a_0} e_1 \xrightarrow{a_1} e_2 \xrightarrow{a_2} \dots \xrightarrow{a_{n-1}} e_n$$

$E = \{e, e', \dots\}$ je konečná množina stavů prostředí, $A = \{a, a', \dots\}$ konečná množina akcí agenta. *Běh* je posloupnost střídajících se stavů a akcí. R je množina všech konečných běhů, $R^A \subseteq R$ ty končící akcí, $R^E \subseteq R$ ty končící stavem prostředí.

► Přechodová funkce prostředí (*state transformer function*)

$$\tau : R^A \rightarrow 2^E, \quad Env = \langle E, e_0, \tau \rangle$$

Zobrazuje běh končící akcí na množinu možných následujících stavů — prostředí je tedy nedeterministické a *historicky závislé*. $\tau(r) = \emptyset$ znamená konec běhu. Prostor je trojice: stavy, počáteční stav, přechodová funkce.

► Agent jako funkce běhu

$$Ag : R^E \rightarrow A$$

Agent rozhoduje deterministicky a na základě *celé historie* systému; $\mathcal{AG}$ značí množinu všech agentů.

1.6 Čistě reaktivní agent a agent s vnitřním stavem

► Čistě reaktivní agent (*tropistic agent*)

$$Ag : E \rightarrow A$$

Reaguje pouze na *aktuální* stav prostředí, historii ignoruje. Ke každému reaktivnímu agentovi existuje funkčně ekvivalentní standardní agent, *obráceně to neplatí*. Termostat: $Ag(e) = \text{off}$ pro „teplota OK“, jinak on.

► Agent s vnitřním stavem

$see : E \rightarrow Per$	(vnímání)
$next : I \times Per \rightarrow I$	(aktualizace vnitřního stavu)
$action : I \rightarrow A$	(výběr akce)

I je množina vnitřních stavů, Per množina vjemů. Cyklus: agent startuje v i_0 , see převede stav prostředí na vjem, $next$ aktualizuje vnitřní stav, $action$ zvolí akci. Vyjadřovací síla je *stejná* jako u standardního agenta.

1.7 Utilita: jak agentovi říct, co má dělat

► Utilita stavu a utilita běhu

$$u : E \rightarrow \mathbb{R}, \quad u : R \rightarrow \mathbb{R}$$

Cíl se agentovi zadává *nepřímo*, mírou úspěšnosti. Hodnocení jednotlivých stavů je krátkozraké, proto se zavádí utilita celého běhu (např. utilita nejhoršího navštíveného stavu nebo průměr).

► **Optimální agent (maximalizace očekávané utility)**

$$Ag_{\text{opt}} = \arg \max_{Ag \in \mathcal{AG}} \sum_{r \in R(Ag, Env)} u(r) P(r \mid Ag, Env), \quad \sum_r P(r \mid Ag, Env) = 1$$

$P(r \mid Ag, Env)$ je pravděpodobnost běhu r . Definice je elegantní, ale **nekonstruktivní** — neříká, jak takového agenta navrhnout, a utilitní funkci bývá obtížné vůbec zadat.

► **Tileworld — utilita běhu**

$$u(r) = \frac{N_f}{N_a}$$

N_f = počet děr zaplněných agentem během běhu r , N_a = počet všech děr, které se během r objevily. Klasický příklad utility v *dynamickém* prostředí.

2 Metody pro řízení agentů: symbolické a konekcionistické reaktivní plánování, hybridní přístupy

2.1 Klasický přístup UI a deduktivní agent

► **Deduktivní agent (agent jako dokazovač vět)**

$$DB \vdash_{\rho} \varphi$$

L je množina formulí predikátové logiky 1. řádu, $D = 2^L$ množina databází, vnitřní stav agenta je $DB \in D$. Zápis znamená „formuli φ lze odvodit z DB pomocí pravidel ρ “. Agent hledá akci, pro niž lze odvodit $Do(a)$; nejde-li to, akci alespoň *konzistentní* s databází.

2.3 Plánování: STRIPS

► **STRIPS — posloupnost databází podle plánu**

$$B_i = (B_{i-1} \setminus D_{a_i}) \cup A_{a_i}, \quad i = 1, \dots, n$$

Akce je popsána trojicí $\langle P_a, D_a, A_a \rangle$ (předpoklady, mazaná množina, přidávaná množina); plánovací problém je $\langle B_0, O, G \rangle$. Plán $\pi = (a_1, \dots, a_n)$ je **přípustný**, pokud $B_{i-1} \models P_{a_i}$ pro každé i , a **korektní**, je-li přípustný a navíc $B_n \models G$.

3 Problém hledání cesty

3.2 A*

► **Ohodnocení vrcholu v A***

$$\begin{aligned} g(n) &= \text{cena nejlepší dosud nalezené cesty } s \rightarrow n, \\ h(n) &= \text{heuristický odhad ceny } n \rightarrow g_{\text{cil}}, \\ f(n) &= g(n) + h(n) \end{aligned}$$

$f(n)$ je odhad ceny nejlepší cesty $s \rightarrow g_{\text{cil}}$ *vedoucí přes* n ; A^* expanduje vrchol s nejmenším f . Pro $h \equiv 0$ degeneruje na Dijkstru.

► Přípustnost a konzistence heuristiky

$$h(n) \leq h^*(n) \quad (\text{přípustná}), \quad h(n) \leq w(n, m) + h(m), \quad h(g_{\text{cil}}) = 0 \quad (\text{konzistentní})$$

$h^*(n)$ je skutečná cena nejlevnější cesty z n do cíle; přípustná heuristika *nikdy nenadhodnocuje*. Konzistence je trojúhelníková nerovnost na každé hraně (n, m) s cenou $w(n, m)$. Platí: **konzistence** $\Rightarrow$ **přípustnost**. Při přípustné h je A^* optimální, při konzistentní h je navíc f podél cesty neklesající (stačí uzavřený seznam bez reexpansí).

3.3 Dynamické prostředí: D* Lite

► LPA* / D* Lite — lookahead hodnota

$$rhs(n) = \begin{cases} 0 & n = s, \\ \min_{p \in pred(n)} (g(p) + w(p, n)) & \text{jinak} \end{cases}$$

$pred(n)$ jsou předchůdci n , $w(p, n)$ cena hrany (p, n) . Vrchol je *lokálně konzistentní*, pokud $g(n) = rhs(n)$. Změní-li se cena hrany, stanou se některé vrcholy nekonzistentními, zařadí se do prioritní fronty a změna se propaguje jen do zasažené části — proto inkrementální přeplánování stojí méně než A^* od nuly.

4 Komunikace a znalosti v MAS: ontologie, řečové akty, FIPA-ACL, protokoly

4.7 KQML a FIPA-ACL

► Semantika performativu *inform* (FP / RE)

$$\text{FP: } B_i\varphi \wedge \neg B_i(Bif_j\varphi \vee Uif_j\varphi), \quad \text{RE: } B_j\varphi$$

Sémantika ACL se zapisuje v modální logice s operátory $B_i\varphi$ (agent i věří φ), $U_i\varphi$ (je nejistý), $I_i\varphi$ (má záměr). **FP** (*feasibility precondition*) — co musí platit, aby odesílatel mohl akt provést; **RE** (*rational effect*) — efekt, kvůli němuž akt provádí. Příjemce *není povinen* RE naplnit (autonomie!).

5 Distribuované řešení problémů, kooperace, teorie her a aukce

5.8 Hra v normální formě

► Hra v normální formě

$$\langle N, (A_i)_{i \in N}, (u_i)_{i \in N} \rangle$$

N množina hráčů, A_i množina akcí hráče i , u_i jeho utilitní funkce. Pro dva hráče se zapisuje *výplatní maticí* (řádky = strategie i , sloupce = strategie j , buňka u_i/u_j). Strategie je *ryzí* (jedna akce) nebo *smíšená* (rozdělení pravděpodobnosti nad ryzími).

► Nashovo ekvilibrium

$$u_i(s_i^*, s_{-i}^*) \geq u_i(s_i, s_{-i}^*) \quad \text{pro každého } i \text{ a každou jeho strategii } s_i$$

s_{-i} značí strategie všech ostatních hráčů. Profil s^* je NE, pokud **žádný hráč nemá jednostranný důvod se odchýlit** — strategie jsou vzájemně nejlepší odpovědi. V ryzích strategiích nemusí existovat, ve smíšených existuje vždy (Nash).

5.9 Klasické hry

► Věžňovo dilema — podmínky na výplaty

$$T > R > P > S \quad \text{a často navíc} \quad 2R > T + S$$

R (reward) za oboustrannou spolupráci, P (punishment) za oboustrannou zradu, T (temptation) za zradu spolupracujícího, S (sucker's payoff) za zrazení. $T > R$ a $P > S$ činí zradu *dominantní strategií*, takže DD je jediné NE — ale CC je Pareto-lepší. Druhá podmínka ($2R > T + S$) je nutná pro iterovanou verzi: střídavé vykořisťování se nesmí vyplatit více než trvalá spolupráce.

► Výpočet smíšeného NE ve hře 2×2 (podmínka indifference)

$$u_i(\text{akce}_1) = u_i(\text{akce}_2) \quad \text{např.} \quad 1 \cdot q + 0 \cdot (1 - q) = 0 \cdot q + 2 \cdot (1 - q)$$

Protihráč j volí pravděpodobnost q tak, aby byl hráč i *indiferentní* mezi svými akcemi (jinak by i hrál ryzí strategii). Z uvedené rovnosti $q = 2 - 2q$, tedy $q = 2/3$. V „Bitvě pohlaví“ tak každý hraje svou preferovanou možnost s $2/3$ a očekávaná utilita $2/3$ je *nižší* než v kterémkoli ryším ekvilibriu.

5.15 Návrh mechanismů, VCG a vyjednávání

► VCG — Vickrey–Clarke–Groves

$$p_i = \max_x \sum_{j \neq i} \hat{v}_j(x) - \sum_{j \neq i} \hat{v}_j(x^*)$$

$\hat{v}_i$ je ohlášená valuační, x^* alokace maximalizující $\sum_i \hat{v}_i(x)$. Agent i platí **externalitu, kterou způsobuje ostatním** — rozdíl mezi tím, co by ostatní získali bez něj, a tím, co získají s ním. Mechanismus je pravdomluvný, efektivní a individuálně racionální; pro jeden předmět se redukuje na Vickreyovu aukci (2. cena). Nevýhody: WDP se řeší $n+1$ -krát, výnos prodávajícího může být i nulový.

► Zeuthenova strategie — ochota riskovat konflikt

$$\text{Risk}_i = \frac{u_i(\text{vlastní návrh}) - u_i(\text{návrh protějšku})}{u_i(\text{vlastní návrh})}$$

V monotónním protokolu ústupků ustupuje agent s *nižším* Risk, a to právě tak málo, aby se poměry obrátily. Čítatel je „co ztratím přijetím cizího návrhu“, jmenovatel „co mám v sázce“. Dvojice Zeuthenových strategií je v Nashově ekvilibriu a dohoda maximalizuje součin utilit (Nashovo řešení).

6 Metody pro učení agentů a zpětnovazební učení

6.2 Markovský rozhodovací proces

► Cíl v MDP — očekávaný diskontovaný výnos

$$\mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t, s_{t+1}) \right]$$

MDP je $\langle S, A, T, R \rangle$ s přechodovými pravděpodobnostmi $T(s, a, s')$ a odměnou R ; platí *markovská vlastnost* (další stav a odměna závisí jen na aktuálním stavu a akci). $\gamma \in [0, 1]$ diskontuje budoucnost a zaručuje konečnost součtu. Politika je $\pi : S \rightarrow A$ (nebo stochasticky $\pi(a|s)$); hledáme π^* maximalizující tento výnos.

► Bellmanova rovnice pro evaluaci politiky

$$V^\pi(s) = \sum_{s'} T(s, \pi(s), s') [R(s, \pi(s), s') + \gamma V^\pi(s')]$$

$V^\pi(s)$ je očekávaná utilita stavu s , sleduje-li agent politiku π ; $Q^\pi(s, a)$ totéž pro dvojici stav–akce. Rovnice je rekursivní rozklad „okamžitá odměna + diskontovaná hodnota následníka“.

► Bellmanovy rovnice optimality

$$V^*(s) = \max_{a \in A} \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma V^*(s')],$$

$$Q^*(s, a) = \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma \max_{a'} Q^*(s', a')]$$

Optimální politika se získá jako $\pi^*(s) = \arg \max_a Q^*(s, a)$ — z Q^* tedy bez znalosti modelu, z V^* jen se znalostí T a R . Iterováním těchto rovnic pracují *value iteration* a *policy iteration* (model-based).

6.3 Q-learning a SARSA

► Q-learning (Watkins, 1989)

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[\underbrace{r + \gamma \max_{a'} Q(s', a')}_{\text{TD cíl}} - Q(s, a) \right], \quad 0 \leq \alpha \leq 1$$

Agent provedl ve stavu s akci a , dostal **okamžitou odměnu** r (jedno pozorování, nikoli funkce R jako u Bellmana) a přešel do s' ; a' probíhá akce dostupné v s' , α je rychlost učení a γ diskontní faktor. Ekvivalentně $Q(s, a) \leftarrow (1 - \alpha)Q(s, a) + \alpha(r + \gamma \max_{a'} Q(s', a'))$; hranatá závorka je *TD chyba*. **Off-policy**: cíl používá $\max_{a'}$, učí se tedy hodnotu *optimální* politiky bez ohledu na to, jak agent skutečně jedná. Konverguje $Q \rightarrow Q^*$, je-li každá dvojice (s, a) navštívena nekonečněkrát a α vhodně klesá.

► SARSA

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma Q(s', a') - Q(s, a)]$$

Aktualizace používá *skutečně zvolenou* následující akci a' (podle stejné politiky, kterou agent jedná) — **on-policy**. Učí se hodnotu politiky včetně náhodného průzkumu, a je proto *opatrnější*: v úloze „chůze po útesu“ se drží dál od propasti než Q-learning.

► ε -greedy a softmax (dilema průzkumu a využití)

$$\pi(s) = \begin{cases} \text{náhodná akce z } A & \text{s pravděpodobností } \varepsilon, \\ \arg \max_a Q(s, a) & \text{s pravděpodobností } 1 - \varepsilon, \end{cases} \quad \pi(a|s) \propto e^{Q(s,a)/\tau}$$

ε se v čase snižuje (*annealing*). Softmax/Boltzmann s teplotou τ váží akce podle jejich hodnoty (ne uniformně jako ε -greedy). Další alternativy: optimistická inicializace Q , UCB.

6.4 Metody založené na politice

► REINFORCE (policy gradient)

$$z_{t+1} = z_t + \alpha G_t \nabla_z \ln \pi(A_t | S_t, z_t)$$

Politika je parametrizovaná vektorem z , tedy $\pi(a | s, z)$; G_t je výnos od času t (Monte Carlo z celé epizody). Intuice: *zvyš pravděpodobnost akcí, po nichž následoval vysoký výnos*. Zvládá *spojité* akční prostory a stochastické politiky, ale má velký rozptyl (řeší se odečtením baseline — *actor-critic*).

02 Přírodou inspirované počítání

Selekce a operátory, teorie schémat, evoluční strategie, diferenciální evoluce, rojové algoritmy, lokální prohledávání, aplikace.

1 Genetické algoritmy, genetické a evoluční programování

1.1 Obecné schéma evolučního algoritmu

1.1.5 Seleční mechanismy

► Ruletová (fitness-proporcionální) selekce

$$p_i = \frac{f(x_i)}{\sum_{j=1}^n f(x_j)} = \frac{f(x_i)}{n \bar{f}}, \quad \mathbb{E}[\text{počet výběrů } x_i] = n p_i = \frac{f(x_i)}{\bar{f}}$$

x_i je i -tý jedinec, $\bar{f}$ průměrná fitness populace, n její velikost; výběr je *s vracením*, takže jeden jedinec může být vybrán vícekrát. Nevýhody: předčasná dominance „supermana“ (jedinec s extrémní fitness ovládne populaci a diverzita zmizí), ztráta selekčního tlaku na konci běhu (podobné fitness $\Rightarrow$ téměř náhodný výběr), citlivost na afinní transformace fitness (f a $f + c$ dají jiné p_i) a vysoký rozptyl skutečných počtů výběrů.

► Turnajová selekce velikosti k

$$p_i = \frac{(n - i + 1)^k - (n - i)^k}{n^k} \quad (i = 1 \text{ značí nejlepšího})$$

Vyber náhodně (uniformně, s vracením) k jedinců a vrať nejlepšího; k (typicky 2, 3, 5) přímo řídí selekční tlak. Odvození: pravděpodobnost, že všech k padne mezi i -tého a horší, minus pravděpodobnost, že všech k padne ostře pod i -tého. Výhody: nepotřebuje globální informaci, je invariantní vůči monotónním transformacím fitness, paralelizovatelná, funguje i tam, kde fitness není dána a porovnání se získává souhrou.

► Lineární pořadová selekce

$$p_i = \frac{1}{n} \left(s^- + (s^+ - s^-) \frac{i - 1}{n - 1} \right), \quad 1 \leq s^+ \leq 2, \quad s^- = 2 - s^+$$

Pozor na konvenci: zde $i = 1$ značí **nejhoršího**, $i = n$ nejlepšího. s^+ je očekávaný počet kopií nejlepšího jedince. Exponenciální varianta: $p_i \propto (1 - c) c^{n-i}$. Pořadová selekce udržuje *konstantní* selekční tlak během celého běhu a je odolná vůči „supermanům“ i vůči změně měřítka fitness.

► Boltzmannova selekce

$$p_i \propto e^{f(x_i)/T}$$

Teplota T klesá v čase: vysoké $T \Rightarrow$ téměř uniformní selekce (explorace), nízké $T \Rightarrow$ téměř deterministická (exploatace). Přímá souvislost se simulovaným žíháním.

► Doba převzetí (*takeover time*)

$$\tau^* \approx \frac{\ln n}{\ln k} \quad (\text{turnaj velikosti } k)$$

τ^* = počet generací, za který jediná kopie nejlepšího jedince (bez variace) zaplní celou populaci — kvantifikace *selekčního tlaku*. Pro fitness-proporcionální selekci je doba převzetí delší a závisí na rozložení fitness.

► Generation gap a modely populace

$$G = \frac{\lambda}{n}$$

Podíl nahrazované populace: generační model $G = 1$ (celá populace nahrazena potomky), steady-state $\lambda \in \{1, 2\}$. *Elitismus*: k nejlepších se bezpodmínečně kopíruje dál (zaručuje monotonii nejlepší fitness, je nutnou podmínkou řady konvergenčních vět). Deterministická selekce ES: $(\mu + \lambda)$ vybírá μ nejlepších z rodičů i potomků, (μ, λ) jen z potomků.

1.2 Genetické algoritmy

1.2.2 Binární reprezentace

► Binární kódování reálného čísla

$$x = a + z \cdot \frac{b - a}{2^k - 1}, \quad \text{přesnost} = \frac{b - a}{2^k - 1}$$

$x \in [a, b]$ kódované na k bitů jako celé číslo $z \in \{0, \dots, 2^k - 1\}$. Výhoda: explicitní kontrola nad přesností. Nevýhoda: *Hammingovy útesy* (sousední čísla se liší v mnoha bitech, např. 0111 $\rightarrow$ 1000) — řeší se *Grayovým kódem*.

1.2.4 Mutace a inverze

► Bitová mutace

$$p_M \approx \frac{1}{m}$$

m je délka řetězce; každý bit se převrací nezávisle s pravděpodobností p_M ; doporučená hodnota znamená „v průměru se změní jeden bit na jedince“. Typické další parametry SGA: $n \in [50, 500]$, $p_C \in [0,6; 0,9]$.

1.2.5 Škálování fitness

► Lineární škálování

$$f' = af + b, \quad \bar{f}' = \bar{f}, \quad f'_{\max} = C_{\text{mult}} \cdot \bar{f}, \quad C_{\text{mult}} \in [1,2; 2]$$

Dvě podmínky určují a a b . Zachovává průměr a omezuje náskok nejlepšího jedince na C_{mult} -násobek průměru. Nutná pojistka proti záporným hodnotám u nejhorších.

► Sigma truncation, mocinné a Boltzmannovo škálování

$$f' = \max(0, f - (\bar{f} - c\sigma_f)), \quad f' = f^k, \quad f' = e^{f/T}$$

σ_f je směrodatná odchylka fitness, $c \in [1; 3]$, T teplota. Sigma truncation odstraní odlehlé nízké hodnoty a automaticky se přizpůsobuje rozptylu; u mocinného škálování k v průběhu běhu roste (tlak roste). Nejrobustnější a dnes nejobvyklejší je ale *pořadové* škálování (nahrazení fitness pořadím).

1.3 Reprezentace jedince a genetické operátory

1.3.2 Reálná reprezentace

► Aritmetické křížení

$$\vec{z} = \alpha \vec{x} + (1 - \alpha) \vec{y}, \quad \alpha \in (0, 1)$$

$\vec{x}, \vec{y}$ jsou rodiče a $\vec{z}$ potomek — konvexní kombinace rodičů; pro $\alpha = 1/2$ prostý průměr. Varianty: *jednoduché* (všechny složky), *jednoduché aritmetické* (jedna náhodná složka), *celé/single* (kombinace s jednobodovým křížením). Nevýhoda: potomci leží vždy *uvnitř* konvexního obalu rodičů $\Rightarrow$ populace se stahuje.

► **BLX- α (*blend crossover*)**

$$z_i \sim U[\min(x_i, y_i) - \alpha I, \max(x_i, y_i) + \alpha I], \quad I = |x_i - y_i|, \quad \alpha \approx 0,5$$

Rozšiřuje interval o αI na obě strany, takže potomci mohou ležet *i vně* rodičů — odstraňuje stahování populace, které trápí čistě aritmetické křížení.

► **SBX (*simulated binary crossover*)**

$$z_{1,i} = \frac{1}{2}[(1 + \beta)x_i + (1 - \beta)y_i], \quad z_{2,i} = \frac{1}{2}[(1 - \beta)x_i + (1 + \beta)y_i]$$

$$\beta = (2u)^{1/(\eta+1)} \text{ pro } u \leq \frac{1}{2}, \quad \beta = \left(\frac{1}{2(1-u)}\right)^{1/(\eta+1)} \text{ pro } u > \frac{1}{2}, \quad u \sim U(0, 1)$$

Napodobuje chování jednobodového binárního křížení v reálném prostoru: potomci vzniknou „roztažením“ dvojice rodičů kolem jejich *středu* faktorem β . Platí $|z_1 - z_2| = \beta |x - y|$ a střed rodičů zůstává zachován. Parametr η (distribuční index) řídí, jak blízko rodičům potomci padnou — velké $\eta \Rightarrow$ blízko; $u \sim U(0, 1)$ se losuje pro každou složku. Standardní operátor v NSGA-II.

► **Gaussovská mutace reálného vektoru**

$$x'_i = x_i + \sigma \cdot N_i(0, 1)$$

σ je velikost kroku (*step size*); její řízení je hlavní téma evolučních strategií.

1.4 Genetické a evoluční programování

1.4.3 Bloat

► **Parsimony pressure (boj s bloatem v GP)**

$$f' = f - \alpha \cdot \text{velikost}$$

Bloat = tendence programů růst bez odpovídajícího zlepšení fitness (hromadění *intronů* typu (+ x 0)). Alternativy: tvrdé limity na hloubku/počet uzlů, lexikografické porovnání (při shodné fitness vyhrává menší jedinec), anti-bloat operátory (*hoist*, *shrink*), nebo velikost jako druhé kritérium ve vícekritériální optimalizaci.

2 Teorie schémat a pravděpodobnostní modely SGA

2.1 Teorie schémat

2.1.1 Schéma, jeho řád a definující délka

► **Schéma, řád, definující délka**

$$S \in \{0, 1, *\}^m, \quad o(S) = \text{počet pevných pozic}, \quad d(S) = \text{poslední pevná} - \text{první pevná pozice}$$

Schéma s r hvězdičkami reprezentuje 2^r jedinců. Příklad: $S = 1**0*1$ má $m = 6$, $o(S) = 3$, $d(S) = 6 - 1 = 5$. $F(S, t)$ = průměrná fitness reprezentantů S v populaci $P(t)$ — pozor, závisí na *aktuální* populaci, nejen na S a f .

► **Kombinatorika schémat**

$$\#\{\text{schémat délky } m\} = 3^m, \quad \#\{\text{schémat, jejichž reprezentantem je jeden jedinec}\} = 2^m$$

Populace n jedinců reprezentuje mezi 2^m a $n \cdot 2^m$ schémata (podle míry jejich podobnosti). Odtud *implicitní paralelismus*: GA pracuje explicitně s n jedinci, ale implicitně zpracovává mnohem víc schémat — užitečně zpracovávaných je podle Hollanda řádu n^3 .

2.1.2 Hollandova věta o schématech

► Věta o schématech (Holland, 1975)

$$\mathbb{E}[C(S, t+1)] \geq C(S, t) \frac{F(S, t)}{\bar{f}(t)} \left[1 - p_C \frac{d(S)}{m-1} - p_M o(S) \right]$$

$C(S, t)$ = počet reprezentantů S v $P(t)$. Slovně: **krátká** (malé $d(S)$), **nízkého řádu** (malé $o(S)$) a **nadprůměrná** ($F(S, t) > \bar{f}(t)$) schémata se v po sobě jdoucích generacích množí exponenciálně. To je *hypotéza stavebních bloků*: GA skládá řešení z krátkých, dobrých stavebních bloků.

► Odvození, krok 1 — selekce

$$p_s(S) = \sum_{v \in S \cap P(t)} \frac{f(v)}{F(t)} = \frac{C(S, t) F(S, t)}{F(t)}, \quad \mathbb{E}[C(S, t+1)] = n p_s(S) = C(S, t) \frac{F(S, t)}{\bar{f}(t)}$$

$F(t) = \sum_{u \in P(t)} f(u)$, $\bar{f}(t) = F(t)/n$. Je-li schéma trvale nadprůměrné o ε , tj. $F(S, t) = \bar{f}(t)(1 + \varepsilon)$, dostáváme $C(S, t) = C(S, 0)(1 + \varepsilon)^t$ — **exponenciální růst** (pokles pro $\varepsilon < 0$).

► Odvození, kroky 2 a 3 — křížení a mutace

$$p_{\text{surv}}^{\text{cross}}(S) \geq 1 - p_C \frac{d(S)}{m-1}, \quad p_{\text{surv}}^{\text{mut}}(S) = (1 - p_M)^{o(S)} \approx 1 - p_M o(S)$$

Jednobodové křížení volí bod řezu z $m-1$ možností; schéma je jistě rozbito, padne-li řez mezi první a poslední pevnou pozici. Nerovnost „ $\geq$ “ platí proto, že i při řezu uvnitř může být schéma obnoveno druhým rodičem. Mutace: schéma přežije, nezmění-li se *žádná* z $o(S)$ pevných pozic; aproximace platí pro $p_M \ll 1$. Složením obou (a zanedbáním součinu) vzniká věta o schématech.

2.1.5 Kritika teorie schémat

► Deceptivní úloha (kdy GA selhává)

$$S_1 = (111* \dots *), \quad S_2 = (* \dots *11) \quad \text{nadprůměrná, ale} \quad f(111*****11) \ll f(000*****00)$$

Selekce vede GA k jedničkovým blokům, přestože optimum leží jinde — stavební bloky „lžou“. Hlavní protipříklad k hypotéze stavebních bloků.

2.2 Pravděpodobnostní modely jednoduchého GA

2.2.3 Operátor $\mathcal{G}$

► Operátor $\mathcal{G}$ a jeho rozklad

$$p(t+1) = \mathcal{G}(p(t)), \quad \mathcal{G} = \mathcal{M} \circ \mathcal{F}$$

$p \in \Lambda$ (simplex) je vektor podílů jednotlivých řetězců v populaci, s vektor selekčních pravděpodobností. $\mathcal{F}$ odpovídá selekci, $\mathcal{M}$ *míchání* (křížení + mutace dohromady). Iterováním $\mathcal{G}$ z počáteční populace známe úplné chování SGA nad *nekonečnou* populací.

► Část $\mathcal{F}$ — fitness-proporcionální selekce maticově

$$s(t) = \frac{\mathbf{F} p(t)}{\sum_j \mathbf{F}_{jj} p_j(t)}$$

$\mathbf{F}$ je diagonální matice s $\mathbf{F}_{ii} = f(i)$. Čítatel $(\mathbf{F}p)_i = f(i)p_i$ je „váha“ řetězce i , jmenovatel je průměrná fitness populace. Podíl řetězce se tedy mění přesně o faktor $f(i)/\bar{f}$ — v souladu s větou o schématech.

► Část $\mathcal{M}$ — míchání

$$r(i, j, k) = \Pr[\text{potomek } k \text{ vznikne z rodičů } i, j], \quad \mathbb{E}[p_k(t+1)] = \sum_i \sum_j s_i(t) s_j(t) r(i, j, k)$$

Jde o *kvadratický* operátor na simplexu. Klíčové zjednodušení: jednobodové křížení i bitová mutace „nevidí“ absolutní hodnoty bitů, jen shody a neshody, takže $r(i, j, k) = r(i \oplus k, j \oplus k, 0)$ ($\oplus = \text{XOR}$). Stačí tedy jediná *míchací matice* $\mathbf{M}_{ij} = r(i, j, 0)$ rozměru $2^l \times 2^l$.

2.2.5 Konečné populace: Markovův řetězec

► Konečné populace jako Markovův řetězec

$$N = \binom{n + 2^l - 1}{2^l - 1}, \quad \mathbf{Q}_{i,j} = n! \prod_{y=0}^{2^l-1} \frac{(\mathcal{G}(p_i)_y)^{\mathbf{Z}(y,j)}}{\mathbf{Z}(y,j)!}$$

Stavy řetězce = jednotlivé možné populace (multimnožiny n řetězců délky l), jejich počet je N . $\mathbf{Z}(y, i)$ = počet výskytů jedince y v populaci i . Přejchod je *multinomické* losování n jedinců podle rozdělení $\mathcal{G}(p)$. Model je exaktní, ale N roste tak rychle, že je prakticky nepoužitelný.

3 Evoluční strategie, diferenciální evoluce, koevoluce, otevřená evoluce

3.1 Evoluční strategie

3.1.2 $(1+1)$ -ES a pravidlo $1/5$

► Pravidlo $1/5$ úspěchu (Rechenberg)

$$p > 1/5 \Rightarrow \sigma \leftarrow \sigma/c, \quad p < 1/5 \Rightarrow \sigma \leftarrow \sigma \cdot c, \quad 0,8 \leq c \leq 1$$

p = podíl úspěšných mutací za posledních k iterací, c = multiplikativní konstanta. *Optimální poměr úspěšných mutací je přibližně $1/5$* : je-li úspěchů víc, je krok příliš malý (zvětší σ), je-li jich méně, je krok příliš velký (zmenší σ). Jde o *adaptivní*, nikoli *samoadaptivní* řízení parametru — σ není součástí genomu.

3.1.3 Samoadaptace strategických parametrů

► Samoadaptace strategických parametrů (Schwefelova pravidla)

$$\sigma'_i = \sigma_i \cdot \exp(\tau' N(0, 1) + \tau N_i(0, 1)), \quad x'_i = x_i + \sigma'_i \cdot N_i(0, 1)$$

$$\tau' \propto \frac{1}{\sqrt{2n}}, \quad \tau \propto \frac{1}{\sqrt{2\sqrt{n}}}$$

Jedinec má tvar $C = [\vec{x}, \vec{\sigma}]$ — strategické parametry jsou **součástí genomu** a podléhají mutaci i selekci. $N(0, 1)$ je *jedno* losování společné pro celý jedinec, $N_i(0, 1)$ se losuje pro každou složku zvlášť. Exponenciála zaručuje kladnost σ a symetrii zvětšení/zmenšení; τ' a τ jsou rychlosti učení (globální a pro jednotlivé složky). **Pořadí je zásadní: nejprve se mutuje σ , teprve pak se s novým σ mutuje x** — jinak by se hodnotilo staré σ .

► Kovarianční matice z σ_i a úhlů natočení

$$c_{ii} = \sigma_i^2, \quad c_{ij} = \frac{1}{2}(\sigma_i^2 - \sigma_j^2) \tan(2\alpha_{ij})$$

Tři úrovně samoadaptace: jedno σ (izotropní mutace), n hodnot σ_i (osově orientovaný elipsoid), $\sigma_i + \text{úhly } \alpha_{ij}$ (plná kovarianční matice, libovolně natočený elipsoid). CMA-ES místo losování α_{ij} odhaduje $\mathbf{C}$ z *cesty evoluce* úspěšných kroků.

3.2 Diferenciální evoluce

3.2.2 Algoritmus DE/rand/1/bin

► Mutace — dárcovský vektor

$$\vec{v}_i = \vec{x}_a + F(\vec{x}_b - \vec{x}_c), \quad F \in [0, 2], \text{ typicky } F \approx 0,8$$

$\vec{x}_a, \vec{x}_b, \vec{x}_c$ jsou tři navzájem různí jedinci, různí od $\vec{x}_i$; F je mutační konstanta (škálovací faktor). Klíčová myšlenka: *velikost kroku se bere z populace samotné* — na začátku (rozptýlená populace) jsou rozdíly velké, ke konci malé. Adaptace měřítko je tedy zdarma, bez strategických parametrů.

► Binomické křížení — zkušební vektor

$$u_{j,i} = \begin{cases} v_{j,i} & \text{pokud } \text{rand}_j \leq C \text{ nebo } j = I_{\text{rand}}, \\ x_{j,i} & \text{jinak} \end{cases}$$

$\text{rand}_j \sim U(0, 1)$, $C \in [0, 1]$ je práh křížení, I_{rand} náhodný index z $\{1, \dots, D\}$. Podmínka $j = I_{\text{rand}}$ je „pojistka“: zaručuje, že alespoň jedna složka pochází od dárce, takže potomek není nikdy identickou kopií rodiče.

► Environmentální selekce (souboj 1:1)

$$\vec{x}_i(t+1) = \begin{cases} \vec{u}_i & \text{pokud } f(\vec{u}_i) \leq f(\vec{x}_i(t)), \\ \vec{x}_i(t) & \text{jinak} \end{cases}$$

Selekce je elitistická na úrovni jednotlivce — populace se nikdy nezhorší. Rodičovská selekce je triviální: rodičem je postupně *každý* jedinec. Varianty mutace se značí DE/báze/počet diferencí/křížení, např. DE/best/1/bin používá místo $\vec{x}_a$ nejlepšího jedince.

3.3 Koevoluce

3.3.5 Evoluce kooperace a věžňovo dilema

► Věžňovo dilema jako model evoluce kooperace

	C	D	
C	R/R	S/T	$T > R > P > S, \quad 2R > T + S$
D	T/S	P/P	

Typicky $R = -1$, $T = 0$, $P = -2$, $S = -3$. Zrada je dominantní strategie, DD je Nashovo ekvilibrium, ale CC je Pareto-lepší. V *iterované* verzi (Axelrodovy turnaje) vítězí *tit for tat*: hodná (nezradí první), oplácějící, odpouštějící a průhledná strategie. Formální model recipročního altruismu — kooperace se vyplatí při dostatečném „stínu budoucnosti“.

3.3.6 Diverzita, druhy a niky

► Fitness sharing

$$f'(i) = \frac{f(i)}{\sum_j sh(d(i, j))}, \quad sh(d) = \begin{cases} 1 - (d/\sigma_{\text{share}})^\alpha & d < \sigma_{\text{share}}, \\ 0 & \text{jinak} \end{cases}$$

Fitness se „dělí“ mezi podobné jedince, takže obsazená nika se stává méně atraktivní — vzniká tlak na pokrytí *různých* nik. σ_{share} je poloměr niky, d vzdálenost (Hammingova, fenotypová, ...), α exponent sdílecí funkce sh . Problém je vždy volba σ_{share} ; NSGA-II ji proto nahradilo *crowding distance*.

3.4 Otevřená evoluce

► Novelty search — řídkost okolí

$$\rho(x) = \frac{1}{k} \sum_{i=1}^k \text{dist}(x, \mu_i)$$

μ_i jsou k nejbližších sousedů x v aktuální populaci **a v permanentním archivu**, měreno v *prostoru chování* (např. koncová pozice robota v bludišti). Fitness = ρ ; původní účelová funkce se *nepoužívá vůbec*. Motivace (Lehman & Stanley): u deceptivních úloh je cílová funkce zavádějící a vede do lokálních optim.

4 Rojové optimalizační algoritmy

4.1 Optimalizace rojem částic (PSO)

► PSO — pohybové rovnice

$$\vec{v}_i \leftarrow \underbrace{w \vec{v}_i}_{\text{setrvačnost}} + \underbrace{c_1 r_1 (\vec{p}_i - \vec{x}_i)}_{\text{kognitivní složka}} + \underbrace{c_2 r_2 (\vec{g} - \vec{x}_i)}_{\text{sociální složka}}, \quad \vec{x}_i \leftarrow \vec{x}_i + \vec{v}_i$$

$\vec{p}_i$ ($pBest$) = nejlepší pozice, kterou částice i kdy navštívila; $\vec{g}$ ($gBest$) = nejlepší pozice nalezená rojem. $r_1, r_2 \sim U(0, 1)$ se losují pro každou složku zvlášť, c_1, c_2 jsou koeficienty učení (původně $c_1 = c_2 = 2$), w je setrvačnost. Částice pravidelně *přeletí* přes $\vec{g}$ — to je zdroj explorační; proto se rychlost omezuje ($|v_j| \leq v_{\max}$) nebo se používá konstrikční faktor.

4.2 Optimalizace mravenčí kolonií (ACO)

► ACO — pravidlo přechodu (Ant System)

$$w_{ij} = [\tau_{ij}]^\alpha [\eta_{ij}]^\beta, \quad p_{ij}^k = \frac{w_{ij}}{\sum_{l \in \mathcal{N}_i^k} w_{il}}, \quad \eta_{ij} = \frac{1}{d_{ij}} \implies p_j \propto \frac{\tau_j^\alpha}{d_j^\beta}$$

τ_{ij} = feromon na hraně, η_{ij} = heuristická „viditelnost“ (převrácená vzdálenost), $\mathcal{N}_i^k$ = dosud nenavštívená města mravence k , w_{ij} = skóre kandidáta. Je to **obyčejná ruleta**: skóre / součet skóre. Indexy i, k jsou během jednoho rozhodnutí konstanty, takže si stačí pamatovat pravý tvar — „feromon nahoře, vzdálenost dole“ — a dopsat normalizaci. α, β váží feromon vs. heuristiku (typicky $\alpha = 1, \beta \in [2, 5]$); $\alpha = 0$ dá hladový algoritmus, $\beta = 0$ čistě feromonové hledání (stagnuje).

► ACO — aktualizace feromonu

$$\tau_{ij} \leftarrow (1 - \rho) \tau_{ij} + \sum_{k=1}^m \Delta \tau_{ij}^k, \quad \Delta \tau_{ij}^k = \begin{cases} Q/L_k & \text{prošel-li mravenec } k \text{ hranou } (i, j), \\ 0 & \text{jinak} \end{cases}$$

$\rho \in (0, 1)$ je míra odpařování (zapomínání — brání předčasné konvergenci), L_k délka trasy mravence k , Q konstanta, m počet mravenců, $\Delta \tau_{ij}^k$ příspěvek mravence k . **Kratší trasa $\Rightarrow$ více feromonu**. ACS navíc odpařuje lokálně během konstrukce a ukládá jen po nejlepší trase.

5 Lokální prohledávání a memetické algoritmy

5.2 Simulované žíhání

► Metropolisovo kritérium (simulované žíhání)

$$P(\text{přijmout } y) = \begin{cases} 1, & \Delta \leq 0 \quad (\text{zlepšení}), \\ e^{-\Delta/T}, & \Delta > 0 \quad (\text{zhoršení}), \end{cases} \quad \Delta = f(y) - f(x)$$

Pro minimalizaci, kandidát $y \in N(x)$. T je teplota: při vysokém T se algoritmus chová jako náhodná procházka (např. $\Delta = 2$, $T = 5$ dá $P = 0,67$), při nízkém jako čistý horolezec ($T = 0,5$ dá $P = 0,018$). Při pevné T konverguje k Boltzmannovu rozdělení $\pi(x) \propto e^{-f(x)/T}$.

► Rozvrhy chlazení

$$T_{k+1} = \alpha T_k, \quad \alpha \in [0,8; 0,99] \quad T_k = T_0 - \beta k \quad T_k = \frac{c}{\log(k+1)}$$

T_k je teplota v k -té iteraci, α chladičí faktor, β krok lineárního poklesu. Geometrický (v praxi nejběžnější), lineární, logaritmický. **Jen pro logaritmický je dokázána konvergence** k množině globálních optim s pravděpodobností 1 (při dostatečně velkém c , souvisejícím s výškou nejhlubší bariéry) — prakticky je ale nepoužitelně pomalý.

6 Aplikace evolučních algoritmů

6.1 Evoluce pravidlových a expertních systémů

6.1.2 Learning classifier systems (Michigan)

► XCS — přesnost klasifikátoru

$$\kappa = \alpha (\epsilon/\epsilon_0)^{-\nu} \quad (\epsilon > \epsilon_0), \quad \kappa = 1 \quad \text{jinak}$$

Klasifikátor je pětice (c, a, p, ϵ, F) : podmínka, akce, predikce odměny, chyba predikce, fitness. Wilsonova myšlenka: *predikce* má odhadovat odměnu, ale *evoluce* má preferovat **spolehlivé (přesné)** klasifikátory — fitness je proto relativní přesnost v rámci action setu, ne síla. κ je přesnost, α, ϵ_0, ν parametry (práh a strmost poklesu). p a ϵ se aktualizují pravidly Q-learningu ($r + \gamma \max_a p_a$), GA běží *nikdy* jen uvnitř action setu.

► ZCS — posílení

$$\text{každému v } A : +\frac{\beta r}{|A|}, \quad \text{každému v } A_{-1} : +\frac{\gamma B}{|A_{-1}|}$$

A = action set (pravidla prosazující zvolenou akci), A_{-1} = předchozí action set, B = „kbelík“ (podíl β odebraný ze síly pravidel v A), r = odměna z prostředí. Zjednodušení Hollandovy *bucket brigade*, kde pravidlo muselo „zaplatit“ tomu, které ho aktivovalo.

6.1.4 Připomenutí: metriky klasifikace

► Metriky klasifikace (fitness pravidlových systémů)

$$\text{přesnost} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{senzitivita} = \frac{TP}{TP + FN}, \quad \text{specifita} = \frac{TN}{TN + FP}$$

Fitness pravidlového systému (LCS, GIL) bývá kombinací přesnosti, pokrytí a jednoduchosti (počet pravidel) — tedy přirozeně vícekritériální úloha. Podrobněji viz odd. 5.2.3.

6.2 Neuroevoluce

6.2.3 NEAT

► NEAT — míra podobnosti genomů (speciace)

$$\delta = \frac{c_1 E}{N} + \frac{c_2 D}{N} + c_3 \overline{\Delta W}$$

Předpoklad: síť je v NEAT *seznam hran* a každá hrana nese *inovační číslo* — pořadové číslo přidělené při prvním vzniku dané strukturální novinky. Hrany se stejným číslem tedy mají **společný evoluční původ**. Porovnání dvou genomů jen roztřídí jejich hrany do tří skupin: *shodné* (totéž inovační číslo v obou), **disjoint** (chybí u druhého, ale *uvnitř* rozsahu jeho čísel) a **excess** (leží *za* nejvyšším inovačním číslem druhého genomu).

Příklad: $A = \{1, 2, 3, 4, 5, 8\}$, $B = \{1, 2, 3, 6, 7\}$. Shodné jsou 1, 2, 3. Nejvyšší číslo B je 7, takže geny 4, 5 (u A) a 6, 7 (u B) leží uvnitř rozsahu $\Rightarrow D = 4$; gen 8 je za ním $\Rightarrow E = 1$; $N = 6$ (větší genom).

Co který člen dělá: E a D měří rozdíl *struktury* (kolik hran mají genomy navíc jeden proti druhému), $\overline{\Delta W}$ rozdíl *parametrů* (průměrný rozdíl vah přes *shodné* geny — jen tam má porovnávat vah smysl). N = velikost většího genomu normalizuje, aby velké sítě nevycházely vzdálené jen svou velikostí; c_1, c_2, c_3 jsou váhy, kterými volíš, zda víc rozhoduje topologie, nebo váhy. Síť s δ pod prahem tvoří jeden **druh** a sdílí fitness — nová topologie tak dostane čas doladit váhy dřív, než ji vytlačí zavedená řešení.

6.3 Kombinatorické úlohy a práce s omezeními

6.3.2 Tři obecné strategie pro omezení

► Penalizace omezení (problém batohu)

$$f'(x) = \sum_i x_i v_i - \alpha \max \left(0, \sum_i x_i c_i - C_{\max} \right)$$

$C_{\max}$ je kapacita batohu, v_i cena a c_i objem předmětu i , $x_i \in \{0, 1\}$ jeho výběr. Tři obecné strategie pro omezení: (1) **penalizace** (uvedený vzorec — volba α je zásadní: malá $\Rightarrow$ populace se plní nepřipustnými řešeními, velká $\Rightarrow$ nelze projít nepřipustnou oblastí ke slibnému řešení); (2) **oprava** (u batohu vyhazuj předměty s nejhorším poměrem v_i/c_i — baldwinovsky jen pro fitness, lamarckovsky i do genotypu); (3) **dekodér**, kde každý genotyp reprezentuje přípustné řešení. Čtvrtá možnost: porušení omezení jako druhé kritérium.

6.4 Vícekriteriální optimalizace

6.4.1 Dominance a Pareto fronta

► Dominance a Pareto optimalita

$$x \preceq y \iff \forall i : f_i(x) \leq f_i(y), \quad x \prec y \iff x \preceq y \wedge \exists j : f_j(x) < f_j(y)$$

(Vše minimalizujeme.) $\prec$ je *ostré částečné* uspořádání — ireflexivní a tranzitivní, ale **nikoli úplné**, takže existuje celá množina navzájem neporovnatelných optim. Řešení nedominované žádným přípustným je *Pareto-optimální*; množina takových řešení je *Pareto množina*, její obraz v prostoru kritérií **Pareto fronta**.

6.4.2 Skalarizace — jednoduchá řešení

► Skalarizace

$$f = \sum_i w_i f_i \quad \min f_1 \text{ s.t. } f_i \leq \varepsilon_i \quad \min \max_i \lambda_i |f_i(x) - z_i^*|$$

w_i a λ_i jsou váhy kritérií. Lineární skalarizace, ε -constraint, Čebyševova skalarizace (z^* = referenční/ideální bod). **Klíčová nevýhoda lineární skalarizace: nekonvexní části fronty nelze nikdy nalézt;** ε -constraint i Čebyševova je najdou. Každý běh navíc dá jen *jeden* bod fronty.

6.4.4 NSGA-II

► NSGA-II — crowding distance

$$d_i = \sum_{m=1}^k \frac{f_m(i+1) - f_m(i-1)}{f_m^{\max} - f_m^{\min}}$$

Počítá se *pro každou frontu zvlášť*: pro každé kritérium m se jedinci seřadí podle f_m , krajní dostanou ∞ a ostatním se přičte normalizovaná vzdálenost sousedů. Vyjadřuje „obvod kvádrů“ tvořeného nejbližšími sousedy — *velká* hodnota znamená řídce obsazenou oblast, kterou chceme zachovat. Nahrazuje σ_{share} původního NSGA (žádný parametr navíc). Selektce: nejprve nižší fronta, při shodě větší d_i .

6.4.6 Metriky kvality aproximace

► Hypervolume (S -metrika)

$$HV = \text{vol}\left(\bigcup_{x \in \text{fronta}} [f(x), r]\right)$$

Objem oblasti dominované nalezenou frontou a ohraničené *referenčním bodem* r (zvolným tak, aby byl dominován všemi řešeními). Jediná běžná metrika *striktně monotónní vůči dominanci*, která navíc **nevyžaduje znalost skutečné Pareto fronty**. Příklad: fronta $\{(2, 7), (4, 5), (8, 2)\}$, $r = (10, 10)$; po svislých pruzích $2 \cdot 8 + 4 \cdot 5 + 2 \cdot 3 = 16 + 20 + 6 = 42$. GD/IGD a spread naopak skutečnou frontu znát potřebují.

03 Dobývání znalostí

Příprava dat a relevance atributů, asociační pravidla, klasifikace, shlukování, vyhodnocování modelů, analýza sociálních sítí.

2 Příprava dat, výběr atributů a analýza jejich relevance

2.3 Čištění dat: šum a odlehlé hodnoty

► Odlehlá hodnota podle mezikvartilového rozpětí

$$\text{IQR} = Q_3 - Q_1, \quad x > Q_3 + 1,5 \cdot \text{IQR} \quad \text{nebo} \quad x < Q_1 - 1,5 \cdot \text{IQR}$$

Q_1, Q_2, Q_3 jsou kvartily (25 %, 50 % = medián, 75 % pozorování pod nimi). Standardní pravidlo pro detekci *outlieru*; základ krabicového grafu.

2.5 Transformace a standardizace atributů

► Min-max normalizace (*range standardization*)

$$\text{range}(x_{if}) = \frac{x_{if} - \min(f)}{\max(f) - \min(f)} \in [0, 1], \quad \text{range}_{[-1,1]} = 2 \cdot \text{range}(x_{if}) - 1$$

f je atribut, x_{if} jeho hodnota u i -tého objektu. **Proč:** bez standardizace ovládne vzdálenost atribut s největším rozsahem — pro $x_i = (0,1; 20)$ a $x_j = (0,9; 720)$ je $\text{dist} = 700,0005$, tedy první atribut nemá prakticky žádný vliv. *Desítkové škálování* dělí nejmenší mocninou 10, která udrží hodnoty v $[-1, 1]$.

► Standardizace podle průměrné absolutní odchylky

$$m_f = \frac{1}{n}(x_{1f} + \dots + x_{nf}), \quad s_f = \frac{1}{n}(|x_{1f} - m_f| + \dots + |x_{nf} - m_f|), \quad z(x_{if}) = \frac{x_{if} - m_f}{s_f}$$

Dává nulový průměr a jednotkovou *střední absolutní* odchylku. Oproti klasickému z -skóre (se směrodatnou odchylkou) je robustnější vůči odlehlým hodnotám, protože se odchylky neumocňují.

2.6 Diskretizace numerických atributů

2.6.1 Fuzzy diskretizace

► Fuzzy diskretizace — charakteristické funkce a váha objektu

$$\mu_{i-1}(x) = \frac{x_{i+1} - x}{x_{i+1} - x_{i-1}}, \quad \mu_{i+1}(x) = \frac{x - x_{i-1}}{x_{i+1} - x_{i-1}}, \quad w = \prod_j \mu_j < 1$$

Na přechodové zóně mezi dvěma intervaly charakteristické funkce lineárně klesají, resp. rostou, a jejich součet je 1. Jedné numerické hodnotě tak mohou odpovídat *dvě* sousední kategorie; objekt v zóně vstupuje do dat jako „fuzzy objekt“ s vahou w danou součinem přes všechny atributy. Motivace: ostrá diskretizace ztrácí informaci a zavádí *kontradikce*.

2.8 Analýza relevance atributů: filtry a wrappery

2.8.1 Kritéria na kontingenčních tabulkách

► Kontingenční tabulka — marginály a očekávané četnosti

$$r_k = \sum_{l=1}^S a_{kl}, \quad s_l = \sum_{k=1}^R a_{kl}, \quad n = \sum_{k=1}^R \sum_{l=1}^S a_{kl}, \quad e_{kl} = \frac{r_k s_l}{n}$$

a_{kl} = četnost kombinace $A(v_k) \wedge C(v_l)$ vstupního atributu A (R hodnot) a cílového atributu C (S tříd). Odhady pravděpodobností: $P(A(v_k) \wedge C(v_l)) = a_{kl}/n$, $P(A(v_k)) = r_k/n$, $P(C(v_l)) = s_l/n$. e_{kl} je očekávaná četnost při nezávislosti.

► χ^2 jako kritérium relevance a jako test

$$\chi^2 = \sum_{k=1}^R \sum_{l=1}^S \frac{(a_{kl} - e_{kl})^2}{e_{kl}} = n \sum_{k=1}^R \sum_{l=1}^S \frac{(a_{kl} - \frac{r_k s_l}{n})^2}{r_k s_l} = \sum_k \sum_l \frac{a_{kl}^2}{e_{kl}} - n$$

Čím větší, tím lepší (relevantnější atribut). Jako test: při $H_0 : P(A = v_k \wedge C = v_l) = P(A = v_k)P(C = v_l)$ má statistika χ^2 rozdělení s $(R-1)(S-1)$ stupni volnosti; je-li $\chi^2 \geq \chi^2_{(R-1)(S-1)}(\alpha)$, H_0 zamítáme (pro čtyřpolní tabulku a $\alpha = 0,05$ je kritická hodnota 3,84). Poslední tvar je nejrychlejší pro ruční výpočet. **Podmínka použitelnosti:** $e_{kl} = r_k s_l / n \geq 5$ pro všechna k, l .

► Fisherův exaktní test

$$p = \frac{r_1! r_2! s_1! s_2!}{n! a_{11}! a_{12}! a_{21}! a_{22}!} = \frac{\binom{s_1}{a_{11}} \binom{s_2}{a_{12}}}{\binom{n}{r_1}}, \quad P = \sum_{i=0}^m \frac{r_1! r_2! s_1! s_2!}{n! (a_{11} - i)! (a_{12} + i)! (a_{21} + i)! (a_{22} - i)!}$$

Pro čtyřpolní tabulky s *malými* četnostmi, kde χ^2 test nelze použít. p je pravděpodobnost konkrétní tabulky při daných marginálech; P se sečte přes všechny uvažované hodnoty ($m = \min(r_1, s_1)$). Je-li $P \leq \alpha$, H_0 o nezávislosti se zamítá.

2.8.2 Kritéria založená na entropii

► Entropie atributu, vzájemná informace, informační míra závislosti

$$H(A) = \sum_{k=1}^R \frac{r_k}{n} H(A(v_k)), \quad H(A(v_k)) = - \sum_{l=1}^S \frac{a_{kl}}{r_k} \log_2 \frac{a_{kl}}{r_k}$$

$$MI(A, C) = \sum_{k=1}^R \sum_{l=1}^S \frac{a_{kl}}{n} \log_2 \frac{n a_{kl}}{r_k s_l}, \quad ID(A, C) = \frac{MI(A, C)}{H(C)} = \frac{MI(A, C)}{- \sum_l \frac{s_l}{n} \log_2 \frac{s_l}{n}}$$

$H(A)$ je vážený průměr entropií jednotlivých hodnot — **čím menší, tím lepší** atribut. MI i ID naopak **čím větší, tím lepší**; ID je vzájemná informace normalizovaná entropií cílového atributu, takže je srovnatelná napříč úlohami.

2.8.3 Kritéria pro numerické atributy: korelace

► Pearsonův korelační koeficient

$$r = \frac{\text{cov}(X, Y)}{s_X s_Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \in [-1, 1]$$

s_X, s_Y jsou směrodatné odchylky, $\bar{x}, \bar{y}$ průměry. Míra **lineárního** vztahu: $r = \pm 1$ = body přesně na přímce, $r = 0$ = žádná *lineární* závislost. r^2 (*koefficient determinace*) = podíl rozptylu Y vysvětlený lineární závislostí na X . Vztah k regresi: $\beta = \text{cov}(X, Y)/s_X^2$, tedy $r = \beta s_X/s_Y$. **Tři pasti:** měří jen *lineární* vztah (pro $y = x^2$ symetricky kolem nuly vyjde $r = 0$, přestože je závislost funkční — nulová korelace *není* nezávislost); je citlivý na odlehle hodnoty; a korelace není kauzalita.

► Spearmanův koeficient ρ (korelace pořadí)

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \in [-1, 1]$$

Je to **Pearson spočítaný z pořadí** místo z hodnot; d_i = rozdíl pořadí i -tého objektu v X a Y . Uvedený zjednodušený tvar platí, *nejdou-li shodná pořadí (ties)*. Zachytí **libovolný monotónní** vztah (ne jen lineární), je robustní vůči odlehlým hodnotám, **invariantní vůči monotónní transformaci** ($\log$, $\sqrt{\cdot}$) a funguje i pro *ordinální* atributy. *Příklad: $x = (1, 2, 3, 4, 5)$, $y = (1, 2, 4, 8, 16)$ — pořadí shodná, všechna $d_i = 0$, tedy $\rho = 1$, kdežto $r \doteq 0,93$ (Pearson penalizuje nelinearitu).* Alternativa: Kendalovo τ přes konkordantní/diskordantní dvojice.

2.9 Vztahy mezi atributy: regrese

► Lineární regrese jedné proměnné (metoda nejmenších čtverců)

$$E = \sum_{i=1}^p (y_i - \beta x_i - \alpha)^2 \rightarrow \min \quad \Rightarrow \quad \beta = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}, \quad \alpha = \bar{y} - \beta \bar{x}$$

Odvození: položíme $\partial E / \partial \alpha = \partial E / \partial \beta = 0$. β je *výběrová kovariance dělená výběrovým rozptylem x* . Predikce $\hat{y} = \beta x + \alpha$; regresní přímka vždy prochází bodem $(\bar{x}, \bar{y})$.

► Vícerozměrná lineární regrese — normální rovnice

$$E = (Y - X\beta)^T (Y - X\beta), \quad X^T X \beta = X^T Y \quad \Rightarrow \quad \beta = (X^T X)^{-1} X^T Y$$

Y je vektor cílových hodnot, X rozšířená matice vstupních vzorů (první sloupec jedničky), $\beta = (\beta_0, \dots, \beta_m)$. Uzavřené řešení, ale invertování $X^T X$ je pro velké úlohy nákladné $\Rightarrow$ iterativní (gradientní) metody.

3 Metody pro dobývání znalostí

3.1 Asociační pravidla a frekventované vzory

3.1.2 Support, confidence a lift

► Support, confidence, lift

$$\begin{aligned} \text{sup}(R) &= \frac{\text{počet transakcí obsahujících } i \text{ a } j}{\text{počet všech transakcí}} \cdot 100\%, \\ \text{conf}(R) &= \frac{\text{počet transakcí obsahujících } i \text{ a } j}{\text{počet transakcí obsahujících } i} \cdot 100\%, \\ \text{lift}(R) &= \frac{p(i \wedge j)}{p(i)p(j)} \end{aligned}$$

Pro pravidlo $R : i \Rightarrow j$ nad množinou transakcí. *Support* — jak často lze pravidlo použít; *confidence* — jak spolehlivé jsou jeho výsledky (odhad $P(j \mid i)$); *lift* — kolikrát je lepší použít pravidlo než jen předpokládat závěr. **Je-li lift < 1, je pravidlo horší než náhodná volba** a negace závěru může dát lepší pravidlo; lift = 1 znamená nezávislost.

3.1.4 Algoritmus Apriori

► Apriori — rozklad kombinace na pravidla

$$\text{Suc} = \text{Comb} \setminus \text{Ant}, \quad \text{Ant} \cap \text{Suc} = \emptyset, \quad \text{Ant} \cup \text{Suc} = \text{Comb}$$

Po nalezení frekventovaných kombinací se každá rozdělí na všechny možné dvojice podkombinací. *Support* pravidla $\text{Ant} \Rightarrow \text{Suc}$ odpovídá frekvenci *Comb*, *confidence* poměru frekvencí *Comb* a *Ant*. Základ algoritmu je **uzavřenost dolů** (*downward closure*): frekvence nadkombinace $\leq$ frekvence kombinace, takže nadmnožinu nefrekventované množiny lze prořezat.

3.1.5 Vícenásobný minimální support: MS-Apriori

► MS-Apriori — vícenásobný minimální support

$$\text{minsup}(\text{pravidla}) = \min_{i \in s} \text{MIS}(i), \quad \max_{i \in s} \text{sup}(i) - \min_{i \in s} \text{sup}(i) \leq \varphi$$

Řeší *problém vzácných položek* (chléb vs. kuchyňský robot): každá položka má vlastní MIS, minsup pravidla je minimum přes jeho položky, a rozdíl supportů uvnitř množiny je omezen φ . **Důsledek: uzavřenost dolů neplatí** — $\{1, 2\}$ může být nefrekventovaná, a přesto $\{1, 2, 3\}$ frekventovaná; položky se proto třídí vzestupně podle MIS a testuje se proti MIS *první* položky.

3.2 Přístupy založené na principu učení s učitelem

3.2.2 Rozhodovací stromy

► Entropie a vážená průměrná entropie atributu

$$H = - \sum_{j=1}^m p_j \log_2 p_j, \quad H(A(v)) = - \sum_{j=1}^m p_j^{A(v)} \log_2 p_j^{A(v)}, \quad H(A) = \sum_v \frac{|A(v)|}{|D|} H(A(v))$$

p_j = relativní frekvence třídy j na uvažované množině vzorů, m = počet tříd. Konvence $0 \log_2 0 = 0$; přepočít $\log_2 x = \log_{10} x / 0,301$. **Vybírá se atribut s minimální $H(A)$.** Čistý uzel má $H = 0$, dvě stejně velké třídy dají $H = 1$.

► Informační zisk a poměrný informační zisk (ID3, C4.5)

$$\text{GAIN}(D, A) = H(D) - \sum_v \frac{|D_v|}{|D|} H(D_v), \quad \text{GAIN_RATIO}(D, A) = \frac{\text{GAIN}(D, A)}{- \sum_v \frac{|D_v|}{|D|} \log_2 \frac{|D_v|}{|D|}}$$

Očekávané snížení entropie po rozdělení podle atributu; bere se **největší**. Protože $H(D)$ je pro všechny atributy stejná, je maximalizace GAIN ekvivalentní minimalizaci $H(A)$. Jmenovatel GAIN_RATIO (*split info*) penalizuje **nadměrné větvení** — bez něj by vyhrával atribut jako „rodné číslo“, který dělí data na samé jednoprvkové podmnožiny.

► Gini index a kritérium dělení v CART

$$G = \sum_{i=1}^r \frac{n_i}{n} G(v_i), \quad G(v_i) = 1 - \sum_{j=1}^m p_j^2, \quad \Phi = 2P_L P_R \sum_{j=1}^m |P(C_j | t_L) - P(C_j | t_R)|$$

CART generuje *binární* stromy. n_i = počet vzorů s hodnotou v_i , p_j = pravděpodobnost třídy j v těchto vzorech; **nižší G = lepší diskriminace**. Φ je kritérium volby dělicího bodu: P_L, P_R jsou pravděpodobnosti levého a pravého podstromu; Φ **nabývá maxima**, jsou-li všechny vzory dané třídy seskupeny v témže podstromu.

► C4.5 — pesimistický odhad přesnosti pravidla

$$\text{acc} - 1,96 \sqrt{\frac{\text{acc}(1 - \text{acc})}{n}}, \quad \text{acc} = \frac{k}{n}$$

k = správně klasifikované, n = pokryté vzory. C4.5 hodnotí pravidla *na trénovacích datech*, kde je přesnost optimistická; charakteristikou pravidla je proto *dolní mez* intervalu spolehlivosti z binomického rozdělení (95% hladina). Používá se při *rule post-pruning*: vypouštět předpoklady, dokud se tato mez nezhorší.

3.2.3 Bayesovská klasifikace

► Bayesova formule a hypotéza MAP

$$P(H | E) = \frac{P(E | H) P(H)}{P(E)}, \quad H_{MAP} = \arg \max_{H \in \mathcal{H}} P(H | E) = \arg \max_{H \in \mathcal{H}} P(E | H) P(H)$$

$P(H)$ = apriorní pravděpodobnost hypotézy, $P(H | E)$ = posteriorní, $P(E | H)$ = věrohodnost. Jmenovatel $P(E)$ je pro všechny hypotézy stejný, takže jej lze při maximalizaci *zanedbat*.

► Naivní bayesovský klasifikátor

$$P(H | E_1, \dots, E_k) = \frac{P(H)}{P(E_1, \dots, E_k)} \prod_{i=1}^k P(E_i | H), \quad H_{MAP} = \arg \max_{H_t} P(H_t) \prod_{i=1}^k P(E_i | H_t)$$

Předpoklad: jevy $E_1, \dots, E_k$ jsou *podmíněně nezávislé* při platnosti H — v reálných úlohách splněn jen zřídka, odtud „naivní“. Odhady z dat: $P(H_t) = \frac{\text{počet vzorů z } t}{\text{počet všech vzorů}}$, $P(E_k | H_t) = \frac{\text{počet vzorů z } t \text{ splňujících } E_k}{\text{počet vzorů z } t}$. Přes nesplněný předpoklad funguje překvapivě dobře, protože pro *argmax* stačí správné pořadí, ne přesné pravděpodobnosti.

3.2.4 Support Vector Machines

► Lineární SVM — rozhodovací funkce a okraj

$$f(x) = \langle w \cdot x \rangle + b, \quad d_+ = d_- = \frac{1}{\|w\|}, \quad \text{margin} = d_+ + d_- = \frac{2}{\|w\|}$$

Trénovací množina $D = \{(x_i, y_i)\}$, $y_i \in \{1, -1\}$; w je normálový vektor a b posun hyperroviny. Vzdálenost bodu od hyperroviny je $|\langle w \cdot x_i \rangle + b| / \|w\|$. Separujících hyperrovin je mnoho — SVM hledá tu s **největším okrajem**, protože ta podle teorie učení minimalizuje mez chyby.

► Primární optimalizační úloha a Lagrangian

$$\min \frac{\langle w \cdot w \rangle}{2} \quad \text{za podmínek} \quad y_i(\langle w \cdot x_i \rangle + b) \geq 1$$

$$L_P = \frac{\langle w \cdot w \rangle}{2} - \sum_{i=1}^r \alpha_i [y_i(\langle w \cdot x_i \rangle + b) - 1], \quad \alpha_i \geq 0$$

Maximalizace $2/\|w\|$ je ekvivalentní minimalizaci $\langle w \cdot w \rangle / 2$. Podmínka je souhrnný zápis $\langle w \cdot x_i \rangle + b \geq 1$ pro $y_i = 1$ a ≤ -1 pro $y_i = -1$. Řešení musí splňovat *Kuhn–Tuckerovy podmínky*, které jsou pro konvexní účelovou funkci s lineárními omezeními nejen nutné, ale i *postačující*.

► Kuhn–Tuckerovy podmínky a vznik duálu

$$\frac{\partial L_P}{\partial w_j} = 0 \Rightarrow w = \sum_{i=1}^r y_i \alpha_i x_i, \quad \frac{\partial L_P}{\partial b} = 0 \Rightarrow \sum_{i=1}^r y_i \alpha_i = 0, \quad \alpha_i (y_i(\langle w \cdot x_i \rangle + b) - 1) = 0$$

Postup: (1) vynuluj parciální derivace L_P podle *primárních* proměnných w a b ; (2) dosad' získané vztahy zpět do L_P — w a b se vyeliminují a zbudou jen α_i . KKT podmínky jsou obecně jen nutné, pro konvexní účelovou funkci s lineárními omezeními i *postačující*. Poslední je **komplementarita**: součin je nulový, takže je-li $\alpha_i > 0$, musí být $y_i(\langle w \cdot x_i \rangle + b) = 1$ — bod leží *přesně na* okrajové hyperrovině. To jsou **podpůrné vektory**; pro ostatní je $\alpha_i = 0$ a řešení neovlivňuje.

► **Wolfeho duální úloha (vázaná) a rekonstrukce w, b**

$$\max L_D = \sum_{i=1}^r \alpha_i - \frac{1}{2} \sum_{i,j} y_i y_j \alpha_i \alpha_j \langle x_i \cdot x_j \rangle \quad \text{za podmínky} \quad \sum_{i=1}^r y_i \alpha_i = 0, \quad \alpha_i \geq 0$$

$$w = \sum_{i \in sv} y_i \alpha_i x_i, \quad b = y_k - \langle w \cdot x_k \rangle \quad (x_k \text{ podpůrný vektor})$$

Omezení jsou součástí úlohy — vznikla v kroku (1), bez nich je duál nedopsaný. Maximum L_D se nabývá pro tytéž w, b, α_i jako minimum L_P ; řeší se numericky (prakticky SMO). Duál obsahuje vstupy *jen* přes skalární součiny $\langle x_i \cdot x_j \rangle$ — právě to umožňuje kernelový trik. Vztah pro b plyne z komplementarity ($y_k(\langle w \cdot x_k \rangle + b) = 1$ a $y_k^2 = 1$); numericky se průměruje přes všechny podpůrné vektory.

► **Rozhodovací hranice a testování**

$$\langle w \cdot x \rangle + b = \sum_{i \in sv} y_i \alpha_i \langle x_i \cdot x \rangle + b = 0, \quad \text{test: } \text{sign}\left(\sum_{i \in sv} \alpha_i y_i \langle x_i \cdot z \rangle + b\right)$$

z je testovaný vzor, sv množina podpůrných vektorů. Vráť-li výraz 1, je z pozitivní, jinak negativní. Všimni si, že w ani ϕ se nikde nevyčísľují — stačí skalární součiny s podpůrnými vektory.

► **Kernelový trik a měkký okraj**

$$K(x, z) = \langle \phi(x) \cdot \phi(z) \rangle, \quad \min \frac{\langle w \cdot w \rangle}{2} + C \sum_i \xi_i, \quad \xi_i \geq 0$$

Kernel nahradí skalární součin ve všech výrazech, aniž bychom ϕ kdy vyčísľili — odstraňuje prokletí dimenzionality při explicitní transformaci. Příklad ($d = 2$, 2-D vstup): $\langle x \cdot z \rangle^2 = \langle (x_1^2, x_2^2, \sqrt{2}x_1x_2) \cdot (z_1^2, z_2^2, \sqrt{2}z_1z_2) \rangle$. Zda je funkce kernelem, říká *Mercerova věta*; běžné kernely: lineární, polynomiální, gaussovský (RBF), sigmoidální. *Slack variables* ξ_i připouštějí chyby; C řídí kompromis mezi šířkou okraje a počtem chyb.

3.2.5 Logistická regrese

► **Logit a sigmoida**

$$\ln \frac{P(y=1|x)}{1-P(y=1|x)} = \beta_0 + \beta_1 x_1 + \dots + \beta_m x_m = z, \quad P(y=1|x) = \frac{1}{1+e^{-z}} = \sigma(z)$$

β_j jsou koeficienty modelu a z jejich lineární kombinace (*logit*). Modeluje se logaritmus *podmíněné šance* (*conditional odds*) jako lineární kombinace vstupů. Logistická regrese je nejdůležitější případ nelineární regrese a zároveň klasifikátor; výstupem je *pravděpodobnost*, ne jen třída.

► **Učení logistické regrese — věrohodnost a křížová entropie**

$$L = \prod_{i=1}^p \left(\frac{1}{1+e^{-z_i}} \right)^{y_i} \left(\frac{1}{1+e^{z_i}} \right)^{1-y_i}, \quad E = -\log L = -\sum_i \left[y_i \log \sigma(z_i) + (1-y_i) \log (1-\sigma(z_i)) \right]$$

Místo maximalizace věrohodnosti L se minimalizuje *křížová entropie* E (numericky stabilnější, součet místo součinu).

► **Adaptační pravidla logistické regrese**

$$\Delta \beta_j = -\eta \frac{\partial E}{\partial \beta_j} = \eta \sum_i (y_i - \sigma(z_i)) x_{i,j}, \quad \Delta \beta_0 = \eta \sum_i (y_i - \sigma(z_i))$$

η je rychlost učení. Odvození využívá $\sigma' = \sigma(1 - \sigma)$, po zjednodušení se derivace sigmoidy *vykrátí*. Chyba tedy vstupuje do úpravy vah přímo jako rozdíl *pozorované* a *predikované* hodnoty — tentýž tvar jako delta pravidlo perceptronu.

3.2.6 Diskriminační analýza

► Diskriminační analýza — diskriminační funkce

$$x \in C_j \iff g_j(x) = \max_k g_k(x), \quad g_j(x) = \beta_{j0} + \beta_{j1}x_1 + \dots + \beta_{jm}x_m \text{ (lineární DA)}$$

Optimální klasifikace ve smyslu minimální chyby nastane, jsou-li diskriminační funkce úměrné aposteriorním pravděpodobnostem: $g_j(x) = P(C_j | x) = p(x | C_j)P(C_j)/p(x)$; pro dvě třídy $g(x) = p(x | C_1)P(C_1) - p(x | C_2)P(C_2)$.

► LDA vs. QDA pro normální rozdělení

$$g(x) = (\mu_1 - \mu_2)^\top S^{-1}x - \frac{1}{2}(\mu_1 - \mu_2)^\top S^{-1}(\mu_1 + \mu_2) - \ln \frac{P(C_2)}{P(C_1)}$$

$$g_j(x) = \ln p_j - \frac{1}{2}(x - \mu_j)^\top \Sigma^{-1}(x - \mu_j)$$

Pro normální rozdělení s *obecnými* kovariančními maticemi $S_1 \neq S_2$ vychází **kvadratická** diskriminační funkce (QDA); jsou-li matice *shodné* ($S_1 = S_2 = S$), redukuje se na **lineární** (LDA) — první vzorec. Druhý je ekvivalentní tvar LDA se společnou Σ ; odhaduje se jen μ_j (q parametrů na třídu), a hranice mezi dvěma třídami $\{x : g_j(x) = g_k(x)\}$ je *nadrovina*. Jsou-li navíc třídy stejně pravděpodobné a $S = I$, jde o prosté srovnávání vzdáleností od středních hodnot.

3.2.7 Neuronové sítě a extrémní učicí stroje (ELM)

► ELM — extrémní učicí stroj

$$f_L(x) = \sum_{i=1}^L \beta_i G(a_i, b_i, x), \quad H\beta = T \implies \beta = H^+T$$

Dopředná síť s *jednou* skrytou vrstvou o L neuronech, β_i jsou výstupní váhy; G je např. sigmoida $g(\langle a_i \cdot x \rangle + b_i)$ nebo RBF $g(b_i \|x - a_i\|)$. **Klíčová myšlenka:** parametry skrytých neuronů (a_i, b_i) se *neadaptují* — vygenerují se *náhodně*, i bez znalosti dat (s pravděpodobností 1 platí $\lim_{L \rightarrow \infty} \|f - f_L\| = 0$). Učí se jen výstupní váhy, a to *jednou*, Mooreovou–Penroseovou pseudoinverzí H^+ výstupní matice skryté vrstvy H . Neiterativní $\Rightarrow$ rychlé, bez lokálních minim; regularizace přičtením I/C na diagonálu $H^\top H$.

3.2.8 Ensemble metody

► Bagging — pokles rozptylu a bootstrap

$$\text{var}\left(\frac{1}{k} \sum_{i=1}^k h_i\right) = \frac{\sigma^2}{k} \quad (\text{i.i.d.}), \quad 1 - \left(1 - \frac{1}{n}\right)^n \approx 1 - \frac{1}{e} = 63,2\%$$

Bagging snižuje *rozptyl*. Bootstrapový vzorek (výběr n bodů s *opakováním*) obsahuje asi 63,2 % různých bodů originálu — pravděpodobnost, že bod ve vzorku *není*, je $(1 - 1/n)^n \rightarrow 1/e$. Ideální bázeový model: rozhodovací stromy (nízké zkreslení, vysoký rozptyl). **Omezení: bagging nesnižuje zkreslení.**

► Náhodné lesy — rozptyl při korelovaných komponentách

$$\text{var} = \rho\sigma^2 + \frac{(1 - \rho)\sigma^2}{k}$$

ρ je vzájemná pozitivní korelace k klasifikátorů. Člen ρ^2 je **nezávislý na k** — právě on omezuje přínos baggingu, protože bootstrapované stromy bývají korelované. Náhodný les korelaci snižuje tím, že v každém uzlu předloží jen *náhodnou podmnožinu* $m \approx \sqrt{\text{počet příznaků}}$ příznaků.

► AdaBoost — váha komponenty a převážení vzorů

$$\alpha_t = \frac{1}{2} \ln \frac{1 - \epsilon_t}{\epsilon_t}, \quad W_{t+1}(i) = \frac{W_t(i) e^{\pm \alpha_t}}{\sum_j W_{t+1}(j)}$$

ϵ_t = vážená chyba v t -té iteraci, $W_1(i) = 1/n$. Znaménko v exponentu: $+\alpha_t$ pro *nesprávně* klasifikované (jejich váha roste), $-\alpha_t$ pro správně klasifikované. Konec, když $t \geq T$, $\epsilon_t = 0$ nebo $\epsilon_t \geq 0,5$. **Boosting snižuje zkreslení** (bagging rozptyl), musí ale běžet *sekvenčně* a je citlivý na šum.

3.3 Klastrová analýza

3.3.1 Formulace úlohy a míry vzdálenosti

► Metriky vzdálenosti

$$d_H = \sum_{i=1}^m |x_{1i} - x_{2i}|, \quad d_E = \sqrt{\sum_{i=1}^m (x_{1i} - x_{2i})^2}, \quad d_C = \max_i |x_{1i} - x_{2i}|, \quad d_q = \left(\sum_{i=1}^m |x_{1i} - x_{2i}|^q \right)^{1/q}$$

Hammingova (Manhattan, L_1), euklidovská (L_2), Čebyševova (L_∞) a Minkowského (L_q), jejímiž speciálními případy jsou první tři: $d_H = d_1$, $d_E = d_2$, $d_C = \lim_{q \rightarrow \infty} d_q$. Všechny předpokládají *stejný rozptyl* veličin $\Rightarrow$ nutná normalizace.

► Mahalanobisova vzdálenost

$$d_M^2(x_1, x_2) = (x_1 - x_2)^\top S^{-1} (x_1 - x_2)$$

S je kovarianční matice. Zohledňuje *různé rozptyly i korelace* mezi veličinami; pro $S = I$ se redukuje na kvadrát euklidovské vzdálenosti. Používá se, mají-li veličiny *různý rozptyl*.

► Vzdálenost mezi klastry (metody spojování)

$$D_{\min} = \min_{x_i, x_j} d(x_i, x_j), \quad D_{\max} = \max_{x_i, x_j} d(x_i, x_j), \quad D_{\text{avg}} = \frac{1}{n_k n_l} \sum_{i=1}^{n_k} \sum_{j=1}^{n_l} d(x_i, x_j)$$

Single linkage (nejbližší soused — řetězí, umí protáhlé tvary), *complete linkage* (nejvzdálenější soused — kompaktní kulovité klastry), *average linkage* (kompromis), *centroidní* $D = d(c_k, c_l)$. Volba metody určuje tvar nalezených klastrů v hierarchickém shlukování.

3.3.2 Metoda k -means

► k -means — centroid a k -medoids — účelová funkce

$$c_k = \frac{1}{|C_k|} \sum_{x \in C_k} x, \quad O = \sum_{i=1}^n \min_j d(x_i, y_j)$$

k -means iteruje „spočti centroidy $\rightarrow$ přiřaď každý vzor k nejbližšímu“, dokud dochází k přesunům. k -medoids hledá k reprezentantů $y_1, \dots, y_k$ z *původní databáze* minimalizujících O — je proto robustní vůči odlehlým hodnotám a funguje pro libovolný typ dat, ale je pomalejší; složitost jedné iterace $O(k n d)$. CLARA/CLARANS jej škálují vzorkováním, resp. náhodným prohledáváním.

3.3.5 Vektorová kvantizace: algoritmus LVQ

► LVQ — adaptace vah (shlukování s učitelem)

$$q = \arg \min_j \|x - w_j\|_2^2, \quad w_q(k+1) = w_q(k) \pm \mu(k)(x - w_q(k))$$

Znaménko + („přitáhni“), souhlasí-li třída x s třídou vítězného vektoru w_q , jinak – („odtlač“). Rychlost učení klesá, např. $\mu(k) = \mu(k-1)/(k+1)$. Váhové vektory se inicializují prvními m vzory (musí pokrýt všechny třídy), čímž se neurony „zkalibrují“ s třídami.

4 Charakteristická a diskriminační pravidla a jejich zajímavost

4.1 Pravidla jako srozumitelná forma klasifikace

► Fuzzy implikace jako reziduum t-normy

$$t(\varphi \Rightarrow \psi) = \sup\{c \in [0, 1] : T(t(\varphi), c) \leq t(\psi)\}, \quad t(\varphi \Leftrightarrow \psi) = T(t(\varphi \Rightarrow \psi), t(\psi \Rightarrow \varphi))$$

Booleovská pravidla pracují s $t(\varphi) \in \{0, 1\}$, fuzzy pravidla se stupni pravdivosti $t(\varphi) \in [0, 1]$. Na objektech, kde antecedent *plně* platí ($t(\varphi) = 1$), implikace splývá s ekvivalencí — proto se v praxi pravidla vyhodnocují právě tam.

4.3 Charakteristická a diskriminační pravidla: t-weight a d-weight

► t-weight (typičnost) a kvantitativní charakteristické pravidlo

$$t\text{-weight}(q_a) = \frac{\text{count}(q_a)}{\sum_{i=1}^N \text{count}(q_i)} \in [0, 1]$$

$$\forall X \text{ target}(X) \Rightarrow \text{cond}_1(X) [t: w_1] \vee \dots \vee \text{cond}_N(X) [t: w_N]$$

$q_1, \dots, q_N$ jsou zobecněné záznamy cílové třídy, X objekt (pravidlo platí pro všechny). t-weight = *podíl objektů cílové třídy, které q_a pokrývá* (součet přes všechny záznamy je 100 %). Charakteristické pravidlo je **nutná podmínka** — implikace z třídy. Odpovídá *recallu* pravidla vůči cílové třídě.

► d-weight (rozlišovací váha) a kvantitativní diskriminační pravidlo

$$d\text{-weight}(q_a) = \frac{\text{count}(q_a \in C_t)}{\text{count}(q_a \in C_t) + \sum_{j=1}^m \text{count}(q_a \in C_j)} \in [0, 1]$$

$$\forall X \text{ target}(X) \Leftarrow \text{cond}(X) [d: w]$$

C_t je cílová třída, $C_1, \dots, C_m$ kontrastní třídy. d-weight = *podíl objektů pokrytých záznamem q_a , které patří do cílové třídy*. Diskriminační pravidlo je **postačující podmínka** — implikace do třídy. Odpovídá *precision* pravidla. *Kvantitativní popisné pravidlo* kombinuje obojí: $\Leftrightarrow$ s $[t: w, d: w']$.

4.6 Observační pravidla: konfidence, podpora a testy hypotéz

► Observační pravidlo s konfidencí a podporou

$$\text{conf} = \frac{a}{a+b}, \quad \text{sup} = \frac{a}{n}, \quad (\varphi \sim \psi) = 1 \iff \text{conf} \geq c_0 \wedge \text{sup} \geq s_0$$

Čtyřpolní tabulka: a objektů splňuje $\varphi \wedge \psi$, b objektů $\varphi \wedge \neg\psi$, c objektů $\neg\varphi \wedge \psi$, d objektů $\neg\varphi \wedge \neg\psi$, $n = a+b+c+d$. conf je nestranný odhad $P(\psi | \varphi)$. Druhý typ observačních pravidel je založen na *testech hypotéz* místo prahů. Každá volba míry a prahu je jiný *zobecněný kvantifikátor*, a tedy jiná množina nalezených pravidel.

4.8 Měření zajímavosti pravidel

► Střední hodnota ceny (různá cena různých chyb)

$$\frac{1}{n} \sum_{i,j} c(i,j) n_{ij}$$

$c(i,j)$ = cena klasifikace třídy i jako j , n_{ij} = odpovídající četnost. Tradiční chybovost je speciální případ: $c(i,i) = 0$, jinak 1. Realističtější, protože nedoručený ham vadí víc než nerozpoznaný spam a nerozpoznané napadení sítě víc než falešný poplach.

5 Reprezentace, vyhodnocování a vizualizace znalostí

5.2 Vyhodnocování modelů

5.2.1 Kritéria hodnocení klasifikačních metod

► Přesnost a křížová validace

$$Accuracy = \frac{\text{počet správných klasifikací}}{\text{počet všech testovaných případů}}, \quad Accuracy_{CV} = \frac{1}{k} \sum_{i=1}^k Accuracy_i$$

Zásadní pravidlo: trénovací množina se nesmí použít při testování a testovací při učení — jen neviděná data dají nezkrácený odhad. *Holdout* pro velká data, *k-násobná křížová validace* ($k = 5$ nebo 10) pro menší, *leave-one-out* pro velmi malá. *Validační* množina (třetí část) slouží k ladění parametrů algoritmu.

► Interval spolehlivosti pro křížovou validaci

$$Accuracy_{CV} \pm t_{N,k-1} \cdot s_{Accuracy}, \quad s_{Accuracy} = \sqrt{\frac{1}{k(k-1)} \sum_{i=1}^k (Accuracy_i - Accuracy_{CV})^2}$$

Přibližný $N\%$ interval; $t_{N,k-1}$ je kvantil Studentova rozdělení s $k-1$ stupni volnosti. Umožňuje říct, zda je rozdíl mezi dvěma modely *statisticky významný*, nebo jen šum.

5.2.3 Matice záměn a odvozené míry

► Matice záměn: precision, recall, F_1

$$p = \text{precision} = \frac{TP}{TP + FP}, \quad r = \text{recall} = \frac{TP}{TP + FN}, \quad F_1 = \frac{2pr}{p+r} = \frac{2}{\frac{1}{p} + \frac{1}{r}}$$

TP/TN = správně klasifikované pozitivní/negativní vzory, FP/FN = nesprávně. *Precision* = podíl správných mezi vzory označenými za pozitivní; *recall* = podíl nalezených mezi skutečně pozitivními. **Obě hodnoty jen pozitivní třídu** — proto se používají u nevyvážených dat, kde je accuracy zavádějící. F_1 je *harmonický průměr*, a je tedy blíž tomu *menšímu* z obou čísel: velký je jen tehdy, jsou-li velké *obě* míry.

5.2.5 ROC křivka a AUC

► ROC křivka: TPR, FPR, TNR

$$TPR = \frac{TP}{TP + FN}, \quad FPR = \frac{FP}{FP + TN}, \quad TNR = \frac{TN}{FP + TN}$$

ROC je graf TPR proti FPR při měnícím se prahu skóre. *TPR* je *recall* pozitivní třídy (též *senzitivita*), *TNR* *specifita* ($= 1 - FPR$). **AUC** = plocha pod křivkou: 0,5 = náhodný klasifikátor, 1,0 = dokonalý; interpretuje se jako pravděpodobnost, že náhodný pozitivní vzor dostane vyšší skóre než náhodný negativní. Na rozdíl od accuracy nezávisí na zvoleném prahu ani na poměru tříd.

6 Modely pro analýzu sociálních sítí, centralita a detekce komunit

6.3 Síla vazeb

► Překryv sousedství (síla vazby)

$$O(i, j) = \frac{|N_i \cap N_j|}{|N_i \cup N_j| - 2}$$

N_i = sousedé uzlu i ; -2 ve jmenovateli vylučuje i a j samotné. **Čím větší překryv, tím silnější vazba.** Souvisí se *sílou slabých vazeb* (Granovetter): mosty a zkratkové mosty mají překryv blízký nule, ale zprostředkovávají nové informace. *Zkratkový most*: hrana, jejímž odstraněním se vzdálenost koncových uzlů zvětší na více než 2 — čím větší výsledná vzdálenost, tím slabší vazba.

6.4 Klíčoví hráči: míry centrality

► Centrality

$$C_D(v) = \deg(v), \quad C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}, \quad C_C(v) = \frac{n-1}{\sum_u d(v, u)}$$

Stupňová (C_D) — kolik lidí osoba dosáhne **přímo**; propojenost, vliv, popularita. *Mezilehlá* (C_B) — σ_{st} je počet nejkratších cest mezi s a t , $\sigma_{st}(v)$ počet těch přes v ; indikuje uzly na komunikačních cestách, tedy místa, kde se síť může **rozpadnout**. *Blízkostní* (C_C , kde $d(v, u)$ je vzdálenost uzlů a n počet uzlů sítě) — převrácená průměrná délka nejkratších cest; míra *dosahu* a rychlosti šíření. **Jednotlivé míry nestačí**: dva uzly *společně* mohou být pro síť důležitější než nejcentrálnější uzel sám.

► Vlastní centralita (*eigenvector centrality*)

$$x_i = \frac{1}{\lambda} \sum_{j \in M(i)} x_j = \frac{1}{\lambda} \sum_{j \in V} a_{i,j} x_j \iff Ax = \lambda x$$

A je matice sousednosti, $M(i)$ množina sousedů i , x_i centralita uzlu i . Centralita uzlu je úměrná součtu centralit jeho sousedů — moc a status jsou definovány *rekurzivně*. Vlastních čísel je mnoho, ale *požadavek nezápornosti* všech složek vlastního vektoru vybírá právě **největší** λ (Perronova–Frobeniova věta). Vektor je určen až na násobek $\Rightarrow$ nutná normalizace. Blíže souvisí s PageRankem.

6.5 Koheze: míry na úrovni sítě

► Reciprocita, hustota, klastrovací koeficient

$$\text{density} = \frac{|E|}{|V|(|V|-1)/2} \text{ (neor.)}, \quad \frac{|E|}{|V|(|V|-1)} \text{ (or.)}, \quad C_i = \frac{2|\{e_{jk} : v_j, v_k \in N_i\}|}{k_i(k_i-1)}$$

Reciprocita = podíl obousměrných vztahů; **má smysl jen v orientovaných grafech**. *Hustota* = podíl hran na počtu *možných*; klika má hustotu 1. *Klastrovací koeficient* uzlu = hustota jeho *sousedství* N_i , $k_i = |N_i|$ (u orientovaných grafů bez faktoru 2); koeficient sítě $C = \frac{1}{|V|} \sum_i C_i$ indikuje přítomnost (sub)komunit.

6.7 Modelování vlivu

► Model lineárního prahu (LTM)

$$\sum_{u \in N_v^{\text{aktivní}}} w_{u,v} \geq \theta_v \sum_{u \in N_v} w_{u,v}$$

$w_{u,v}$ je váha vazby ze souseda u na v . Každý uzel v si zvolí prah θ_v *náhodně* z $U[0, 1]$; aktivní uzly zůstávají aktivní a v každém kroku se aktivují uzly splňující tuto podmínku. LTM se soustředí na **příjemce** vlivu (ten

sčítá tlak okolí); nezávislý kaskádový model (ICM) naopak na *odesílatele* — každý nově aktivovaný uzel dostane jediný pokus aktivovat každého souseda.

► Maximalizace vlivu

$$\max_{|B| \leq k} \sigma(B)$$

$\sigma(B)$ = očekávaný počet uzlů ovlivněných počáteční aktivační množinou B . Úloha je **NP-těžká**, ale σ je submodulární, takže *hladový* přístup (přidávej uzel s největším marginálním přírůstkem) dává řešení na úrovni **63 %** ($1 - 1/e$) optima.

6.8 Vliv versus korelace

► Logistický model vlivu

$$p(a) = \frac{e^{\alpha \ln(a+1) + \beta}}{1 + e^{\alpha \ln(a+1) + \beta}}, \quad \ln \frac{p(a)}{1 - p(a)} = \alpha \ln(a + 1) + \beta$$

a = počet aktivních kontaktů uzlu, α = *koeficient sociální korelace*, β = vrozená tendence k aktivaci, $\ln(a + 1)$ = vysvětlující proměnná (logaritmus tlumí vliv velkého počtu kontaktů). Jde o logistickou regresi; *shuffle test* (přeházení časových značek) rozliší skutečný vliv od pouhé korelace.

6.9 Homofilie, výběr a sociální vliv

► Test homofilie

$$\text{očekávaný podíl heterogenních hran} = 2pq$$

p , q jsou podíly obou hodnot atributu v síti; při náhodném přiřazení je pravděpodobnost hrany muž-muž p^2 , žena-žena q^2 , různopohlavní $2pq$. **Je-li podíl heterogenních hran významně nižší než $2pq$, jde o důkaz homofilie**; významně vyšší znamená *inverzní* homofilii (partnerské vztahy). Příklad: 5 z 18 hran různopohlavních, $p = 2/3$, $q = 1/3$, $2pq = 4/9$, tj. očekáváno 8 z 18 $\Rightarrow$ homofilie. Test funguje i pro více než dvě hodnoty.

6.13 Analýza vazeb: huby, autority a algoritmus HITS

► HITS — huby a autority

$$a(i) = \sum_{(j,i) \in E} h(j), \quad h(i) = \sum_{(i,j) \in E} a(j), \quad \text{maticově} \quad a = L^\top h, \quad h = La$$

L je matice sousednosti hypertextového grafu *bázové množiny* (kořenová množina S z vyhledávače + stránky odkazující na S a odkazované z S). $a(i)$ je skóre autority a $h(i)$ skóre hubu stránky i ; vzájemné zesilování: dobrá autorita je odkazovaná dobrými huby a naopak. **Normalizace je nezbytná** — bez ní hodnoty rostou nade všechny meze a mocninná iterace nekonverguje.

► HITS — spektrální analýza

$$a_k = (L^\top L)^{k-1} a_0, \quad h_k = (LL^\top)^k h_0, \quad \frac{a_k}{c_1^k} = x_1 z_1 + x_2 \left(\frac{c_2}{c_1}\right)^k z_2 + \dots$$

$L^\top L$ je *symetrická*, má tedy n vlastních vektorů $z_1, \dots, z_n$ s vlastními čísly $|c_1| \geq \dots \geq |c_n|$; rozvineme-li $a_0 = \sum_i x_i z_i$, jde pro $c_1 > c_2$ a $k \rightarrow \infty$ každý člen kromě prvního k nule. Vektor autorit tedy konverguje k **hlavnímu vlastnímu vektoru** $L^\top L$ — rychlost konvergence určuje poměr c_2/c_1 .

6.14 PageRank

► Prestiž pořadí a základní PageRank

$$P(i) = A_{1i}P(1) + \dots + A_{ni}P(n) \iff P = A^\top P, \quad P(i) = \sum_{(j,i) \in E} \frac{P(j)}{O_j}$$

Prestiž je lineární kombinace pořadí těch, kteří na i odkazují — *charakteristická rovnice* vlastního systému matice $A^\top$. PageRank navíc **dělí** skóre stránky mezi její odkazy: O_j = počet výstupních odkazů j , tedy $A_{ij} = 1/O_i$ pro $(i, j) \in E$. Hlas důležité stránky váží víc, ale stránka odkazující na tisíc jiných dá každé málo.

► Finální PageRank s tlumícím faktorem

$$P = \left(\frac{1-d}{n}\right) \mathbf{E} + d A^\top P \implies P(i) = (1-d) + d \sum_{(j,i) \in E} \frac{P(j)}{O_j}$$

$\mathbf{E} = \mathbf{e}\mathbf{e}^\top$ je matice samých jedniček ($n \times n$). Model *náhodného surfaře*: s pravděpodobností d (typicky 0,85) následuje náhodný odkaz, s $1-d$ skočí na náhodnou stránku. **Proč augmentace**: řeší slepé uličky (stránky bez odkazů) a pastí — rozšířená matice je stochastická, *irreducibilní* i *aperiodická*, takže mocninná iterace konverguje k jedinému stacionárnímu rozdělení. Druhý tvar vzniká přeskálováním tak, aby $\mathbf{e}^\top P = n$.

6.16 Detekce komunit

► Modularita Q

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j)$$

A_{ij} = prvek matice sousednosti, m = počet hran, k_i = stupeň vrcholu i , c_i = komunita i , δ = Kroneckerovo delta (sčítá se tedy jen přes dvojice *uvnitř* komunit). $k_i k_j / 2m$ je *očekávaný* počet hran mezi i a j v náhodné síti se stejnými stupni. Síť má smysluplnou komunitní strukturu, je-li hran uvnitř komunit *víc*, než by odpovídalo náhodě. Maximalizuje ji *Louvainova metoda* (hladově, $O(n \log n)$) a její upřesnění *Leiden*.

► Poměrový a normalizovaný řez

$$\text{RatioCut}(\pi) = \frac{1}{k} \sum_{i=1}^k \frac{\text{cut}(C_i, \bar{C}_i)}{|C_i|}, \quad \text{NCut}(\pi) = \frac{1}{k} \sum_{i=1}^k \frac{\text{cut}(C_i, \bar{C}_i)}{\text{vol}(C_i)}$$

$\pi = \{C_1, \dots, C_k\}$ je *rozdělení* na komunity (nikoli Ludolfovo číslo), $\text{cut}(A, B) = \sum_{i \in A, j \in B} a_{ij}$, $|C_i|$ = počet uzlů, $\text{vol}(C_i)$ = součet stupňů v C_i . Prostý minimální řez vrací nevyvážená rozdělení (často singleton) — **obě míry proto normalizují velikost komunity a preferují vyvážené řezy**. S balančním omezením a obecnými vahami je úloha **NP-těžká**; řeší se spektrálně.

6.17 Predikce vazeb

► Sousedské míry predikce vazeb

$$\text{CN}(i, j) = |S_i \cap S_j|, \quad \text{Jaccard} = \frac{|S_i \cap S_j|}{|S_i \cup S_j|}, \quad \text{AA}(i, j) = \sum_{k \in S_i \cap S_j} \frac{1}{\log |S_k|}$$

S_i = sousedé uzlu i . Každá míra opravuje slabinu předchozí: *společní sousedé* nezohledňují stupně (dvě celebrity mají mnoho společných sousedů náhodou); *Jaccard* normalizuje vůči stupňům *koncových* uzlů, ne však prostředních; *Adamic-Adar* snižuje váhu společného souseda s jeho stupněm — populární soused je společný mnoha párům, a je tedy méně informativní.

► Katzova míra

$$\text{Katz}(i, j) = \sum_{t=1}^{\infty} \beta^t W_{ij}^{(t)}, \quad K = \sum_{t=1}^{\infty} \beta^t A^t = (I - \beta A)^{-1} - I$$

$W_{ij}^{(t)}$ = počet procházek délky t mezi i a j , $\beta < 1$ = *diskontní faktor* potlačující dlouhé procházky (nutný pro konvergenci geometrické řady). Měří *nepřímou* propojenost, a pomáhá proto ve **velmi řídkých** sítích, kde je společných sousedů málo a sousedské míry nerozlišují. A je matice sousednosti, I jednotková matice a K matice Katzových koeficientů. Součet Katzových koeficientů uzlu vůči ostatním je jeho *Katzova centralita*.

Na co si dát pozor u vzorců

- **Konvence pořadí:** u turnajové selekce značí $i = 1$ nejlepšího, u lineární pořadové selekce nejhoršího. Zkoušející se na to rád zeptá.
- **Směr optimalizace:** entropie $H(A)$ a Gini se *minimalizují*, informační zisk, χ^2 , MI a Φ se *maximalizují*.
- **Off-policy vs. on-policy:** jediný rozdíl mezi Q-learningem a SARSA je $\max_{a'} Q(s', a')$ vs. $Q(s', a')$.
- **Harmonický vs. aritmetický průměr:** F_1 je harmonický, a proto je blízko té *menší* z obou měř.
- **Kde je normalizace nutná:** HITS, vlastní centralita a PageRank bez ní nekonvergují; míry vzdálenosti bez normalizace atributů měří jen ten s největším rozsahem.
- **Nerovnost ve větě o schématech** je „ $\geq$ “, ne rovnost — schéma může být křížením i *obnovením*.