

# Shrnutí ke zkoušce

Opakovací výtah ze všech tří okruhů

SZZ Umělá inteligence, MFF UK

září 2026

Generovaný dokument: pouze oddíly „Shrnutí ke zkoušce“ z učebních textů 01-multiagentni-systemy, 02-prirodou-inspirovane-pocitani a 03-dobyvani-znalosti, beze změny obsahu. Číslování kapitol odpovídá zdrojovým textům (= položkám okruhu). Odkazy na oddíly zdrojových textů jsou vypuštěny. Znovu vygenerovat: `python zkouseni/gen-07-shrnuti.py` a `2x pdflatex`.

## Obsah

|            |                                                                                                |          |
|------------|------------------------------------------------------------------------------------------------|----------|
| <b>I</b>   | <b>Multiagentní systémy</b>                                                                    | <b>2</b> |
| 1          | Architektura autonomního agenta a mechanismus výběru akcí                                      | 2        |
| 2          | Metody pro řízení agentů: symbolické a konekcionistické reaktivní plánování, hybridní přístupy | 2        |
| 3          | Problém hledání cesty                                                                          | 3        |
| 4          | Komunikace a znalosti v MAS: ontologie, řečové akty, FIPA-ACL, protokoly                       | 3        |
| 5          | Distribuované řešení problémů, kooperace, teorie her a aukce                                   | 3        |
| 6          | Metody pro učení agentů a zpětnovazební učení                                                  | 4        |
| 7          | Metodologie návrhu, jazyky a prostředí MAS                                                     | 5        |
| <b>II</b>  | <b>Přírodou inspirované počítání</b>                                                           | <b>5</b> |
| 1          | Genetické algoritmy, genetické a evoluční programování                                         | 5        |
| 2          | Teorie schémat a pravděpodobnostní modely SGA                                                  | 6        |
| 3          | Evoluční strategie, diferenciální evoluce, koevoluce, otevřená evoluce                         | 6        |
| 4          | Rojové optimalizační algoritmy                                                                 | 7        |
| 5          | Lokální prohledávání a memetické algoritmy                                                     | 8        |
| 6          | Aplikace evolučních algoritmů                                                                  | 8        |
| <b>III</b> | <b>Dobývání znalostí</b>                                                                       | <b>9</b> |
| 1          | Základní paradigmaty dobývání znalostí                                                         | 9        |

|   |                                                                  |    |
|---|------------------------------------------------------------------|----|
| 2 | Příprava dat, výběr atributů a analýza jejich relevance          | 9  |
| 3 | Metody pro dobývání znalostí                                     | 10 |
| 4 | Charakteristická a diskriminační pravidla a jejich zajímavost    | 12 |
| 5 | Reprezentace, vyhodnocování a vizualizace znalostí               | 12 |
| 6 | Modely pro analýzu sociálních sítí, centralita a detekce komunit | 13 |
| 7 | Praktické využití technik                                        | 15 |

# Multiagentní systémy

## 1 Architektura autonomního agenta a mechanismus výběru akcí

- Agent = autonomní systém zasazený do prostředí, vnímá a jedná, plní delegované cíle. MAS = interagující agenti *bez nutně sdíleného cíle*.
- Tři vlastnosti: reaktivita, proaktivita, sociálnost; těžké je vyvážení.
- Dennett: intencionální systém, tři postoje (fyzikální, návrhový, intencionální); intencionální postoj = abstrakce pro zvládnutí složitosti.
- Prostedí: 4 dichotomie (pozorovatelnost, statické/dynamické, determinismus, diskretnost); reálná prostředí v nejtěžší variantě.
- Formalismus:  $E, A$ , běh  $r = e_0 a_0 e_1 \dots e_n$ ,  $R^A/R^E$ ,  $\tau : R^A \rightarrow 2^E$  (historie + nedeterminismus),  $Env = \langle E, e_0, \tau \rangle$ ,  $Ag : R^E \rightarrow A$ , systém  $\langle Ag, Env \rangle$ .
- Funkční ekvivalence (vzhledem k prostředí / prostá). Čistě reaktivní  $Ag : E \rightarrow A$  (slabší); agent s vnitřním stavem (*see, next, action*) — oba převeditelné na standardního agenta.
- Utilita  $u : E \rightarrow \mathbb{R}$  vs.  $u : R \rightarrow \mathbb{R}$ ; optimální agent maximalizuje *očekávanou* utilitu — nekonstruktivní. Tileworld,  $u(r) = N_f/N_a$ .
- Prostedí úlohy  $\langle Env, \Psi \rangle$ ; pesimista/optimista/realista; úlohy dosažení ( $G$ ) a udržení ( $B$ ).
- **Mechanismus výběru akcí** = jádro otázky: vyjmenovat rodiny mechanismů a zástupce (tabulka výše).

## 2 Metody pro řízení agentů: symbolické a konekcionistické reaktivní plánování, hybridní přístupy

- **Deduktivní agent**:  $DB \in 2^L$ ,  $DB \vdash_\rho Do(a)$ ; dvoufázový výběr akce (dokazatelná akce  $\rightarrow$  konzistentní akce  $\rightarrow$  nic). Elegantní, nepraktický; problém transdukce a vypočitatelné racionality.
- **BDI**: dvě fáze — deliberace (*brf, options, filter*) a means-ends reasoning (plánování). Beliefs subjektivní a omylné, desires mohou být nekonzistentní, intentions = závazky: přetrvávají, omezují další deliberaci.
- **STRIPS**: deskriptor akce  $\langle P_a, D_a, A_a \rangle$ , plánovací problém  $\langle B_0, O, G \rangle$ ,  $B_i = (B_{i-1} \setminus D_{a_i}) \cup A_{a_i}$ ; plán *přípustný* ( $B_{i-1} \models P_{a_i}$ ) vs. *korektní* (navíc  $B_n \models G$ ). Umět projít svět kostek.
- **BDI smyčka** a role *reconsider* a *sound*.
- **Commitment**: blind / single-minded / open-minded; bold vs. cautious agent; efektivita = dosažené/všechny záměry; pomalé prostředí  $\rightarrow$  bold, rychlé  $\rightarrow$  cautious.
- **PRS**: první implementace BDI; plán = Goal + Context + Body; knihovna plánů místo plánování; zásobník záměrů; deliberace metaplány nebo utilitou; potomci AgentSpeak/Jason, JAM, JACK, Jadex.
- Reaktivní přístup: trojice *situatedness* — *embodiment* — *emergence*; odmítá symbolickou reprezentaci.
- **Subsumpce** (Brooks) = *symbolické* reaktivní plánování: jednoduchá chování *situace*  $\rightarrow$  *akce*, paralelní, pevná priorita. Umět Steelsova průzkumníka Marsu a roli stigmergie (drobky).
- **Agent network architecture** (Maes) = *konekcionistické* reaktivní plánování: moduly s předpoklady a efekty (add, delete); aktivace se šíří následnickými, předchůdcovskými a konfliktními spoji; zdroje: stav světa, cíle, inhibice od chráněných cílů; vybere se proveditelný modul s nejvyšší aktivací nad prahem.  $\gamma/\phi$  ladí proaktivitu vs. reaktivitu.
- Omezení reaktivních agentů: bez modelu světa, krátkodobý pohled, neinženýrský návrh, neškálovatelné množství vrstev.
- **Hybridní**: horizontální (paralelní vrstvy + mediátor,  $m^n$  kombinací, úzké hrdlo) vs. vertikální (sériové, one-pass/two-pass,  $n - 1$  rozhraní, křehké).

- **TouringMachines** = horizontální 3 vrstvy (modelling, planning, reactive) + řídicí pravidla. **InterRaP** = vertikální two-pass 3 vrstvy (kooperativní plánování, lokální plánování, behaviorální) + vlastní KB na vrstvu. **Stanley** = reálné nasazení.
- **IDA** (Franklin) + *global workspace theory* (Baars): mysl jako MAS jednoduchých nevědomých procesů komunikujících přes blackboard; koalice soutěží o vstup do „vědomí“, vítězná se vykoná; hierarchie kontextů. Nejsložitější architektura, mnoho ad hoc rozhodnutí.
- Čtyři typy arbitráže mezi chováními: **pevná priorita** (subsumpce), **úroveň aktivace** (Maes), **mediační funkce** (vrstvené), **soutěž koalic** (IDA).

### 3 Problém hledání cesty

- $A^*$ :  $f = g + h$ ; *přípustnost*  $h \leq h^* \Rightarrow$  optimalita; *konzistence*  $h(n) \leq w(n, m) + h(m) \Rightarrow$  každý vrchol se expanduje jednou.  $h \equiv 0$  dá Dijkstru; weighted  $A^*$  je  $\varepsilon$ -suboptimální.
- Dynamické prostředí:  $LPA^*$  (hodnoty  $g$  a  $rhs$ , lokální konzistence  $g = rhs$ ),  $D^*$  Lite (prohledávání od cíle, inkrementální oprava), *freespace assumption*.
- MAPF: vrcholové a hranové (swap) konflikty, sum-of-costs vs. makespan; optimální MAPF je NP-těžký.
- Prioritizované plánování / Cooperative  $A^*$  s rezervační tabulkou — rychlé, ale neúplné. **CBS** — nízká úroveň  $A^*$  s omezeními, vysoká úroveň větvení stromu omezení podle konfliktu; optimální a úplný.

### 4 Komunikace a znalosti v MAS: ontologie, řečové akty, FIPA-ACL, protokoly

- Ontologie = explicitní formalizovaný popis části reality (glosář + thesaurus); Gruberova definice. Formalismus: třídy, instance, vlastnosti, relace (tranzitivní *is-a*), fakta. Ontologie + fakta = znalostní báze.
- Škála formalizace od slovníku po libovolná logická omezení; aplikační / doménové / horní ontologie.
- RDF = trojice *subjekt-predikát-objekt*, jednoduché a rychlé; RDFS přidává třídy.
- OWL = deskripční logika (rozhodnutelný fragment FOL), *open world assumption*, T-Box vs. A-Box; profily Lite/DL/Full (*SHIF*, *SHOIN*), OWL 2 = *SRIOQ* + profily EL/QL/RL.
- KIF = FOL v LISPovské syntaxi, obsah zprávy; KQML = obálka.
- Epistemická logika:  $K_i\varphi$  + možné světy; znalost = S5 (axiom T), přesvědčení = KD45. Společná znalost  $C_G\varphi$  nevznikne nespolehlivou komunikací (koordinovaný útok).
- Komunikace agentů = *akce*, ne volání metody — příjemce není povinen vyhovět.
- Austin: řečové akty; lokuce / ilokuce / perlokuce. Searle: podmínky zdařilosti, pět kategorií (asertiva, direktiva, komisiva, expresiva, deklarace); performativní sloveso + propoziční obsah.
- Cohen & Perrault: sémantika řečových aktů ve stylu STRIPS (pre / efekt) s modálními operátory; umět Request(S,H,A) a Inform(S,H, $\varphi$ ) — efekt Inform =  $H$  věří, že  $S$  věří  $\varphi$ .
- KQML (obálka) + KIF (obsah); parametry a performativa; kritika (chybí commit, nejasná sémantika).
- FIPA-ACL: struktura zprávy (performative, sender/receiver, content, language, ontology, protocol, conversation-id, reply-by), 22 performativ, sémantika FP a RE v jazyce SL; neverifikovatelnost.
- Protokoly: FIPA-Request, FIPA-Query, Contract Net (+ iterovaný), Subscribe, Brokering, aukční protokoly.

### 5 Distribuované řešení problémů, kooperace, teorie her a aukce

- Koherence (výkon celku) vs. koordinace (minimalizace synchronizační režie).

- CDPS: benevolence + sdílený cíl; odlišit od PPS (homogenní procesory, paralelní algoritmus) a od MAS (vlastní cíle, konflikty, vyjednávání).
- Tři fáze CDPS: dekompozice — řešení podproblémů — syntéza. Sdílení úloh (dohoda) vs. sdílení výsledků (proaktivní/reaktivní), čtyři přínosy: jistota, úplnost, přesnost, včasnost.
- **CNET**: recognition — announcement — bidding — awarding/expediting; manažer a dodavatel, hierarchické subkontrakty; standardizován jako FIPA-Contract-Net.
- **BBS**: tabule (hierarchie abstrakce, mutex), experti (skills), arbitr (výběr experta); volná vazba mezi experty; úzké hrdlo přístupu k tabuli.
- DisCSP / DCOP: proměnné a omezení rozdělené mezi agenty, nikdo nevidí celý problém; ABT (ok? / nogood); DCOP maximalizuje sociální blahobyt.
- Sobecký agent maximalizuje *svoji* očekávanou utilitu za předpokladu, že ostatní dělají totéž; společná utilita se tím nemaximalizuje.
- Hra v normální formě, ryzí vs. smíšené strategie, dominance a dominantní strategie, iterované odstraňování dominovaných strategií.
- **Nashovo ekvilibrium** = vzájemně nejlepší odpovědi, nikdo nemá důvod se jednostranně odchýlit; naivní hledání  $m^n$ ; **Nashova věta** (existence ve smíšených strategiích); hledání PPAD-úplné.
- **Pareto optimalita** (nelze zlepšit jednomu bez přitížení jinému) vs. **sociální blahobyt** (součet utilit); maximum sw je Pareto-optimální, obráceně ne.
- **Věžňovo dilemma**:  $T > R > P > S$ ;  $D$  dominantní;  $(D, D)$  jediné NE a jediné ne-Pareto-optimální;  $(C, C)$  maximalizuje sw. Tragedy of the commons. Iterované PD, stín budoucnosti, Axelrod a TFT (slušná, odvetná, odpouštějící, nezávistivá, srozumitelná).
- Umět spočítat smíšené NE pro  $2 \times 2$ : pravděpodobnosti volím tak, aby byl *protihráč* indiferentní.
- Sociální volba: plurality / IRV / sekvenční / Borda / Slater; Condorcetův paradox (cyklická kolektivní preference); kritéria Pareto, Condorcetův vítěz, IIA, univerzalita, nediktátorství; **Arrowova věta** (Pareto + IIA  $\Rightarrow$  diktatura); Gibbard–Satterthwaite (každý systém lze manipulovat).
- Aukce = mechanismus alokace vzácných zdrojů; efektivní aukce dá zdroj tomu, kdo ho oceňuje nejvíc. Dimenze: private/common value, open cry/sealed bid, first/second price, počet kol.
- Čtyři základní typy a strategie: anglická (přihazuj po  $\varepsilon$  do svého ocenění) a Vickrey (nabídní pravdivě) mají *dominantní* strategii; holandská (čekej na ocenění  $-\varepsilon$ ) a FPSB (nabídní pod oceněním) *dominantní* strategii **nemají**. Umět **důkaz pravdomluvnosti** Vickreyho.
- Ekvivalence: anglická  $\leftrightarrow$  Vickreyova, holandská  $\leftrightarrow$  FPSB. **Věta o ekvivalenci výnosů** a kdy neplatí (averze k riziku, common values, prokletí vítěze, koluze). Umět příklad s oceněními 80/60/30.
- Návrh mechanismů (obrácená teorie her), princip odhalení; kombinatorické aukce a WDP (NP-těžký); **VCG** = alokace maximalizující sw + platba rovná externalitě.
- Vyjednávání: monotónní protokol ústupků + Zeuthenova strategie (ustupuje ten s nižším rizikem).

## 6 Metody pro učení agentů a zpětnovazební učení

- Metody učení agentů: s učitelem / bez učitele / zpětnovazební; imitační učení a inverzní RL; evoluční metody (LCS, neuroevoluce); co se agent učí (model prostředí, model protivníka, politiku); individuální vs. sociální učení. RL je nejběžnější.
- **MDP** =  $\langle S, A, T, R, \gamma \rangle$ , Markovská vlastnost, politika  $\pi$ , hodnotové funkce  $V^\pi$ ,  $Q^\pi$ ; Bellmanova rovnice optimality; value iteration (kontrakce, konverguje) a policy iteration.
- **Q-learning**:  $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$ , off-policy, tabulkový; umět spočítat jeden krok s čísly.
- **SARSA**:  $\dots + \alpha[r + \gamma Q(s', a') - Q(s, a)]$ , on-policy, opatrnější (cliff walking).  $\varepsilon$ -greedy jako řešení dilematu průzkum/využití.
- **Policy gradient** (REINFORCE,  $\nabla \ln \pi$  krát výnos) a **actor-critic** (herec = politika, kritik = hodnotová funkce, výhoda  $A = Q - V$ ); DQN (replay buffer, target network).
- **Markovská hra** = MDP pro  $N$  agentů se sdruženým akčním prostorem a individuálními odměnami; nejlepší odpověď, Nashovo ekvilibrium, Pareto-optimalita. **Minimax-Q** (nulový součet, LP v každé aktualizaci), Nash-Q (obecný součet).
- Problémy MARL: nestacionarita, exponenciální sdružený akční prostor, částečná pozorovatelnost,

přiřazení zásluh; řešení CTDE. Self-play a AlphaZero.

## 7 Metodologie návrhu, jazyky a prostředí MAS

- Proč nestačí OO metodologie: autonomie, vlastní cíle, organizační (nikoli strukturální) vztahy.
- **Gaia**: organizace + role; analýza = model rolí (permissions, responsibilities s liveness a safety, activities, protocols) + model interakcí; návrh = model agentů, služeb a znalostí. Předpoklad kooperativních agentů a statické organizace.
- **FIPA platforma**: AMS (bílé stránky, AID, životní cyklus: initiated, active, waiting, suspended, transit), DF (žluté stránky, služby), MTS/ACC (doručování ACL zpráv).
- **JADE** = Java, FIPA, Agent + Behaviour + ACLMessage, hotové protokoly a ladicí nástroje. **Jason/AgentSpeak** = BDI jazyk, plán spouštěč : kontext <- tělo, potomek PRS. **NetLogo** = ABM simulace (turtles/patches/links). **SPADE** = Python + XMPP.
- **Jason prakticky**: testovací cíl ?g, aktualizace +b; not (negace jako neúspěch) vs. ~ (silná negace); anotace [source(...)]; .send s performativy tell/achieve = řečové akty; prostředí v Javě (executeAction, addPercept), projekt .mas2j; přizpůsobení přes selekční funkce cyklu, AgArch a vlastní interní akce.

## Část II

# Přírodou inspirované počítání

## 1 Genetické algoritmy, genetické a evoluční programování

- EA = populační stochastické prohledávání; cyklus *inicializace* → *ohodnocení* → *rodičovská selekce* → *rekombinace* → *mutace* → *ohodnocení* → *environmentální selekce*.
- Variace (křížení, mutace) tvoří diverzitu, selekce ji odebírá a směřuje hledání; návrh EA = hledání rovnováhy explorační/exploatační.
- Selekce: **ruleta** ( $p_i = f_i / \sum f_j$ , vysoký rozptyl, citlivá na škálování), **SUS** (stejně střední hodnoty, nízký rozptyl), **turnaj** (tlak řízen  $k$ , invariantní k transformacím fitness, nepotřebuje explicitní fitness), **pořadová** (konstantní tlak), **Boltzmannova** (tlak roste s časem).
- Elitismus zaručuje monotonii nejlepší fitness; generační vs. steady-state model se liší podílem nahrazované populace.
- No Free Lunch: neexistuje univerzálně nejlepší algoritmus ⇒ doménová specializace reprezentace a operátorů.
- Historické větve GA / ES / EP / GP a jejich charakteristické volby (viz srovnávací tabulka) je dobré umět vyjmenovat z paměti.
- SGA = binární řetězce + ruleta + 1-bodové křížení + bit-flip mutace + generační náhrada. Parametry:  $n$ ,  $p_C \approx 0,7$ ,  $p_M \approx 1/m$ .
- Binární kódování reálných čísel:  $x = a + z(b - a)/(2^k - 1)$ ; problém Hammingových útesů řeší Grayův kód.
- Křížení: 1-bodové (rozbití schématu s pravděpodobností  $d(S)/(m-1)$ ), 2-bodové (bez okrajového biasu), uniformní (nejvíce disruptivní, bez pozičního biasu).
- Mutace je v GA sekundární — brání nevratné ztrátě alel; inverze je historický operátor pro evoluci uspořádání genů.
- Škálování fitness (lineární, sigma truncation, mocninné, pořadové, Boltzmannovo) opravuje slabiny fitness-proporcionální selekce: dominanci supermanů na začátku a ztrátu tlaku na konci.
- Reprezentace + operátory = fitness krajina. Pro nominální atributy jen nezaujaté mutace, pro ordinální i zaujaté (creep).
- Reálná reprezentace: gaussovská mutace  $x' = x + \sigma N(0, 1)$ ; aritmetické křížení  $\alpha \vec{x} + (1 - \alpha) \vec{y}$  (zmenšuje rozptyl), proto BLX- $\alpha$  a SBX.

- Permutace: PMX (pozice + mapování), OX (relativní pořadí), CX (absolutní pozice pomocí cyklů), ER (hrany, nejlepší pro TSP). Umět předvést PMX a OX na konkrétním osmiprvkovém příkladu!
- Mutace permutací: swap, insert, inverze (2-opt), scramble.
- Stromové GP (Koza): terminály + neterminály, uzavřenost a dostatečnost; inicializace grow / full / ramped half-and-half; křížení = výměna podstromů (neterminály s vyšší pravděpodobností), více typů mutací včetně mutace konstant; fitness = spuštění programu.
- Bloat = růst velikosti bez zlepšení fitness (introny); tři vysvětlení: replication accuracy, removal bias, crossover bias. Obrana: limity velikosti, penalizace (parsimony pressure), anti-bloat operátory (hoist, shrink, size-fair), vícekritériální přístup.
- ADF = evolvované podprogramy (modularita); operátory pracují na větvích odděleně. Typované GP a gramatické GP omezují prostor na smysluplné programy.
- Varianty: lineární GP (byte kód, Tierra), grafové GP, Cartesian GP (lineární genotyp  $\rightarrow$  2D DAG, bodová mutace, (1 + 4)-ES), vývojové GP (strom staví graf — obvody, sítě).
- Gramatická evoluce: lineární genom celých čísel, výběr pravidla gramatiky pomocí modula, derivační strom  $\rightarrow$  fenotyp; robustní kódování, standardní operátory GA, ale nelokální mapování.
- EP: konečné automaty, genotyp = fenotyp, jen mutace, turnajová selekce z rodičů i potomků; příklad predikce prvočísel (degenerace fitness).
- Headless chicken experiment: test, zda křížení skutečně kombinuje stavební bloky, nebo je jen makromutací.

## 2 Teorie schémat a pravděpodobnostní modely SGA

- Schéma = slovo nad  $\{0, 1, *\}$ ;  $o(S)$  = počet pevných pozic;  $d(S)$  = vzdálenost první a poslední pevné pozice;  $F(S)$  = průměrná fitness reprezentantů v dané populaci. Celkem  $3^m$  schémat, jedinec je reprezentantem  $2^m$  z nich.
- TST:  $\mathbb{E}[C(S, t + 1)] \geq C(S, t) \frac{F(S)}{f} [1 - p_C \frac{d(S)}{m-1} - p_M o(S)]$ ; odvození ve třech krocích (selekce  $\rightarrow$  exponenciální růst, křížení  $\rightarrow d(S)/(m-1)$ , mutace  $\rightarrow (1 - p_M)^{o(S)}$ ).
- BBH: GA skládá krátká, nízkého řádu, nadprůměrná schémata (stavební bloky). Důsledky: záleží na kódování, na velikosti populace, škodí předčasná konvergence.
- Implicitní paralelismus ( $\sim n^3$  užitečně zpracovaných schémat), analogie s  $k$ -rukým banditou (exponenciální alokace pokusů vítězi).
- Kritika: nerovnost pro jeden krok, konečné populace, deceptivní úlohy, kolaterální konvergence, velký rozptyl fitness, ignorování konstruktivních efektů, závislost schémat.
- Voseho model: řetězce ztotožníme s čísly  $0..2^l - 1$ ; populaci popisuje vektor relativních četností  $p(t)$  v simplexu a vektor selekčních pravděpodobností  $s(t)$ .
- Hledáme  $\mathcal{G} = \mathcal{M} \circ \mathcal{F}$  s  $p(t + 1) = \mathcal{G}(p(t))$ .  $\mathcal{F}$  (selekce) je dána diagonální maticí fitness:  $s = \mathbf{F}p / \sum_j \mathbf{F}_{jj}p_j$ ;  $\mathcal{M}$  (křížení + mutace) je kvadratický operátor  $\mathbb{E}[p'_k] = \sum_{i,j} s_i s_j r(i, j, k)$ . Díky symetrii  $r(i, j, k) = r(i \oplus k, j \oplus k, 0)$  stačí jediná míchací matice.
- Pevné body:  $\mathcal{F}$  — populace kopií nejlepšího jedince;  $\mathcal{M}$  — rovnoměrné rozdělení. Kombinace vede k přerušovaným rovnováhám. Pevné body  $\mathcal{G}$  nejsou známy.
- Konečné populace: Markovův řetězec se stavy = populace,  $N = \binom{n+2^l-1}{2^l-1}$  stavů, matice  $\mathbf{Q}$  je exaktní, ale astronomicky velká. Ireducibilita při  $p_M > 0$ ; elitistický GA konverguje k optimu s pravděpodobností 1.
- Nekonečné populace = deterministický model (exaktní, nepraktický), konečné = stochastický (realistický, nezvládnutelný). Limitní přechod je spojuje.

## 3 Evoluční strategie, diferenciální evoluce, koevoluce, otevřená evoluce

- ES: reálné vektory, mutace hlavní operátor, náhodná rodičovská selekce, deterministická environmentální selekce; jedinec =  $[\vec{x}, \vec{\sigma}]$ .

- $(\mu, \lambda)$  vs.  $(\mu + \lambda)$ : umět vyjmenovat rozdíly (elitismus, konvergence, lokální optima, samoadaptace).
- $(1 + 1)$ -ES a pravidlo  $1/5$ :  $p > 1/5 \Rightarrow$  zvětši  $\sigma$ ,  $p < 1/5 \Rightarrow$  zmenši; jde o adaptivní, nikoli samoadaptivní řízení.
- Samoadaptace:  $\sigma' = \sigma \exp(\tau' N(0, 1) + \tau N_i(0, 1))$ , poté  $x' = x + \sigma' N(0, 1)$ ; **nejdřív  $\sigma$ , pak  $x$** . Počet strategických parametrů: 1 (izotropní),  $n$  (nekorelované),  $n(n + 1)/2$  (korelované, s úhly natočení).
- Rekombinace: lokální ( $\rho = 2$ ) / globální ( $\rho = \mu$ ), diskrétní (dominantní) / intermediární (aritmická).
- CMA-ES:  $\theta = (\vec{m}, \sigma, \mathbf{C}, \vec{p}_\sigma, \vec{p}_c)$ , vzorkování  $\mathcal{N}(\vec{m}, \sigma^2 \mathbf{C})$ , evoluční cesty, rank-1 a rank- $\mu$  update, řízení kroku podle délky  $\vec{p}_\sigma$ ; invariantní vůči monotónním transformacím fitness a lineárním transformacím prostoru.
- DE/rand/1/bin: dárce  $\vec{v} = \vec{x}_a + F(\vec{x}_b - \vec{x}_c)$ ; binomické křížení s prahem  $C$  a pojistkou  $j = I_{\text{rand}}$ ; souboj potomka s vlastním rodičem (nahrazení jen při zlepšení).
- Parametry:  $F \in [0, 2]$  (typ. 0,5–0,9),  $C \in [0, 1]$ ,  $N \approx 10D$ .
- Geometrická podstata: měřítko a orientace kroků se přebírají z aktuálního rozptylu populace  $\Rightarrow$  automatická adaptace bez strategických parametrů.
- Varianty: rand/1, rand/2, best/1, best/2, current-to-best; **bin** vs. **exp** křížení.
- Umět předvést jeden krok s konkrétními čísly (mutace  $\rightarrow$  křížení  $\rightarrow$  selekce).
- Koevoluce = kontextová fitness + dynamická krajina. *Kompetitivní*: predátor–kořist, host–parazit, Hillisovy řadičské sítě. *Kooperativní*: dekompozice na komponenty, CCGA, moduly + blueprints.
- Patologie: cyklení (intransitivita), odpojení, efekt Červené královny, průměrné stabilní stavy, přespecializace, zapomínání. Léky: archivy (hall of fame), sdílená fitness, měření proti pevné sadě.
- Věžňovo dilema:  $T > R > P > S$ ,  $2R > T + S$ ;  $D$  dominantní,  $DD$  Nashovo ekvilibrium a jediné Pareto-neoptimální; iterovaná verze  $\Rightarrow$  TFT; čtyři vlastnosti úspěšné strategie (slušnost, dráždivost, odpouštění, nezávistivost) + srozumitelnost jako pátá; Pavlov v zašuměném prostředí.
- Diverzita: fitness sharing, crowding, speciace, ostrovní model, nenáhodné páření.
- Dynamická fitness: diploidie, hypermutace, náhodná migrace, udržování diverzity,  $(\mu, \lambda)$ -ES.
- Otevřená evoluce: bez pevného cíle; znaky = trvalá novost, neomezený růst složitosti, nové třídy entit, evoluce evolvability. Systémy Tierra, Avida, Polyworld, ECHO — všechny se dříve či později zaseknou. Generativní (nepřímé) reprezentace: L-systémy, celulární automaty, buněčné kódování, CPPN.
- Novelty search měří řídkost  $\rho(x)$  v prostoru chování vůči populaci a permanentnímu archivu, účelovou funkci vůbec nepoužívá; navazuje quality-diversity a MAP-Elites (mřížka deskriptorů chování).
- Interaktivní evoluce: fitness = člověk (Biomorphs, Picbreeder, EndlessForms); omezením je malá populace a únava uživatele.

## 4 Rojové optimalizační algoritmy

- PSO: rovnice  $\vec{v} \leftarrow w\vec{v} + c_1 r_1 (\vec{p} - \vec{x}) + c_2 r_2 (\vec{g} - \vec{x})$ ,  $\vec{x} \leftarrow \vec{x} + \vec{v}$ ; setrvačnost  $w$  (klesá  $0,9 \rightarrow 0,4$ ), kognitivní a sociální složka,  $c_1 = c_2 = 2$ ; omezení  $v_{\text{max}}$  nebo constriction  $\chi \approx 0,729$ ; topologie gbest vs. lbest (kruh, mřížka).
- Rozdíl PSO vs. GA: žádné operátory, částice mají paměť ( $\vec{p}_i, \vec{g}$ ), informace teče jednosměrně od lepších.
- ACO: pravděpodobnost přechodu  $p_{ij} \propto \tau_{ij}^\alpha \eta_{ij}^\beta$  s  $\eta = 1/d$ ; aktualizace  $\tau \leftarrow (1 - \rho)\tau + \sum_k Q/L_k$  (odpařování + uložení úměrné kvalitě).
- AS (původní, všichni aktualizují) vs. ACS (globální update jen nejlepším, lokální update při průchodu, pseudonáhodné pravidlo  $q_0$ ) vs. MAX-MIN (meze feromonu). Akce démona = lokální prohledávání.
- ABC (dělnice / pozorovatelky / průzkumnice s limitem = restart), firefly (přitažlivost klesá exponenciálně se vzdáleností).

- Klíčová slova: stigmergie, emergence, decentralizace, kladná zpětná vazba + odpařování, vhodnost pro dynamické prostředí.

## 5 Lokální prohledávání a memetické algoritmy

- Hill climbing: steepest ascent / first improvement / stochastic / s náhodnými restarty; problémy: lokální optima, plošiny, hřebeny.
- SA: Metropolisovo kritérium  $P = \min(1, e^{-\Delta/T})$ ; rozvrh chlazení (geometrický v praxi, logaritmický pro důkaz konvergence); pro pevné  $T$  konverguje k Boltzmannovu rozdělení  $\propto e^{-f/T}$ .
- Tabu search: tabu list tahů, tenure, aspirační kritérium, střednědobá a dlouhodobá (frekvenční) paměť; vždy se jde do nejlepšího nezakázaného souseda, i když je horší.
- Scatter search: referenční množina kombinující kvalitu a diverzitu, aritmetické kombinace + vylepšení.
- Memetický algoritmus = EA + lokální prohledávání nad jedinci; **lamarckismus** (mění genotyp, rychlejší) vs. **baldwinismus** (mění jen fitness, zachovává diverzitu). Memetic computing: memy v genomu nebo v koevolvující populaci.
- Ladění vs. řízení parametrů; pevné / adaptivní / samoadaptivní strategie.

## 6 Aplikace evolučních algoritmů

- **Michigan**: jedinec = jedno pravidlo, řešením je celá populace, nutné rozdělení odměny (credit assignment). **Pittsburgh**: jedinec = celá sada pravidel, fitness přímočará, operátory složité (GIL).
- Hollandův LCS: podmínky nad  $\{0, 1, *\}$ , vnitřní zprávy a receptory, bucket brigade (pravidlo platí předchůdci za právo jednat).
- ZCS: bez zpráv; match set  $M \rightarrow$  ruletový výběr akce  $\rightarrow$  action set  $A$ ; posílení  $A$  a  $A_{-1}$ , daň pro  $M \setminus A$ ; cover operátor.
- XCS: klasifikátor  $(c, a, p, \epsilon, F)$ , **fitness podle přesnosti predikce**  $\kappa = \alpha(\epsilon/\epsilon_0)^{-\nu}$ , aktualizace Q-learningem, nikový GA v action setu; evoluuje úplnou a minimální mapu vstup-výstup. Varianty: UCS (učení s učitelem), XCSF (aproximace funkcí).
- Umět vysvětlit, proč přesnost jako fitness řeší nedostatky „strength-based“ systémů.
- Co se evoluuje: váhy / topologie / obojí / hyperparametry učení. Výhody EA: bez gradientu, rekurentní sítě, RL, paralelizace.
- Problém konkurujících konvencí (permutační problém) — křížení sítí je bez opatření destruktivní.
- Kódování architektury: přímé (matice), gramatické (Kitano), buněčné (Gruau, GP program pro růst sítě); GNARL = EP nad grafy, strukturální i parametrické mutace řízené teplotou.
- NEAT: seznam hran s **inovačními čísly** (křížení jen shodných genů), **speciace** podle podobnosti genomů se sdílenou fitness (ochrana nových topologií), **complexification** od minimální sítě.
- HyperNEAT: substrát  $S : \mathbb{R}^4 \rightarrow \mathbb{R}$  generující váhy z souřadnic neuronů, reprezentovaný CPPN (DAG s různými aktivačními funkcemi) evolvovaným pomocí NEAT; zachycuje symetrie a regularity.
- NAS: prostor (lineární / DAG buněk / super síť), strategie (EA, RL, bayesovská, gradientní), odhad výkonu (sdílení vah — ENAS); DeepNEAT a CoDeepNEAT (moduly + blueprints); ES pro deep RL.
- Batoh: bitová mapa, triviální operátory, problém s omezením kapacity. Tři strategie pro omezení: **penalizace** (volba váhy  $\alpha$ ), **oprava** (lamarckovsky/baldwinovsky), **dekodér** („přidej, pokud se vejde“ — každý genotyp je přípustný); čtvrtá možnost = vícekritériální formulace.
- TSP: fitness triviální, problém je kódování. Sousednostní a ordinální reprezentace nepoužívat; permutační + PMX/OX/CX/ER, případně maticová. Inicializace: nejbližší soused, vkládání hran. Mutace: inverze (2-opt).
- SAT: fitness = počet splněných klauzulí (samotné  $f$  nestačí), vážení klauzulí, zjemňující funkce; reprezentace bitová, reálná, klauzulová, cestová; WalkSAT jako lokální heuristika. U reálné reprezentace  $(x \mapsto (1-y)^2, \neg x \mapsto (1+y)^2, \text{minimalizace})$  pozor: hodnoty jsou *penalty*, takže disjunkce

(klauzule) je **součin** a konjunkce (formule) **součet**.

- Rozvrhování: přímé maticové kódování, tvrdá omezení řešit v operátorech, měkká ve fitness; job shop — permutace s dekodérem vs. přímé kódování.
- Obecné pravidlo: u kombinatorických úloh rozhoduje kódování a operátory respektující strukturu úlohy; hybridizace s lokální heuristikou (2-opt, WSAT) je téměř vždy výhodná.
- Dominance ( $x \prec y$ : ve všech kritériích ne horší a alespoň v jednom lepší), Pareto množina a Pareto fronta; dvojí cíl = konvergence + diverzita.
- Skalarizace: lineární (jednoduchá, ale nenajde nekonvexní části fronty),  $\varepsilon$ -constraint, Čebyševova.
- NSGA-II: nedominované třídění do front, crowding distance  $d_i = \sum_m (f_m(i+1) - f_m(i-1)) / (f_m^{\max} - f_m^{\min})$ , krajní body  $\infty$ ; crowded comparison (nižší fronta, při shodě větší crowding); elitismus spojením  $P_t \cup Q_t$ . Umět spočítat crowding distance na příkladu.
- SPEA2 (archiv, síla dominujících, hustota přes  $\sigma$ -tého souseda), MOEA/D (Čebyševova skalarizace, váhové vektory, sousedství), SMS-EMOA (příspěvek k hypervolume), NSGA-III (referenční body pro many-objective).
- Hypervolume: objem dominovaný frontou vůči referenčnímu bodu; jediná běžná metrika monotónní vůči dominanci a bez znalosti skutečné fronty. Dále GD, IGD, spread,  $\varepsilon$ -indikátor.

## Část III

# Dobývání znalostí

## 1 Základní paradigmaty dobývání znalostí

- **KDD** = netriviální proces získávání implicitních, dosud neznámých a potenciálně užitečných informací z dat; interaktivní a iterativní.
- **Pět fází KDD**: výběr  $\rightarrow$  předzpracování  $\rightarrow$  transformace  $\rightarrow$  dobývání  $\rightarrow$  interpretace. Příprava dat spotřebuje 60–80 % času.
- **Kořeny oboru**: umělá inteligence (strojové učení), databáze, statistika + potřeba podpory rozhodování. **OLAP** odpovídá na předem položené otázky, KDD hledá vzory, o nichž nevíme.
- **Tři typy úloh**: klasifikace/predikce (přesnost  $>$  jednoduchost), popis (srozumitelnost, plné pokrytí), hledání nugetů (překvapivost, nemusí pokrývat).
- **Deskriptivní vs. prediktivní úlohy**; **s učitelem vs. bez učitele** vs. **poloučené**.
- **Škály atributů**: nominální, ordinální, intervalová, poměrová — určují přípustné operace i metody. Nominální  $\rightarrow$  v binárních atributů; poměrový s exponenciálním chováním  $\rightarrow$  logaritmovat.
- **Metodologie**: SEMMA (Sample, Explore, Modify, Model, Assess), CRISP-DM (6 fází, pořadí není striktní, cyklické), ASUM-DM (CRISP-DM + projektové řízení).
- Nejčastější doplňující otázka: *proč pořadí fází CRISP-DM není striktní?* — protože výsledky fáze určují další kroky; např. zjištěná kvalita dat vede zpět k přeformulování cíle.

## 2 Příprava dat, výběr atributů a analýza jejich relevance

- **Cíl přípravy dat**: vybrat relevantní data, reprezentovat je pro zvolený algoritmus, výsledkem jedna tabulka objektů  $\times$  atributy.
- **Chybějící hodnoty**: ignorovat objekt / nová hodnota „nevím“ / existující hodnota (modus, poměrně, libovolně) / doplnit modelem. Umět říct, kdy je která volba vhodná (absence jako informace  $\rightarrow$  „nevím“).
- **Odlehle hodnoty**:  $IQR = Q_3 - Q_1$ , outlier mimo  $[Q_1 - 1,5 IQR, Q_3 + 1,5 IQR]$ . Umět spočítat kvartily z vzestupně seřazených dat (pravidlo  $n/4$  a  $3n/4$ , zaokrouhlení nahoru) a nakreslit box plot.
- **Standardizace**: desítkové škálování, min-max do  $[0, 1]$  a  $[-1, 1]$ , z-skóre podle střední absolutní odchylky (robustní k outlierům). Motivace: bez ní vzdálenost ovládne atribut s největším rozsahem.

hem.

- **Diskretizace:** ekvidistantní (stejná délka), ekvifrekvenční (stejný počet objektů), s využitím třídy (entropie shora dělením,  $\chi^2$  zdola slučováním); **fuzzy diskretizace** — procedura Interval, rozostřené hranice, jedné hodnotě dvě kategorie se součtem charakteristických funkcí 1, váha objektu  $\prod_j \mu_j$ . **KEX** seskupuje hodnoty kategoriálního atributu (Assign: kód třídy podle  $\chi^2$  testu proti apriornímu rozdělení tříd, jinak „?“; Group: hodnoty se stejným kódem).
- **Redukce dat:** příliš mnoho objektů  $\rightarrow$  vzorkování (reprezentativnost!), efektivní uložení, více modelů nad podmnožinami; nevyvážené třídy  $\rightarrow$  váhy chyb nebo různé pravděpodobnosti výběru. Příliš mnoho atributů  $\rightarrow$  *transformace* (PCA: méně nových atributů jako lineární kombinace, ale nutné znát všechny původní a chybí interpretace) vs. *selekce* (podmnožina původních, interpretace zůstává).
- **Filtry vs. wrappery:** filtr počítá charakteristiku pro každý atribut samostatně a je nezávislý na modelu (rychlý, ale nezachytí interakce); wrapper staví model nad podmnožinou a vyhodnocuje jej (drahý, zohledňuje interakce). Prohledávání *bottom-up* (přidávání) nebo *top-down* (odebírání).
- **Filtrační kritéria:**  $\chi^2$  (větší = lepší), entropie  $H(A)$  (menší = lepší),  $MI(A, C)$ ,  $ID(A, C) = MI/H(C)$  (větší = lepší). Umět zdůvodnit normalizaci ID: bez ní jsou zvýhodněny atributy s mnoha hodnotami.
- $\chi^2$  **test:**  $(R - 1)(S - 1)$  stupňů volnosti, podmínka  $r_{kSl}/n \geq 5$ ; pro malé četnosti **Fisherův exaktní test**. Umět projít výpočet na čtyřpolní tabulce (příklad s úvěrem:  $\chi^2 = 42,857 > 3,84 \Rightarrow$  závislost).
- **Regrese:** metoda nejmenších kvadrátů,  $\beta$  jako kovariance dělená rozptylem,  $\alpha = \bar{y} - \beta\bar{x}$ ; více-rozměrně  $\beta = (X^T X)^{-1} X^T Y$ .

### 3 Metody pro dobývání znalostí

#### Asociační pravidla.

- **Support** = podíl transakcí s  $i$  i  $j$ ; **confidence** = podíl transakcí s  $i$  i  $j$  mezi transakcemi s  $i$ ; **lift** =  $p(i \wedge j)/(p(i)p(j))$ .  $\text{Lift} < 1 \Rightarrow$  pravidlo horší než náhoda, negace závěru může být lepší. Umět spočítat všechny tři z malé tabulky transakcí.
- **Apriori** využívá *uzavřenost dolů* (každá podmnožina frekventované množiny je frekventovaná), prohledává *do šířky*; APRIORI-GEN = krok spojení (kombinace shodné v  $k - 2$  kategoriích) + krok prořezání (chybí-li podkombinace délky  $k - 1$ ). Prostor pravidel je  $O(2^m)$ , MBA produkuje *nadměrné množství pravidel*.
- **Taxonomie a virtuální položky** řeší volbu úrovně položek; vzácné položky výše v taxonomii, časté níže; virtuální položky nesou informaci o transakci (den, čas, zákazník) — pozor na redundanci pravidel.
- **MS-Apriori:** problém vzácných položek  $\rightarrow$  každá položka má vlastní MIS, minsup pravidla je *minimum* MIS jeho položek, plus omezení rozdílu supportů  $\varphi$ . *Uzavřenost dolů přestává platit*  $\Rightarrow$  položky se setřídí vzestupně podle MIS, používá se množina semen  $L$  (ne  $F_1$ ) a **tailCount** pro generování pravidel. Umět uvést protipříklad k uzavřenosti dolů.
- **CAR:** transakce označované třídou, pravidlo  $X \rightarrow y$ ; dolují se *přímo v jednom kroku* přes pravidlové položky (*condset*,  $y$ ); lze zadat různé minsupy různým třídám (101 % = zakázat třídu).
- **Sekvenční vzory:** sekvence = uspořádaný seznam množin položek; *velikost* = počet prvků, *délka* = počet položek; podsekvence přes vnořené inkluze. Algoritmus **GSP** pracuje obdobně jako Apriori. Pozor:  $\langle \{3\}\{8\} \rangle$  a  $\langle \{3, 8\} \rangle$  se navzájem *neobsahují*.
- **FP-Growth:** 2 průchody daty, žádné generování kandidátů; FP-strom sdílí *prefixy* (pořadí položek podle klesajícího supportu — heuristika), spojové seznamy položek; extrakce zdola nahoru *rozděl a panuj* přes *prefixové podstromy* a *podmíněné FP-stromy* (aktualizovat počítadla  $\rightarrow$  odstranit uzly položky  $\rightarrow$  odstranit nefrekventované položky). Nejhorší případ: unikátní transakce  $\Rightarrow$  strom větší než data.

#### Učení s učitelem.

- **Rozhodovací stromy:** TDIDT (rozděl a panuj), volba atributu podle *minimální vážené entropie*  $H(A) = \sum_v \frac{|A(v)|}{|D|} H(A(v))$ , ekvivalentně maximálního *informačního zisku*. Umět projít příklad s úvěrem (příjem 0,5747; konto 0,6667; pohlaví 0,9183; nezaměstnaný 0,825) a převést strom na pravidla. Složitost indukce  $O(np \log p)$ , klasifikace  $O(q \log p)$ .
- **ID3** (Quinlan 1986) — hladový, informační zisk. **C4.5** (1993) — chybějící a spojitá data, prořezávání validací (*reduced-error pruning, subtree raising*), *rule post-pruning*, odhad přesnosti dolní mezí  $acc - 1,96\sqrt{acc(1-acc)/n}$ , *poměrný* informační zisk (penalizuje nadměrné větvení). **C5.0** — komerční, boosting. **CART** — *binární* stromy, Gini index  $G(v_i) = 1 - \sum_j p_j^2$  (nižší = lepší), kritérium  $\Phi = 2P_L P_R \sum_j |P(C_j|t_L) - P(C_j|t_R)|$ .
- **Bayes:**  $H_{MAP} = \arg \max_H P(E | H)P(H)$  (jmenovatel lze zanedbat); *naivní* předpoklad podmíněné nezávislosti  $\Rightarrow \arg \max_{H_t} P(H_t) \prod_i P(E_i | H_t)$ . Umí nekompletní vzory; problém nulových pravděpodobností. Umět spočítat příklad (0,1042 vs. 0,0416).
- **SVM:** maximální okraj  $2/\|w\|$ , primární úloha  $\min \frac{\langle w, w \rangle}{2}$  za podmínek  $y_i(\langle w, x_i \rangle + b) \geq 1$ ; Kuhn–Tuckerovy podmínky jsou pro konvexní úlohu s lineárními omezeními nutné i *postačující*;  $\alpha_i > 0$  jen pro *podpůrné* vektory (plyne z *komplementarity*). **Wolfeho duál** vznikne ve dvou krocích: vynulovat  $\partial L_P / \partial w$  a  $\partial L_P / \partial b$  (dá  $w = \sum_i y_i \alpha_i x_i$  a  $\sum_i y_i \alpha_i = 0$ ) a dosadit zpět do  $L_P$ , čímž se  $w, b$  vyliminují; je to úloha *vázaná* —  $\max L_D$  za podmínek  $\sum_i y_i \alpha_i = 0, \alpha_i \geq 0$ . Zpět:  $w$  ze stacionarity,  $b = y_k - \langle w, x_k \rangle$  z *komplementarity*. **Kernelový trik:** duál potřebuje jen skalární součiny  $\Rightarrow K(x, z) = \langle \phi(x), \phi(z) \rangle$ ,  $\phi$  nikdy nevyčíslíme (Mercerova věta). Jen 2 třídy, jen reálný prostor, neinterpretovatelné.
- **Logistická regrese:**  $\ln \frac{p}{1-p} = \beta^\top x$ , tedy  $p = \sigma(z) = 1/(1 + e^{-z})$ ; učení maximální věrohodností / minimalizací křížové entropie;  $\sigma' = \sigma(1 - \sigma) \Rightarrow$  adaptační pravidlo  $\Delta \beta_j = \eta \sum_i (y_i - \sigma(z_i)) x_{ij}$ .
- **Diskriminační analýza:**  $g_j(x)$  pro každou třídu, klasifikuje se maximem; pro dvě třídy stačí znaménko  $g = g_1 - g_2$ ; optimální je  $g_j \propto P(C_j | x)$ ; normální rozdělení  $\rightarrow$  kvadratická funkce, při shodných kovariančních maticích *lineární*  $\Rightarrow$  stačí odhadnout  $\mu_j$  a  $S$ .
- **ELM:** náhodné parametry skrytých neuronů (i bez znalosti dat), výstupní váhy *jednou* pseudoinverzí  $\beta = H^+ T$ ; regularizace  $I/C$  na diagonále. Rychlé, bez lokálních minim, funguje s libovolnou omezenou po částech spojitou přenosovou funkcí.
- **Ensemble:** *bagging* snižuje *rozptyl* ( $\sigma^2 \rightarrow \sigma^2/k$  pro i.i.d.), bootstrap obsahuje  $\approx 63,2\%$  různých bodů ( $1 - 1/e$ ), stromy jsou ideální komponenty (nízké zkreslení, vysoký rozptyl); zkreslení nesnižuje. *Náhodné lesy* řeší korelaci komponent — rozptyl je  $\rho \sigma^2 + (1 - \rho) \sigma^2/k$ , první člen na  $k$  nezávisí; náhodnost přes bootstrap a náhodnou podmnožinu  $m \approx \sqrt{\# \text{příznaků}} \text{ příznaků}$  v každém uzlu. *Boosting/AdaBoost* snižuje *zkreslení*, váhy chybně klasifikovaných vzorů rostou,  $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$ , běží *sekvenčně*, je citlivý na šum. Umět srovnat lesy vs. boosting (paralelní a levné vs. vyčerpávající a přesnější při stejném počtu stromů).

## Klastrová analýza.

- **Metriky:** Hammingova/Manhattan ( $L_1$ ), euklidovská ( $L_2$ ), Čebyševova ( $L_\infty$ ), Minkowského ( $L_q$ , ostatní jsou její speciální případy); **Mahalanobisova**  $d_M^2 = (x_1 - x_2)^\top S^{-1}(x_1 - x_2)$  pro veličiny s různým rozptylem. Před shlukováním *normalizovat*.
- **Vzdálenost klastrů:** nejbližší soused (min), nejvzdálenější soused (max), průměrná vzdálenost, centroidní metoda.
- **k-means** (Lloyd 1982): náhodné rozdělení  $\rightarrow$  centroidy  $\rightarrow$  přesuny  $\rightarrow$  opakuj, dokud dochází k přesunům. Nikdy nezvýší cenu, ale bez záruky aproximace  $\Rightarrow$  **k-means++** (pravděpodobnost  $\propto$  kvadrát vzdálenosti k nejbližšímu centroidu), **LocalSearch++**.
- **k-medians** (Manhattan, medián po dimenzích, robustnější) vs. **k-medoids** (reprezentanti z dat, hill-climbing s výměnami,  $O(knd)$  na iteraci, libovolný typ dat). **PAM** testuje všech  $k(n - k)$  výměn ( $O(kn^2d)$ ); **CLARA** aplikuje PAM na vzorky (riziko špatného vzorku), **CLARANS** zkouší náhodné výměny nad plnými daty (*MaxAttempt, MaxLocal*).
- **Hierarchické shlukování** zdola nahoru: každý vzor svůj klastř  $\rightarrow$  slučuj dva nejbližší; výstupem **dendrogram**, počet klastrů se volí až řezem. **CURE:** škálovatelná varianta (vzorkování, hierarchické slučování po částech); rychlá, libovolný tvar klastrů.

- **LVQ**: shlukování *s učitelem* — vítězný váhový vektor se ke vzoru přitáhne při souhlasu tříd a odtlačí při nesouhlasu;  $\mu$  klesá jako  $\mu(k-1)/(k+1)$ .
- **Mřížkové a hustotní metody** (MAFIA, DBSCAN): klastry libovolného tvaru jako souvislé husté oblasti; DBSCAN — jádrové body ( $\geq \tau$  bodů v radiu  $\varepsilon$ ), klastry = komponenty souvislosti grafu jádrových bodů, šum = odlehlé hodnoty.

## 4 Charakteristická a diskriminační pravidla a jejich zajímavost

- **Proč pravidla**: klasifikátor  $f: X \rightarrow \{C_1, \dots, C_m\}$  je matematický předpis, málo srozumitelný; pravidlo logiky ( $\varphi \Rightarrow \psi$ ,  $\varphi \Leftrightarrow \psi$ ) je srozumitelnější. Booleovská implikace pravdivá při  $t(\varphi) = 0$  nebo  $t(\varphi) = t(\psi) = 1$ ; fuzzy implikace = reziduum t-normy,  $t(\varphi) \leq t(\psi) \Rightarrow$  implikace pravdivá se stupněm 1.
- **AOI — indukce orientovaná na atributy**: zvedne data na vyšší pojmovou úroveň podle *koncepčních hierarchií* a teprve nad nimi hledá pravidelnosti. Dvě operace: *odstranění* atributu (mnoho hodnot a žádná hierarchie — jméno, rodné číslo) a *zobecnění* atributu (hodnoty  $\rightarrow$  pojmy o úroveň výš), po každém kroku sloučení shodných záznamů s čítačem *count*. Kdy přestat: práh na počet různých hodnot *atributu* (2–8) a práh na počet záznamů *relace* (10–30); příliš nízké prahy  $\Rightarrow$  **přílišné zobecnění** („všichni klienti jsou lidé“). Odpovídá operaci *roll-up* v OLAP, ale běží automaticky nad relací. Puštěna na cílovou třídu dá *charakterizaci*, na cílovou i kontrastní *diskriminaci*.
- **Charakteristické vs. diskriminační pravidlo** (Han–Kamber): charakterizace popisuje cílovou třídu ( $\Rightarrow$ , nutná podmínka, **t-weight** =  $\frac{\text{count}(q_a)}{\sum_i \text{count}(q_i)}$ ); diskriminace ji odlišuje od kontrastních ( $\Leftarrow$ , postačující podmínka, **d-weight** = podíl pokrytých objektů patřících do cílové třídy). Umět spočítat z tabulky; d-weight vždy srovnat s *apriorním* podílem třídy.
- **Extrakce ze stromu**: cesta kořen  $\rightarrow$  list = konjunkce podmínek, cesty do listů téže třídy = disjunkce; učení dělením podle informačního zisku či Giniho indexu; prořezávání pravidla zkracuje; zobecněná (šikmá) dělení snižují srozumitelnost.
- **Evoluce pravidel**: genetický algoritmus, fitness = AC/PR/TPR/TNR/AUC; michiganský přístup (jedinec = pravidlo) vs. pittsburghský (jedinec = soubor pravidel).
- **Observační pravidla** (Hájek–Havránek 1978, GUHA):  $\varphi \sim \psi$  se zobecněným kvantifikátorem nad čtyřpolní tabulkou ( $a, b, c, d$ ); (1) odhady pravděpodobností — asociační pravidla,  $\frac{a}{a+b} \geq c_0$  (konfidence)  $\wedge \frac{a}{n} \geq s_0$  (podpora); (2) testy hypotéz — jednostranný Fisherův test zamítá nezávislost ve prospěch pozitivní závislosti.
- **Statisticky**: regresní analýza = charakteristický popis vztahu  $Y$  na  $X_1, \dots, X_n$  (nejmenší čtverce, vícerozměrná, logistická); diskriminační analýza = klasifikace do známých tříd prokládáním rozdělení: ML odhad  $\theta_j$ , predikce  $\arg \max_j p_j f(x \mid \theta_j)$ ; **LDA** (společná  $\Sigma$ , hranice nadrovina,  $q$  parametrů) vs. **QDA** (vlastní  $\Sigma_j$ , hranice kvadratická plocha,  $+\frac{q(q+1)}{2}$  parametrů); dvě třídy  $\rightarrow$  znaménko  $g = g_1 - g_2$ .
- **Zajímavost**: pravidlo = binární klasifikátor  $\rightarrow$  AC, PR (= konfidence), TPR (recall), TNR, F-míra, AUC; role: fitness, třídění (malware podle precision), filtrace redundantních, prahování (konfidence a podpora = zobecněný kvantifikátor); různé ceny chyb (střední hodnota ceny). Subjektivně: srozumitelnost, jednoduchost, neočekávanost, akceschopnost.
- **Aplikace**: spam (metainformace, 3. třída karanténa, Łukasiewiczova disjunkce proti FP), malware (dvouvrstvá hierarchie pravidel), síťové hrozby (signatury), doporučování (pravidla z clickstreamu).

## 5 Reprezentace, vyhodnocování a vizualizace znalostí

- **Formy reprezentace znalostí**: IF-THEN pravidla (nejsrozumitelnější, lokální), rozhodovací strom (globální, čitelný do hloubky 4–5), rozhodovací tabulka, matematická funkce (kompaktní, neinterpretovatelná), prototypy/centroidy, pravděpodobnostní model, grafy a sítě, instance ( $k$ -NN, CBR). Umět ke každé formě říct, z jaké metody vzniká a čím se platí za její srozumitelnost.

- **Kritéria hodnocení metod:** prediktivní přesnost, efektivita (čas konstrukce i použití), robustnost, škálovatelnost, interpretovatelnost, kompaktnost modelu.
- **Odhad chyby:** *holdout* (velká data; trénovací a testovací množina se nesmí míchat), *k-násobná křížová validace* (menší data; 5 a 10 je běžné; přesnost jako průměr  $k$  přesností + interval spolehlivosti s  $t_{N,k-1}$ ), *leave-one-out* (velmi malá data,  $m$ -násobná CV), *validační množina* (třetí část dat, na ní se ladí *parametry* algoritmu).
- **Matice záměn:**  $TP, FN, FP, TN$ ;  $p = \frac{TP}{TP+FP}$ ,  $r = \frac{TP}{TP+FN}$ ,  $F_1 = \frac{2pr}{p+r}$  (harmonický průměr — blíž menšímu z čísel). Umět vysvětlit, proč accuracy nestačí u nevyvážených dat (1 % průniků  $\Rightarrow$  99 % přesnosti „nedělat nic“).
- **ROC:**  $TPR = \frac{TP}{TP+FN}$  (senzitivita = recall pozitivní třídy) proti  $FPR = \frac{FP}{FP+TN}$ ;  $TNR = \text{specificita} = 1 - FPR$ . Křivka vede z (0,0) do (1,1), diagonála = náhodné hádání. Umět popsat konstrukci ze žebříčku (dělení na každém případě). **AUC:** 1 pro perfektní, 0,5 pro náhodný klasifikátor; potřebná proto, že se ROC křivky dvou klasifikátorů mohou *křížit*.
- **Skórování a lift:** místo třídy se přiřadí odhad pravděpodobnosti (u stromu confidence v listu), vzory se seřadí a rozdělí do příhrádek; lift křivka proti diagonále náhodného výběru. Umět provést ekonomickou úvahu (kolik zásilek se vyplatí).
- **Tři roviny „vyhodnocování“:** statistická kvalita modelu, zajímavost vzorů, vyhodnocení uživatelem. První dvě objektivní, třetí subjektivní. **Čtyři kritéria zajímavosti znalosti:** srozumitelnost, platnost, užitečnost, novost.
- **Vizualizace:** technika podle úlohy (histogram, box plot, scatter, SPLOM, paralelní souřadnice, heatmapa, dendrogram, projekce, ROC/lift); tři role v KDD (explorace — Anscombeho kvartet, vizualizace modelu, prezentace); zásady (Tufte, nekreslovat osami, barva podle typu dat). Znáť omezení: t-SNE a UMAP zkreslují globální vzdálenosti.

## 6 Modely pro analýzu sociálních sítí, centralita a detekce komunit

- **SNA** = sociální vědy + analýza sítí + teorie grafů; soustředí se na *vztahy*, ne na entity a jejich atributy. Reprezentace: obrázek, seznam hran, matice sousednosti (u orientovaných grafů nesymetrická). *Ego síť* vs. „celá“ síť — *problém specifikace hranic*: žádná studovaná síť není celá.
- **Síla vazeb:** silné vs. slabé; *síla slabých vazeb* (Granovetter 1973). Homofilie, tranzitivita a přemostění; homofilie + tranzitivita  $\rightarrow$  *kliky*. Most = hrana, jejíž odstranění rozpojí koncové uzly; *zkratkový most* = vzdálenost po odstranění vzroste nad 2. **Překryv sousedství**  $O(i,j) = \frac{|N_i \cap N_j|}{|N_i \cup N_j| - 2}$  — čím větší, tím silnější vazba.
- **Čtyři míry centrality:** *stupňová* (kolik lidí přímo dosáhne), *mezilehlá* (na kolika nejkratších cestách leží; kde se síť rozpadne), *blízkostní* (převrácená průměrná délka nejkratších cest; rychlost šíření), *vlastní* ( $Ax = \lambda x$ , jen *největší* vlastní číslo dává nezáporný vektor; jak dobře je spojen s dobře propojenými). Umět interpretační tabulku a vysvětlit, proč nestačí jedna míra (uzly 3 a 5 *společně* > uzel 10). **Strukturní ekvivalence:** pozice lze vyměnit bez změny struktury.
- **Koheze:** reciprocita (jen orientované grafy), hustota ( $|E|/|V|^2$ ); klika = 1; orientované mají poloviční), **klastrovací koeficient**  $C_i = \frac{2|e_{jk}|}{k_i(k_i-1)}$  a síť jako průměr, průměr sítí (*diameter*) = nejdelší nejkratší cesta, průměrná vzdálenost, excentricita. **Malý svět** = vysoký  $C$  + krátká průměrná cesta.
- **Šest vlastností reálných komplexních sítí:** efekt malého světa (Milgram, medián 6), tranzitivita/klastrování, mocninné rozdělení stupňů, odolnost (robustní k náhodnému, zranitelná cíleným odstraněním hubů), vzorce míchání (asortativní míchání = homofilie), komunitní struktura. **Bezškálové sítě:** růst + *preferenční připojování* (rich-get-richer, Matoušův efekt, kumulativní výhoda); důvody — popularita, kvalita, smíšený model (halo efekt). **Centralizace** a struktura *jádro-periferie* (bow-tie analýza).
- **Modelování vlivu:** společné rysy (orientovaný graf, aktivní/neaktivní, *aktivovaný uzel nelze deaktivovat*). **LTM** — prah  $\theta_v$  uniformně z  $[0,1]$ , aktivace při  $\sum_{\text{aktivní}} w_{u,v} \geq \theta_v \sum w_{u,v}$ ; soustředí se na *příjemce*. **ICM** — *jediná* příležitost aktivovat každého souseda s pravděpodobností  $p_{v,u}$ ; soustředí se na *vysílající*. **Maximalizace vlivu** je NP-těžká, hladový přístup dává **63 %** optima.

- **Vliv vs. korelace:** *test korelace* (podíl hran mezi různými hodnotami atributu vs.  $2p(1-p)$ ; příklad kuřáků  $14\% < 49\%$ ); tři procesy — homofilie, *zmatení*, vliv; logistický model  $\ln \frac{p(a)}{1-p(a)} = \alpha \ln(a+1) + \beta$ ,  $\alpha$  = koeficient sociální korelace; **shuffle test** — zpřeházej časové značky; liší-li se  $\alpha'$  významně od  $\alpha$ , jde o důkaz *vlivu*.
- **Test homofilie:** heterogenních hran je významně méně než  $2pq \Rightarrow$  homofilie; významně *více*  $\Rightarrow$  *inverzní* homofilie (partnerské vztahy). Umět příklad: 5 z 18 vs.  $2pq = 8$  z 18.
- **Výběr vs. sociální vliv:** výběr = charakteristiky řídí tvorbu vazeb; vliv = vazby formují *mutabilní* charakteristiky. *Imutabilní* (pohlaví, rasa, věk) vs. *mutabilní* (chování, názory). Rozlišit lze jen *longitudinálními* studiemi (obezita: Christakis & Fowler, 12 000 lidí / 32 let  $\rightarrow$  důkaz pro *sociální vliv*).
- **Afiliční síť:** bipartitní (osoby  $\times$  fokusy), sociálně-afiliční má dva typy hran. **Tři uzávěry:** tranzitivní (společný přítel), *fokální* (společný fokus; *výběr*), *členský* (přítel už ve fokusu; *sociální vliv*). Metodika měření  $T(k)$  ze dvou snímků; bazový model  $T_{\text{base}}(k) = 1 - (1-p)^k$ ; empiricky velký nárůst z 1 na 2 a poté *klesající výnosy*.
- **Schellingův model:** agenti dvou typů v mřížce, spokojení při  $\geq t$  sousedech téhož typu, nespokojení se přesouvají  $\Rightarrow$  *samovolná segregace*. Ukazuje, jak se *imutabilní* charakteristika stane silně korelovanou s *mutabilní* (volbou místa) a jak lokální homofilie vytvoří globální vzorec.
- **Strukturní balance:** balancované trojúhelníky jsou +++ a +-- (tj. všechny tři pozitivní, nebo právě jedna pozitivní). **Věta o balanci:** úplný balancovaný graf  $\Rightarrow$  všichni přátelé, nebo rozdělení na dvě skupiny vnitřních přátel a vzájemných nepřátel — umět důkaz ( $X$  = přátelé  $A$ ,  $Y$  = nepřátelé  $A$ , tři kroky). **Slabá balance:** zakázána jen konfigurace *dvě pozitivní a jedna negativní*  $\Rightarrow$  rozdělení na *libovolný počet* skupin. Aplikace: evropské aliance 1872–1907, Bangladéš 1972.
- **HITS:** dotazově *závislý*; kořenová množina  $S$  ( $t = 200$ )  $\rightarrow$  bazová množina  $B$ ;  $a = L^T h$ ,  $h = La$ , mocninová iterace s **nutnou normalizací**;  $a_k = (L^T L)^{k-1} a_0$  konverguje k hlavnímu vlastnímu vektoru  $L^T L$ . Slabiny: snadné spamování, drift tématu, neefektivnost v době dotazu.
- **PageRank:** dotazově *nezávislý*,  $P(i) = \sum_{(j,i) \in E} P(j)/O_j$ , *nepotřebuje normalizaci* (celkový PageRank je konstantní — „kapalina“). Problém „pomalého úniku“  $\Rightarrow$  *škálované* pravidlo s tlumicím faktorem  $d$  (0,8–0,9; 0,85 v článku), „vodní cyklus“. Markovský řetězec potřebuje *stochastickou, ireducibilní a aperiodickou* matici — webový graf nesplňuje ani jednu (visící stránky, není silně souvislý, periodicitu); vše se řeší *jedinou* strategií (odkaz z každé stránky na každou s malou pravděpodobností). Finální tvar  $P(i) = (1-d) + d \sum_{(j,i) \in E} P(j)/O_j$ , výpočet mocninovou iterací. Výhody: odolnost proti spamu (vstupní odkazy nelze snadno získat), globální offline míra; kritika: dotazová nezávislost.
- **Tematické komunity:**  $K = (T, M)$ , téma určuje komunitu, komunity se mohou *překrývat*, hierarchie subkomunit. *Bipartitní jádra* —  $(i, j)$ -jádro, vějíře = huby, středy = autority; prořezání + generování jader; najde jen jádra, ne témata ani hierarchii. *Komunity pojmenovaných entit:* graf ze společných výskytů ve větě  $\rightarrow$  trojúhelníky  $\rightarrow$  jádra  $\rightarrow$  klastrování podle textové podobnosti.
- **Detekce komunit — definice je subjektivní;** explicitní vs. implicitní skupiny. *Minimální řez:* nevyvážené skupiny,  $O(n^5)$  / Karger  $O(n^4)$ , s obecnými vahami a balančními omezeními **NP-těžké**  $\Rightarrow$  *poměrový a normalizovaný řez* (dělení  $|C_i|$ , resp.  $\text{vol}(C_i)$ ).
- **Girvanové–Newman:** divizivní, odstraňuje hrany s nejvyšší *mezilehlostí*,  $O(m^2n)$  /  $O(n^3)$ ; počet komunit se vybere podle nejvyšší **modularity**  $Q = \frac{1}{2m} \sum_{i,j} (A_{ij} - \frac{k_i k_j}{2m}) \delta(c_i, c_j)$ ,  $Q \in [-1, 1]$ , smysluplné komunity  $Q \geq 0,3$ .
- **Louvain:** hladová aglomerativní maximalizace modularity ve dvou fázích (lokální přesuny  $\rightarrow$  supergraf),  $O(n \log n)$ ; nevýhody: citlivost na pořadí, *nesouvislé komunity*, lokální optima. **Leiden** přidává fázi *upřesnění rozdělení*; jen tvrdé rozdělení. Výzvy: neznámý počet komunit, heterogenní velikosti a hustoty.
- **Čtyři kategorie metod:** *uzlově orientované* (kliky — NP-těžké, rekursivní prořezávání uzlů se stupněm  $< k-1$ , **CPM** pro *překrývající se* komunity přes graf klik sdílejících  $k-1$  uzlů;  $k$ -kliky /  $k$ -klub /  $k$ -klan;  $k$ -jádro a  $k$ -plex jsou komplementární; LS množiny a  $k$ -komponenty), *skupinově orientované* ( $\gamma$ -husté kvazikliky), *síťově orientované* (podobnost vrcholů — Jaccard, kosinus +

$k$ -means; MDS; blokové modely; spektrální shlukování přes grafový laplacián s *nejmenšími* vlastními čísly; maximalizace modularity přes matici modularity s *největšími* — vše sjednoceno jako maticová faktorizace  $X \approx S\Sigma S^\top$ , vyžaduje zadat počet komunit), *hierarchicky orientované* (divizivní = Girvanové–Newman, aglomerativní = Louvain, Walktrap).

- **Predikce vazeb:** obsahové míry (homofilie) vs. strukturní (tranzitivní uzávěr; silnější). Sousedské míry: *společní sousedé*  $|S_i \cap S_j|$  (nezohledňuje stupně), *Jaccard*  $\frac{|S_i \cap S_j|}{|S_i \cup S_j|}$  (normalizuje stupně obou uzlů, ne prostředních sousedů), *Adamic–Adar*  $\sum_k \frac{1}{\log |S_k|}$  (váha klesá se stupněm společného souseda). **Katzova míra**  $\sum_t \beta^t W_{ij}^{(t)} = (I - \beta A)^{-1} - I$  pro *řídke* sítě s málo společnými sousedy; součet přes ostatní uzly = *Katzova centralita*. **Klasifikační pojetí:** pozitivně-neoznačovaná úloha, vzorek negativ, logistická regrese jako bazový klasifikátor, cenově citlivé varianty; výhoda — klasifikátor se sám naučí relevanci příznaků a lze použít *asymetrické* příznaky u orientovaných sítí.

## 7 Praktické využití technik

- Ke každé aplikaci umět říct **trojici**: typ úlohy (deskriptivní / prediktivní, s učitelem / bez učitele), použitá metoda, způsob vyhodnocení.
- **Vlajkové aplikace dobývání znalostí:** analýza nákupního košíku (asociační pravidla), detekce podvodů (příklad zdravotní pojišťovny — stroj *zaostřuje* pozornost experta, nenahrazuje jej), kreditní skórování (stromy a Bayes; požadavek srozumitelnosti), segmentace zákazníků (klastrování, centroid = typický zákazník), churn a cílený marketing (nevyvážená data  $\rightarrow$  ROC/AUC a *lift*), klasifikace textu (SVM), predikce časových řad (posuvné okno), web usage mining (sekvenční vzory).
- **Vlajkové aplikace SNA:** identifikace klíčových hráčů v kriminálních a teroristických sítích (centralita), doporučování přátel (predikce vazeb), optimalizace komunikačních sítí, epidemiologie (Rockdale County 1996), vakcinace cílená na *huby*, marketing a kaskádové finanční krachy v bezškálových sítích, segmentace zákazníků operátora podle jazykových komunit (Louvain, 2 mil. zákazníků).
- **Klíčová vlastnost SF sítí pro praxi:** odolnost proti náhodným poruchám (až 80 % uzlů) vs. zranitelnost cíleným útokem (5–15 % hubů) — z toho plyne jak strategie vakcinace, tak nemožnost vymýtit internetové viry.
- **Nasazení není konec:** monitoring driftu, zpětná vazba modelu do dat, soukromí (i anonymizovaný graf lze deanonymizovat), spravedlnost (chráněný atribut lze rekonstruovat z ostatních), GDPR čl. 22 a AI Act.