

Internet a klasifikační metody, 4. přednáška

Kdy dělá klasifikátor nejméně chyb na nových datech?

volitelný předmět pro magisterské studium

Martin Holeňa



O čem to bude?

- ◆ Schopnost klasifikátoru generalizovat pro nové vstupy
 - souvislost s šířkou pásu mezi třídami
- ◆ Generalizující klasifikátory pro 2 lineárně separabilní třídy
 - opěrné vektory a jejich význam
- ◆ Zobecnění pro 2 lineárně neseparabilní třídy
- ◆ Zobecnění pro více tříd + další zobecnění


Generalizační schopnost klasifikátoru

- ◆ = Schopnost správně klasifikovat možné nové vstupy
 - při zohlednění pravděpodobnosti jednotlivých nových vstupů
 - → formálně nejčastěji E_{vstupy} přesnost = $1 - E_{\text{vstupy}}$ chybovost
- ◆ Pro začátek: 2 třídy $C_{\pm} \subset \mathbb{R}^d$, lineárně separabilní, klasifikátor $F: \mathbb{R}^d \rightarrow \{1, -1\}$

$$F(x) = \begin{cases} 1 & \text{při } w^T x + b \geq 0 \\ -1 & \text{při } w^T x + b < 0 \end{cases}, E_{\text{vstupy}} \text{ chybovost} = P(C_+ \cap F^{-1}(-1)) + P(C_- \cap F^{-1}(1))$$

Souvislost s pásem mezi třídami

- ◆ Předpokládáme, že nadrovina oddělující $C_1 \cap \{x_1, \dots, x_q\}$ a $C_2 \cap \{x_1, \dots, x_q\}$ se $C_1 \cap \{x_1, \dots, x_q\}$ ani $C_2 \cap \{x_1, \dots, x_q\}$ nedotýká $\rightarrow$ vzdálena $\rho > 0$ od učicích dat



Souvislost s pásem mezi třídami

- ◆ Předpokládáme, že nadrovina oddělující $C_1 \cap \{x_1, \dots, x_q\}$ a $C_2 \cap \{x_1, \dots, x_q\}$ se $C_1 \cap \{x_1, \dots, x_q\}$ ani $C_2 \cap \{x_1, \dots, x_q\}$ nedotýká $\rightarrow$ vzdálena $\rho > 0$ od učicích dat
- ◆ *Domněnka: E_{vstupy} chybovost je nerostoucí funkcí $\rho(?)$*
 - nezkazí to vliv směru oddělující nadroviny??
- ◆ Při omezených w v definici F ($(\exists \Lambda > 0) \|w\| \leq \Lambda$) a $R = \max_{i=1, \dots, q} \|x_i\|$ lze

odvodit: $(\exists \gamma > 0) E_{\text{vstupy}} \text{chybovost} < \sqrt{\frac{\gamma}{p} \left(\frac{\Lambda^2 R^2}{\rho^2} \ln^2 q + |\ln P(\text{vstup } x: \|x\| > 0)| \right)}$

Takže maximalizační úloha pro ρ

- ◆ Označme $\delta = \rho\|w\|$, w – směrový vektor nadroviny $H: w^T x + b = 0$
 - $\max \rho = \max \frac{\delta}{\|w\|} \rightarrow \max \delta$ a současně $\min \|w\|$
 - přitom omezení $\rho \leq$ vzdálenost x_i od H , $i = 1, \dots, q$
- ◆ Budeme řešit dvoustupňově, při omezeních pro $i = 1, \dots, q$
 1. stupeň: *fixujeme δ , minimalizujeme $\|w\|$*
 2. stupeň: přidáme *maximalizaci δ*

Minimalizační úloha pro $\|w\|$

♦ Raději minimalizujeme $\|w\|^2$ (má stejné minimum jako $\|w\|$)

- při častých vyhodnocováních dost ušetříme nepočítáním $\sqrt{}$

♦ Přeformulujeme *omezení* $\rho \leq \text{vzdálenost } x_i \text{ od } H, i = 1, \dots, q$:

$$\rho \leq \frac{|w^\top x_i + b|}{\|w\|} \rightarrow \frac{\delta}{\|w\|} \leq \frac{|w^\top x_i + b|}{\|w\|} \rightarrow \delta \leq |w^\top x_i + b| = c_i(w^\top x_i + b), c_i \in \{-1, 1\}$$


♦ připomínka: *Lagrangeova funkce* $L = \|w\|^2 + \underbrace{\sum_{i=1}^q \alpha_i (\delta - c_i(w^\top x_i + b))}_{=0}$
Lagrangeovy koeficienty α_i při $\min \|w\|^2$ splňují KKT podmínky:

Řešení Lagrangeovy funkce

- ◆ $K(\hat{w}, \hat{b}) = \arg \min \|w\|^2$ splňujícím $\delta \leq c_i(\hat{w}^\top x_i + \hat{b})$ existují $\hat{\alpha}_1, \dots, \hat{\alpha}_q$ že
 1. L má v $(\hat{w}, \hat{b}, \hat{\alpha}_1, \dots, \hat{\alpha}_q)$ *minimum vůči (w, b) , maximum vůči $(\alpha_1, \dots, \alpha_q)$*
 2. ve $(\hat{w}, \hat{b}, \hat{\alpha}_1, \dots, \hat{\alpha}_q)$ platí *KKT podmínky*, $\hat{\alpha}_i (\delta - c_i(\hat{w}^\top x_i + \hat{b})) = 0$, $i = 1, \dots, q$
- ◆ $Z \frac{\partial L}{\partial w}, \frac{\partial L}{\partial b}(\hat{w}, \hat{b}, \hat{\alpha}_1, \dots, \hat{\alpha}_q) = 0$ vychází $\hat{w} = \sum_{i=1}^q \frac{\hat{\alpha}_i}{2} c_i x_i$, $\sum_{i=1}^q \hat{\alpha}_i c_i = 0$
 - zjednodušíme přeznačením $\hat{\alpha}_i^{\text{new}} = \frac{1}{2} \hat{\alpha}_i^{\text{old}} \rightarrow \hat{w} = \sum_{i=1}^q \hat{\alpha}_i c_i x_i$, $\sum_{i=1}^q \hat{\alpha}_i c_i = 0$
 - $\rightarrow \|\hat{w}\|^2 = \hat{w}^\top \hat{w} = \sum_{i,j=1}^q \hat{\alpha}_i \hat{\alpha}_j c_i c_j x_i^\top x_j$, $L = -\sum_{i,j=1}^q \hat{\alpha}_i \hat{\alpha}_j c_i c_j x_i^\top x_j + 2\delta \sum_{i=1}^q \hat{\alpha}_i$


Výsledek: kvadratická optimalizace

- ♦ L má v $(\hat{w}, \hat{b}, \hat{\alpha}_1, \dots, \hat{\alpha}_q)$ maximum vůči $(\alpha_1, \dots, \alpha_q) \rightarrow (\hat{\alpha}_1, \dots, \hat{\alpha}_q)$ je řešením úlohy $2\delta \sum_{i=1}^q \hat{\alpha}_i - \sum_{i,j=1}^q \hat{\alpha}_i \hat{\alpha}_j c_i c_j x_i^\top x_j = \max_{\alpha_1, \dots, \alpha_q} 2\delta \sum_{i=1}^q \alpha_i - \sum_{i,j=1}^q \alpha_i \alpha_j c_i c_j x_i^\top x_j$ při omezeních $\sum_{i=1}^q \alpha_i c_i = 0$ a KKT: $\hat{\alpha}_i (\delta - c_i (\hat{w}^\top x_i + \hat{b})) = 0$ – *duální úloha*
- ♦ + *přidáme* 2. stupeň maximalizační úlohy pro ρ : *maximalizaci* δ
- ♦ $\rightarrow$ *kvadratická optimalizace*: 1 lokální optimum = globální
 - snadno vyřeší každý optimalizační software



Opěrné vektory

- ♦ Získané $\hat{\alpha}_1, \dots, \hat{\alpha}_q$ dosadíme do $\hat{w} = \sum_{i=1}^q \hat{\alpha}_i c_i x_i$; uvědomme si, že:
 - $\hat{w} = \sum_{i \in S} \hat{\alpha}_i c_i x_i$, kde $S = \{i: \hat{\alpha}_i > 0\}$, takže pro $i \in S, \delta - c_i(\hat{w}^\top x_i + \hat{b}) = 0$ díky KKT
 - pomocí získaného $\hat{\delta} = \max \delta$ pro libovolné $i \in S$ dopočítáme $\hat{b} = c_i \hat{\delta} - \hat{w}^\top x_i$
- ♦ $\rightarrow$ Vektory $x_i, i \in S$ leží v nadrovině $H_+ : \hat{w}^\top x_i + \hat{b} + \hat{\delta}$ nebo $H_- : \hat{w}^\top x_i + \hat{b} - \hat{\delta}$
 - názvy: $H_+ | H_-$ – *opěrné nadroviny*, $C_+ | C_- \cap \{x_1, \dots, x_q\}$, $x_i, i \in S$ – opěrné vektory
 - $\rightarrow$ označení metody: *Support Vector Machine (SVM)*



Rekapitulace SVM algoritmu

♦ Vstup: učicí data $(x_1, c_1), \dots, (x_q, c_q)$

1. $(\hat{\alpha}_1, \dots, \hat{\alpha}_q, \hat{\delta}) = \arg \max_{\alpha_1, \dots, \alpha_q} 2\delta \sum_{i=1}^q \alpha_i - \sum_{i,j=1}^q \alpha_i \alpha_j c_{ij} x_i^\top x_j$ při $\sum_{i=1}^q \alpha_i c_i = 0$ a KKT





2. $S = \{i: \hat{\alpha}_i > 0\}$ a vybereme nějaké $i_b \in S$


3. $\hat{w} = \sum_{i \in S} \hat{\alpha}_i c_i x_i$, $\hat{b} = c_{i_b} \hat{\delta} - \hat{w}^\top x_{i_b}$

♦ Výstup: klasifikátor F , $F(x) = \begin{cases} 1 & \text{při } \sum_{i \in S} \hat{\alpha}_i c_i x^\top x_i + \hat{b} \geq 0 \\ -1 & \text{při } \sum_{i \in S} \hat{\alpha}_i c_i x^\top x_i + \hat{b} < 0 \end{cases}$

Připomínka: jak k lineární separabilitě?

- ◆ Transformací do prostoru *vyšší dimenze*





$$f(x) = \text{sgn}(w_1 x_1^2 + w_2 x_2^2 + w_3 \sqrt{2} x_1 x_2 + b)$$

Připomínka: jak k lineární separabilitě?

- ◆ Transformací do prostoru *vyšší dimenze*
- ◆ Metoda pomocí jádra: zobrazení $\kappa: X^2 \rightarrow \mathcal{R}$, $\kappa(x, y) = \kappa(y, x)$,
s každou $\begin{pmatrix} \kappa(x_i, x_i) & \cdots & \kappa(x_i, x_j) \\ \vdots & \ddots & \vdots \\ \kappa(x_j, x_i) & \cdots & \kappa(x_j, x_j) \end{pmatrix}$ pozitivně semidefinitní
 - q -dimenzionální množina $M = \{\varphi_1, \dots, \varphi_q\}$, $\varphi_i: X \rightarrow \mathcal{R}$, $\varphi_i(x) = \kappa(x_i, x)$
 - vektorový prostor $V = \{\sum_{i=1}^q a_i \varphi_i \mid a_1, \dots, a_q \in \mathcal{R}\} =$ lineární obal M
 - skalární součin na V : $\langle \sum_{i=1}^q a_i \varphi_i, \sum_{i=1}^q b_i \varphi_i \rangle = \sum_{i,j=1}^q a_i b_j \kappa(x_i, x_j)$

Pro SVM se hodí již známý trik

◆ Připomínka: *kernel trick* – počítáme skalární součin

v prostoru *V dimenze q* pomocí $\kappa(x_i, x_j)$, tj. pomocí $x_i, x_j \in \mathbb{R}^d$

- q – počet dat $\rightarrow$ většinou $d \ll q$

◆ Vhodnost pro SVM: skalárním součinem klasifikátor F

kompletně definujeme:
$$F(x) = \begin{cases} 1 & \text{při } \sum_{i \in S} \hat{\alpha}_i c_i \kappa(x, x_i) + \hat{b} \geq 0 \\ -1 & \text{při } \sum_{i \in S} \hat{\alpha}_i c_i \kappa(x, x_i) + \hat{b} < 0 \end{cases}$$

SVM pro vícetřídní klasifikaci

♦ Výrazně nepoužívanější přístup: pomocí více 2-třídních

1. *Každá* ze tříd $C_1, \dots, C_m$ *proti každé* $\left(\frac{m(m-1)}{2}\right)$ klasifikací

- výsledek: C_k s nejvíce z $m - 1$ možných vítězství

2. *Každá* třída C_k *proti sjednocení* $\bigcup_{j \neq k} C_j$ zbývajících


- $c_{i,k} \in \{1, -1\}$ volíme tak, aby $c_{i,k} = 1 \leftrightarrow x_i \in C_k, c_{i,k} = -1 \leftrightarrow x_i \in \bigcup_{j \neq k} C_j$
- výsledek: C_k s $k = \arg \max_{j=1, \dots, m} \sum_{i \in S} \hat{a}_{i,k} c_{i,k} \kappa(x, x_i) + \hat{b}$

SVM s tolerujícími omezeními

♦ Místo omezení $\rho \leq$ vzdálenost x_i od $H \rightarrow \delta \leq c_i(w^\top x_i + b)$


uvažujeme $\rho - \xi_i \leq$ vzdálenost x_i od $H \rightarrow \delta - \xi_i \leq c_i(w^\top x_i + b), \xi_i \geq 0$


Class A_1



SVM s tolerujícími omezeními


- ◆ Místo omezení $\rho \leq$ vzdálenost x_i od $H \rightarrow \delta \leq c_i(w^\top x_i + b)$
uvažujeme $\rho - \xi_i \leq$ vzdálenost x_i od $H \rightarrow \delta - \xi_i \leq c_i(w^\top x_i + b), \xi_i \geq 0$
 - význam: menší vliv šumu v datech





SVM s tolerujícími omezeními

- ◆ Místo omezení $\rho \leq$ vzdálenost x_i od $H \rightarrow \delta \leq c_i(w^\top x_i + b)$
uvažujeme $\rho - \xi_i \leq$ vzdálenost x_i od $H \rightarrow \delta - \xi_i \leq c_i(w^\top x_i + b), \xi_i \geq 0$
 - význam: menší vliv šumu v datech
- ◆ Snaha udržet *tolerující (slack) proměnné* ξ_i malé $\rightarrow$
v 1. stupni maximalizace pásu *minimalizujeme* $\|w\|^2 + C \sum_{i=1}^q \xi_i, C > 0$
 - C – poměr mezi tolerancí ξ_i a původní minimalizací $\|w\|^2$ (~ 0)



SVM při filtraci spamu


- ♦ Výhoda: lepší *generalizační schopnost*
 - často využívány specificky pro *obrázkový spam*
 - + příbuzný problém odfiltrování pornografických webových stránek
- ♦ Nevýhoda: velká *výpočetní náročnost*
 - kvůli řešení optimalizačního problému
 - protiopatření: paralelní a distribuované implementace

SVM v doporučovacích systémech

- ◆ Obsahové filtrování, hlavně obrázků a videí
 - *obrázky*: přiřazování částí obrázku *sémantickým konceptům*
 - *videa*: rozpoznávání *událostí*, slov *mluveného* jazyka
- ◆ Nelineární, kromě mluveného jazyka (← vysocedimenzionální příznaky)
- ◆ Vícetřídní, každá třída proti sjednocení zbývajících,
kromě sémantických konceptů: každá třída proti každé



SVM při detekci malware

- ◆ Používají *dynamické vlastnosti* software = průběh interakcí s OS – kódován posloupností volání *API*
 - kombinovány s klasifikátorem používajícím statické vlastnosti
- ◆ *Nelineární*, používají se s různými kernely
- ◆ Bud' *2-třídní*: neškodný software × malware, nebo *vícetřídní*: neškodný software × různé druhy malware




Aktivně se učící SVM

- ◆ *Aktivní učení* klasifikátoru: učení, při kterém
 1. část učicích dat dodávána na vyžádání
 - obvykle x_i od začátku, od uživatele *vyžádáno* $c_i \in \{-1,1\}$
 2. výběr vyžádaných určený *očekávaným zlepšením kvality*
- ◆ Použitelné pro libovolný klasifikátor; nejrelevantnější SVM ←
← očekávané zlepšení počítáno přes nové vstupy



Internet a SVM s aktivním učením

- ◆ Doporučovací systémy: *obsahové filtrování* podle *příkladů*
 - velké množství možností → uživatel požádán ohodnotit příklady nejvíce pomáhající zpřesnit jeho přání



Internet a SVM s aktivním učením

- ◆ Doporučovací systémy: *obsahové filtrování* podle *příkladů*
 - velké množství možností → uživatel požádán ohodnotit

příklady nejvíce pomáhající zpřesnit jeho přání
- ◆ Detekce *malware* nebo *síťových útoků*
 - množství nového software | záznamů síťového provozu →
 - aktivní učení: kde nejpotřebnější klasifikace člověkem